Tutoriumsblatt 2

Tabellen mit pandas

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Masken, `loc` und `iloc` von Hand auswerten, mit der Rangfolge von `&` und `|`,
- Gruppentabellen vorhersagen und die Quote der Summen als gewichtetes Mittel begründen,
- die Zeilenzahl eines Joins mit $\sum_k n_L(k)\, n_R(k)$ vorhersagen und die m:n-Falle beheben,
- Tabellen zwischen breit und lang umformen und Wochenwerte mit Lücken richtig mitteln.

So arbeitest du mit dem Blatt

Du programmierst nicht: Jeden Code liest du wie der Computer (Schreibtischtest), es zählen die Werte, nicht die Formatierung. Die Ausgaben sind in pandas 2.3 (Browser) und pandas 3 gleich. Hilfsmittel: Taschenrechner und Skript. Mit den Werten unter „Zur Kontrolle“ rechnest du weiter, falls du hängst. Die kleinen Tabellen und Wochenreihen sind fiktiv, die Werkszahlen stammen aus Skript und Notebook. Zum Notebook: Aufgabe 1 gehört zu TODO 1, 3 und 4; Aufgabe 2 zu TODO 5, 6 und B1; Aufgabe 3 zu TODO 7 und 8; Aufgabe 4 zu TODO 9; Aufgabe 5 und der Zusatz zu TODO 10.

Aufgabe 1 Masken, loc und iloc

7 Punkte · etwa 15 Min.

Bezug: Modul 2, Lerneinheiten 1 (Von der Liste zum Array) und 3 (Auswählen und filtern)

Die Tabelle `t` enthält die sechs Schichten der Linien 1 und 2 vom 5. März 2025. Du brauchst sie auch in Aufgabe 2.

Index	linie	schicht	ist_stueck	ausschuss_stueck
0	1	Früh	400	8
1	2	Früh	250	5
2	1	Spät	400	6
3	2	Spät	200	7
4	1	Nacht	250	7
5	2	Nacht	150	3

(a) Was gibt der Code aus? Wie viele Divisionen laufen in der ersten Codezeile? Welchen Datentyp haben `quote` und `m`, und warum ist `m.sum()` eine Anzahl? [2 P]

```
t["quote"] = t["ausschuss_stueck"] / t["ist_stueck"]
m = t["ausschuss_stueck"] >= 7
print(m.tolist())
print(m.sum(), m.mean())
print(t.loc[m, "ist_stueck"].sum(), t.loc[~m, "quote"].max())
```

(b) Gesucht: Schichten mit Quote über 2,5 %, die nachts *oder* auf Linie 2 liefen. Welche Beschriftungen enthalten `A` und `B`, welcher passt? Was passiert bei `C`, und warum? [2 P]

```
A = t[(t["schicht"] == "Nacht") | (t["linie"] == 2) & (t["quote"] > 0.025)]
B = t[((t["schicht"] == "Nacht") | (t["linie"] == 2)) & (t["quote"] > 0.025)]
C = t[t["linie"] == 2 & t["ist_stueck"] > 300]
```

(c) Gib für jeden Ausdruck die Beschriftungen und Werte an oder den Fehler. [2 P]

```
l1 = t[t["linie"] == 1]
(i)   t.loc[1:3, "ist_stueck"]          (ii)  t.iloc[1:3, 2]
(iii) l1.loc[2:4, "ist_stueck"]         (iv)  l1.iloc[2, 2]
(v)   l1.loc[1, "ist_stueck"]
```

(d) In `produktion` (5.788 Zeilen) markiert `nacht_l2` die 471 Nachtschichten der Linie 2, `maske` die 80 davon mit Planerfüllung unter 0,8. Was liefert `maske.mean()`? Welcher Anteil der Nachtschichten auf Linie 2 blieb unter 80 % des Solls, und wie berechnest du ihn? [1 P]

Aufgabe 2 Gruppieren und Quoten richtig aggregieren

10 Punkte · etwa 22 Min.

Bezug: Modul 2, Lerneinheit 4 (Split-Apply-Combine)

Du arbeitest mit `t` samt Spalte `quote`. Für eine Gruppe von n Schichten mit Stück s_i, Ausschuss a_i und Quoten $q_i = a_i/s_i$ heißt $\bar{q} = \frac{1}{n}\sum_i q_i$ das *Mittel der Quoten* und $Q = \sum_i a_i / \sum_i s_i$ die *Quote der Summen*.

(a) Schreibe `g` als Tabelle auf. Welche Form (`g.shape`) und welchen Index hat `g`? [3 P]

```
g = t.groupby("linie").agg(
    schichten=("ist_stueck", "size"), ist=("ist_stueck", "sum"),
    ausschuss=("ausschuss_stueck", "sum"), ist_min=("ist_stueck", "min"),
    mittel_der_quoten=("quote", "mean"))
g["quote_der_summen"] = g["ausschuss"] / g["ist"]
```

(b) Was gibt der Code aus? Welche Länge und welchen Index haben die beiden Ergebnisse von `groupby`? Warum gibt es keinen Fehler, und was ist an `falsch` falsch? [2 P]

```
t["abw"] = t["ist_stueck"] - t.groupby("linie")["ist_stueck"].transform("mean")
t["falsch"] = t.groupby("linie")["ist_stueck"].mean()
print(t[["linie", "ist_stueck", "abw", "falsch"]])
```

(c) Zeige $Q = \sum_i w_i\, q_i$ mit $w_i = s_i / \sum_j s_j \geq 0$ und $\sum_i w_i = 1$. Berechne die Gewichte für Linie 1 als Brüche, prüfe damit Q aus (a) und vergleiche mit den Gewichten im Mittel der Quoten. Zur Kontrolle: Linie 1 hat $\sum_i s_i = 1.050$ und $\sum_i a_i = 21$. [2 P]

(d) Aus dem Skript kennst du $Q - \bar{q} = c_{sq}/\bar{s}$ mit $c_{sq} = \frac{1}{n}\sum_i (s_i - \bar{s})(q_i - \bar{q})$. Berechne c_{sq} für beide Linien (Quoten in Prozent, $s_i - \bar{s}$ steht in `abw`) und prüfe die Formel an (a). Zur Kontrolle: Linie 1 hat $\bar{s} = 350$ und $\bar{q} = 2{,}1\,\%$. Linie 2 hat ungleiche Stückzahlen und trotzdem $Q = \bar{q}$. Wann genau gilt $Q = \bar{q}$? Wovon hängt ab, welches Maß größer ist? [2 P]

(e) Im Nordwerk (1.217.169 Stück, 26.154 Teile Ausschuss) ist $\bar{q} = 2{,}02\,\%$ und $Q = 2{,}15\,\%$. Linie 1 fertigt im Mittel 309 Stück je Schicht bei 2,51 %, Linie 4 nur 134 Stück bei 0,98 %. Welches Vorzeichen hat c_{sq}, und warum? Wie viele Ausschussteile ergäbe eine Hochrechnung mit 2,02 %? Welche Quote nennst du der Werksleitung? [1 P]

Aufgabe 3 Joins und Zeilenzahlen

9 Punkte · etwa 19 Min.

Bezug: Modul 2, Lerneinheit 5 (Tabellen verknüpfen)

Für Linie 1 (M-03, M-04, M-08, M-09, M-10) sollen Stillstand und Wartung einer Woche nebeneinander stehen: links `st` (Störungen), rechts `wa` (Wartungseinsätze).

id	maschine	stillstand_min
S-1	M-03	40
S-2	M-04	25
S-3	M-03	60
S-4	M-09	15
S-5	M-03	20
S-6	M-10	30

auftrag	maschine	stunden
W-1	M-03	2
W-2	M-04	1
W-3	M-03	3
W-4	M-08	2
W-5	M-03	1

(a) Bestimme $n_L(k)$ in `st` und $n_R(k)$ in `wa` für jeden Schlüssel k und die Kardinalität. Wie viele Zeilen hat der Join `st.merge(wa, on="maschine", how=...)` für inner, left und outer? [3 P]

(b) Begründe $N_{\text{inner}} = \sum_k n_L(k)\, n_R(k)$, leite Formeln für N_{left} und N_{outer} her und prüfe sie an (a). Im Nordwerk hat `stoerungen` 14.263 Zeilen, `maschine` ist in `maschinen` eindeutig, und jede Meldung nennt eine Maschine daraus. Wie viele Zeilen hat der left join über `maschine`? [2 P]

(c) Sei `j = st.merge(wa, on="maschine")`. Was ergeben die Summen von `stillstand_min` und `stunden` in `j`, und was wäre für diese Maschinen richtig? Zeige: Eine linke Zeile mit Schlüssel k steht $n_R(k)$-mal in `j`. Warum hilft kein fester Teiler? Zur Kontrolle: `j` hat 10 Zeilen. [2 P]

(d) Abhilfe: erst aggregieren, dann verknüpfen. Schreibe `je_maschine` mit Spaltensummen auf. Warum besteht `validate` jetzt, und was hätte es bei den Rohtabellen gemeldet? [2 P]

```
st_agg = st.groupby("maschine", as_index=False).agg(
    meldungen=("id", "size"), stillstand_min=("stillstand_min", "sum"))
wa_agg = wa.groupby("maschine", as_index=False).agg(
    einsaetze=("auftrag", "size"), stunden=("stunden", "sum"))
je_maschine = st_agg.merge(wa_agg, on="maschine", how="outer",
                           validate="one_to_one")
```

Aufgabe 4 Breit und lang

6 Punkte · etwa 13 Min.

Bezug: Modul 2, Lerneinheit 6 (Tidy Data)

`wb` ist eine kleine Tabelle im Format des Wochenberichts mit den Linien 2 und 3:

kw	L2_Früh	L2_Spät	L2_Nacht	L3_Früh	L3_Spät	L3_Nacht
2025-KW10	1000	950	850	1150	1100	1000
2025-KW11	1050	1000	900	1200	1050	950

```
lang = wb.melt(id_vars="kw", var_name="spalte", value_name="ist_stueck")
# hier wie im Skript 6.3: linie (int64) und schicht (SCHICHT_TYP) aus spalte bilden
lang = lang.drop(columns="spalte")
p1 = lang.pivot_table(index="linie", columns="schicht", values="ist_stueck",
                      aggfunc="sum", observed=True)    # p2 ebenso mit "mean"
```

(a) Welche Regeln für tidy Data verletzt `wb`? Welche Variablen stecken in den Namen? [1 P]

(b) Welche Form hat `lang` nach `melt` und am Ende? Wie lauten die ersten vier Zeilen nach `melt`? Was macht `melt` allgemein aus n Zeilen, k Spalten in `id_vars` und m Wertspalten? [2 P]

(c) Berechne `p1` und `p2`. Welche Frage beantwortet `p2`? Was passiert mit `pivot` statt `pivot_table`, und warum? Zur Kontrolle: `lang` hat am Ende 12 Zeilen. [2 P]

(d) Der echte Wochenbericht hat 101 Zeilen und 13 Spalten. Welche Form hat `lang` dort am Ende? Wie viele Werte summiert jede Zelle wie in `p1`? Welche Gesamtsumme erwartest du? [1 P]

Aufgabe 5 Wochen, Lücken und gleitende Mittel

8 Punkte · etwa 18 Min.

Bezug: Modul 2, Lerneinheit 7 (Zeit)

Die Series `tag` enthält die Tagessummen der Linie 4 an allen Produktionstagen vom 21.7. (Montag der KW 30) bis 5.9.2025, mit dem Datum als Index. In KW 33 und 34 ruht das Werk. Die Wochensummen sind 1950 (KW 30), 2010 (KW 31), 2040 (KW 32), 1890 (KW 35) und 2010 (KW 36).

```
w1 = tag.resample("W").sum()
w2 = tag.groupby(tag.index.strftime("%G-KW%V")).sum()
print(len(w1), len(w2), w1.mean(), w2.mean())
r1 = w1.rolling(3).mean()
r2 = w1.where(w1 > 0).rolling(3, min_periods=1).mean()
```

(a) Der 1.1.2026 ist ein Donnerstag. Bestimme ISO-Jahr und KW für Montag, 29.12.2025, und Freitag, 2.1.2026. Was liefert `strftime` für den 29.12.2025 mit `"%G-KW%V"` und mit `"%Y-KW%V"`? Welche Tage bekommen mit dem zweiten Format denselben Text? Wann liegen die Werksferien 2026 (KW 33, 34)? [2 P]

(b) Wie viele Zeilen haben `w1` und `w2`, und wie sind sie beschriftet? Was gibt `print` aus? Welche Frage beantwortet jeder der beiden Mittelwerte? [2 P]

(c) Berechne `r1` und `r2` für alle Wochen von `w1`. Welche Reihe zeigt das Niveau der Betriebswochen? Zur Kontrolle: `w1` hat 7 Zeilen. [2 P]

(d) Welche Wochen mittelt `w2.rolling(3).mean()` in der Zeile `2025-KW35`? Warum ist das kein Mittel über drei Kalenderwochen? Im Werk liefert `resample("W")` 105 Wochen mit 1.217.169 Stück, 4 davon ohne Produktion. Berechne die mittlere Menge je Betriebswoche und je Kalenderwoche, auf ganze Stück gerundet. [2 P]

Aufgabe 6 (⋆) Gleitende Ausschussquote über die Werksferien

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 2, Lerneinheiten 4 und 7

`woche` enthält Wochensummen der Linie 1 aus `resample("W").sum()`, für KW 31 bis 36 Stück $s_w = (5000;\ 3000;\ 0;\ 0;\ 4500;\ 5500)$ und Ausschuss $a_w = (150;\ 60;\ 0;\ 0;\ 90;\ 165)$.

```
a, s = woche["ausschuss_stueck"], woche["ist_stueck"]
quote_3w = a.rolling(3).sum() / s.rolling(3).sum()
q = a / s
v1, v2 = q.rolling(3).mean(), q.fillna(0).rolling(3).mean()
v3 = q.rolling(3, min_periods=1).mean()
```

(a) Zeige: `quote_3w` ist ein gewichtetes Mittel der Wochenquoten im Fenster, Wochen ohne Produktion haben das Gewicht 0.

(b) Was steht in `q` für die Ferienwochen? Berechne `quote_3w`, `v1`, `v2` und `v3` für KW 33 bis 36.

(c) Welche Reihe gehört als „Ausschussquote der letzten drei Wochen“ in den Bericht? Begründe.

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Masken, loc und iloc

(a) Die Quoten sind $8/400 = 2{,}0\,\%$, $5/250 = 2{,}0\,\%$, $6/400 = 1{,}5\,\%$, $7/200 = 3{,}5\,\%$, $7/250 = 2{,}8\,\%$ und $3/150 = 2{,}0\,\%$. Die Maske ist in den Zeilen 0, 3 und 4 wahr. Ausgabe:

```
[True, False, False, True, True, False]
3 0.5
850 0.02
```

Die erste Codezeile führt **sechs Divisionen** aus, Eintrag für Eintrag in kompiliertem Code. `quote` hat den Typ `float64`, `m` den Typ `bool`. `True` zählt als 1, `False` als 0, also ist die Summe die Anzahl der Treffer (3) und der Mittelwert ihr Anteil ($3/6 = 0{,}5$). Die Treffer haben $400 + 200 + 250 = 850$ Stück. `~m` wählt die Zeilen 1, 2 und 5 mit den Quoten 0,02; 0,015 und 0,02, das Maximum ist 0,02.

(b) `&` bindet stärker als `|`. Python liest A als „Nacht *oder* (Linie 2 *und* Quote über 2,5 %)“:

$$\text{A: } \{4,5\} \cup (\{1,3,5\} \cap \{3,4\}) = \boxed{[3,4,5]}, \qquad \text{B: } \{1,3,4,5\} \cap \{3,4\} = \boxed{[3,4]}.$$

B erfüllt den Wunsch. A enthält zusätzlich Zeile 5 (Linie 2, Nacht, 2,0 %), denn dort reicht schon die Nacht. Bei C bindet `&` sogar stärker als `==` und `>`. Python liest eine Vergleichskette:

```
x = 2 & t["ist_stueck"]
t["linie"] == x > 300        # bedeutet (t["linie"] == x) and (x > 300)
```

`and` verlangt einen einzigen Wahrheitswert für eine ganze Series, deshalb bricht C ab mit `ValueError: The truth value of a Series is ambiguous.`

(c) `loc` schließt das Ende ein, `iloc` nicht. `l1` hat die Beschriftungen 0, 2 und 4 an den Positionen 0, 1 und 2. Die Spalte an Position 2 ist `ist_stueck`.

Ausdruck	Beschriftungen	Ergebnis
(i) `t.loc[1:3, "ist_stueck"]`	1, 2, 3	250, 400, 200
(ii) `t.iloc[1:3, 2]`	1, 2	250, 400
(iii) `l1.loc[2:4, "ist_stueck"]`	2, 4	400, 250
(iv) `l1.iloc[2, 2]`	4 (Position 2)	eine Zahl: 250
(v) `l1.loc[1, "ist_stueck"]`	keine	`KeyError: 1`

Bei (v) gibt es die Beschriftung 1 in `l1` nicht, Zeile 1 von `t` gehört zu Linie 2.

(d) `maske.mean()` teilt durch alle Zeilen: $80/5.788 \approx \boxed{0{,}0138}$, der Anteil an allen Schichten des Werks. Gefragt ist der Anteil an den 471 Nachtschichten der Linie 2: $80/471 \approx \boxed{0{,}170}$, also 17,0 %. Ausdruck: `maske.sum() / nacht_l2.sum()` oder `maske[nacht_l2].mean()`.

Typischer Fehler

In (b) Vorschlag A wählen, weil man ihn von links nach rechts liest: erst „Nacht oder Linie 2“, dann „und Quote“. Python wertet aber zuerst `&` aus, und der Fehler bleibt still. In (c) bei `iloc` das Ende mitnehmen, den Index als Spalte an Position 0 mitzählen oder `l1.iloc[2, 2]` als Zeile mit der Beschriftung 2 lesen.

Bewertung: (a) Ausgabe 1 P, Divisionen, Datentypen und Begründung 1 P. (b) Zeilen von A und B ½ P, Entscheidung ½ P, Erklärung von C 1 P. (c) alle fünf Ausdrücke 2 P, je Fehler einen halben Punkt Abzug. (d) beide Anteile mit Ausdruck 1 P.

Lösung zu Aufgabe 2 Gruppieren und Quoten richtig aggregieren

(a) Linie 1 (Zeilen 0, 2, 4): $400 + 400 + 250 = 1.050$ Stück, $8 + 6 + 7 = 21$ Teile Ausschuss, Minimum 250, $\bar{q}_1 = (2{,}0+1{,}5+2{,}8)/3 = 2{,}1\,\%$, $Q_1 = 21/1.050 = 2{,}0\,\%$. Linie 2 (Zeilen 1, 3, 5): $250+200+150 = 600$ Stück, $5+7+3 = 15$ Teile, Minimum 150, $\bar{q}_2 = (2{,}0+3{,}5+2{,}0)/3 = 2{,}5\,\%$, $Q_2 = 15/600 = 2{,}5\,\%$.

linie	schichten	ist	ausschuss	ist_min	mittel_der_quoten	quote_der_summen
1	3	1050	21	250	0,021	0,020
2	3	600	15	150	0,025	0,025

`g.shape` ist $\boxed{(2, 6)}$. Der Schlüssel `linie` ist der Index mit den Werten 1 und 2, er zählt nicht als Spalte.

(b) Linie 1 hat den Mittelwert 350, Linie 2 den Mittelwert 200. Ausgabe:

```
   linie  ist_stueck    abw  falsch
0      1         400   50.0     NaN
1      2         250   50.0   350.0
2      1         400   50.0   200.0
3      2         200    0.0     NaN
4      1         250 -100.0     NaN
5      2         150  -50.0     NaN
```

`transform("mean")` liefert **6 Werte mit dem Index von `t`**, jede Zeile den Mittelwert ihrer Linie. `mean()` liefert wie `agg` **2 Werte mit dem Index `linie`** (1 und 2). Die Zuweisung ordnet über den Index zu, Beschriftungen ohne Partner bekommen `NaN`. Deshalb gibt es keinen Fehler. Die Linien 1 und 2 treffen die Zeilen 1 und 2: Zeile 1 (Linie 2) bekommt den Mittelwert der Linie 1, Zeile 2 (Linie 1) den der Linie 2, alle anderen `NaN`. Richtig ist `transform`.

(c) Mit $S = \sum_j s_j$ gilt

$$Q = \frac{\sum_i a_i}{S} = \sum_i \frac{s_i}{S} \cdot \frac{a_i}{s_i} = \boxed{\sum_i w_i\, q_i}, \qquad w_i = \frac{s_i}{S} \geq 0, \qquad \sum_i w_i = \frac{\sum_i s_i}{S} = 1.$$

Linie 1: $w = (\frac{400}{1.050};\ \frac{400}{1.050};\ \frac{250}{1.050}) = (\frac{8}{21};\ \frac{8}{21};\ \frac{5}{21})$. Probe:

$$\tfrac{8}{21} \cdot 2{,}0\,\% + \tfrac{8}{21} \cdot 1{,}5\,\% + \tfrac{5}{21} \cdot 2{,}8\,\% = \tfrac{16+12+14}{21}\,\% = \tfrac{42}{21}\,\% = \boxed{2{,}0\,\%} = Q_1.$$

Im Mittel der Quoten hat jede Schicht das Gewicht $\frac{1}{3} = \frac{7}{21}$. In Q zählt die kleine Nachtschicht weniger ($\frac{5}{21}$), die beiden großen Schichten zählen mehr ($\frac{8}{21}$).

(d) Quoten in Prozent, also $q_i - \bar{q}$ in Prozentpunkten, $s_i - \bar{s}$ aus `abw`:

Linie 1: $\bar{s} = 350$, $\bar{q} = 2{,}1$				Linie 2: $\bar{s} = 200$, $\bar{q} = 2{,}5$			
Schicht	$s_i - \bar{s}$	$q_i - \bar{q}$	Produkt	Schicht	$s_i - \bar{s}$	$q_i - \bar{q}$	Produkt
Früh	50	−0,1	−5	Früh	50	−0,5	−25
Spät	50	−0,6	−30	Spät	0	1,0	0
Nacht	−100	0,7	−70	Nacht	−50	−0,5	25
Summe			−105	Summe			0

Linie 1: $c_{sq} = -105/3 = \boxed{-35}$ und $c_{sq}/\bar{s} = -35/350 = -0{,}1$ Prozentpunkte, also $Q_1 = 2{,}1 - 0{,}1 = 2{,}0\,\%$ wie in (a). Linie 2: $c_{sq} = \boxed{0}$, also $Q_2 = \bar{q}_2 = 2{,}5\,\%$. Wegen $\bar{s} > 0$ gilt $Q = \bar{q}$ **genau dann, wenn** $c_{sq} = 0$, also wenn Stückzahl und Quote unkorreliert sind. Gleiche Stückzahlen sind nur der einfachste Fall, Linie 2 zeigt es mit ungleichen. Bei $c_{sq} > 0$ (große Schichten haben eher hohe Quoten) liegt Q über $\bar{q}$, bei $c_{sq} < 0$ darunter, wie in Linie 1 mit ihrer kleinen Nachtschicht.

(e) $Q - \bar{q} = 2{,}15 - 2{,}02 = 0{,}13$ Prozentpunkte, also ist $\boxed{c_{sq} > 0}$: Im Werk haben Schichten mit vielen Stück eher hohe Quoten. Das liegt vor allem an den Linien: Linie 1 fertigt viel bei hoher Quote, Linie 4 wenig bei niedriger. Innerhalb einer Linie liegen beide Maße fast gleich (Skript, Abschnitt 4.4). Hochrechnung: $0{,}0202 \cdot 1.217.169 \approx \boxed{24.587}$ Teile statt 26.154, rund 1.567 Teile oder 6 % zu wenig (mit dem ungerundeten Mittel 2,0178 % sind es 1.594). Der Werksleitung nennst du $\boxed{Q = 2{,}15\,\%}$, den Anteil des Ausschusses an allen gefertigten Teilen.

Typischer Fehler

In (b) erwarten, dass `falsch` in jeder Zeile den Mittelwert der eigenen Linie enthält. Die Zuweisung ordnet über den Index zu, nicht über die Spalte `linie`. In (d) durch $n - 1$ statt durch n teilen, wie bei der Standardabweichung von `describe`. Dann ist $c_{sq} = -52{,}5$, und die Formel liefert $-0{,}15$ statt $-0{,}1$ Prozentpunkte.

Bewertung: (a) Einzelquoten und Mittel der Quoten 1 P, Anzahl, Summen, Minimum, Form und Index 1 P, Quote der Summen 1 P. (b) Spalte `abw` 1 P, Spalte `falsch` mit Erklärung 1 P. (c) Herleitung 1 P, Gewichte mit Probe 1 P. (d) c_{sq} für beide Linien 1 P, Bedingung und Richtung 1 P. (e) Vorzeichen mit Begründung ½ P, Hochrechnung und Wahl der Quote ½ P. Folgefehler aus (a) werden nicht doppelt abgezogen.

Lösung zu Aufgabe 3 Joins und Zeilenzahlen

(a) Zähler je Schlüsselwert und Beiträge zu den Zeilenzahlen:

k	$n_L(k)$	$n_R(k)$	inner $n_L n_R$	left	outer
M-03	3	3	9	9	9
M-04	1	1	1	1	1
M-08	0	1	0	0	1
M-09	1	0	0	1	1
M-10	1	0	0	1	1
Summe	6	5	$\boxed{10}$	$\boxed{12}$	$\boxed{13}$

Der Join ist **m:n**: `maschine` kommt in beiden Tabellen mehrfach vor, M-03 links und rechts je dreimal.

(b) `merge` kombiniert jede linke Zeile mit jeder rechten Zeile mit demselben Schlüssel. Für einen Wert k gibt es $n_L(k)$ mal $n_R(k)$ solche Paare (Produktregel). Verschiedene Schlüssel werden nie kombiniert, also addieren sich die Paare über alle k. Beim left join bleibt jede linke Zeile ohne Partner einmal stehen, mit `NaN` rechts, beim outer join auch jede rechte:

$$N_{\text{left}} = \sum_k n_L(k)\,\max\left(n_R(k), 1\right), \qquad N_{\text{outer}} = N_{\text{left}} + \sum_{k:\, n_L(k)=0} n_R(k).$$

Probe: $N_{\text{left}} = 9 + 1 + 1 + 1 = 12$ und $N_{\text{outer}} = 12 + 1 = 13$ wie in (a). Nordwerk: Jede Maschine einer Meldung steht genau einmal in `maschinen`, also ist $n_R(k) = 1$ für jedes k in `stoerungen`. Damit ist $N_{\text{left}} = \sum_k n_L(k) = \boxed{14.263}$, die Zeilenzahl bleibt (m:1).

(c) In `j` stehen 9 Zeilen für M-03 und eine für M-04. Jede Meldung zu M-03 erscheint dreimal, jeder Einsatz an M-03 auch:

$$\text{Stillstand: } (40+60+20)\cdot 3 + 25\cdot 1 = \boxed{385} \text{ Minuten statt } 120+25=145,$$
$$\text{Stunden: } (2+3+1)\cdot 3 + 1\cdot 1 = \boxed{19} \text{ statt } 6+1=7.$$

Allgemein: Eine linke Zeile mit Schlüssel k bildet mit jeder der $n_R(k)$ rechten Zeilen dieses Schlüssels ein Paar, steht also $n_R(k)$-mal in `j`. Hat eine linke Spalte je Schlüssel die Summe $S_L(k)$, ist ihre Summe in `j` also $\sum_k n_R(k)\, S_L(k)$. Der Faktor hängt vom Schlüssel ab, hier 3 für M-03 und 1 für M-04. Kein fester Teiler macht aus 385 die richtigen 145.

(d) Nach dem Aggregieren:

maschine	meldungen	stillstand_min	einsaetze	stunden
M-03	3	120	3	6
M-04	1	25	1	1
M-08	NaN	NaN	1	2
M-09	1	15	NaN	NaN
M-10	1	30	NaN	NaN

Nach `groupby` steht jede Maschine in `st_agg` und `wa_agg` höchstens einmal: Der Join ist 1:1, `validate` besteht, und es gibt genau eine Zeile je Maschine. Bei den Rohtabellen hätte `validate` mit einem `MergeError` abgebrochen, weil die Schlüssel links und rechts nicht eindeutig sind. Spaltensummen: $120+25+15+30 = \boxed{190}$ Minuten wie in `st` und $6+1+2 = \boxed{9}$ Stunden wie in `wa`, dazu 6 Meldungen und 5 Einsätze, so viele Zeilen wie `st` und `wa` haben. `NaN` heißt „kein Eintrag“ und macht die Zahlenspalten zu `float64` (pandas zeigt `3.0` statt `3`), mit `fillna(0)` wird daraus 0.

> **Typischer Fehler**
>
> Beim left join die Zeilenzahl der linken Tabelle angeben (hier 6). Das gilt nur, wenn der Schlüssel rechts eindeutig ist. Ebenso falsch: Zeilen addieren statt multiplizieren, etwa für M-03 $3+3=6$ statt $3\cdot 3=9$ Zeilen.

Bewertung: (a) Zählertabelle 1 P, inner ½ P, left ½ P, outer ½ P, Kardinalität ½ P. (b) Begründung für inner 1 P, Formeln für left und outer mit Probe und Anwendung 1 P. (c) beide Summen mit Vergleich 1 P, allgemeine Begründung 1 P. (d) Tabelle 1 P, `validate` und Summen 1 P.

Lösung zu Aufgabe 4 Breit und lang

(a) Regel 1 ist verletzt: Linie und Schicht sind Variablen, ihre Werte (L2, Früh und so weiter) stehen in den Spaltennamen. Regel 2 ist verletzt: Eine Zeile enthält sechs Beobachtungen, eine Wochensumme je Linie und Schicht. Die tidy Form hat die Variablen `kw`, `linie`, `schicht` und `ist_stueck`.

(b) Direkt nach `melt` ist die Form $\boxed{(12, 3)}$ mit den Spalten `kw`, `spalte` und `ist_stueck`. `melt` stapelt Spalte für Spalte, erst beide Wochen von `L2_Früh`, dann `L2_Spät` (nicht Zeile für Zeile):

```
          kw   spalte  ist_stueck
0  2025-KW10  L2_Früh        1000
1  2025-KW11  L2_Früh        1050
2  2025-KW10  L2_Spät         950
3  2025-KW11  L2_Spät        1000
```

Am Ende hat `lang` die Spalten `kw`, `ist_stueck`, `linie` und `schicht`, die Form ist $\boxed{(12, 4)}$. Allgemein entstehen $\boxed{n \cdot m}$ Zeilen und $k + 2$ Spalten, nach dem Zerlegen $k + 3$.

(c) Je Linie und Schicht gibt es zwei Werte, einen je Woche:

p1	Früh	Spät	Nacht	p2	Früh	Spät	Nacht
2	2050	1950	1750	2	1025	975	875
3	2350	2150	1950	3	1175	1075	975

`p2` beantwortet: Wie viel fertigt eine Schichtart einer Linie im Mittel in einer Woche? Die Spalten stehen in Schichtfolge, weil `schicht` eine geordnete Kategorie ist. `pivot` bricht ab mit `ValueError: Index contains duplicate entries, cannot reshape`. Jede Kombination aus Linie und Schicht kommt zweimal vor, und `pivot` aggregiert nicht. Gegenprobe: Die Summe von `p1` ist $12.200 = 6.050 + 6.150$, die Summe aller Wertzellen von `wb`.

(d) $101 \cdot 12 = \boxed{1.212}$ Zeilen und 4 Spalten. Die Kreuztabelle hat $4 \cdot 3 = 12$ Zellen, jede summiert **101 Werte**, einen je Woche. Gegenprobe: Die Gesamtsumme muss $\boxed{1.217.169}$ sein, die Summe von `ist_stueck` in `produktion`. Ebenso müssen die Summen je Linie und Schicht übereinstimmen.

Bewertung: (a) beide Regeln mit Variablen 1 P. (b) Form und erste Zeilen 1 P, Endform und allgemeine Formel 1 P. (c) `p1` und `p2` mit Deutung 1 P, Fehler bei `pivot` mit Begründung 1 P. (d) Form, Werte je Zelle und Gegenprobe 1 P.

Lösung zu Aufgabe 5 Wochen, Lücken und gleitende Mittel

(a) ISO-Woche 1 ist die Woche mit dem ersten Donnerstag. Der 1.1.2026 ist ein Donnerstag, also reicht KW 1 von 2026 von Montag, 29.12.2025, bis Sonntag, 4.1.2026. Beide Tage liegen in $\boxed{\text{ISO-Jahr 2026, KW 1}}$. Mit `"%G-KW%V"` entsteht `2026-KW01`, mit `"%Y-KW%V"` entsteht `2025-KW01`. Diesen Text bekommen auch die Tage vom 1. bis 5.1.2025 (Teil der echten KW 1 von 2025). Die Gruppierung wirft also den 29. bis 31.12.2025 und den 1. bis 5.1.2025 zu einer „Woche“ zusammen. Werksferien: Montag der KW 33 liegt $32 \cdot 7 = 224$ Tage nach dem 29.12.2025, also 3 Tage bis zum 1.1. und weitere 221 Tage. Das ist Tag 222 des Jahres. Januar bis Juli haben 212 Tage: **Montag, 10.8.2026** bis **Sonntag, 23.8.2026**. Im Nordwerk schadet `%Y` zufällig nicht, weil vom 24.12. bis 1.1. nicht produziert wird.

(b) `w1` hat **7 Zeilen**, je Kalenderwoche eine, beschriftet mit dem Sonntag: 27.7., 3.8., 10.8., 17.8., 24.8., 31.8. und 7.9.2025, mit den Werten 1950, 2010, 2040, 0, 0, 1890 und 2010. `w2` hat **5 Zeilen**, `2025-KW30` bis `2025-KW32`, `2025-KW35` und `2025-KW36`. Für die Ferien gibt es keine Zeilen zum Gruppieren. Beide Summen sind 9.900, also $9.900/7 \approx \boxed{1.414{,}3}$ und $9.900/5 = \boxed{1.980}$:

```
7 5 1414.2857142857142 1980.0
```

`w1.mean()` beantwortet „Wie viel fertigte Linie 4 im Schnitt je Kalenderwoche?“, `w2.mean()` „Wie viel fertigt sie in einer Betriebswoche?“. Die Summen sind gleich, nur der Nenner unterscheidet sich.

(c) Fensterbreite 3, die Lücken als 0 (`r1`) oder als `NaN` (`r2`):

Woche bis	27.7.	3.8.	10.8.	17.8.	24.8.	31.8.	7.9.
w1	1950	2010	2040	0	0	1890	2010
r1	NaN	NaN	2000	1350	680	630	1300
r2	1950	1980	2000	2025	2040	1890	1950

Am 17.8. ist `r1` gleich $(2010 + 2040 + 0)/3 = 1350$ und `r2` gleich $(2010 + 2040)/2 = 2025$. `r1` zählt die Ferienwochen als 0 mit und fällt am 24.8. und 31.8. auf ein Drittel von `r2`. `r2` mittelt nur vorhandene Werte und zeigt das Niveau der Betriebswochen.

(d) Das Fenster in `2025-KW35` mittelt die letzten drei *Zeilen* von `w2`, KW 31, 32 und 35: $(2010 + 2040 + 1890)/3 = 1.980$. `rolling(3)` zählt Zeilen, nicht Zeit, und weil die Ferien fehlen, reicht das Fenster über fünf Kalenderwochen (28.7. bis 31.8.). Werk: $1.217.169/105 \approx \boxed{11.592}$ Stück je Kalenderwoche und $1.217.169/101 \approx \boxed{12.051}$ je Betriebswoche. Auch die 101 Wochen enthalten kurze Wochen mit Feiertagen.

> **Typischer Fehler**
>
> Den 29.12.2025 der KW 53 von 2025 zuordnen. 2025 hat nur 52 ISO-Wochen, denn es beginnt an einem Mittwoch und ist kein Schaltjahr. Ebenfalls häufig: die Wochen von `resample("W")` mit dem Montag beschriften. `"W"` steht für `"W-SUN"`, beschriftet wird mit dem Sonntag.

Bewertung: (a) ISO-Wochen und beide Texte mit Folge für die Gruppierung 1 P, Ferientermine 1 P. (b) Zeilen und Beschriftungen 1 P, Mittelwerte mit Zuordnung 1 P. (c) `r1` 1 P, `r2` 1 P. (d) Fenster von `w2` mit Begründung 1 P, Werkswerte mit Zuordnung 1 P.

Lösung zu Aufgabe 6 Gleitende Ausschussquote über die Werksferien (Zusatz)

(a) Für ein Fenster F aus drei Wochen mit $S_F = \sum_{v \in F} s_v > 0$ gilt wie in Aufgabe 2(c) mit $a_v = s_v\, q_v$ für $s_v > 0$:

$$\texttt{quote_3w} = \frac{\sum_{v \in F} a_v}{S_F} = \sum_{v \in F,\ s_v > 0} \frac{s_v}{S_F}\, q_v .$$

Eine Ferienwoche hat $s_v = a_v = 0$. Sie trägt zu Zähler und Nenner nichts bei, ihr Gewicht ist $0/S_F = 0$, und ihre undefinierte Quote $0/0$ wird nie gebraucht.

(b) In `q` steht für KW 33 und 34 `NaN`, denn $0/0$ ist nicht definiert. Die übrigen Wochenquoten sind 3,0; 2,0; 2,0 und 3,0 %.

Woche	`quote_3w`	`v1`	`v2` (mit 0)	`v3` (ohne `NaN`)
KW 33	$210/8.000 = \boxed{2{,}625\,\%}$	NaN	1,667 %	2,5 %
KW 34	$60/3.000 = \boxed{2{,}0\,\%}$	NaN	0,667 %	2,0 %
KW 35	$90/4.500 = \boxed{2{,}0\,\%}$	NaN	0,667 %	2,0 %
KW 36	$255/10.000 = \boxed{2{,}55\,\%}$	NaN	1,667 %	2,5 %

Probe mit den Gewichten aus (a): KW 33 $0{,}625 \cdot 3{,}0 + 0{,}375 \cdot 2{,}0 = 2{,}625$, KW 36 $0{,}45 \cdot 2{,}0 + 0{,}55 \cdot 3{,}0 = 2{,}55$. `v1` ist in allen vier Wochen `NaN`, weil jedes Fenster eine Ferienwoche enthält.

(c) In den Bericht gehört `quote_3w`: der Anteil des Ausschusses an allen Teilen der drei Wochen wie im Datenblatt, ohne Sonderregel für die Ferien. `v2` zeigt die Ferien als Wochen ohne Ausschuss, in KW 34 und 35 sinkt die Quote scheinbar auf ein Drittel. `v3` gibt der kleinen KW 32 dasselbe Gewicht wie der großen KW 31. Einschränkung: In KW 34 und 35 stützt sich das Fenster nur auf eine Betriebswoche.