Tutoriumsblatt 3

SQL und Datenqualität

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- SQL-Abfragen, Joins und Fensterfunktionen von Hand auswerten, `NULL` richtig behandeln,
- fehlende Werte einordnen und hochrechnen, Ausreißer robust erkennen,
- Prüfregeln präzise formulieren und k-Anonymität bestimmen und erhöhen.

So arbeitest du mit dem Blatt

Du programmierst nicht: Jede Abfrage liest du wie die Datenbank (Schreibtischtest), das Ergebnis schreibst du als Tabelle mit `NULL` für fehlende Werte, gleich in SQLite 3.39 (Browser) und 3.45. Hilfsmittel: Taschenrechner und Skript. Hängst du, rechnest du mit den Werten unter „Zur Kontrolle“ weiter. Kleine Tabellen sind fiktiv, Werkszahlen stammen aus Skript und Rohdatenbank. Zum Notebook: Aufgabe 1 gehört zu TODO 2 und 3; Aufgabe 2 zu 4 und 5; Aufgabe 3 zu 7; Aufgabe 4 zu 8 und 9; Aufgabe 5 zu 6 und 10 bis 12; der Zusatz zu 8.

Aufgabe 1 Abfragen, NULL und die logische Reihenfolge

9 Punkte · etwa 19 Min.

Bezug: Modul 3, Lerneinheit 2 (SQL-Grundlagen)

Die Tabelle `s` enthält die neun Schichten der Linien 1 bis 3 vom Dienstag, 16. Juni 2026, im Format der Rohdatenbank.

linie	schicht	ist_stueck	ausschuss_stueck	personal	hallentemp_c
1	Früh	340	8	9	23,5
2	Früh	210	6	8	24,0
3	Früh	230	4	NULL	23,5
1	Spät	330	9	10	NULL
2	Spät	200	7	8	25,0
3	Spät	240	3	7	24,5
1	Nacht	280	6	8	24,0
2	Nacht	170	5	NULL	NULL
3	Nacht	210	2	6	23,5

(a) Schreibe das Ergebnis auf. Was steht in `quote`, und warum? Wie lautet die Spalte richtig, als SQL und als Zahlen (auf vier Nachkommastellen)? Warum gehört die Bedingung auf die Summe in `HAVING`? Zur Kontrolle: Nach `WHERE` bleiben 6 Zeilen. [3 P]

```
SELECT linie, COUNT(*) AS schichten, SUM(ist_stueck) AS ist,
       SUM(ausschuss_stueck) AS ausschuss,
       SUM(ausschuss_stueck) / SUM(ist_stueck) AS quote
FROM s WHERE schicht <> 'Nacht' GROUP BY linie
HAVING SUM(ist_stueck) >= 450 ORDER BY ausschuss DESC
```

(b) Gib das Ergebnis an. Welche zwei Fehler stecken in `je_zeile`? Wie viele Zeilen zählt `SELECT COUNT(*) AS n FROM s WHERE` mit (i) `hallentemp_c = NULL`, (ii) `personal <> 8`, (iii) `NOT (personal = 8)` und (iv) `personal <> 8 OR personal IS NULL`? [3 P]

```
SELECT COUNT(*) AS zeilen, COUNT(personal) AS mit_personal, AVG(personal) AS mittel,
       SUM(personal) / COUNT(*) AS je_zeile, AVG(hallentemp_c) AS temp FROM s
```

(c) Wie viele Zeilen oder Gruppen geben in (a) die Schritte `FROM`, `WHERE`, `GROUP BY` und `HAVING` weiter? Warum kennt `ORDER BY` den Namen `ausschuss` aus `SELECT`? Was passiert, wenn du in (a) `HAVING` weglässt und die Bedingung als `AND SUM(ist_stueck) >= 450` ins `WHERE` schreibst? [2 P]

(d) In der Rohdatenbank fehlt `personal` in 74 der 5.788 verschiedenen Schichten, `AVG(personal)` ergibt 8,2891 (Skript 4.2 und 4.3). Wie groß ist die Summe der Personalzahlen? Was liefert `SUM(personal) / COUNT(*)` über diese 5.788 Schichten ohne und mit dem Faktor `1.0` davor? [1 P]

Aufgabe 2 Joins, Anti-Join und Fensterfunktionen

7 Punkte · etwa 15 Min.

Bezug: Modul 3, Lerneinheit 3 (JOINs und Fensterfunktionen)

Aus der Instandhaltung der Linie 4 stammen `ma` mit vier Maschinen und `wa` mit acht Wartungen, Abzug vom 1. Oktober 2026.

maschine	name
M-06	Montagelinie A
M-07	Prüfstand
M-17	Montagelinie B
M-18	Schraubstation

wartung_id	maschine	datum	status	dauer_min
W-1	M-06	2026-08-03	erledigt	55
W-2	M-07	2026-08-20	erledigt	95
W-3	M-17	2026-08-31	erledigt	30
W-4	M-07	2026-09-08	erledigt	30
W-5	M-06	2026-09-14	erledigt	60
W-6	m-06	2026-09-28	erledigt	25
W-7	M-17	2026-10-05	geplant	NULL
W-8	M-06	2026-10-12	geplant	NULL

(a) Schreibe das Ergebnis auf. Vor `GROUP BY` hat die verknüpfte Tabelle so viele Zeilen wie `wa`: Steht jede Wartung darin? Warum unterscheiden sich `zeilen` und `wartungen` bei M-18? [2 P]

```
SELECT m.maschine, COUNT(*) AS zeilen, COUNT(w.wartung_id) AS wartungen,
       SUM(w.dauer_min) AS minuten
FROM ma AS m LEFT JOIN wa AS w ON m.maschine = w.maschine
GROUP BY m.maschine ORDER BY m.maschine
```

(b) Welche Zeilen liefert der Anti-Join, und welche Fehlerart zeigt der Treffer? Was liefert er mit `JOIN` statt `LEFT JOIN`, was mit `w.maschine IS NULL` im `WHERE`? [2 P]

```
SELECT w.wartung_id, w.maschine FROM wa AS w LEFT JOIN ma AS m
ON w.maschine = m.maschine WHERE m.maschine IS NULL
```

(c) Schreibe das Ergebnis auf (6 Zeilen). Die letzte erledigte Wartung je Maschine liefert `SELECT * FROM (...) WHERE nr = 1` um diese Abfrage. Warum geht `AND nr = 1` nicht in ihrem `WHERE`? Was stimmt für M-06 nicht, was änderte sich ohne den Filter auf `status`? [2 P]

```
SELECT wartung_id, maschine, datum,
       ROW_NUMBER() OVER (PARTITION BY maschine ORDER BY datum DESC) AS nr,
       LAG(datum) OVER (PARTITION BY maschine ORDER BY datum) AS vorher
FROM wa WHERE status = 'erledigt' ORDER BY maschine, datum
```

(d) Von den 14.434 Störungsmeldungen der Rohdatenbank haben 156 eine unbekannte Kennung (Skript 3.1), und jede der 20 Maschinen hat Meldungen. Wie viele Zeilen hat der `LEFT JOIN` mit `maschinen` links und `stoerungen` rechts, und welche Meldungen fehlen darin? [1 P]

Aufgabe 3 Fehlende Werte: Mechanismen und Folgen

8 Punkte · etwa 17 Min.

Bezug: Modul 3, Lerneinheit 4 (Fehlende Werte)

Notation wie im Skript: $R = 1$, wenn ein Wert fehlt, K ist die Kategorie einer Meldung, S ihre Schicht, n_s die Zahl aller Meldungen der Schicht s.

(a) Ordne MCAR, MAR oder MNAR zu und begründe in einem Satz, wovon das Fehlen abhängt: (i) In zufällig gewählten 10 % der Personalakten fehlt die Qualifikation. (ii) Der Logger der Linie 1 startet montags um 6 Uhr neu, der Wert der Frühschicht geht meist verloren. (iii) Dauert eine Störung über das Schichtende hinaus, bleibt der Stillstand oft leer. (iv) Bei M-19 fehlt die Kategorie oft, weil ihr Terminal die Auswahlliste nicht anzeigt. [2 P]

(b) Zehn Meldungen einer Woche an M-05 hatten laut Rückfrage die Kategorien: früh Material, mechanisch, elektrisch; spät Material, mechanisch, Software; nachts zweimal Material, mechanisch, Bedienung. Erfasst fehlt die Kategorie nur nachts, bei einem Materialfehler und bei der Bedienung, innerhalb der Schicht zufällig. Lösche die Meldungen ohne erfasste Kategorie. Wie viele Materialfehler zählst du je Schicht, wie viele sind es wahr? Berechne je Schicht $\hat{P}(K = \text{Material} \mid S = s)$ unter den bekannten und $\hat{N}_s = n_s \cdot \hat{P}(K = \text{Material} \mid S = s)$. Vergleiche den Materialanteil unter allen bekannten Kategorien mit dem wahren, und bestätige den wahren mit der totalen Wahrscheinlichkeit. Zur Kontrolle: Es bleiben 8 Meldungen. [3 P]

(c) Hängt das Fehlen nur von der Schicht ab, $P(R = 1 \mid K = k, S = s) = P(R = 1 \mid S = s)$, dann zeige $P(K = k \mid S = s, R = 0) = P(K = k \mid S = s)$. Schreibe $P(K = k \mid R = 0)$ als Summe über die Schichten. Warum ist dieser Gesamtanteil verzerrt, und wann nicht? [2 P]

(d) Im Juli und August beider Jahre hat die Rohdatenbank 824 verschiedene Schichten, 665 mit Hallentemperatur, im Mittel 23,12 °C (Skript 4.3), die Lücken sind MNAR. Zwischen welchen Grenzen liegt der wahre Mittelwert, wenn über die Lücken nur die Fachregel 10 bis 40 °C bekannt ist? Warum machen die beobachteten Werte sie nicht enger? Wie lauten sie, wenn jede fehlende Schicht mindestens 23,12 °C warm war? [1 P]

Aufgabe 4 Ausreißer und Einheitenfehler

8 Punkte · etwa 18 Min.

Bezug: Modul 3, Lerneinheit 5 (Ausreißer und Plausibilität)

Der Logger der Linie 2 in Halle 1 lieferte montags bis freitags vom 6. bis 17. Juli 2026 in der Frühschicht diese Werte in °C: 23,0; 24,5; 22,0; 77,0 (am 9.7.); 23,5; 25,0; 17,0; 22,5; 24,0; 21,5.

(a) Bestimme Q_1 und Q_3 wie im Skript 5.1 (linear interpoliert an der Stelle $h = (n-1)\,p$ der sortierten Werte $x_{(0)} \le \dots \le x_{(n-1)}$), den IQR und die Grenzen der IQR-Regel. Welche Werte meldet sie? [2 P]

(b) Berechne den Median $\tilde{x}$, den MAD und den robusten z-Wert M_i für 17,0; 25,0 und 77,0. Welche Werte meldet $|M_i| > 3{,}5$? Vergleiche mit (a). Zur Kontrolle: $\tilde{x} = 23{,}25$. [2 P]

(c) Die Fachregel lautet: 10 bis 40 °C. Welche Kandidaten verletzen sie? Woran erkennst du, ob 77,0 ein Einheitenfehler ist, und welcher Wert in °C ergibt sich? Was machst du mit 17,0? [1 P]

(d) Berechne $z_i = (x_i - \bar{x})/s$ für 77,0 und 17,0, roh und nach der Korrektur aus (c). Zur Kontrolle: roh ist $s \approx 17{,}36$, korrigiert $\bar{x} = 22{,}8$. Warum meldet $|z_i| > 3$ nie etwas? Was ändert die Korrektur an Quartilen, Median und MAD? [2 P]

(e) Auf Linie 3 stehen im Januar und Februar 2025 Stillstände in Stunden, etwa 0,75; 2,25 und 4,42 (Skript 5.5). Rechne sie in Minuten um (auf 5 gerundet). Welche findet SQLite mit `WHERE stillstand_min % 5 != 0`, welche mit `WHERE stillstand_min < 5`? Warum fiele ein Wert von 5,0 Stunden keiner Regel auf, und wie findest du ihn? [1 P]

Aufgabe 5 Prüfregeln, Dubletten und Personendaten

8 Punkte · etwa 18 Min.

Bezug: Modul 3, Lerneinheiten 6 (Datenprüfungen als Tests) und 7 (Daten über Menschen)

Die sieben Probezeilen `au` im Format der Tabelle `auftraege` enthalten typische Fehler. Es gibt die Linien 1 bis 4, der Abzug umfasst den 1. Oktober 2024 bis 30. September 2026.

auftrag_id	kunde	linie	menge	bestellt_am	liefertermin	geliefert_am	status
A-02302	K-055	1	0,22	2026-09-01	2026-09-22	2026-09-21	geliefert
A-02303	K-038	1	250	2026-09-23	2026-09-09	2026-09-22	geliefert
A-02304	K-020	2	80	02.09.2026	2026-09-16	2026-09-15	geliefert
A-02305	K-057	5	120	2026-09-03	2026-09-17	2026-09-17	geliefert
A-02306	K-003	4	50	2026-09-03	2026-09-24	1900-01-01	geliefert
A-02307	K-040	3	200	2026-09-04	2026-09-25	NULL	offen
A-02308	K-040	3	200	2026-09-04	2026-09-25	NULL	offen

(a) Ordne die Fehlerarten Duplikat, Schlüsselfehler, Einheitenfehler, Platzhalter, Plausibilität und Format je einer Zeile zu, mit je einer Prüfregel, die genau die Verstöße markiert (in Worten oder wie im Skript 6.1). Welche Zeile wirkt verdächtig, ist aber kein Fehler? Welche Regel muss vor der Plausibilitätsregel laufen? [3 P]

(b) A-02307 und A-02308 sind bis auf die Kennung gleich. Warum ist Löschen ohne eindeutigen Schlüssel eine Ermessensfrage, und was stützt die Entscheidung? Im Nordwerk sind 171 der 195 inhaltsgleichen Störungsmeldungen Kopien aus einem Nachimport, die übrigen echt (Skript 6.3). Welcher Anteil wäre zu Unrecht gelöscht, wenn du alle 195 löschst? [1 P]

Acht erfundene Beschäftigte im Format von `bedienende`, ohne Name, E-Mail und Telefon. Altersgruppen wie im Skript 7.4 (unter 30, 30 bis 39, 40 bis 49, 50 bis 59, ab 60) mit dem Alter 2026 − Geburtsjahr.

Personalnr.	Geburtsdatum	Linie	Schichtgruppe	Qualifikation
P-11	1990-03-12	1	A	Anlagenführer
P-12	1993-08-25	1	B	Maschinenbediener
P-13	1968-11-02	1	A	Einrichter
P-14	1972-04-19	1	B	Einrichter
P-15	1999-07-30	2	B	Maschinenbediener
P-16	2002-01-15	2	A	Prüfer
P-17	1974-06-08	2	A	Anlagenführer
P-18	1971-12-21	2	A	Maschinenbediener

(c) Welche Spalten sind direkte, welche Quasi-Kennungen? Bestimme k und die Zahl der Personen allein in ihrer Gruppe für (i) Geburtsdatum, Linie, Schichtgruppe, (ii) Altersgruppe, Linie, Schichtgruppe und (iii) Altersgruppe, Linie. Was verrät (iii) trotz $k = 2$? Ist (iii) mit dem gesalzenen Hash der Personalnummer (Skript 7.3, Salz in der Personalabteilung) anonym, und ohne ihn? Nordwerk: 126 Beschäftigte haben 125 verschiedene Geburtsdaten. Wie viele sind darüber allein bestimmbar? Zur Kontrolle: Je 2 Personen sind unter 30 und 30 bis 39. [4 P]

Aufgabe 6 (⋆) Wie groß kann ein z-Wert werden?

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 3, Lerneinheit 5

Seien $x_1, \ldots, x_n$ Werte mit $n \geq 2$, $s > 0$ und $d_j = x_j - \bar{x}$. (a) Zeige $|z_i| \leq (n-1)/\sqrt{n}$ (Skript 5.2) mit $\sum_j d_j = 0$ und Cauchy-Schwarz. Wann gilt Gleichheit? (b) Ab welchem n ist $|z_i| > 3$ möglich? (c) Was geschieht in Aufgabe 4 mit M_i und z_i des größten Werts, wenn er auf 770 steigt?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Abfragen, NULL und die logische Reihenfolge

(a) `WHERE` entfernt die drei Nachtschichten. Linie 1 hat $340 + 330 = 670$ Stück und $8 + 9 = 17$ Teile Ausschuss, Linie 2 hat $210 + 200 = 410$ und $6 + 7 = 13$, Linie 3 hat $230 + 240 = 470$ und $4 + 3 = 7$. `HAVING` streicht Linie 2 wegen $410 < 450$.

linie	schichten	ist	ausschuss	quote
1	2	670	17	0
3	2	470	7	0

In `quote` steht **0**: Beide Summen sind ganze Zahlen, und SQLite teilt dann ganzzahlig, ohne Fehlermeldung.

Richtig ist `1.0 * SUM(ausschuss_stueck) / SUM(ist_stueck) AS quote` mit $17/670 \approx \boxed{0{,}0254}$ für Linie 1 und $7/470 \approx \boxed{0{,}0149}$ für Linie 3, also 2,54 % und 1,49 %. `WHERE` prüft einzelne Zeilen, bevor Gruppen entstehen. Eine Summe gibt es erst je Gruppe, also gehört die Bedingung in `HAVING`.

(b) Bekannt sind 7 Personalzahlen mit der Summe $9 + 8 + 10 + 8 + 7 + 8 + 6 = 56$ und 7 Temperaturen mit der Summe 168,0.

zeilen	mit_personal	mittel	je_zeile	temp
9	7	8,0	6	24,0

`AVG` überspringt `NULL`: $56/7 = 8{,}0$ und $168{,}0/7 = 24{,}0$.

In `je_zeile` stecken **zwei Fehler**: Der Nenner `COUNT(*)` zählt die beiden Schichten ohne Wert mit, als hätte dort niemand gearbeitet ($56/9 \approx 6{,}22$), und SQLite teilt ganzzahlig und schneidet auf 6 ab. Die vier Bedingungen zählen $n = \boxed{0}, \boxed{4}, \boxed{4}$ und $\boxed{6}$ Zeilen. (i) `= NULL` ist nie wahr, auch nicht ohne Wert. (ii) Vier Schichten haben 9, 10, 7 oder 6 Personen. Für die beiden `NULL` ist der Vergleich unbekannt, und `WHERE` behält nur wahre Bedingungen. (iii) `NOT` macht aus unbekannt wieder unbekannt. (iv) `IS NULL` holt die beiden dazu, $4 + 2 = 6$.

(c) `FROM` liefert 9 Zeilen, `WHERE` 6 Zeilen, `GROUP BY` bildet 3 Gruppen, `HAVING` behält 2. Danach berechnet `SELECT` die Spalten und vergibt die Namen, erst dann sortiert `ORDER BY`. Deshalb kennt es `ausschuss`, `WHERE` kennt den Namen im SQL-Standard nicht. Die geänderte Abfrage bricht ab mit `misuse of aggregate: SUM()`: Beim Filtern der Zeilen gibt es noch keine Gruppen und damit keine Summe.

(d) $5.788 - 74 = 5.714$ Schichten haben einen Wert, die Summe ist $8{,}2891 \cdot 5.714 \approx \boxed{47.364}$. Ohne Faktor teilt SQLite ganzzahlig durch alle 5.788 Schichten und liefert $\boxed{8}$, mit dem Faktor `1.0` sind es $47.364/5.788 \approx \boxed{8{,}1831}$. Keine der beiden Zahlen ist das mittlere Personal, das sind 8,2891.

> **Typischer Fehler**
>
> In (b) bei (iii) 6 erwarten, weil `NOT` die Bedingung umkehrt. `NOT` vertauscht wahr und falsch, unbekannt bleibt unbekannt. In (a) für `quote` 0,0254 eintragen, ohne die ganzzahlige Division zu bemerken, und in (b) für `je_zeile` 6,22 oder 8.

Bewertung: (a) Ergebnistabelle 1 P, `quote` mit Begründung und Korrektur 1 P, `HAVING` begründet 1 P. (b) Ergebnis der Abfrage 1 P, beide Fehler in `je_zeile` ½ P, (i) bis (iv) mit Begründung 1½ P. (c) Zeilen und Gruppen je Schritt ½ P, Name in `ORDER BY` ½ P, Abbruch mit Begründung 1 P. (d) Summe ½ P, beide Ergebnisse ½ P.

Lösung zu Aufgabe 2 Joins, Anti-Join und Fensterfunktionen

(a) M-06 findet W-1, W-5 und W-8, M-07 findet W-2 und W-4, M-17 findet W-3 und W-7. M-18 hat keinen Partner und bekommt eine Zeile, in der alle Spalten von `wa` `NULL` sind: $3 + 2 + 2 + 1 = 8$ Zeilen.

maschine	zeilen	wartungen	minuten
M-06	3	3	115
M-07	2	2	125
M-17	2	2	30
M-18	1	0	NULL

`SUM` überspringt die geplanten Wartungen ohne Dauer: $55 + 60 = 115$ für M-06 und $95 + 30 = 125$ für M-07.

Die gleiche Zeilenzahl beweist **nichts**: W-6 mit der Kennung `m-06` fehlt, dafür ist die aufgefüllte Zeile von M-18 dazugekommen. `COUNT(*)` zählt diese Zeile und gibt M-18 eine Wartung, `COUNT(w.wartung_id)` zählt nur vorhandene Werte und gibt richtig 0.

(b) Der Anti-Join liefert **W-6 mit** `m-06`, einen **Schlüsselfehler**: Der Fremdschlüssel verweist wegen der Schreibweise ins Leere. Mit `JOIN` fallen Zeilen ohne Partner schon beim Verknüpfen weg, er liefert dann **keine Zeile**. Mit `w.maschine IS NULL` ebenfalls **keine**: Geprüft wird die Spalte der linken Tabelle, die hier nie `NULL` ist. Beim Anti-Join prüfst du die Schlüsselspalte der rechten Tabelle.

(c) Das Ergebnis der Fensterabfrage:

wartung_id	maschine	datum	nr	vorher
W-1	M-06	2026-08-03	2	NULL
W-5	M-06	2026-09-14	1	2026-08-03
W-2	M-07	2026-08-20	2	NULL
W-4	M-07	2026-09-08	1	2026-08-20
W-3	M-17	2026-08-31	1	NULL
W-6	m-06	2026-09-28	1	NULL

`nr` zählt je Maschine vom neuesten Datum an, `vorher` ist das Datum der vorigen Zeile derselben Maschine. `m-06` steht zuletzt, weil Kleinbuchstaben nach Großbuchstaben sortiert werden.

Fensterfunktionen berechnet die Datenbank im Schritt `SELECT`, also **nach** `WHERE`. Beim Filtern gibt es `nr` noch nicht, SQLite bricht ab (`misuse of aliased window function nr`). Die äußere Abfrage liefert W-5, W-4, W-3 und W-6. Für M-06 meldet sie den 14.9.2026, die letzte Wartung war aber W-6 am 28.9.2026: `m-06` bildet eine eigene Partition. Erst die Kennungen vereinheitlichen, dann nummerieren. Ohne den Filter bekämen die geplanten W-8 und W-7 die Nummer 1, die „letzte Wartung“ von M-06 und M-17 läge in der Zukunft.

(d) Der Join hat $14.434 - 156 = \boxed{14.278}$ Zeilen. Es fehlen die 156 Meldungen mit unbekannter Kennung: Sie stehen rechts ohne Partner, und ein `LEFT JOIN` behält nur die Zeilen links. Aufgefüllte Zeilen gibt es nicht, weil jede Maschine Meldungen hat. Für alle Meldungen gehört `stoerungen` nach links.

> **Typischer Fehler**
>
> In (a) für M-18 bei `zeilen` 0 eintragen oder aus 8 Zeilen schließen, dass keine Wartung verloren ging. In (b) mit `w.maschine IS NULL` einen Anti-Join erwarten. In (c) `nr` aufsteigend nach Datum vergeben, obwohl im Fenster `ORDER BY datum DESC` steht.

Bewertung: (a) Ergebnistabelle 1 P, Zeilenzahl und M-18 erklärt 1 P. (b) Zeile mit Fehlerart 1 P, beide Varianten 1 P. (c) Tabelle 1 P, Begründung zu `nr` = 1 ½ P, M-06 und geplante Wartungen ½ P. (d) 14.278 mit den fehlenden Meldungen 1 P.

Lösung zu Aufgabe 3 Fehlende Werte: Mechanismen und Folgen

(a) (i) **MCAR**: Welche Akte fehlt, entschied der Zufall, unabhängig von allen Werten. (ii) **MAR**: Das Fehlen hängt nur von Wochentag und Schicht ab, beide sind über `datum` und `schicht` immer bekannt. Ist es montags früh kühler, macht Löschen den Mittelwert zu warm, Bedingen auf Wochentag und Schicht hilft. (iii) **MNAR**: Es fehlen gerade die langen Stillstände, das Fehlen hängt vom fehlenden Wert selbst ab. (iv) **MAR**: Das Fehlen hängt von der Maschine ab, und die steht in jeder Meldung.

(b) Es bleiben $3 + 3 + 2 = 8$ Meldungen.

Schicht s	n_s	bekannt	Material gezählt	$\hat{P}(K = \text{Material} \mid S = s)$	$\hat{N}_s$	wahr
Früh	3	3	1	1/3	$3 \cdot 1/3 = 1$	1
Spät	3	3	1	1/3	$3 \cdot 1/3 = 1$	1
Nacht	4	2	1	1/2	$4 \cdot 1/2 = \boxed{2}$	2

Gezählt hat jede Schicht einen Materialfehler, du würdest auf „kein Unterschied“ schließen. Wahr hat die Nacht **doppelt so viele** wie jede andere Schicht. Die Lücken drücken die Anzahl der Nacht, die Anteile je Schicht stimmen mit den wahren überein (1/3, 1/3 und $2/4 = 1/2$), die Hochrechnung trifft hier genau. Unter allen bekannten Kategorien sind $\boxed{3/8 = 37{,}5\,\%}$ Material, wahr sind es $\boxed{4/10 = 40\,\%}$. Mit $P(S = s) = n_s/10$:

$$P(K = \text{Material}) = \tfrac{3}{10} \cdot \tfrac{1}{3} + \tfrac{3}{10} \cdot \tfrac{1}{3} + \tfrac{4}{10} \cdot \tfrac{1}{2} = \tfrac{1}{10} + \tfrac{1}{10} + \tfrac{2}{10} = \tfrac{4}{10}.$$

(c) Unter der Annahme ist auch $P(R = 0 \mid K = k, S = s) = 1 - P(R = 1 \mid S = s) = P(R = 0 \mid S = s)$. Satz von Bayes, bedingt auf $S = s$:

$$\begin{aligned} P(K = k \mid S = s, R = 0) &= \frac{P(R = 0 \mid K = k, S = s)\, P(K = k \mid S = s)}{P(R = 0 \mid S = s)} \\ &= \boxed{P(K = k \mid S = s)}. \end{aligned}$$

Der Gesamtanteil mischt die Schichten mit ihren Anteilen unter den *bekannten* Meldungen. Mit der totalen Wahrscheinlichkeit, bedingt auf $R = 0$, und der Gleichung oben:

$$\begin{aligned} P(K = k \mid R = 0) &= \textstyle\sum_s P(S = s \mid R = 0)\, P(K = k \mid S = s, R = 0) \\ &= \textstyle\sum_s P(S = s \mid R = 0)\, P(K = k \mid S = s), \\ P(S = s \mid R = 0) &= P(R = 0 \mid S = s)\, P(S = s)/P(R = 0). \end{aligned}$$

Schichten mit wenigen Lücken bekommen zu viel Gewicht, in (b) $\frac{3}{8}$, $\frac{3}{8}$ und $\frac{2}{8}$ statt $\frac{3}{10}$, $\frac{3}{10}$ und $\frac{4}{10}$: $\frac{3}{8} \cdot \frac{1}{3} + \frac{3}{8} \cdot \frac{1}{3} + \frac{2}{8} \cdot \frac{1}{2} = \frac{3}{8}$. Unverzerrt wäre er, wenn die Lückenquote $P(R = 1 \mid S = s)$ in allen Schichten gleich wäre, dann sind die Gewichte $P(S = s)$, oder wenn $P(K = k \mid S = s)$ in allen Schichten gleich wäre.

(d) Über die $824 - 665 = 159$ fehlenden Werte weißt du nur $10 \le x \le 40$. Mit $665 \cdot 23{,}12 = 15.374{,}8$ liegt der Mittelwert zwischen $(15.374{,}8 + 159 \cdot 10)/824 \approx \boxed{20{,}59\ °\text{C}}$ und $(15.374{,}8 + 159 \cdot 40)/824 \approx \boxed{26{,}38\ °\text{C}}$. Jede Belegung der Lücken mit Werten von 10 bis 40 °C erzeugt dieselben beobachteten Daten, die Daten sagen also nichts darüber, welche gilt. Unter MNAR hängt das Fehlen gerade vom unbekannten Wert ab. Enger machen die Grenzen nur Annahmen: Mit „jede fehlende Schicht mindestens 23,12 °C“ liegt der Mittelwert zwischen $\boxed{23{,}12\ °\text{C}}$ und 26,38 °C. Der wahre Wert aus Modul 2, 23,56 °C, liegt darin.

Typischer Fehler

In (b) mit den bekannten statt mit allen Meldungen hochrechnen, etwa $\hat{N}_{\text{Nacht}} = 2 \cdot \frac{1}{2} = 1$, oder den Anteil auf alle Meldungen beziehen, $4 \cdot \frac{1}{4} = 1$ mit $\frac{1}{4}$ statt $\frac{1}{2}$. In beiden Fällen gleicht nichts die Lücke aus, und es bleibt die gezählte 1.

Bewertung: (a) vier Fälle 2 P, je Fall mit Begründung ein halber Punkt. (b) gezählt gegen wahr mit Schluss 1 P, Anteile und Hochrechnung 1 P, Gesamtanteil mit totaler Wahrscheinlichkeit 1 P. (c) Herleitung 1 P, Gesamtanteil mit Begründung und Bedingung 1 P. (d) beide Grenzen, Begründung und Grenzen unter der Annahme 1 P.

Lösung zu Aufgabe 4 Ausreißer und Einheitenfehler

(a) Sortiert: 17,0; 21,5; 22,0; 22,5; 23,0; 23,5; 24,0; 24,5; 25,0; 77,0, also $x_{(0)} = 17{,}0$ bis $x_{(9)} = 77{,}0$, und $n - 1 = 9$.

$$h = 9 \cdot 0{,}25 = 2{,}25, \qquad Q_1 = x_{(2)} + 0{,}25\,(x_{(3)} - x_{(2)}) = 22{,}0 + 0{,}25 \cdot 0{,}5 = \boxed{22{,}125},$$
$$h = 9 \cdot 0{,}75 = 6{,}75, \qquad Q_3 = x_{(6)} + 0{,}75\,(x_{(7)} - x_{(6)}) = 24{,}0 + 0{,}75 \cdot 0{,}5 = \boxed{24{,}375}.$$

$\text{IQR} = 24{,}375 - 22{,}125 = 2{,}25$ und $1{,}5\,\text{IQR} = 3{,}375$. Die Grenzen sind $22{,}125 - 3{,}375 = \boxed{18{,}75}$ und $24{,}375 + 3{,}375 = \boxed{27{,}75}$. Die Regel meldet **17,0 und 77,0**.

(b) $\tilde{x} = (23{,}0 + 23{,}5)/2 = 23{,}25$. Die absoluten Abweichungen lauten sortiert 0,25; 0,25; 0,75; 0,75; 1,25; 1,25; 1,75; 1,75; 6,25; 53,75, also $\text{MAD} = (1{,}25 + 1{,}25)/2 = \boxed{1{,}25}$.

$$M_{17{,}0} = 0{,}6745 \cdot (-6{,}25)/1{,}25 \approx \boxed{-3{,}37}, \qquad M_{25{,}0} = 0{,}6745 \cdot 1{,}75/1{,}25 \approx \boxed{0{,}94},$$
$$M_{77{,}0} = 0{,}6745 \cdot 53{,}75/1{,}25 \approx \boxed{29{,}00}.$$

$|M_i| > 3{,}5$ meldet nur **77,0**, die IQR-Regel zusätzlich 17,0. Sie schlägt früher an: Bei Normalverteilung liegt $Q_3 + 1{,}5\,\text{IQR}$ bei etwa $\mu + 2{,}7\,\sigma$, die Schwelle $|M_i| = 3{,}5$ bei etwa $\mu + 3{,}5\,\sigma$. Beide Regeln melden Kandidaten, keine Fehler.

(c) Nur **77,0** verletzt die Fachregel. Als Grad Fahrenheit gelesen ist $C = (77{,}0 - 32) \cdot 5/9 = 45 \cdot 5/9 = \boxed{25{,}0\ °\text{C}}$, passend zu den Nachbartagen mit 22,0 und 23,5 °C. Ein einzelner Wert kann auch ein Tippfehler sein. Für Fahrenheit sprechen der glatte Wert in °C, die Temperatur der Linie 1 in derselben Halle am 9.7. und der Zeitverlauf des Loggers, etwa ein Block von Werten um 70 bis 80 wie auf Linie 3 im Juni 2025. Die Annahme schreibst du auf. 17,0 erfüllt die Fachregel und ist **nur ein Kandidat**: behalten, markieren und nachfragen, etwa nach einem offenen Hallentor. Löschtest du ungewöhnliche, aber mögliche Werte, würde der Mittelwert zu warm.

(d) Roh: $\bar{x} = 280/10 = 28{,}0$ und $\sum_i (x_i - \bar{x})^2 = 2.713$, also $s = \sqrt{2.713/9} \approx 17{,}36$, $z_{77{,}0} = 49/17{,}36 \approx \boxed{2{,}82}$ und $z_{17{,}0} = -11/17{,}36 \approx \boxed{-0{,}63}$. Korrigiert (77,0 wird 25,0): $\bar{x} = 228/10 = 22{,}8$ und $\sum_i (x_i - \bar{x})^2 = 50{,}6$, also $s = \sqrt{50{,}6/9} \approx 2{,}37$, $z_{25{,}0} = 2{,}2/2{,}37 \approx 0{,}93$ und $z_{17{,}0} = -5{,}8/2{,}37 \approx \boxed{-2{,}45}$. Der falsche Wert zieht $\bar{x}$ auf 28,0 und bläht s auf mehr als das Siebenfache auf. So versteckt er sich selbst und den Wert 17,0 (**Maskierung**). Bei $n = 10$ gilt außerdem immer $|z_i| \le 9/\sqrt{10} \approx 2{,}85 < 3$ (Skript 5.2). Quartile, Median und MAD ändert die Korrektur **nicht**: 77,0 und 25,0 liegen beide über $x_{(7)} = 24{,}5$, ihre absoluten Abweichungen 53,75 und 1,75 beide über 1,25.

(e) Mal 60, gerundet auf 5: $0{,}75 \cdot 60 = \boxed{45}$, $2{,}25 \cdot 60 = \boxed{135}$ und $4{,}42 \cdot 60 = 265{,}2$, also $\boxed{265}$ Minuten. SQLite schneidet bei `%` zuerst auf ganze Zahlen ab: $0 \bmod 5 = 0$, $2 \bmod 5 = 2$, $4 \bmod 5 = 4$. Die erste Regel findet **2,25 und 4,42**, nicht 0,75, die zweite **alle drei**. Genau 5,0 Stunden sehen aus wie gültige 5 Minuten. Finden lässt sich der Wert nur über das Muster im Zeitverlauf: Im Block von Linie 3 im Januar und Februar 2025 liegt der Median je Monat bei 0,5 statt bei 25 bis 30, also gelten dort alle Meldungen als Stunden.

> **Typischer Fehler**
>
> In (a) die Quartile als Mediane der unteren und oberen Hälfte bestimmen, also 22,0 und 24,5 (Tukeys Angelpunkte). Das ist eine andere Konvention, mit IQR 2,5 und Grenzen 18,25 und 28,25. In (b) beim MAD den Betrag vergessen: Der Median der Abweichungen $x_i - \tilde{x}$ ist 0, und M_i wird unendlich groß.

Bewertung: (a) Quartile 1 P, IQR, Grenzen und Kandidaten 1 P. (b) Median und MAD 1 P, drei Werte M_i mit Vergleich 1 P. (c) Fachregel, Umrechnung und Entscheidung zu 17,0 1 P. (d) z-Werte roh und korrigiert 1 P, Maskierung, Schranke und robuste Größen 1 P. (e) Umrechnung, beide Regeln und Wert 5,0 1 P.

Lösung zu Aufgabe 5 Prüfregeln, Dubletten und Personendaten

(a) **Duplikat** A-02308: alle Spalten außer `auftrag_id` gleich einer früheren Zeile. **Schlüsselfehler** A-02305: `auftrag_id` doppelt oder `linie` nicht in `linien`. **Einheitenfehler** A-02302: `menge` nicht ganzzahlig oder unter 10, wohl 220 Stück in Tausend erfasst. **Platzhalter** A-02306: `geliefert_am` vor dem Beginn des Abzugs. **Plausibilität** A-02303: `liefertermin` vor `bestellt_am`, vermutlich vertauscht. **Format** A-02304: `bestellt_am` oder `liefertermin` nicht im Muster JJJJ-MM-TT. Als Code wie im Skript 6.1, jede Regel markiert genau ihre Zeile:

```
ISO = r"\d{4}-\d{2}-\d{2}"
INHALT = ["kunde", "linie", "menge", "bestellt_am", "liefertermin",
          "geliefert_am", "status"]
REGELN_AUFTRAEGE = {
    "Duplikat": lambda t: t.duplicated(INHALT),
    "Schlüsselfehler": lambda t: (t["auftrag_id"].duplicated()
                                  | ~t["linie"].isin([1, 2, 3, 4])),
    "Einheitenfehler": lambda t: (t["menge"] % 1 != 0) | (t["menge"] < 10),
    "Platzhalter": lambda t: t["geliefert_am"] < "2024-10-01",
    "Plausibilität": lambda t: t["liefertermin"] < t["bestellt_am"],
    "Format": lambda t: ~(t["bestellt_am"].str.fullmatch(ISO)
                          & t["liefertermin"].str.fullmatch(ISO)),
}
```

A-02307 sieht verdächtig aus: offen, ohne Lieferdatum, der Termin am 25.9. ist vorbei. Bei einem offenen Auftrag fehlt das Lieferdatum aber zu Recht (Skript 4.4), das ist ein Fall für die Termintreue. Die **Formatregel** muss vor der Plausibilitätsregel laufen, besser noch das Vereinheitlichen: Der Vergleich von Datumstexten stimmt nur im Format JJJJ-MM-TT.

(b) Ohne eindeutigen fachlichen Schlüssel kann keine Regel unterscheiden, ob derselbe Auftrag zweimal erfasst wurde oder ob der Kunde am selben Tag zweimal dieselbe Menge abgerufen hat. Jede Dublettenregel ist eine **Annahme**. Stützen können sie fortlaufende Kennungen und der Zeitpunkt der Erfassung, etwa ein nachträglich angehängter Block, und eine Rückfrage im Vertrieb. Regel und Begründung schreibst du auf. Nordwerk: Du verlierst $195 - 171 = \boxed{24}$ echte Meldungen, $24/195 \approx \boxed{12{,}3\,\%}$ der Löschungen wären falsch.

(c) **Direkte Kennungen**: `personal_nr`, dazu Name, E-Mail und Telefon. **Quasi-Kennungen**: Geburtsdatum, Linie und Schichtgruppe. Die Qualifikation ist das Merkmal, das eine Zuordnung verraten würde. Das Alter ist 36, 33, 58, 54, 27, 24, 52 und 55.

	Quasi-Kennungen	Gruppen	k	allein
(i)	Geburtsdatum, Linie, Schichtgruppe	acht Gruppen mit je einer Person	$\boxed{1}$	8
(ii)	Altersgruppe, Linie, Schichtgruppe	P-17 und P-18 in (50 bis 59, 2, A), sechs Personen einzeln	$\boxed{1}$	6
(iii)	Altersgruppe, Linie	(30 bis 39, 1), (50 bis 59, 1), (unter 30, 2) und (50 bis 59, 2) mit je zwei	$\boxed{2}$	0

Erst ohne Schichtgruppe ist $k = 2$. Die Gruppe (50 bis 59, Linie 1) besteht aus P-13 und P-14, beide sind Einrichter: Wer weiß, dass eine Person zwischen 50 und 59 ist und auf Linie 1 arbeitet, kennt ihre Qualifikation, obwohl er zwei Zeilen findet (**Homogenität**). Nordwerk: 125 Werte bei 126 Personen heißt, genau ein Geburtsdatum kommt doppelt vor. $\boxed{124}$ Personen sind allein bestimmbar, $k = 1$.

Nicht anonym. Mit dem Salz und den Personalnummern rechnet die Personalabteilung jedes Pseudonym nach und ordnet jede Zeile einer Person zu. Die Tabelle ist **pseudonymisiert**, und pseudonymisierte Daten bleiben personenbezogen (Art. 4 Nr. 5 DSGVO, Erwägungsgrund 26). Ohne die Spalte gibt es keine direkte Zuordnung mehr, aber bei $k = 2$ und der homogenen Gruppe ist eine Zuordnung mit vernünftigerweise eingesetzten Mitteln nicht ausgeschlossen. Anonym ist die Tabelle damit nicht gesichert, oft wird $k \geq 5$ verlangt. Vor einer Weitergabe fragst du die oder den Datenschutzbeauftragten.

Bewertung: (a) Duplikat, Schlüssel- und Einheitenfehler 1 P, Platzhalter, Plausibilität und Format 1 P, unauffällige Zeile und Reihenfolge der Regeln 1 P. (b) Begründung ½ P, beide Zahlen ½ P. (c) Kennungen ½ P, drei Werte von k mit Anzahlen 1½ P, Homogenität und Nordwerk 1 P, anonym oder pseudonymisiert mit Begründung 1 P.

Lösung zu Aufgabe 6 Wie groß kann ein z-Wert werden? (Zusatz)

(a) Wegen $\sum_j d_j = 0$ ist $d_i = -\sum_{j \neq i} d_j$, und $\sum_j d_j^2 = (n-1)\,s^2$. Mit Cauchy-Schwarz:

$$d_i^2 = \Big(\sum_{j \neq i} d_j\Big)^2 \leq (n-1) \sum_{j \neq i} d_j^2 = (n-1)\big((n-1)\,s^2 - d_i^2\big).$$

Umgestellt ist $n\,d_i^2 \leq (n-1)^2 s^2$, also $|z_i| = |d_i|/s \leq (n-1)/\sqrt{n}$. Gleichheit gilt in Cauchy-Schwarz genau dann, wenn alle d_j mit $j \neq i$ gleich sind, also alle übrigen Werte gleich. Neun Werte 23,0 und ein Wert 77,0 ergeben $\bar{x} = 28{,}4$, $d_i = 48{,}6$, die übrigen $d_j = -5{,}4$, $s = \sqrt{(48{,}6^2 + 9 \cdot 5{,}4^2)/9} = \sqrt{291{,}6} \approx 17{,}076$ und $z_i \approx 2{,}846 = 9/\sqrt{10}$.

(b) $(n-1)/\sqrt{n} > 3 \iff n - 3\sqrt{n} - 1 > 0 \iff \sqrt{n} > (3 + \sqrt{13})/2 \approx 3{,}303 \iff n > 10{,}91$. Erst ab $\boxed{n = 11}$ ist $|z_i| > 3$ möglich: $9/\sqrt{10} \approx 2{,}85$, aber $10/\sqrt{11} \approx 3{,}02$.

(c) Steigt der größte Wert auf 770, bleiben Median und MAD gleich: Der Median hängt nur von $x_{(4)}$ und $x_{(5)}$ ab, und die Abweichung $770 - 23{,}25 = 746{,}75$ bleibt die größte. Also ist $M = 0{,}6745 \cdot 746{,}75/1{,}25 \approx \boxed{402{,}95}$: M_i wächst ohne Schranke mit dem Wert, eine Schranke wie für z_i gibt es nicht. Der klassische z-Wert steigt nur von 2,82 auf etwa 2,85, denn $\bar{x}$ und s wachsen mit, und er bleibt unter $9/\sqrt{10}$.