Tutoriumsblatt 4

Explorative Analyse und Visualisierung

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Lage und Streuung von Hand bestimmen und begründen, welche Kennzahl ein Ausreißer verschiebt,
- Histogramm, ECDF und Boxplot lesen, zeichnen und einander zuordnen,
- Pearson und Spearman von Hand rechnen und begründen, warum $|r| \leq 1$ gilt,
- eine Simpson-Umkehr durch Schichten auflösen, Confounder benennen und irreführende Grafiken verbessern.

So arbeitest du mit dem Blatt

Du programmierst nicht: Du rechnest mit dem Taschenrechner, liest Grafiken ab und skizzierst auf Papier. Quartile bestimmst du wie im Skript 3.2: sortiert $x_{(0)} \leq \cdots \leq x_{(n-1)}$ und linear interpoliert an der Stelle $h = (n-1)\,p$. Die Standardabweichung s teilt durch $n-1$. Hängst du, rechnest du mit den Werten unter „Zur Kontrolle“ weiter. Werkszahlen stammen aus den geprüften Dateien und dem Skript, Tabellen mit dem Vermerk „ausgedacht“ sind fiktiv. Zum Notebook: Aufgabe 1 gehört zu TODO 5; Aufgabe 2 zu 2 bis 4; Aufgabe 3 zu 6 und 7; Aufgabe 4 zu 9 und 10; Aufgabe 5 zu 1, 11 und 12; der Zusatz zu 6.

Aufgabe 1 Lage, Streuung und ein Ausreißer

10 Punkte · etwa 20 Min.

Bezug: Modul 4, Lerneinheiten 3 (Lage und Streuung: Mittelwert, Median, Quantile, MAD) und 2 (Verteilungen: Histogramm, Dichte, ECDF, Boxplot)

Die Roboter-Schweißzelle 2 (M-14) auf Linie 3 meldete in KW 39/2025 acht Störungen. Die Stillstände in Minuten, in zeitlicher Reihenfolge: 55, 20, 10, 105, 330, 15, 5, 20.

(a) Berechne den Mittelwert $\bar{x}$, den Median $\tilde{x}$, Q_1, Q_3 und den IQR. Warum liegt $\bar{x}$ so weit über $\tilde{x}$? [2 P]

(b) Berechne s und den MAD. Vergleiche s mit IQR/1,349 und MAD/0,6745, die bei Normalverteilung etwa σ ergeben (Skript 3.3). Welcher Anteil von $\sum_i (x_i - \bar{x})^2$ stammt von einem einzigen Wert? Welche Zahl beschreibt die Streuung der typischen Störungen? [3 P]

(c) Zeichne den Boxplot der acht Stillstände waagerecht auf einer Achse von 0 bis 350 Minuten, mit Whiskern nach der 1,5-IQR-Regel (Skript 2.4). Gib beide Grenzen und beide Whiskerenden an. Zur Kontrolle: IQR = 53,75. [2 P]

(d) Die längste Störung hätte auch eine ganze Schicht dauern können, 480 statt 330 Minuten. Welche Kennzahlen aus (a) und (b) ändern sich, und auf welche Werte? Zur Kontrolle: Dann ist $\sum_i (x_i - \bar{x})^2 = 182.587{,}5$. Wie viele der acht Werte musst du mindestens beliebig vergrößern, damit $\bar{x}$, s, Q_3 (und damit der IQR), $\tilde{x}$ und der MAD beliebig groß werden? Vergleiche die Anteile mit den Bruchpunkten im Skript 3.4. [3 P]

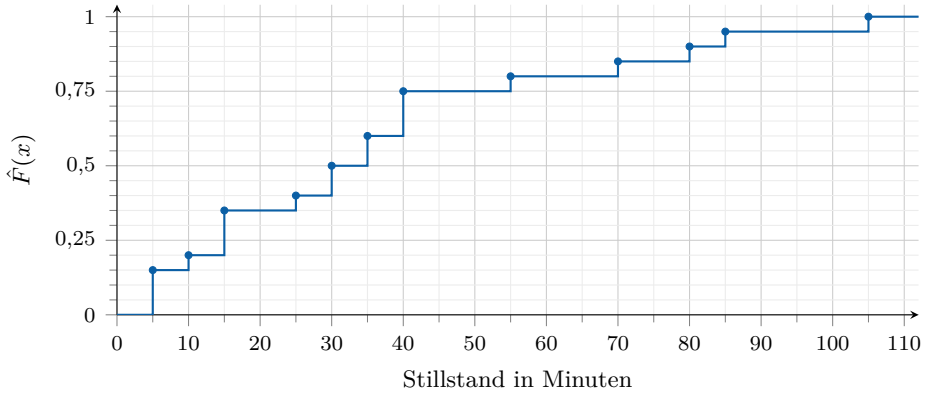
Aufgabe 2 Verteilungen lesen

8 Punkte · etwa 18 Min.

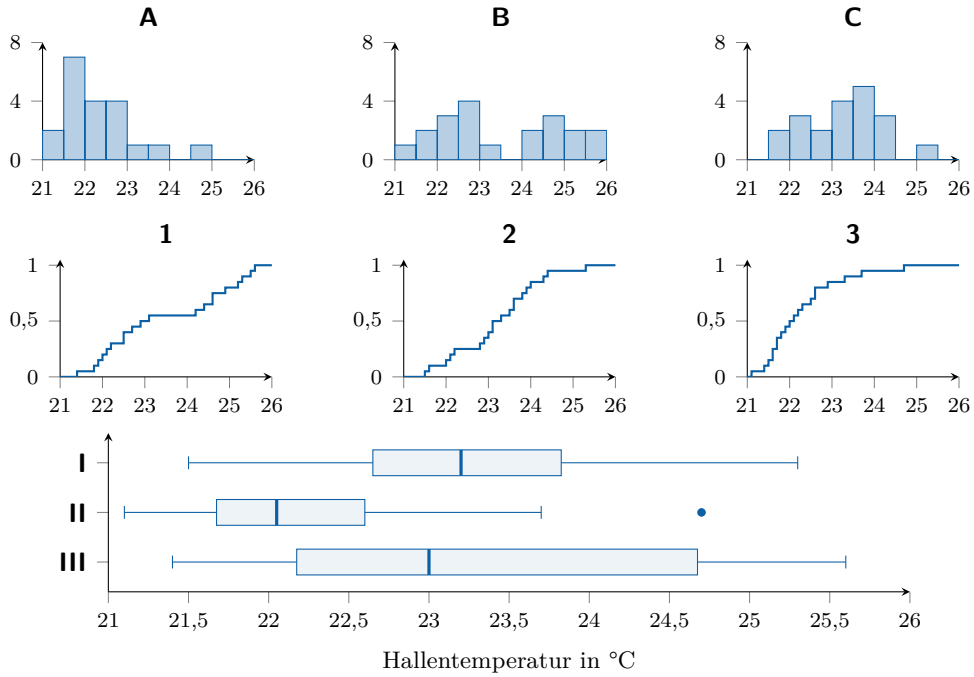
Bezug: Modul 4, Lerneinheit 2 (Verteilungen: Histogramm, Dichte, ECDF, Boxplot)

(a) Über alle 5.788 Schichten liegt die Hallentemperatur zwischen 17,6 und 28,9 °C, mit $Q_1 = 20{,}5\,°C$ und $Q_3 = 22{,}5\,°C$. Die Werte sind auf 0,1 °C gerundet. Berechne die Klassenbreite h nach Freedman und Diaconis (Skript 2.1) auf vier Nachkommastellen und die Zahl der Klassen. Wie viele mögliche Messwerte fallen in eine Klasse, und was zeigt das Histogramm deshalb? Welche Klassenbreite nimmst du? [2 P]

(b) Die ECDF unten zeigt die Stillstände der 20 Störungen am Härteofen M-10 im Juni 2025. Lies wie im Skript 2.3 den Median, Q_1 und Q_3 ab, jeweils als kleinstes x mit $\hat{F}(x) \geq p$. Welcher Anteil der Störungen dauerte länger als 60 Minuten, wie viele genau 40 Minuten? Welchen Median meldet pandas, und warum? [3 P]



(c) Die Grafiken unten zeigen die Hallentemperatur in drei Stichproben von je 20 Frühschichten, gemischt: Histogramme A bis C, ECDFs 1 bis 3 und Boxplots I bis III. Ordne zu, was zusammengehört, mit je einem Merkmal als Begründung. Eine Stichprobe stammt aus Wochen, in denen das Wetter mehrmals umschlug: welche? Was verrät ihr Boxplot nicht? [3 P]



Aufgabe 3 Korrelation von Hand und ein einzelner Punkt

9 Punkte · etwa 19 Min.

Bezug: Modul 4, Lerneinheit 4 (Zusammenhänge: Streudiagramm, Pearson, Spearman)

Fünf Schichten der Linie 3 (ausgedacht, im Bereich der Werksdaten): x_i ist der Stillstand der Schicht in Minuten, summiert über alle Störungen, y_i die Planerfüllung in Prozent, gefertigte durch geplante Stück.

Schicht i	1	2	3	4	5
x_i (min)	10	30	50	70	90
y_i (%)	97	98	88	85	82

(a) Berechne Pearson r und Spearman ρ auf drei Nachkommastellen. Ohne gleiche Werte gilt für ρ die Kurzformel aus Skript 4.3. Zur Kontrolle: $\bar{x} = 50$ und $\bar{y} = 90$. [3 P]

(b) Eine sechste Schicht hat 470 Minuten Stillstand und 84 % Planerfüllung. Berechne r und ρ für alle sechs Schichten. Zur Kontrolle: $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = -2.960$. Was hätte dir r allein gesagt, was ρ? Was prüfst du an der sechsten Schicht, bevor du sie behältst oder streichst? [3 P]

(c) Zeige, dass r die Kovarianz $s_{xy} = \frac{1}{n-1}\sum_i (x_i - \bar{x})(y_i - \bar{y})$ geteilt durch $s_x\, s_y$ ist. Begründe mit der Cauchy-Schwarz-Ungleichung $\left|\sum_i a_i b_i\right| \le \sqrt{\sum_i a_i^2}\,\sqrt{\sum_i b_i^2}$, dass $|r| \le 1$ gilt und wann $r = -1$ ist. Ändert sich r, wenn du den Stillstand in Stunden angibst? [2 P]

(d) Im ganzen Werk ist für Stillstand und Planerfüllung je Schicht $r = -0{,}816$ und $\rho = -0{,}741$ (Skript 4.2 und 4.3), also $|r| > |\rho|$. In (b) war es umgekehrt. Erkläre beide Fälle mit derselben Eigenschaft von r. [1 P]

Aufgabe 4 Simpson und Confounding

7 Punkte · etwa 16 Min.

Bezug: Modul 4, Lerneinheit 5 (Wenn Kennzahlen täuschen: Anscombe und Simpson)

Die Instandhaltung erprobt eine zustandsorientierte Wartung und hat bei den älteren Maschinen damit begonnen. Ausgedachte Zahlen für ein Quartal, eine Maschinenschicht ist eine Maschine in einer Schicht.

Baujahr	Wartung	Maschinenschichten	Störungen
bis 2012	zustandsorientiert	600	420
bis 2012	nach Plan	200	160
ab 2013	zustandsorientiert	200	60
ab 2013	nach Plan	600	210

(a) Berechne die Störungen je Maschinenschicht in jeder Zeile und je Wartungsart insgesamt. Welche Wartung ist in jeder Baujahrgruppe besser, welche insgesamt? [2 P]

(b) Schreibe beide Gesamtraten als gewichtete Mittel der Gruppenraten und erkläre damit die Umkehr. Welche Variable ist der Confounder, über welche zwei Pfeile? Im Werk haben die fünf Maschinen bis Baujahr 2012 im Mittel 0,58 Störungen je Schicht, die 15 jüngeren 0,46. Vergleiche fair, indem du beide Wartungsarten mit denselben Gewichten mittelst, dem Anteil jeder Baujahrgruppe an allen 1.600 Maschinenschichten. Um wie viel Prozent weniger Störungen hat dann die zustandsorientierte Wartung? [2 P]

(c) Über alle 5.788 Schichten hängen Personal und Ausschussquote mit $r = -0{,}279$ zusammen, innerhalb jeder Linie liegt r zwischen $-0{,}013$ und $0{,}006$ (Skript 5.3). Die Personalabteilung will auf Linie 2 je Schicht eine Person mehr einplanen, um den Ausschuss zu senken. Welche Variable ist mit dem Personal verwechselt, über welche Pfeile? Wie kontrollierst du sie, und was sagen die Daten zum Vorschlag? [2 P]

(d) Nachts liegt die Quote der Summen bei 2,20 %, früh bei 2,08 %. Bei einer Auslastung von 0,7 bis unter 0,8 liegt die Nacht bei 2,08 % und die Frühschicht bei 1,72 %, von 0,8 bis unter 0,9 bei 2,43 % gegen 2,05 % (Skript 5.4). Dass die geringere Auslastung der Nacht einen Teil ihres Nachteils verdeckt, weißt du aus dem Skript. Der Schichtleiter sagt: „Nachts nur 6 % mehr Ausschuss, kein Handlungsbedarf.“ Um wie viel Prozent liegt die Nacht insgesamt und in den beiden Klassen über der Frühschicht? Nimm begründet Stellung. [1 P]

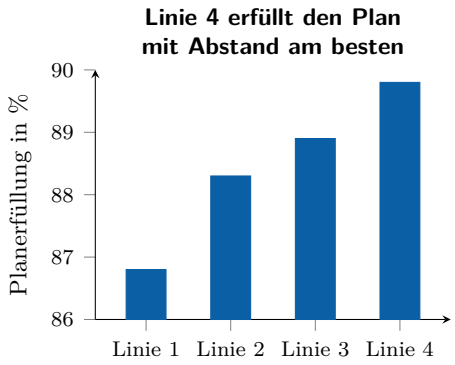
Aufgabe 5 Wahrnehmung und Gestaltung

6 Punkte · etwa 14 Min.

Bezug: Modul 4, Lerneinheiten 6 (Wahrnehmung: Position vor Fläche vor Farbe, Achsen, Log-Skala) und 7 (Eine Grafik, die eine Entscheidung trägt)

Ein Bericht über beide Jahre zeigt die Planerfüllung je Linie als Balken, rechts nachgezeichnet. Die Tabelle nennt Median und Whiskerenden aller Schichten aus dem Skript 2.4, in Prozent.

Linie	Median	unterer Whisker	oberer Whisker
1	86,8	64,6	104,9
2	88,3	66,9	105,4
3	88,9	67,4	108,4
4	89,8	71,6	106,2



(a) Nenne zwei Dinge, die an der Grafik irreführen. Berechne den Lügenfaktor (Skript 6.2) für Linie 4 gegenüber Linie 1. Skizziere eine bessere Grafik zur Frage „Unterscheiden sich die Linien in der Planerfüllung ihrer Schichten?“. [3 P]

(b) Derselbe Bericht zeigt die monatliche Ausschussquote als Farbfeld (Heatmap): vier Zeilen für die Linien, 24 Spalten für die Monate, Farbe in der Regenbogenskala `jet`. Die Werksleitung fragt: „Haben die Linien 1 und 2 im Sommer mehr Ausschuss?“ Wähle Grafiktyp und Kodierung und begründe mit der Rangfolge von Cleveland und McGill. Nenne zwei Gründe gegen `jet`. [2 P]

(c) Für die Tabelle aus Aufgabe 4 liegen zwei Titel vor: „Störungen nach Wartungsart“ und „Zustandsorientierte Wartung erhöht die Störungen“. Was fehlt dem ersten, was stimmt am zweiten nicht? Formuliere einen Titel, der den Befund nennt. [1 P]

Aufgabe 6 (⋆) Woher kommt die Kurzformel für Spearman?

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 4, Lerneinheit 4

Seien $R_1, \dots, R_n$ und $S_1, \dots, S_n$ die Ränge der x- und der y-Werte, ohne gleiche Werte also je eine Anordnung von $1, \dots, n$, und $d_i = R_i - S_i$. (a) Zeige $\sum_i (R_i - \bar{R})^2 = n(n^2-1)/12$ mit $\sum_{i=1}^{n} i = n(n+1)/2$ und $\sum_{i=1}^{n} i^2 = n(n+1)(2n+1)/6$. (b) Zeige $\sum_i d_i^2 = 2\sum_i (R_i - \bar{R})^2 - 2\sum_i (R_i - \bar{R})(S_i - \bar{S})$ und folgere $\rho = 1 - 6\sum_i d_i^2 / (n(n^2-1))$. (c) Fünf Schichten der Linie 4 hatten 11, 11, 11, 12 und 13 Beschäftigte und 0, 1, 2, 3 und 4 Ausschussteile. Berechne ρ als Pearson der mittleren Ränge und mit der Kurzformel. Warum weichen beide voneinander ab?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Lage, Streuung und ein Ausreißer

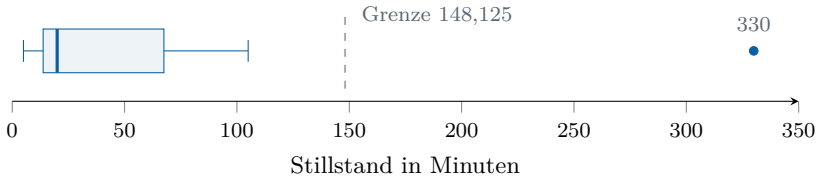
(a) Sortiert: 5, 10, 15, 20, 20, 55, 105, 330, also $x_{(0)} = 5$ bis $x_{(7)} = 330$ und $n - 1 = 7$. Es ist $\bar{x} = 560/8 = \boxed{70}$ und $\tilde{x} = (x_{(3)} + x_{(4)})/2 = (20 + 20)/2 = \boxed{20}$.

$$h = 7 \cdot 0{,}25 = 1{,}75, \qquad Q_1 = x_{(1)} + 0{,}75\,(x_{(2)} - x_{(1)}) = 10 + 0{,}75 \cdot 5 = \boxed{13{,}75},$$
$$h = 7 \cdot 0{,}75 = 5{,}25, \qquad Q_3 = x_{(5)} + 0{,}25\,(x_{(6)} - x_{(5)}) = 55 + 0{,}25 \cdot 50 = \boxed{67{,}5}.$$

$\mathrm{IQR} = 67{,}5 - 13{,}75 = \boxed{53{,}75}$. Der Mittelwert ist die Summe geteilt durch n, und die Störung von 330 Minuten trägt allein $330/8 = 41{,}25$ Minuten dazu bei. Die Verteilung ist rechtsschief: viele kurze Störungen, wenige lange.

(b) Die Abweichungen vom Mittelwert 70 lauten -65, -60, -55, -50, -50, -15, 35 und 260, ihre Quadrate 4.225, 3.600, 3.025, 2.500, 2.500, 225, 1.225 und 67.600. Die Summe ist 84.900, also $s = \sqrt{84.900/7} \approx \boxed{110{,}13}$. Die absoluten Abweichungen vom Median 20 lauten sortiert 0, 0, 5, 10, 15, 35, 85 und 310, also $\mathrm{MAD} = (10 + 15)/2 = \boxed{12{,}5}$. Zum Vergleich: $\mathrm{IQR}/1{,}349 \approx 39{,}84$ und $\mathrm{MAD}/0{,}6745 \approx 18{,}53$, s ist 2,8- und 5,9-mal so groß. Von der Quadratsumme stammen $67.600/84.900 \approx \boxed{79{,}6\,\%}$ vom einen Wert 330. Die Streuung der typischen Störungen beschreibt der **MAD**: Die Hälfte der Störungen liegt höchstens 12,5 Minuten vom Median entfernt. s nimmt den langen Stillstand voll mit.

(c) Die Grenzen liegen bei $13{,}75 - 1{,}5 \cdot 53{,}75 = 13{,}75 - 80{,}625 = \boxed{-66{,}875}$ und $67{,}5 + 80{,}625 = \boxed{148{,}125}$. Der untere Whisker endet beim kleinsten Wert **5**, der obere beim größten Wert innerhalb der Grenze, **105**. Der Wert 330 erscheint als Punkt.



(d) Mit 480 statt 330 ist $\sum_i x_i = 710$ und $\bar{x} = 710/8 = \boxed{88{,}75}$, also $150/8 = 18{,}75$ Minuten mehr. Es ist $s = \sqrt{182.587{,}5/7} \approx \boxed{161{,}51}$. Median, Q_1, Q_3, IQR und MAD **bleiben gleich**: Der Median hängt nur von $x_{(3)}$ und $x_{(4)}$ ab, die Quartile von $x_{(1)}$, $x_{(2)}$, $x_{(5)}$ und $x_{(6)}$, der größte Wert $x_{(7)}$ kommt in keiner Formel vor. Seine absolute Abweichung $480 - 20 = 460$ bleibt die größte, der MAD hängt nur von der vierten und fünften ab.

Bruchpunkte bei $n = 8$: Für $\bar{x}$ und s genügt **ein** Wert, $1/8 = 12{,}5\,\%$. Für Q_3 genügen **zwei**, denn $x_{(6)}$ geht mit dem Gewicht 0,25 ein: $2/8 = 25\,\%$. Für den Median braucht es **vier**, erst dann ist $x_{(4)}$ verfälscht: $4/8 = 50\,\%$. Für den MAD ebenfalls **vier**: Bei drei verfälschten Werten bleibt der Median endlich, und die vierte und fünfte Abweichung gehören zu unverfälschten Werten. Das passt zum Skript 3.4: $1/n$, $25\,\%$, $50\,\%$ und $50\,\%$.

Zum Nachprüfen im Notebook:

```
x = pd.Series([55, 20, 10, 105, 330, 15, 5, 20])
print(x.mean(), x.median(), x.quantile(0.25), x.quantile(0.75))
print(round(x.std(), 2), (x - x.median()).abs().median())
```

liefert `70.0 20.0 13.75 67.5` und `110.13 12.5`.

Typischer Fehler

In (a) die Quartile als Mediane der unteren und der oberen Hälfte bestimmen, also 12,5 und 80 (Tukeys Angelpunkte). Das ist eine andere Konvention, mit IQR 67,5. In (b) durch n statt $n-1$ teilen wie `np.std`: $\sqrt{84.900/8} \approx 103{,}02$ statt 110,13.

Bewertung: (a) Mittelwert und Median ½ P, Quartile 1 P, IQR mit Begründung ½ P. (b) s 1 P, MAD 1 P, Vergleich, Anteil und Deutung 1 P. (c) Grenzen und Whiskerenden 1 P, Zeichnung 1 P. (d) neue Werte 1 P, unveränderte Kennzahlen begründet 1 P, Bruchpunkte 1 P.

Lösung zu Aufgabe 2 Verteilungen lesen

(a) $h = 2 \cdot (22{,}5 - 20{,}5) \cdot 5.788^{-1/3} = 4/17{,}955 \approx \boxed{0{,}2228\ °\text{C}}$. Wegen $(28{,}9 - 17{,}6)/0{,}2228 \approx 50{,}7$ braucht es $\boxed{51}$ Klassen. Die möglichen Messwerte liegen im Abstand 0,1 °C, eine Klasse fasst **2 oder 3** davon, im Mittel 2,23. 12 der 51 Klassen fassen drei und sind deshalb um etwa die Hälfte höher als ihre Nachbarn: ein **Zackenmuster** aus der Rundung, kein Merkmal der Temperatur. Anders als beim Stillstand (Skript 2.1) kann keine Klasse wegen der Rundung leer bleiben. Nimm ein Vielfaches der Auflösung, etwa $h = 0{,}2$ °C mit 57 Klassen zu je zwei möglichen Werten.

(b) $\hat{F}$ erreicht 0,5 erstmals bei 30 Minuten, also Median $\boxed{30}$. Wegen $\hat{F}(10) = 0{,}20$ und $\hat{F}(15) = 0{,}35$ ist $Q_1 = \boxed{15}$, wegen $\hat{F}(40) = 0{,}75$ ist $Q_3 = \boxed{40}$. Länger als 60 Minuten dauerten $1 - \hat{F}(60) = 1 - 0{,}80 = \boxed{20\,\%}$, also 4 Störungen. Bei 40 springt $\hat{F}$ von 0,60 auf 0,75, um 3/20: $\boxed{3}$ Störungen dauerten genau 40 Minuten. pandas meldet $\boxed{32{,}5}$, denn es interpoliert an der Stelle $19 \cdot 0{,}5 = 9{,}5$ zwischen $x_{(9)} = 30$ und $x_{(10)} = 35$. Die ECDF ist zwischen 30 und 35 genau 0,5, jeder Wert dazwischen teilt die Daten in zwei Hälften.

(c) **A, 3 und II** gehören zusammen: ein Gipfel bei 21,5 bis 22 °C mit langem Schwanz nach rechts, die ECDF steigt früh steil und nähert sich nur langsam der 1, der Boxplot ist schmal mit einem Punkt bei 24,7 °C. **B, 1 und III**: zwei Gipfel mit einer Lücke von 23,5 bis 24 °C, die ECDF ist dort flach, der Boxplot hat die breiteste Box. **C, 2 und I**: ein Gipfel, ungefähr symmetrisch, die ECDF ist S-förmig, der Median liegt mittig in der Box.

Der Wetterumschwung steckt in **Stichprobe B**: kühle Tage um 22 °C, warme um 24,5 bis 25,5 °C. Ihr Boxplot zeigt eine breite Box mit dem Median 23,0 °C nahe $Q_1 = 22{,}175$ °C, als wäre die Verteilung rechtsschief. **Die zwei Gipfel und die Lücke verrät er nicht**. In II liegt 24,7 °C über der oberen Grenze $22{,}6 + 1{,}5 \cdot 0{,}925 = 23{,}9875$. Die Daten stammen aus Linie 2 vom 2. bis 26. September 2025 (A), Linie 1 vom 13. Mai bis 11. Juni 2026 (B) und Linie 1 vom 27. Juli bis 4. September 2026 (C), sortiert in °C:

A, 3, II	21,1	21,4	21,5	21,6	21,6	21,7	21,7	21,8	21,9	22,0	22,1	22,2	22,3	22,5	22,6	22,6	22,9	23,3	23,7	24,7
B, 1, III	21,4	21,8	21,9	22,0	22,1	22,2	22,5	22,5	22,7	22,9	23,1	24,2	24,4	24,6	24,6	24,9	25,2	25,3	25,5	25,6
C, 2, I	21,5	21,6	22,0	22,1	22,2	22,8	22,9	23,0	23,1	23,1	23,3	23,5	23,6	23,6	23,8	23,9	24,0	24,3	24,4	25,3

Typischer Fehler

In (b) den Anteil über 60 Minuten als $\hat{F}(60) = 0{,}80$ ablesen. $\hat{F}(x)$ zählt die Werte bis einschließlich x, der Anteil darüber ist $1 - \hat{F}(60)$. In (a) die Zahl der Klassen abrunden: 50 Klassen der Breite 0,2228 °C reichen nur bis $17{,}6 + 50 \cdot 0{,}2228 \approx 28{,}74$ °C.

Bewertung: (a) h und Klassenzahl 1 P, Zackenmuster und Wahl der Klassenbreite 1 P. (b) Median und Quartile 1 P, Anteil und Anzahl 1 P, pandas-Median mit Begründung 1 P. (c) Zuordnung mit Begründung 2 P, Wetterumschwung und was der Boxplot verschweigt 1 P.

Lösung zu Aufgabe 3 Korrelation von Hand und ein einzelner Punkt

(a) Mit $\bar{x} = 250/5 = 50$ und $\bar{y} = 450/5 = 90$, Rängen R_i von x und S_i von y, beide aufsteigend:

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	Produkt	R_i	S_i	d_i
10	97	−40	7	−280	1	4	−3
30	98	−20	8	−160	2	5	−3
50	88	0	−2	0	3	3	0
70	85	20	−5	−100	4	2	2
90	82	40	−8	−320	5	1	4

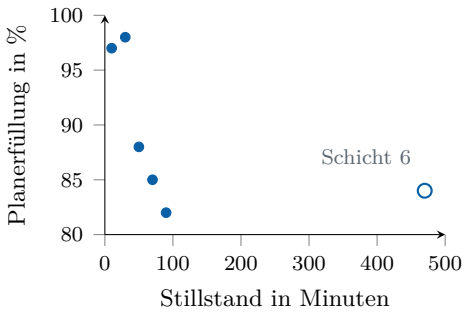
Die Summe der Produkte ist -860, die Quadratsummen sind 4.000 und $49+64+4+25+64 = 206$. Also $r = -860/\sqrt{4.000 \cdot 206} = -860/\sqrt{824.000} \approx \boxed{-0{,}947}$. Mit $\sum_i d_i^2 = 9+9+0+4+16 = 38$ ist $\rho = 1 - 6 \cdot 38/(5 \cdot 24) = 1 - 228/120 = \boxed{-0{,}9}$.

(b) Jetzt ist $\bar{x} = 720/6 = 120$ und $\bar{y} = 534/6 = 89$. Die Abweichungen lauten -110, -90, -70, -50, -30, 350 und 8, 9, -1, -4, -7, -5, die Produkte -880, -810, 70, 200, 210 und -1.750 mit der Summe -2.960. Die Quadratsummen sind $12.100+8.100+4.900+2.500+900+122.500 = 151.000$ und $64+81+1+16+49+25 = 236$:

$$r = \frac{-2.960}{\sqrt{151.000 \cdot 236}} = \frac{-2.960}{\sqrt{35.636.000}} \approx \boxed{-0{,}496}.$$

Die Ränge von y sind 5, 6, 4, 3, 1, 2, die Differenzen d_i also -4, -4, -1, 1, 4, 4 mit $\sum_i d_i^2 = 66$ und $\rho = 1 - 6 \cdot 66/(6 \cdot 35) = 1 - 66/35 \approx \boxed{-0{,}886}$.

Nach r allein wäre der Zusammenhang nur noch **mäßig**, r hat sich fast halbiert. ρ ändert sich **kaum**: Als Rang ist die sechste Schicht die längste mit der zweitniedrigsten Planerfüllung, das passt zum Trend. Für r stammen $122.500/151.000 \approx 81\,\%$ der Quadratsumme von x aus dieser Schicht, und sie liegt weit über der Linie der anderen fünf.



470 Minuten sind fast die ganze Schicht von 480 Minuten. Im Werk blieben alle 23 Schichten der Linie 3 mit mehr als 300 Minuten Stillstand unter 71 % Planerfüllung. Prüfe die Meldungen: doppelt erfasst, über das Schichtende gebucht, eine Maschine, die den Takt nicht bestimmt, oder ein Einheitenfehler wie in Modul 3. Streichen nur mit dokumentiertem Grund, sonst beide Koeffizienten berichten und das Streudiagramm zeigen.

(c) Teile Zähler und Nenner der Formel aus Skript 4.2 durch $n-1$, im Nenner unter jeder der beiden Wurzeln einmal:

$$r = \frac{\frac{1}{n-1}\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n-1}\sum_i (x_i - \bar{x})^2}\,\sqrt{\frac{1}{n-1}\sum_i (y_i - \bar{y})^2}} = \boxed{\frac{s_{xy}}{s_x\, s_y}}.$$

Mit $a_i = x_i - \bar{x}$ und $b_i = y_i - \bar{y}$ ist der Betrag des Zählers nach Cauchy-Schwarz höchstens so groß wie der Nenner, also $\boxed{|r| \le 1}$. Gleichheit gilt genau dann, wenn $b = c\,a$ für eine Zahl c

ist, also $y_i - \bar{y} = c\,(x_i - \bar{x})$ für alle i: Alle Punkte liegen auf einer Geraden durch $(\bar{x}, \bar{y})$ mit der Steigung c, und $r = -1$ heißt $c < 0$. In Stunden wird jedes a_i zu $a_i/60$, Zähler und $\sqrt{\sum_i a_i^2}$ bekommen beide den Faktor $1/60$: r **bleibt gleich**, ebenso bei jedem anderen positiven Faktor und jeder Verschiebung des Nullpunkts.

(d) r summiert Produkte von Abweichungen vom Mittelwert. Punkte weit weg vom Mittelwert haben deshalb großes Gewicht, ρ sieht nur Ränge. In (b) liegt der ferne Punkt neben dem Trend und schwächt r. Im Werk liegen die 603 Schichten mit mehr als 200 Minuten Stillstand weit draußen und fast auf einer Geraden (Skript 4.3), sie verstärken r. Für ρ sind sie in beiden Fällen nur die letzten Ränge. Weichen r und ρ ab, schaust du ins Streudiagramm und berichtest beide.

Zum Nachprüfen im Notebook, ohne SciPy wie im Skript 4.4:

```
paare = pd.DataFrame({"still": [10, 30, 50, 70, 90, 470], "plan": [97, 98, 88, 85, 82, 84]})
fuenf = paare.iloc[:5]
print(round(fuenf.corr().iloc[0, 1], 4), round(fuenf.corr(method="spearman").iloc[0, 1], 4))
print(round(paare.corr().iloc[0, 1], 4), round(paare.corr(method="spearman").iloc[0, 1], 4))
```

liefert `-0.9474 -0.9` und `-0.4958 -0.8857`.

> **Typischer Fehler**
> In (a) die Ränge von y absteigend vergeben, also 98 auf Rang 1. Dann ist $\sum_i d_i^2 = 2$ und $\rho = +0{,}9$, das Vorzeichen kippt. Beide Variablen rangierst du aufsteigend.

Bewertung: (a) r mit Rechenweg 2 P, ρ 1 P. (b) r 1 P, ρ 1 P, Deutung und Prüfung der Schicht 1 P. (c) normierte Kovarianz und Cauchy-Schwarz 1 P, Gleichheitsfall und Einheiten 1 P. (d) Erklärung beider Fälle 1 P.

Lösung zu Aufgabe 4 Simpson und Confounding

(a) Je Zeile: $420/600 = 0{,}70$, $160/200 = 0{,}80$, $60/200 = 0{,}30$ und $210/600 = 0{,}35$ Störungen je Maschinenschicht. Insgesamt hat die zustandsorientierte Wartung $480/800 = \boxed{0{,}60}$, die Wartung nach Plan $370/800 = \boxed{0{,}4625}$. In **jeder** Baujahrgruppe ist die zustandsorientierte Wartung besser ($0{,}70 < 0{,}80$ und $0{,}30 < 0{,}35$), **insgesamt** schlechter: eine Simpson-Umkehr.

(b) Die Gewichte sind die Anteile der Baujahrgruppen innerhalb jeder Wartungsart, etwa $600/800 = 0{,}75$: $q_{\text{zust}} = 0{,}75 \cdot 0{,}70 + 0{,}25 \cdot 0{,}30 = 0{,}525 + 0{,}075 = 0{,}60$ und $q_{\text{Plan}} = 0{,}25 \cdot 0{,}80 + 0{,}75 \cdot 0{,}35 = 0{,}20 + 0{,}2625 = 0{,}4625$. Die zustandsorientierte Wartung läuft zu drei Vierteln auf alten Maschinen, und alte Maschinen haben mehr Störungen, egal wie sie gewartet werden. Der Confounder ist das **Baujahr**: Baujahr → Wartungsart, weil mit den alten Maschinen begonnen wurde, und Baujahr → Störungen, im Werk 0,58 gegen 0,46 je Schicht. Jede Baujahrgruppe hat 800 der 1.600 Maschinenschichten, also das Gewicht 0,5: $0{,}5 \cdot 0{,}70 + 0{,}5 \cdot 0{,}30 = \boxed{0{,}50}$ gegen $0{,}5 \cdot 0{,}80 + 0{,}5 \cdot 0{,}35 = \boxed{0{,}575}$. Die zustandsorientierte Wartung hat $(0{,}575 - 0{,}50)/0{,}575 \approx \boxed{13{,}0\,\%}$ weniger Störungen.

(c) Verwechselt ist die **Linie**: Linie → Personal, denn die Endmontage braucht viele Hände (Linie 4 im Mittel 11,3 Beschäftigte), und Linie → Ausschuss, denn Zerspanung erzeugt mehr Ausschuss (Linie 2 im Mittel 2,98 %, Linie 4 0,98 %). Kontrollieren heißt **innerhalb der Linien vergleichen**: r je Linie, Facetten oder eine Farbe je Linie. Dort ist r praktisch null, die Daten stützen den Vorschlag **nicht**. Innerhalb einer Linie schwankt das Personal nur um wenige Köpfe, ob eine Person mehr auf Linie 2 hilft, können diese Daten gar nicht zeigen. Das klärt ein geplanter Versuch (Modul 12).

(d) Insgesamt liegt die Nacht um $(2{,}20 - 2{,}08)/2{,}08 = 0{,}12/2{,}08 \approx \boxed{5{,}8\,\%}$ höher, das sind die 6 % des Schichtleiters. Bei gleicher Auslastung sind es dagegen $0{,}36/1{,}72 \approx \boxed{20{,}9\,\%}$ und $0{,}38/2{,}05 \approx \boxed{18{,}5\,\%}$, also rund ein Fünftel. Das Skript nennt für die zweite Klasse 0,37 Prozentpunkte, weil es mit den ungerundeten Quoten rechnet. Auch $0{,}37/2{,}05 \approx 18{,}0\,\%$ ist richtig. Der Schichtleiter vergleicht unfair: Seine 6 % mischen den Unterschied der Schichten mit dem der Auslastung. Fair ist der Vergleich innerhalb der Klassen, und dort ist die Nacht **deutlich** schlechter. Es lohnt sich also, nach Ursachen zu suchen. Zu jeder Zelle gehört die Zahl der Schichten, ab 0,9 gibt es nachts nur 8. Ob der Abstand mehr als Zufall ist, klären die Module 5 und 6.

Typischer Fehler

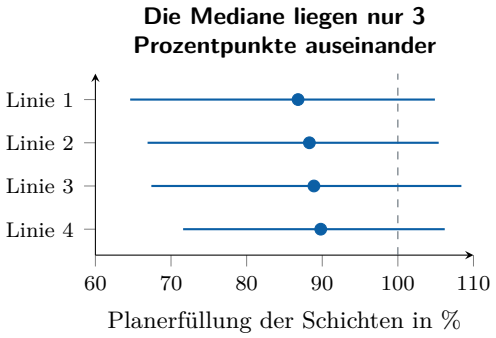
In (a) die Gesamtrate als einfaches Mittel der Gruppenraten bilden, $(0{,}70 + 0{,}30)/2 = 0{,}50$ und $(0{,}80 + 0{,}35)/2 = 0{,}575$. Das ist nicht die Quote der Summen, sondern zufällig der faire Vergleich aus (b), weil beide Baujahrgruppen gleich viele Maschinenschichten haben. Die Umkehr bleibt so unentdeckt.

Bewertung: (a) Raten je Zeile 1 P, Gesamtraten und Umkehr 1 P. (b) gewichtete Mittel und Confounder mit Pfeilen 1 P, fairer Vergleich mit Prozent 1 P. (c) Confounder mit Pfeilen 1 P, Kontrolle und Stellungnahme 1 P. (d) relative Unterschiede ½ P, begründete Stellungnahme ½ P.

Lösung zu Aufgabe 5 Wahrnehmung und Gestaltung

(a) Erstens beginnt die Balkenachse bei 86 statt bei 0: Die Balken sind $86{,}8 - 86 = 0{,}8$ und $89{,}8 - 86 = 3{,}8$ Prozentpunkte lang, Linie 4 wirkt fast fünfmal so gut. Zweitens zeigen die Balken nur Mediane: Die Schichten streuen von Whisker zu Whisker über 35 bis 41 Prozentpunkte, dagegen sind 3 Prozentpunkte zwischen den Medianen wenig. Der Titel behauptet trotzdem „mit Abstand“. Der Lügenfaktor ist der Effekt in der Grafik, $3{,}8/0{,}8 - 1 = 375\,\%$ mehr, geteilt durch den Effekt in den Daten, $89{,}8/86{,}8 - 1 = 3/86{,}8 \approx 3{,}46\,\%$ mehr: $3{,}75 \cdot 86{,}8/3 = \boxed{108{,}5}$.

Besser zeigst du je Linie den Median als Punkt und die Spanne der Whisker als Strich auf einer gemeinsamen Achse. Position statt Länge, deshalb darf die Achse einen Ausschnitt zeigen, etwa 60 bis 110 %. Gleich gut sind Boxplots nebeneinander wie im Skript 2.4.



(b) Die Frage verbindet Zeitverlauf und Vergleich, also **Liniendiagramme**: vier kleine Vielfache, eines je Linie, mit gemeinsamer Zeitachse und gemeinsamer y-Achse für die Quote in Prozent, die Sommermonate grau hinterlegt (Skript 7.3). Vier Linien in einer Axes, direkt beschriftet, gehen auch. Die Quote ist dann eine **Position auf gemeinsamer oder gleicher Skala**, Stufe 1 und 2 bei Cleveland und McGill. In der Heatmap ist sie eine Farbe, Stufe 6, und Unterschiede von wenigen Zehntelprozentpunkten sind kaum zu vergleichen. Gegen `jet`: Die Helligkeit steigt, fällt und springt, das Auge sieht Grenzen, wo die Quote gleichmäßig wächst. In Graustufen und bei einer Rot-Grün-Schwäche geht die Ordnung verloren. Wenn eine Heatmap, dann mit einer sequenziellen Skala wie `viridis`.

(c) „Störungen nach Wartungsart“ nennt nur das **Thema**, keinen Befund und kein Verb. „Zustandsorientierte Wartung erhöht die Störungen“ ist **falsch**: Insgesamt mehr Störungen entstehen durch die älteren Maschinen (Simpson), in jeder Baujahrgruppe sind es weniger. Außerdem behauptet „erhöht“ eine Ursache, die ein Vergleich ohne Versuch nicht trägt. Besser: **„Bei gleichem Baujahr hat die zustandsorientierte Wartung 13 bis 14 % weniger Störungen“**, denn $0{,}10/0{,}80 = 12{,}5\,\%$ und $0{,}05/0{,}35 \approx 14{,}3\,\%$.

Typischer Fehler

In (a) das Verhältnis der Balkenlängen, 4,75, als Lügenfaktor angeben oder die Verhältnisse statt der Zuwächse teilen, $4{,}75/1{,}0346 \approx 4{,}59$. Tufte teilt die Zuwächse: 375 % durch 3,46 %.

Bewertung: (a) zwei irreführende Punkte 1 P, Lügenfaktor 1 P, bessere Grafik 1 P. (b) Grafiktyp und Kodierung mit Rangfolge 1 P, zwei Gründe gegen `jet` 1 P. (c) beide Titel beurteilt und eigener Titel mit Befund 1 P.

Lösung zu Aufgabe 6 Woher kommt die Kurzformel für Spearman? (Zusatz)

(a) Es ist $\bar{R} = (n+1)/2$ und $\sum_i (R_i - \bar{R})^2 = \sum_i R_i^2 - n\,\bar{R}^2$, also

$$\sum_i (R_i - \bar{R})^2 = \frac{n(n+1)(2n+1)}{6} - \frac{n(n+1)^2}{4} = \frac{n(n+1)\big(2(2n+1) - 3(n+1)\big)}{12}$$
$$= \frac{n(n+1)(n-1)}{12} = \boxed{\frac{n(n^2-1)}{12}}.$$

(b) Wegen $\bar{R} = \bar{S}$ ist $d_i = (R_i - \bar{R}) - (S_i - \bar{S})$. Quadrieren und summieren, mit $\sum_i (S_i - \bar{S})^2 = \sum_i (R_i - \bar{R})^2$ aus (a):

$$\sum_i d_i^2 = \sum_i (R_i - \bar{R})^2 + \sum_i (S_i - \bar{S})^2 - 2\sum_i (R_i - \bar{R})(S_i - \bar{S}) = 2\,\frac{n(n^2-1)}{12} - 2\sum_i (R_i - \bar{R})(S_i - \bar{S}).$$

ρ ist Pearson der Ränge, der Nenner ist $\sqrt{\sum_i (R_i - \bar{R})^2 \sum_i (S_i - \bar{S})^2} = n(n^2-1)/12$. Mit $\sum_i (R_i - \bar{R})(S_i - \bar{S}) = n(n^2-1)/12 - \frac{1}{2}\sum_i d_i^2$ folgt

$$\rho = 1 - \frac{\frac{1}{2}\sum_i d_i^2}{n(n^2-1)/12} = \boxed{1 - \frac{6\sum_i d_i^2}{n(n^2-1)}}.$$

In Aufgabe 3 (a) ergibt das $1 - 6 \cdot 38/120 = -0{,}9$ wie die Rechnung als Pearson der Ränge.

(c) Die Beschäftigten bekommen die Ränge 2, 2, 2, 4, 5 (mittlerer Rang von 1, 2 und 3), der Ausschuss 1 bis 5. Die Abweichungen vom mittleren Rang 3 sind -1, -1, -1, 1, 2 und -2, -1, 0, 1, 2 mit der Summe der Produkte $2 + 1 + 0 + 1 + 4 = 8$ und den Quadratsummen 8 und 10. Pearson der Ränge: $\rho = 8/\sqrt{8 \cdot 10} = 8/\sqrt{80} \approx \boxed{0{,}894}$. Kurzformel: $d_i = 1, 0, -1, 0, 0$, $\sum_i d_i^2 = 2$ und $1 - 6 \cdot 2/(5 \cdot 24) = \boxed{0{,}9}$. Die Kurzformel setzt in (b) für beide Rangreihen die Quadratsumme $n(n^2-1)/12 = 10$ voraus. Mit gleichen Werten ist sie kleiner, hier 8, und die Formel stimmt nicht mehr. Das Personal nimmt im Werk nur 11 verschiedene Werte an, dort rechnest du Pearson der mittleren Ränge, wie es `rank()` und `corr(method="spearman")` tun.