Tutoriumsblatt 6

Schätzen und Testen

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Schätzer herleiten und vergleichen, Intervalle für Mittelwerte und Anteile berechnen und deuten,
- Fehler erster und zweiter Art im Werk abwägen, Teststärke und Stichprobengröße bestimmen,
- Tests von Hand rechnen, viele Tests korrigieren und die praktische Relevanz beurteilen.

So arbeitest du mit dem Blatt

Du programmierst nicht: Du rechnest mit dem Taschenrechner und den Tabellen unten und begründest. s teilt durch $n-1$, p-Werte gibst du auf vier Nachkommastellen an, Zwischenwerte genauer. Hängst du, rechnest du mit den Werten unter „Zur Kontrolle“ weiter. Werkszahlen stammen aus `daten/` und dem Skript, „ausgedacht“ heißt fiktiv. Zum Notebook: Aufgabe 1 gehört zu TODO 1 und 2; Aufgabe 2 zu 3 und 4; Aufgabe 3 zu 5 und 10; Aufgabe 4 zu 6 bis 9; Aufgabe 5 zu 11 bis 13.

Tabellen für alle Aufgaben

z	$\Phi(z)$	z	$\Phi(z)$
0,04	0,5160	1,50	0,9332
0,50	0,6915	2,00	0,9772
0,53	0,7019	2,10	0,9821
0,77	0,7794	2,35	0,9906
1,00	0,8413	2,50	0,9938
1,39	0,9177	3,16	0,9992
1,44	0,9251	3,50	0,9998

Standardnormalverteilung, $\Phi(-z) = 1 - \Phi(z)$

ν	0,80	0,90	0,95	0,975	0,995
3	0,978	1,638	2,353	3,182	5,841
4	0,941	1,533	2,132	2,776	4,604
5	0,920	1,476	2,015	2,571	4,032
6	0,906	1,440	1,943	2,447	3,707
7	0,896	1,415	1,895	2,365	3,499
8	0,889	1,397	1,860	2,306	3,355
∞	0,842	1,282	1,645	1,960	2,576

Quantile $t_{\nu;\,q}$, Zeile ∞: Quantile z_q

ν	0,90	0,95	0,99
1	2,706	3,841	6,635
2	4,605	5,991	9,210
3	6,251	7,815	11,345
4	7,779	9,488	13,277

Quantile $\chi^2_{\nu;\,q}$

Aufgabe 1 Schätzer und Maximum Likelihood

8 Punkte · etwa 17 Min.

Bezug: Modul 6, Lerneinheit 1 (Schätzer und ihre Güte)

$X_1, \ldots, X_n$ seien unabhängig mit Erwartungswert μ und Varianz σ^2, $\bar{X} = \frac{1}{n}\sum_i X_i$. Verglichen werden $S^2 = \frac{1}{n-1}\sum_i (X_i - \bar{X})^2$ und $\hat{\sigma}_n^2 = \frac{1}{n}\sum_i (X_i - \bar{X})^2$.

(a) Zeige $E(\bar{X}) = \mu$ und $\sum_i (X_i-\mu)^2 = \sum_i (X_i-\bar{X})^2 + n\,(\bar{X}-\mu)^2$. Tipp: $X_i - \mu = (X_i - \bar{X}) + (\bar{X} - \mu)$ und $\sum_i (X_i - \bar{X}) = 0$. Folgere mit $\mathrm{Var}(\bar{X}) = \sigma^2/n$ aus Blatt 5, dass $E\big[\sum_i (X_i - \bar{X})^2\big] = (n-1)\,\sigma^2$ ist. Wie groß sind $E(\hat{\sigma}_n^2)$ und sein Bias, welcher Schätzer ist erwartungstreu? [3 P]

(b) Für normalverteilte Werte gilt $\mathrm{Var}(S^2) = 2\sigma^4/(n-1)$. Zeige $\mathrm{MSE}(\hat{\sigma}_n^2) = (2n-1)\,\sigma^4/n^2$ und vergleiche mit $\mathrm{MSE}(S^2)$ für $n = 2$. Die Endkontrolle misst je Schicht zwei Wellen einer Maschine. Für M-09 ist das Mittel der 1.413 Schichtvarianzen 62,2 µm² mit Teiler $n-1$ und 31,1 µm² mit Teiler n, alle 2.826 Messungen haben $s^2 = 61{,}8\,\mu\mathrm{m}^2$. Berechne den MSE beider

Mittel über $m = 1.413$ unabhängige Schichten in Vielfachen von σ^4. Welches Mittel passt, und warum hilft der kleinere MSE der einzelnen Schicht nicht? [2 P]

(c) Die letzten fünf verspäteten Lieferungen von L-05, Oktober 2025 bis September 2026, kamen 2,3; 8,6; 50,7; 43,2 und 12,7 Stunden nach dem Soll-Termin. Wie in Modul 5 sei $T = \text{Verzug} - 2$ exponentialverteilt mit der Dichte $\lambda e^{-\lambda t}$, $t \geq 0$. Stelle die Log-Likelihood $\ell(\lambda)$ für $t_1, \ldots, t_n$ auf, leite $\hat{\lambda} = 1/\bar{t}$ her und zeige, dass dort ein Maximum liegt. Berechne $\hat{\lambda}$. Wie im Skript 1.4 ist $\mathrm{SE}(\hat{\lambda}) = 1/\sqrt{-\ell''(\hat{\lambda})}$. Zeige $\mathrm{SE}(\hat{\lambda}) = \hat{\lambda}/\sqrt{n}$, berechne $\hat{\lambda} \pm 1{,}96\,\mathrm{SE}$ und deute das Intervall. [3 P]

Aufgabe 2 Intervalle für Durchmesser und Mangelquote

8 Punkte · etwa 17 Min.

Bezug: Modul 6, Lerneinheit 2 (Konfidenzintervalle mit Formel)

Am Dienstag, 30. September 2025, wurden an M-03 in jeder Schicht zwei Wellen gemessen. Die Tabelle zeigt ihre Abweichung vom Sollmaß 25,000 mm.

Schicht	Früh	Spät	Nacht
Abweichung (µm)	16; 25	9; 10	3; 9

(a) Berechne $\bar{x}$, s^2 und den Standardfehler. Bestimme das 95-%-Intervall für die mittlere Abweichung an diesem Tag mit der t-Tabelle. Zur Kontrolle: $s^2 = 57{,}6\,\mu\mathrm{m}^2$. [2 P]

(b) Die Lieferung LF-04620 von L-03 vom 30. September 2026 hatte 2 Mängel unter 50 geprüften Teilen. Berechne in Prozent auf zwei Nachkommastellen das Wald-Intervall $\hat{p} \pm z\sqrt{\hat{p}\,(1-\hat{p})/n}$ und mit $z = 1{,}96$ und $z^2 \approx 3{,}84$ das Wilson-Intervall

$$\frac{\hat{p} + \frac{z^2}{2n}}{1 + \frac{z^2}{n}} \pm \frac{z}{1 + \frac{z^2}{n}} \sqrt{\frac{\hat{p}\,(1-\hat{p})}{n} + \frac{z^2}{4n^2}}$$

Was stimmt an der unteren Wald-Grenze nicht? Was liefert Wald bei 0 Mängeln, und warum versagt es dort? [2 P]

(c) Berechne aus (a) das 99-%-Intervall und den Faktor, um den es breiter ist als das 95-%-Intervall. Wie viele Wellen braucht die Instandhaltung mindestens, damit die halbe Breite des 95-%-Intervalls höchstens 6 µm beträgt, wenn $s \approx 7{,}59$ µm bleibt? Starte mit $z = 1{,}96$ und prüfe mit der t-Tabelle. [2 P]

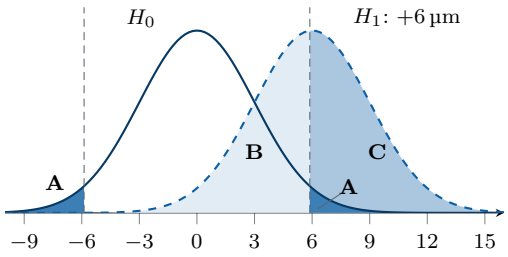
(d) Richtig oder falsch? Begründe jeweils kurz. (i) „Die zwei Wellen einer Schicht teilen Werkzeug und Einstellung. Als Intervall für die mittlere Abweichung von M-03 über viele Schichten ist das aus (a) darum eher zu schmal als zu breit.“ (ii) „Das 99-%-Intervall aus (c) enthält das 95-%-Intervall aus (a) vollständig.“ (iii) „Die Mitte des Wilson-Intervalls aus (b) ist der beobachtete Anteil von 4 %.“ (iv) „Misst die Endkontrolle unter gleichen Bedingungen noch einmal sechs Wellen, liegt deren Mittelwert mit 95 % Wahrscheinlichkeit im Intervall aus (a).“ Tipp zu (iv): Rechne mit bekanntem σ. Wie streut die Differenz zweier unabhängiger Mittelwerte? [2 P]

Aufgabe 3 Testlogik und Teststärke

6 Punkte · etwa 14 Min.

Bezug: Modul 6, Lerneinheiten 3 (Die Logik des Tests) und 5 (Teststärke und Stichprobengröße)

Nach einem Werkzeugwechsel misst die Endkontrolle $n = 16$ Wellen von M-03. Weicht ihr Mittelwert beim zweiseitigen z-Test mit $\alpha = 5\,\%$ vom Sollmaß ab, wird M-03 für etwa eine Stunde angehalten und nachgestellt. Rechne mit bekanntem $\sigma = 12\,\mu m$, über alle Messungen hat M-03 $s = 12{,}2\,\mu m$. Das Bild zeigt die Verteilung des Mittelwerts unter H_0 und bei einer Verstellung um $6\,\mu m$.



Mittelwert der 16 Wellen minus Sollmaß in µm

(a) Formuliere H_0 und H_1. Was bedeuten Fehler erster und zweiter Art hier, und was kostet jeder? Die Instandhaltung schlägt $\alpha = 10\,\%$ vor. Was gewinnt sie, was verliert sie? [2 P]

(b) Zurück zum 30. September 2025 aus Aufgabe 2. Zur Kontrolle: Das 95-%-Intervall reicht von 4,03 bis 19,97 µm, das 99-%-Intervall von −0,49 bis 24,49 µm. Entscheide ohne Rechnung, ob der zweiseitige t-Test von H_0: $\mu = 25{,}000\,mm$ zum Niveau 5 % und zum Niveau 1 % verwirft. Bestätige mit t und der t-Tabelle. Für welche μ_0 verwirft er zum Niveau 5 % nicht? [1 P]

(c) Angenommen, der Wechsel hat M-03 um $\delta = 6\,\mu m$ verstellt. Ab welcher Abweichung $|\bar{x} - 25{,}000\,mm|$ verwirft der Test? Berechne die Teststärke $1 - \beta$ mit der Φ-Tabelle. Welche der Flächen A, B und C im Bild sind α, β und $1 - \beta$? [2 P]

(d) Für die Teststärke $1 - \beta$ braucht der Test etwa $n \approx (z_{1-\alpha/2} + z_{1-\beta})^2\,\sigma^2/\delta^2$ Wellen. Begründe die Formel mit (c), wenn du den kleinen zweiten Rand weglässt. Wie viele Wellen braucht die Endkontrolle für 80 % Teststärke bei $\delta = 6\,\mu m$ mit $\alpha = 5\,\%$, wie viele mit $\alpha = 1\,\%$? [1 P]

Aufgabe 4 Tests von Hand

10 Punkte · etwa 22 Min.

Bezug: Modul 6, Lerneinheit 4 (Die wichtigsten Tests)

An M-03 liegt seit Kurzem ein Ersatzteillager direkt an der Linie (ausgedacht). Die Tabelle zeigt den Stillstand der letzten vier mechanischen Störungen davor und der ersten vier danach.

Ersatzteillager	Stillstand (min)			
vorher	40	55	60	145
nachher	15	20	35	50

(a) Berechne Mittelwerte und Varianzen, die Welch-Statistik t und die Freiheitsgrade ν nach Welch und Satterthwaite. Zur Kontrolle: $s^2_{\text{vorher}} = 2.250$. Entscheide zweiseitig bei $\alpha = 5\,\%$ und grenze den p-Wert mit der t-Tabelle ein. Warum ergibt Student hier dasselbe t, und was unterscheidet sich trotzdem? [3 P]

(b) Bestimme U als Zahl der Paare aus je einer Störung vorher und nachher, in denen der Stillstand vorher länger war. Unter H_0 sind alle $\binom{8}{4} = 70$ Aufteilungen der acht Ränge gleich wahrscheinlich. Wie viele davon haben ein mindestens so großes U? Bestimme den exakten zweiseitigen p-Wert. Warum liegt er unter dem von Welch? [2 P]

Die Endkontrolle hat in allen 2.826 Messungen an M-03 gezählt, wie viele Wellen außerhalb der Toleranz von ±25 µm lagen.

Wellen	Früh	Spät	Nacht
außerhalb	53	40	45
innerhalb	889	902	897

(c) Prüfe mit dem Chi-Quadrat-Unabhängigkeitstest bei $\alpha = 5\,\%$, ob der Anteil außerhalb der Toleranz von der Schicht abhängt: erwartete Häufigkeiten, χ^2, Freiheitsgrade, kritischer Wert, Entscheidung. Was zeigt das Ergebnis, was nicht? [2 P]

(d) Verspätet waren 12 der 30 Lieferungen von L-05 und 330 der 1.179 von L-01. Prüfe mit dem z-Test für zwei Anteile zweiseitig bei $\alpha = 5\,\%$, ob sich die Verspätungsquoten unterscheiden. Zur Kontrolle: Die gemeinsame Quote ist 0,2829. [1 P]

(e) Welcher Test passt? Begründe kurz. (i) Arbeitete M-09 vom 21. bis 25. September 2026 im Mittel auf Sollmaß? Gemessen sind 30 Wellen, zu dünne und zu dicke stören gleich. (ii) Hängt die Störungskategorie davon ab, ob die Maschine vor oder ab 2015 gebaut wurde? (iii) Kommen Lieferungen von L-04 tendenziell früher als die von L-02, ohne dass wenige lange Verzüge den Ausschlag geben? (iv) Eine neue Lieferantin hatte 1 Mangel unter 150 geprüften Teilen (ausgedacht), L-01 hat 750 unter 72.180. Ist ihre Quote anders? [2 P]

Aufgabe 5 Viele Tests und Relevanz

8 Punkte · etwa 18 Min.

Bezug: Modul 6, Lerneinheiten 6 (Viele Tests) und 7 (Signifikant ist nicht relevant)

M-03 wurde vom 7. Juli bis 26. September 2025 jede Woche mit einem t-Test aus 30 Wellen gegen das Sollmaß geprüft, in zehn Messwochen (KW 33 und 34 sind Werksferien):

KW	28	29	30	31	32	35	36	37	38	39
p	0,2326	0,2343	0,0004	0,3470	0,3499	0,0180	0,7007	0,0315	0,0057	0,0152

(a) Wie wahrscheinlich ist mindestens ein falscher Treffer, wenn M-03 in allen zehn Wochen auf Sollmaß arbeitet und die Tests unabhängig sind? Welche Wochen sind bei $\alpha = 5\,\%$ ohne Korrektur, nach Bonferroni, nach Holm und nach Benjamini-Hochberg auffällig? Welches Verfahren passt, wenn jede auffällige Woche einen Stillstand zum Nachmessen auslöst, und welches für eine Liste, die nur genauer angesehen wird? [3 P]

(b) An Linie 1 liegt die Ausschussquote in 471 Nachtschichten im Mittel bei 2,58 % ($s = 1{,}07$), in 471 Frühschichten bei 2,42 % ($s = 1{,}02$). Einheit ist die Schicht von Montag bis Freitag, gemittelt wird nur je Schichtart: Nacht- und Samstagsschichten sind kleiner geplant, und das Datenblatt warnt vor Mitteln über verschieden große Schichten. Berechne den Standardfehler der Differenz, z, den zweiseitigen p-Wert, das 95-%-Intervall und Cohen d mit s_p wie im Skript 4.2 (zur Kontrolle 1,05). Rechne die Intervallgrenzen in Ausschusswellen je Nachtschicht um (nachts im Mittel 285 Wellen). Welches z ergäben dieselben Kennzahlen aus je 50 Schichten, was folgt für p und d? [3 P]

(c) An Linie 4 liegt die Quote, ebenso gemittelt, nachts bei 0,98 % ($s = 0{,}90$), früh bei 1,01 % ($s = 0{,}85$), je 471 Schichten. Unterschiede unter 0,15 Prozentpunkten hält die Werksleitung für bedeutungslos. Berechne z und p des üblichen Tests. Führe den TOST mit zwei einseitigen z-Tests gegen $\pm 0{,}15$ durch und prüfe mit dem 90-%-Intervall. Warum 90 %? [2 P]

Aufgabe 6 (⋆) Woher die Wilson-Formel kommt

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 6, Lerneinheit 2

Wilson sucht alle p mit $|\hat{p} - p| \le z\sqrt{p\,(1-p)/n}$. (a) Quadriere und löse die quadratische Gleichung in p. Zeige, dass ihre Lösungen die Grenzen aus Aufgabe 2 sind. (b) Zeige, dass es für $k = 0$ von 0 bis $z^2/(n + z^2)$ reicht, und vergleiche für $n = 20$ und $n = 200$ mit z^2/n. (c) Zeige, dass die Mitte zwischen $\hat{p}$ und $1/2$ liegt und die untere Grenze nie negativ ist (Tipp: Vieta).

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Schätzer und Maximum Likelihood

(a) Linearität: $E(\bar{X}) = \frac{1}{n}\sum_i E(X_i) = \frac{1}{n} \cdot n\mu = \boxed{\mu}$. Mit dem Tipp und $\sum_i (X_i - \bar{X}) = 0$:

$$\sum_i (X_i - \mu)^2 = \sum_i (X_i - \bar{X})^2 + 2\,(\bar{X} - \mu)\underbrace{\textstyle\sum_i (X_i - \bar{X})}_{=0} + n\,(\bar{X} - \mu)^2.$$

Links ist der Erwartungswert $n\sigma^2$. Rechts ist $E\big[(\bar{X} - \mu)^2\big] = \mathrm{Var}(\bar{X}) = \sigma^2/n$, weil $E(\bar{X}) = \mu$. Also $n\sigma^2 = E\big[\sum_i (X_i - \bar{X})^2\big] + \sigma^2$ und $E\big[\sum_i (X_i - \bar{X})^2\big] = \boxed{(n-1)\,\sigma^2}$. Damit ist $E(\hat{\sigma}_n^2) = \frac{n-1}{n}\,\sigma^2$, der Bias $-\sigma^2/n$, und $E(S^2) = \sigma^2$: S^2 **ist erwartungstreu**. Die Werte liegen näher an ihrem eigenen Mittelwert als an μ, im Mittel fehlt genau ein σ^2 (Skript 1.2).

(b) Wegen $\hat{\sigma}_n^2 = \frac{n-1}{n}\,S^2$ ist $\mathrm{Bias}^2 = \sigma^4/n^2$ und $\mathrm{Var}(\hat{\sigma}_n^2) = \frac{(n-1)^2}{n^2} \cdot \frac{2\sigma^4}{n-1} = \frac{2(n-1)\,\sigma^4}{n^2}$, zusammen $\mathrm{MSE} = (1 + 2n - 2)\,\sigma^4/n^2 = \boxed{(2n-1)\,\sigma^4/n^2}$. Für $n = 2$: $\boxed{0{,}75\,\sigma^4}$ gegen $\mathrm{MSE}(S^2) = 2\sigma^4$, für eine einzelne Schicht ist der verzerrte Schätzer besser. Beim Mitteln über m Schichten teilt sich die Varianz durch m, der Bias bleibt. Verzerrt: $\sigma^4/4 + 0{,}5\,\sigma^4/1.413 \approx \boxed{0{,}2504\,\sigma^4}$, erwartungstreu: $2\sigma^4/1.413 \approx \boxed{0{,}0014\,\sigma^4}$. Die Daten zeigen es: 62,2 µm² passt zu 61,8 µm², 31,1 µm² ist genau die Hälfte. Also mittelt man die s^2 mit Teiler $n - 1$ und zieht erst am Ende die Wurzel (Stolperstein am Ende von Skript 1).

(c) $\ell(\lambda) = \sum_i \ln\left(\lambda e^{-\lambda t_i}\right) = n \ln\lambda - \lambda \sum_i t_i$, also $\ell'(\lambda) = n/\lambda - \sum_i t_i = 0$ und $\hat{\lambda} = n/\sum_i t_i = \boxed{1/\bar{t}}$. Wegen $\ell''(\lambda) = -n/\lambda^2 < 0$ ist es ein Maximum. Die t_i sind 0,3; 6,6; 48,7; 41,2 und 10,7 mit Summe 107,5, also $\bar{t} = 21{,}5$ h und $\hat{\lambda} = 1/21{,}5 \approx \boxed{0{,}0465}$ je Stunde. Aus $-\ell''(\hat{\lambda}) = n/\hat{\lambda}^2$ folgt $\mathrm{SE} = \boxed{\hat{\lambda}/\sqrt{n}}$, hier $0{,}0465/\sqrt{5} \approx 0{,}0208$. Das Intervall $0{,}0465 \pm 0{,}0408$ reicht von $\boxed{0{,}0057}$ bis $\boxed{0{,}0873}$ je Stunde. Als mittlerer Verzug über der Grenze sind das $1/0{,}0873 \approx 11{,}5$ bis $1/0{,}0057 \approx 175$ Stunden: Fünf Lieferungen legen die Rate kaum fest, bei $n = 5$ trägt die Normalnäherung nur grob.

> **Typischer Fehler**
>
> In (c) mit den Verzügen statt mit T rechnen: Summe 117,5 und $\hat{\lambda} = 5/117{,}5 \approx 0{,}0426$. Das Modell beschreibt den Verzug über der Grenze von 2 Stunden.

Bewertung: (a) $E(\bar{X})$ und Zerlegung 1 P, $E\big[\sum_i (X_i - \bar{X})^2\big]$ 1 P, Bias und Erwartungstreue 1 P. (b) MSE-Formel und $n = 2$ 1 P, Mittel über die Schichten mit Deutung 1 P. (c) Herleitung mit Maximum 1 P, $\hat{\lambda}$ 1 P, Standardfehler, Intervall und Deutung 1 P.

Lösung zu Aufgabe 2 Intervalle für Durchmesser und Mangelquote

(a) $\bar{x} = 72/6 = \boxed{12\,\mu\mathrm{m}}$. Die Abweichungen vom Mittelwert sind 4, 13, −3, −2, −9 und −3, ihre Quadrate ergeben 288, also $s^2 = 288/5 = 57{,}6\,\mu\mathrm{m}^2$ und $\mathrm{SE} = \sqrt{57{,}6/6} = \sqrt{9{,}6} \approx 3{,}0984\,\mu\mathrm{m}$. Mit $t_{5;\,0{,}975} = 2{,}571$ ist das Intervall $12 \pm 2{,}571 \cdot 3{,}0984 = 12 \pm 7{,}97$, also $\boxed{4{,}03}$ bis $\boxed{19{,}97\,\mu\mathrm{m}}$. SciPy rechnet mit dem genauen Quantil 2,5706 und erhält 4,04 bis 19,96 µm. Es gilt, wenn die sechs Wellen den Tag zufällig und unabhängig vertreten.

(b) $\hat{p} = 2/50 = 0{,}04$. Wald: SE $= \sqrt{0{,}04 \cdot 0{,}96/50} = \sqrt{0{,}000768} \approx 0{,}02771$ und $1{,}96 \cdot \text{SE} \approx 0{,}05432$, also $\boxed{-1{,}43\,\%}$ bis $\boxed{9{,}43\,\%}$. Eine negative Quote gibt es nicht: Wald legt das Intervall symmetrisch um $\hat{p}$. Wilson: $z^2/n = 0{,}0768$, $z^2/(2n) = 0{,}0384$, $z^2/(4n^2) = 0{,}000384$. Die Mitte ist $0{,}0784/1{,}0768 \approx 0{,}07281$, die halbe Breite $1{,}8202 \cdot \sqrt{0{,}001152} \approx 1{,}8202 \cdot 0{,}03394 \approx 0{,}06178$, also $\boxed{1{,}10\,\%}$ bis $\boxed{13{,}46\,\%}$. Bei 0 Mängeln ist SE $= 0$: Wald liefert $[0, 0]$, als wäre die Quote genau bekannt, und verfehlt jede Quote über 0, weil es den Standardfehler mit $\hat{p}$ statt p rechnet.

(c) $12 \pm 4{,}032 \cdot 3{,}0984 = 12 \pm 12{,}49$, also $\boxed{-0{,}49}$ bis $\boxed{24{,}49\,\mu\text{m}}$, um den Faktor $4{,}032/2{,}571 \approx \boxed{1{,}568}$ breiter. Mit z: $n \geq (1{,}96 \cdot 7{,}59/6)^2 \approx 6{,}15$, also 7 Wellen. Die t-Tabelle widerspricht: $2{,}447 \cdot 7{,}59/\sqrt{7} \approx 7{,}02$ und $2{,}365 \cdot 7{,}59/\sqrt{8} \approx 6{,}35$ sind zu breit, erst $2{,}306 \cdot 7{,}59/\sqrt{9} \approx 5{,}83 \leq 6$. Es braucht $\boxed{9}$ Wellen. Bei wenigen Werten ist das t-Quantil deutlich größer als 1,96.

(d) (i) **Richtig**: Die sechs Werte stammen aus nur drei Schichten, und positiv korrelierte Werte tragen weniger Information, als ihre Zahl verspricht. Der wahre Standardfehler ist größer als $s/\sqrt{n}$, das Intervall trifft seltener als in 95 % der Fälle (Skript 4.7). Für den 30. September selbst ist jede seiner drei Schichten mit zwei Wellen vertreten, dort zählt nur die Streuung innerhalb der Schichten. Darum fragt (i) nach vielen Schichten. (ii) **Richtig**: gleiche Mitte 12 µm, größeres Quantil. (iii) **Falsch**: Die Mitte liegt bei 7,28 %, Wilson zieht sie zu 1/2. (iv) **Falsch**: Auch der neue Mittelwert schwankt. Die Differenz hat die Standardabweichung $\sigma\sqrt{2/n}$, also ist $P(|\bar{X}_2 - \bar{X}_1| \leq 1{,}96\,\sigma/\sqrt{n}) = P(|Z| \leq 1{,}96/\sqrt{2}) = 2\,\Phi(1{,}39) - 1 = 2 \cdot 0{,}9177 - 1 = \boxed{0{,}8354}$. Die 95 % gelten für μ.

> **Typischer Fehler**
> In (a) mit 1,96 statt $t_{5;\,0{,}975} = 2{,}571$ rechnen: $12 \pm 6{,}07$, also 5,93 bis 18,07 µm, zu schmal.

Bewertung: (a) $\bar{x}$, s^2 und Standardfehler 1 P, Intervall 1 P. (b) Wald mit Kritik 1 P, Wilson 1 P. (c) 99-%-Intervall und Faktor 1 P, nötige Zahl der Wellen 1 P. (d) vier Aussagen mit Begründung 2 P.

Lösung zu Aufgabe 3 Testlogik und Teststärke

(a) H_0: $\mu = 25{,}000\,\text{mm}$, H_1: $\mu \neq 25{,}000\,\text{mm}$. **Fehler erster Art**: M-03 steht richtig, der Test schlägt trotzdem an. Das kostet eine Stunde Stillstand und Stückzahl. **Fehler zweiter Art**: M-03 ist verstellt, der Test merkt es nicht. Bis zur nächsten Prüfung fallen mehr Wellen aus der Toleranz. Mit $\alpha = 10\,\%$ wächst die Teststärke, verstellte Maschinen fallen öfter auf. Dafür halten im Mittel 10 statt 5 von 100 korrekten Wechseln die Maschine unnötig an. Das lohnt sich, wenn die zusätzlichen Fehlalarme weniger kosten als der Ausschuss, den die zusätzlich entdeckten Verstellungen ersparen. Das legt das Werk vorher fest.

(b) Das 95-%-Intervall enthält 0 nicht, also **verwirft** der Test zum Niveau 5 %. Das 99-%-Intervall enthält 0, zum Niveau 1 % verwirft er **nicht**. Bestätigung: $t = 12/3{,}0984 \approx \boxed{3{,}87}$ mit $2{,}571 < 3{,}87 < 4{,}032$, also $0{,}01 < p < 0{,}05$. Beide vergleichen $|\bar{x} - \mu_0|$ mit derselben Schranke $t_{5;\,0{,}975} \cdot \text{SE}$. Nicht verworfen wird genau für die μ_0 im 95-%-Intervall, also für Abweichungen von 4,03 bis 19,97 µm.

(c) $\text{SE} = 12/\sqrt{16} = 3\,\mu\text{m}$, der Test verwirft ab $|\bar{x} - 25{,}000\,\text{mm}| > 1{,}96 \cdot 3 = \boxed{5{,}88\,\mu\text{m}}$. Unter H_1 ist $\bar{x} - 25{,}000\,\text{mm}$ normalverteilt mit Mitte 6 µm und SE = 3 µm:

$$1 - \beta = 1 - \Phi\Big(\frac{5{,}88 - 6}{3}\Big) + \Phi\Big(\frac{-5{,}88 - 6}{3}\Big) = \Phi(0{,}04) + \Phi(-3{,}96) \approx 0{,}5160 + 0{,}0000 = \boxed{0{,}5160}.$$

$\Phi(-3{,}96)$ ist kleiner als $1-\Phi(3{,}50)=0{,}0002$. Also ist $\beta\approx 0{,}4840$: Eine Verstellung um 6 µm fällt nur in jedem zweiten Fall auf. Im Bild ist A die Fläche α, je $\alpha/2$ in beiden Rändern unter H_0, B ist β und C ist $1-\beta$: die ganze Fläche unter der gestrichelten Kurve rechts von 5,88 µm, auch unter dem rechten Teil von A.

(d) Ohne den zweiten Rand ist $1-\beta\approx\Phi(\delta\sqrt{n}/\sigma - z_{1-\alpha/2})$. Gleichsetzen mit $\Phi(z_{1-\beta})$ ergibt $\delta\sqrt{n}/\sigma = z_{1-\alpha/2}+z_{1-\beta}$, quadriert die Formel. Mit $\alpha=5\,\%$: $(1{,}960+0{,}842)^2\cdot 144/36 = 7{,}851\cdot 4\approx 31{,}4$, also $\boxed{32}$ Wellen. Mit $\alpha=1\,\%$: $(2{,}576+0{,}842)^2\cdot 4 = 11{,}683\cdot 4\approx 46{,}7$, also $\boxed{47}$ Wellen. Aufrunden, sonst reicht die Teststärke nicht.

Typischer Fehler

In (d) für den zweiseitigen Test $z_{0{,}95}=1{,}645$ nehmen: $(1{,}645+0{,}842)^2\cdot 4\approx 24{,}7$, also 25 Wellen, und die Teststärke liegt unter 80 %.

Bewertung: (a) Hypothesen und beide Fehler mit Folgen 1 P, Abwägung von $\alpha=10\,\%$ 1 P. (b) Entscheidungen, t und Bereich 1 P. (c) Grenze 1 P, Teststärke und Flächen 1 P. (d) Begründung und beide Stichprobengrößen 1 P.

Lösung zu Aufgabe 4 Tests von Hand

(a) Vorher: $\bar{x}_1 = 300/4 = 75$, Abweichungen -35, -20, -15 und 70, $s_1^2 = 6.750/3 = 2.250$. Nachher: $\bar{x}_2 = 120/4 = 30$, Abweichungen -15, -10, 5 und 20, $s_2^2 = 750/3 = 250$. Welch: $s_1^2/n_1 = 562{,}5$ und $s_2^2/n_2 = 62{,}5$, Summe 625, SE $= 25$ und $t = 45/25 = \boxed{1{,}80}$.

$$\nu = \frac{625^2}{562{,}5^2/3 + 62{,}5^2/3} = \frac{390.625}{105.468{,}75 + 1.302{,}08} \approx \boxed{3{,}66}.$$

Es ist $t < t_{4;\,0{,}975} = 2{,}776 < t_{3;\,0{,}975} = 3{,}182$, also **kein Nachweis** bei 5 %. Für 3 und 4 Freiheitsgrade liegt 1,80 zwischen dem 0,90- und dem 0,95-Quantil, also ist $0{,}10 < p < 0{,}20$ (SciPy: 0,1529). Student: $s_p^2 = (3\cdot 2.250 + 3\cdot 250)/6 = 1.250$ und SE $= \sqrt{1.250\cdot(1/4+1/4)} = 25$, bei gleich großen Gruppen dasselbe t. Anders sind die Freiheitsgrade, 6 statt 3,66: Fast die ganze Unsicherheit kommt aus den vier Werten vorher. Gepaart sind die Gruppen nicht, jede Störung kommt nur einmal vor.

(b) 40 schlägt 15, 20 und 35, aber nicht 50. 55, 60 und 145 schlagen alle vier. Also $U = 3+12 = \boxed{15}$ von 16 Paaren, erwartet wären 8. Die Ränge von vorher sind 4, 6, 7 und 8. $U=16$ hat nur die Aufteilung mit den Rängen 5 bis 8, $U=15$ nur diese hier. Also $P(U\geq 15) = 2/70$, und wegen der Symmetrie ist $p = 4/70 \approx \boxed{0{,}0571}$. Der Rangtest zählt nur, wer länger stand. Bei Welch bläht der eine Stillstand von 145 Minuten s_1^2 auf 2.250 auf und damit den Standardfehler.

(c) Zeilensummen 138 und 2.688, Spaltensummen je 942, $n = 2.826$. Erwartet sind $138\cdot 942/2.826 = \boxed{46}$ Wellen außerhalb und $2.688\cdot 942/2.826 = 896$ innerhalb, in jeder Schicht. Außerhalb weichen die Zahlen um 7, -6 und -1 ab, innerhalb umgekehrt:

$$\chi^2 = \frac{7^2+6^2+1^2}{46} + \frac{7^2+6^2+1^2}{896} = \frac{86}{46} + \frac{86}{896} \approx 1{,}870 + 0{,}096 = \boxed{1{,}966}$$

mit $(2-1)(3-1) = 2$ Freiheitsgraden. $1{,}966 < \chi^2_{2;\,0{,}95} = 5{,}991$, sogar $< 4{,}605$, also $p > 0{,}10$ (SciPy: 0,374): **kein Nachweis**, dass der Anteil von der Schicht abhängt. Alle erwarteten Häufigkeiten sind mindestens 5. Gleichheit der Schichten zeigt der Test nicht.

(d) $\hat{p}_{\text{L-05}} = 0{,}400$ und $\hat{p}_{\text{L-01}} = 330/1.179 \approx 0{,}2799$, gemeinsam $\hat{p} = 342/1.209 \approx 0{,}2829$. Unter H_0 ist

$$\text{SE}_0 = \sqrt{0{,}2829 \cdot 0{,}7171 \cdot \left(\frac{1}{30} + \frac{1}{1.179}\right)} \approx 0{,}08327, \qquad z = \frac{0{,}1201}{0{,}08327} \approx \boxed{1{,}44},$$

also $p = 2\,(1 - \Phi(1{,}44)) = 2 \cdot 0{,}0749 = \boxed{0{,}1498}$: **kein Nachweis**. Für L-05 sind $30 \cdot 0{,}2829 \approx 8{,}5$ Verspätungen erwartet, die Näherung trägt.

(e) (i) **Einstichproben-t-Test** gegen 25,000 mm, zweiseitig, weil beide Richtungen stören. (ii) **Chi-Quadrat-Unabhängigkeitstest** der Tafel aus fünf Kategorien und zwei Baujahrgruppen mit 4 Freiheitsgraden. (iii) **Mann-Whitney-U**: Er fragt, ob Werte tendenziell kleiner sind, und ist robust gegen lange Verzüge. Welch vergleicht Mittelwerte. (iv) **Fishers exakter Test**: Für die Neue wären nur $150 \cdot 751/72.330 \approx 1{,}6$ Mängel erwartet, zu wenig für die Näherung.

Zum Nachprüfen im Notebook:

```
vorher, nachher = [40, 55, 60, 145], [15, 20, 35, 50]
w = stats.ttest_ind(vorher, nachher, equal_var=False)
u = stats.mannwhitneyu(vorher, nachher)
chi = stats.chi2_contingency([[53, 40, 45], [889, 902, 897]])
print(round(float(w.statistic), 2), round(float(w.df), 2), round(float(w.pvalue), 4))
print(float(u.statistic), round(float(u.pvalue), 4))
print(round(float(chi.statistic), 3), round(float(chi.pvalue), 3))
```

liefert `1.8 3.66 0.1529`, `15.0 0.0571` und `1.966 0.374`.

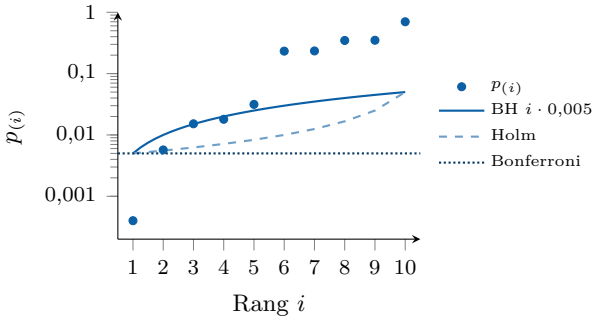
> **Typischer Fehler**
>
> In (b) nur eine Richtung zählen: $p = 2/70 \approx 0{,}0286$ wäre fälschlich signifikant. Wer in (a) Students $\nu = 6$ nimmt, unterschätzt die Unsicherheit der stark streuenden Gruppe.

Bewertung: (a) Kennzahlen und t 1 P, ν 1 P, Entscheidung, p-Bereich und Student 1 P. (b) U 1 P, exakter p-Wert mit Begründung 1 P. (c) erwartete Häufigkeiten und χ^2 1 P, Freiheitsgrade, Entscheidung und Deutung 1 P. (d) z, p-Wert und Entscheidung 1 P. (e) vier Fragen 2 P.

Lösung zu Aufgabe 5 Viele Tests und Relevanz

(a) $1 - 0{,}95^{10} \approx \boxed{0{,}4013}$. Mit Bonferroni sind es nur $1 - 0{,}995^{10} \approx 0{,}0489$. Sortiert, mit den Schwellen $0{,}05/(11 - i)$ für Holm und $i \cdot 0{,}005$ für Benjamini-Hochberg:

i	KW	$p_{(i)}$	Holm	BH
1	30	0,0004	0,0050	0,0050
2	38	0,0057	0,0056	0,0100
3	39	0,0152	0,0063	0,0150
4	35	0,0180	0,0071	0,0200
5	37	0,0315	0,0083	0,0250
6	28	0,2326	0,0100	0,0300



Ohne Korrektur sind **5 Wochen** auffällig: KW 30, 38, 39, 35 und 37. **Bonferroni** mit der Schwelle 0,005: nur KW 30. **Holm**: Schritt 1 gelingt, Schritt 2 scheitert mit $0{,}0057 > 0{,}05/9 \approx 0{,}0056$, also auch nur KW 30. **Benjamini-Hochberg**: Das größte i mit $p_{(i)} \le i \cdot 0{,}005$ ist $i = 4$, denn $0{,}0180 \le 0{,}020$, obwohl $i = 3$ mit $0{,}0152 > 0{,}015$ scheitert. Auffällig sind also KW 30, 38, 39 und 35. Löst jeder Alarm einen Stillstand aus, begrenzt Holm die Familienfehlerrate und

verwirft nie weniger als Bonferroni. Für eine Liste zum Hinsehen passt Benjamini-Hochberg. M-03 liegt über alle Messungen 3,8 µm über dem Sollmaß (Skript 7.1), je Woche ist die Teststärke aber gering (Skript 3.2).

(b) Mit $\mathrm{SE} = \sqrt{(1{,}07^2 + 1{,}02^2)/471} = \sqrt{2{,}1853/471} \approx 0{,}06812$ Prozentpunkten ist

$$z = \frac{0{,}16}{0{,}06812} \approx \boxed{2{,}35}, \qquad p = 2\,(1 - \Phi(2{,}35)) = 2 \cdot 0{,}0094 = \boxed{0{,}0188}.$$

Bei 471 Schichten je Gruppe stimmen Welch und z praktisch überein. Das Intervall ist $0{,}16 \pm 1{,}96 \cdot 0{,}06812$, also $0{,}16 \pm 0{,}13$ oder $\boxed{0{,}03}$ bis $\boxed{0{,}29}$ Prozentpunkte. Mit $s_p = \sqrt{(470 \cdot 1{,}07^2 + 470 \cdot 1{,}02^2)/940} \approx 1{,}05$ ist $d = 0{,}16/1{,}05 \approx \boxed{0{,}15}$, ein kleiner Effekt. In Wellen: $0{,}0003 \cdot 285 \approx 0{,}1$ bis $0{,}0029 \cdot 285 \approx 0{,}8$ Ausschusswellen mehr je Nachtschicht. Mit je 50 Schichten wäre $\mathrm{SE} = \sqrt{2{,}1853/50} \approx 0{,}209$ und $z \approx \boxed{0{,}77}$, $p = 2\,(1 - 0{,}7794) = 0{,}4412$, aber d bliebe 0,15: Signifikanz hängt an n, die Effektstärke nicht. Ob höchstens knapp eine Welle je Nachtschicht eine Maßnahme lohnt, entscheiden die Kosten, nicht der p-Wert. Zur Einheit: Ein z-Test für zwei Anteile aus den Summen (Skript 4.4) behandelte jede der über 285.000 Wellen als unabhängig. Die Wellen einer Schicht teilen aber Einstellung und Material, sein Standardfehler wäre zu klein (Skript 4.7). Die Quoten der Summen, 2,60 und 2,43 %, liegen nahe bei den Mitteln. Früh- und Nachtquote desselben Tages hängen kaum zusammen, ungepaart zu rechnen passt.

(c) $\mathrm{SE} = \sqrt{(0{,}90^2 + 0{,}85^2)/471} = \sqrt{1{,}5325/471} \approx 0{,}05704$, $z = -0{,}03/0{,}05704 \approx -0{,}53$ und $p = 2\,(1 - \Phi(0{,}53)) = \boxed{0{,}5962}$: kein Unterschied nachgewiesen, aber auch keine Gleichheit. TOST mit H_0: $|\Delta| \geq 0{,}15$. Unten: $z = (-0{,}03 + 0{,}15)/0{,}05704 \approx 2{,}10$, $p = 1 - \Phi(2{,}10) = 0{,}0179$. Oben: $z = (-0{,}03 - 0{,}15)/0{,}05704 \approx -3{,}16$, $p = \Phi(-3{,}16) = 0{,}0008$. Der TOST hat $p = \max = \boxed{0{,}0179} < 0{,}05$: Nachts und früh sind an Linie 4 **gleichwertig** im Sinn von $\pm 0{,}15$ Prozentpunkten. Das 90-%-Intervall $-0{,}03 \pm 1{,}645 \cdot 0{,}05704$, also $-0{,}12$ bis $0{,}06$, liegt ganz innerhalb. 90 %, weil jeder einseitige Test 5 % auf seiner Seite nutzt.

Zum Nachprüfen im Notebook:

```
p_kw = [0.2326, 0.2343, 0.0004, 0.3470, 0.3499, 0.0180, 0.7007, 0.0315, 0.0057, 0.0152]
bh = stats.false_discovery_control(p_kw)
print(int((bh < 0.05).sum()), round(float(bh.min()), 4), round(1 - 0.95 ** 10, 4))
```

liefert `4 0.004 0.4013`: vier angepasste p-Werte unter 0,05, der kleinste ist $10 \cdot 0{,}0004$.

> **Typischer Fehler**
>
> In (a) bei Benjamini-Hochberg beim ersten Misserfolg aufhören: Das ergibt 2 statt 4 Wochen. In (b) Cohen d mit dem Standardfehler rechnen: $0{,}16/0{,}06812 \approx 2{,}35$ ist z, nicht d.

Bewertung: (a) Familienfehler 1 P, Bonferroni und Holm 1 P, Benjamini-Hochberg und Wahl des Verfahrens 1 P. (b) Standardfehler, z und p 1 P, Intervall und d 1 P, Umrechnung, 50 Schichten und Deutung 1 P. (c) üblicher Test und TOST 1 P, 90-%-Intervall mit Begründung 1 P.

Lösung zu Aufgabe 6 Woher die Wilson-Formel kommt (Zusatz)

(a) Quadrieren und Ordnen ergibt $(1 + z^2/n)\,p^2 - (2\hat{p} + z^2/n)\,p + \hat{p}^2 \leq 0$. Die Parabel ist nach oben offen, die Ungleichung gilt zwischen den Lösungen

$$p = \frac{2\hat{p} + z^2/n \pm \sqrt{D}}{2\,(1 + z^2/n)}, \qquad D = (2\hat{p} + z^2/n)^2 - 4\,(1 + z^2/n)\,\hat{p}^2 = 4z^2\Big(\frac{\hat{p}\,(1 - \hat{p})}{n} + \frac{z^2}{4n^2}\Big).$$

Mit $\sqrt{D} = 2z\sqrt{\hat{p}(1 - \hat{p})/n + z^2/(4n^2)}$ folgt nach Kürzen die Formel aus Aufgabe 2.

(b) Für $\hat{p} = 0$ sind die Lösungen $(z^2/(2n) \pm z^2/(2n))/(1 + z^2/n)$, also 0 und $\boxed{z^2/(n + z^2)}$. Mit $z^2 = 3{,}8416$: für $n = 20$ ist $3{,}8416/23{,}8416 \approx 0{,}1611$ gegen $z^2/n \approx 0{,}1921$, für $n = 200$ ist es 0,0188 gegen 0,0192. Für großes n ist die obere Grenze etwa $3{,}84/n$.

(c) Die Mitte ist $\frac{n\hat{p}+z^2/2}{n+z^2} = w\,\hat{p} + (1 - w) \cdot \frac{1}{2}$ mit $w = n/(n + z^2)$ zwischen 0 und 1, also liegt sie zwischen $\hat{p}$ und 1/2. Nach Vieta ist das Produkt der Lösungen $\hat{p}^2/(1 + z^2/n) \geq 0$ und ihre Summe $(2\hat{p} + z^2/n)/(1 + z^2/n) > 0$. Beide Lösungen sind also nicht negativ, die untere Grenze ist $\boxed{\geq 0}$. Mit $1 - p$ statt p folgt ebenso, dass die obere Grenze höchstens 1 ist.