Tutoriumsblatt 7

Lineare Regression

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- kleinste Quadrate von Hand rechnen und herleiten, Regressionstabellen und Residuen deuten,
- Vorhersagen mit Intervallen machen, außerhalb der Stichprobe prüfen und begründen, welche Größen ins Modell gehören.

So arbeitest du mit dem Blatt

Du programmierst nicht: Du rechnest mit dem Taschenrechner und der Tabelle unten und begründest, Zwischenwerte genauer, als du sie angibst. Hängst du, rechnest du mit den Werten unter „Zur Kontrolle“ weiter. Werkszahlen stammen aus `daten/` und dem Skript, „ausgedacht“ heißt fiktiv. Eine Quote ist die Ausschussquote einer Schicht in Prozent. Nachtschichten sind kleiner geplant (Datenblatt): Aufgabe 1, 2 und 5 nutzen nur Tagschichten, Modelle mit allen Schichten geben der Nacht einen Koeffizienten. Zum Notebook: Aufgabe 1 gehört zu TODO 1 und 2; Aufgabe 2 zu 3 bis 5; Aufgabe 3 zu 6 bis 9; Aufgabe 4 zu 8 und 10; Aufgabe 5 zu 11 bis 13.

Tabelle für alle Aufgaben
Quantile $t_{\nu;\,q}$ der t-Verteilung, Zeile ∞:
Quantile z_q der Standardnormalverteilung.

q	$\nu = 2$	3	4	5	6	∞
0,95	2,920	2,353	2,132	2,015	1,943	1,645
0,975	4,303	3,182	2,776	2,571	2,447	1,960

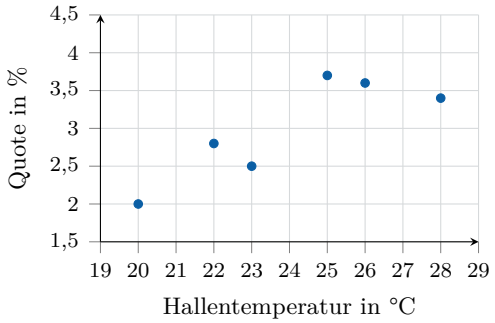
Aufgabe 1 Kleinste Quadrate von Hand

9 Punkte · etwa 20 Min.

Bezug: Modul 7, Lerneinheit 1 (Eine Gerade durch die Punktwolke)

In Linie 2, der Gehäusefertigung, steigt die Ausschussquote mit der Hallentemperatur. Die Tabelle zeigt sechs Tagschichten aus dem ersten Jahr, Oktober 2024 bis September 2025 (ausgedacht): Hallentemperatur x_i in °C und Quote y_i in Prozent.

x_i (°C)	20	22	23	25	26	28
y_i (%)	2,0	2,8	2,5	3,7	3,6	3,4



(a) Leite aus $Q(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$ durch Ableiten die beiden Normalgleichungen her und begründe mit der Hesse-Matrix, dass dort ein Minimum liegt. Zeige damit für die Residuen $e_i = y_i - \hat{y}_i$: $\sum_i e_i = 0$, $\sum_i x_i e_i = 0$, und die Gerade geht durch $(\bar{x}, \bar{y})$. Folgere $\hat{\beta}_1 = \sum_i (x_i - \bar{x})(y_i - \bar{y}) / \sum_i (x_i - \bar{x})^2$. [3 P]

(b) Berechne $\bar{x}$, $\bar{y}$, $\hat{\beta}_1$ und $\hat{\beta}_0$, die Vorhersagen und die Residuen, und prüfe die beiden Summen aus (a). Deute $\hat{\beta}_1$ und $\hat{\beta}_0$ mit Einheit. Zeichne die Gerade und die Residuen ins Bild. Zur Kontrolle: $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 8{,}4$. [3 P]

(c) Berechne SST, SSE, SSR, das Bestimmtheitsmaß R^2 und den Korrelationskoeffizienten r nach Pearson. Zur Kontrolle: SSE = 0,62. [2 P]

(d) Zeige mit (a), dass SST = SSR + SSE gilt, und folgere $R^2 = r^2$ für eine Einflussgröße. Tipp: $\hat{y}_i - \bar{y} = \hat{\beta}_1(x_i - \bar{x})$. [1 P]

Aufgabe 2 Matrixform und Kategorien

8 Punkte · etwa 16 Min.

Bezug: Modul 7, Lerneinheiten 2 (Mehrere Einflüsse gleichzeitig) und 3 (Kategorien und Wechselwirkungen)

Linie 3 hat weniger Ausschuss als Linie 1, ist aber auch geringer ausgelastet. Wie groß ist der Unterschied bei gleicher Auslastung? Sechs Frühschichten (ausgedacht), u_i ist die Auslastung minus 85 % in Prozentpunkten, $\mathrm{L3}_i = 1$ für Linie 3, sonst 0. Das Modell ist $y_i = \beta_0 + \beta_1 u_i + \beta_2 \,\mathrm{L3}_i + \varepsilon_i$.

Linie	1	1	1	3	3	3
Auslastung (%)	85	90	95	75	80	85
u_i	0	5	10	−10	−5	0
Quote y_i (%)	2,5	2,4	2,9	1,1	1,6	1,5

(a) Schreibe die Designmatrix X und den Vektor y auf und berechne $X^\top X$ und $X^\top y$. Zur Kontrolle: $X^\top y = (12{,}0;\ 22;\ 4{,}2)^\top$. [2 P]

(b) Löse die Normalgleichungen $X^\top X\,\hat{\beta} = X^\top y$ von Hand. Tipp: Drücke mit der ersten und der dritten Gleichung $\hat{\beta}_0$ und $\hat{\beta}_2$ durch $\hat{\beta}_1$ aus. Deute die drei Koeffizienten mit Einheit. [2 P]

(c) Eine Kollegin nimmt zusätzlich die Spalte $\mathrm{L1}_i = 1 - \mathrm{L3}_i$ für Linie 1 auf. Begründe über den Rang von X, warum $X^\top X$ dann nicht invertierbar ist. `lstsq` liefert für die Spalten Einsen, u, L1 und L3 ohne Warnung (1,333; 0,040; 1,067; 0,267). Zeige, dass diese Koeffizienten dieselben Vorhersagen ergeben wie (b). Warum sind 1,067 und 0,267 keine Abstände zu einer Referenz? [2 P]

(d) Mach Linie 3 zur Referenz, mit den Spalten Einsen, u und L1. Gib die neuen Koeffizienten ohne neue Rechnung an. Was ändert sich, was bleibt gleich? Ohne u ist der Koeffizient $\tilde{\beta}_2$ von L3 der Unterschied der Linienmittel. Berechne ihn und bestätige $\tilde{\beta}_2 = \hat{\beta}_2 + \hat{\beta}_1\hat{\delta}$, wobei $\hat{\delta}$ das mittlere u von Linie 3 minus das von Linie 1 ist. Welcher Anteil des Unterschieds verschwindet beim Vergleich bei gleicher Auslastung? [2 P]

Aufgabe 3 Eine Regressionstabelle deuten

8 Punkte · etwa 17 Min.

Bezug: Modul 7, Lerneinheiten 3 (Kategorien und Wechselwirkungen) und 4 (Wie sicher sind die Koeffizienten?)

Die Qualitätssicherung vergleicht die Linien 1 und 2 in Halle 1 mit allen 2.894 Schichten: (1) `quote ~ temp_z * C(linie) + ausl_z + nacht` und (2) dasselbe für ln(Quote) mit den 2.882 Schichten, die Ausschuss hatten. `temp_z` ist die Hallentemperatur minus 21 °C, `ausl_z` die Auslastung minus 0,85, `nacht` ist 1 für Nachtschichten. Referenz ist eine Tagschicht von Linie 1. Mittlere Quote: Linie 1 2,50 %, Linie 2 2,98 %.

	(1) Quote in %		(2) ln(Quote)	
	b	SE	*b*	SE
Achsenabschnitt	1,9614	0,0488	0,5944	0,0201
Linie 2	0,6421	0,0556	0,2480	0,0229
`temp_z`	0,2123	0,0202	0,0877	0,0083
`temp_z` × Linie 2	0,0342	0,0270	0,0020	0,0111
`ausl_z`	5,0733	0,4417	2,0996	0,1821
`nacht`	0,7369	0,0639	0,3049	0,0264
Schichten; R^2	2.894; 0,127		2.882; 0,111	

b Koeffizient, SE Standardfehler

(a) Deute in Modell (1) den Achsenabschnitt und die Koeffizienten von Linie 2, `ausl_z` und `nacht` mit Einheit und „bei sonst gleichen“. Rechne `ausl_z` auf 10 Prozentpunkte Auslastung um. Was sagt $R^2 = 0{,}127$, was nicht? [2 P]

(b) Wie stark steigt die Quote je Grad in Linie 1, wie stark in Linie 2? Unterscheiden sich die Steigungen (Niveau 5 %)? Berechne dazu den t-Wert der Wechselwirkung. Um wie viel liegt Linie 2 bei 25 °C über Linie 1? Berechne für `nacht` den t-Wert und das 95-%-Intervall. [2 P]

(c) Mit der Temperatur in °C und der Auslastung als Anteil, also ohne Zentrieren, ändern sich in Modell (1) nur der Achsenabschnitt und der Koeffizient von Linie 2. Berechne beide aus der Tabelle. Was beschreiben sie dann, und warum taugen sie kaum zum Deuten? [2 P]

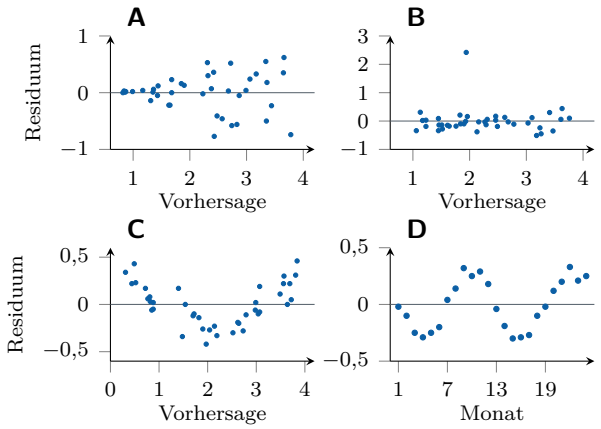
(d) Übersetze in Modell (2) die Temperatursteigung beider Linien und den Nachtkoeffizienten in Prozent, exakt mit $100\,(e^{b}-1)$ und genähert mit $100\,b$, jeweils aus den Koeffizienten der Tabelle und auf zwei Nachkommastellen. Wann reicht die Näherung? Warum ist die Steigung von Linie 2 in Modell (1) größer als die von Linie 1, in Modell (2) aber kaum? [2 P]

Aufgabe 4 Residuen und Diagnose

7 Punkte · etwa 15 Min.

Bezug: Modul 7, Lerneinheit 5 (Residuen lesen: Annahmen und Diagnose)

Die Bilder zeigen Residuen von vier Modellen der Qualitätssicherung (ausgedacht). A bis C tragen sie gegen die Vorhersage in Prozent auf, D die Monatsmittel gegen den Monat, 1 ist Oktober 2024.



(a) Ordne jedem Bild eines der Probleme Krümmung, Trichter, Zeitmuster und Ausreißer zu. Welche Annahme aus Skript 5.1 ist jeweils verletzt? Was folgt für Koeffizienten und Standardfehler, und was tust du? [3 P]

(b) Zurück zu den sechs Schichten aus Aufgabe 1. Berechne die Hebelwerte h_i, ihre Summe und ihren Mittelwert und den Cook-Abstand D_i der Schicht mit 28 °C, mit $\hat\sigma^2 = \mathrm{SSE}/(n-2) = 0{,}155$:

$$h_i = \frac{1}{n} + \frac{(x_i - \bar x)^2}{\sum_j (x_j - \bar x)^2}, \qquad D_i = \frac{e_i^2}{(p+1)\,\hat\sigma^2} \cdot \frac{h_i}{(1-h_i)^2}.$$

Die Schicht mit 25 °C hat das größte Residuum, aber nur $D = 0{,}23$. Deute beide Werte. Was tust du mit der Schicht bei 28 °C? [2 P]

(c) Für Linie 1 regressiert die Qualitätssicherung mit 1.447 Schichten `quote` auf `hallentemp_c`, `nacht`, `auslastung` und zusätzlich `temp_l2`, die Temperatur am Logger von Linie 2, der in derselben Halle an anderer Stelle misst. Die Regressionen der beiden Temperaturen auf die übrigen Größen haben $R^2 = 0{,}8788$ (eigene) und 0,8773 (Linie 2). Berechne beide VIF auf zwei Nachkommastellen und den Faktor, um den ihre Standardfehler wachsen, auf eine. Ohne `temp_l2` hat die eigene Temperatur den VIF 1,22 und den Standardfehler 0,0180, mit `temp_l2` 0,0468. Passt das? Beide Modelle haben $R^2 = 0{,}111$. Was folgt für Vorhersagen, und welche Temperatur gehört ins Modell? [2 P]

Aufgabe 5 Vorhersage und Kausalität

8 Punkte · etwa 21 Min.

Bezug: Modul 7, Lerneinheiten 6 (Vorhersagen und ihre Grenzen) und 7 (Regression ist keine Kausalität)

(a) Die Qualitätssicherung will für eine Tagschicht von Linie 2 bei $x_0 = 27\,°\text{C}$ die Quote vorhersagen, mit der Geraden aus Aufgabe 1 und $\hat{\sigma}^2 = 0{,}155$. Berechne $\hat{y}_0$ und mit

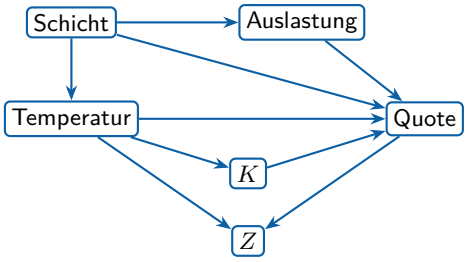
$$\text{SE}_{\text{Mittel}} = \hat{\sigma}\sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_j (x_j - \bar{x})^2}}, \qquad \text{SE}_{\text{einzeln}} = \hat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_j (x_j - \bar{x})^2}}$$

das 95-%-Konfidenzintervall für den Mittelwert solcher Schichten und das 95-%-Vorhersageintervall für eine einzelne. Wie groß wären die halben Breiten beider Intervalle mit 600 Schichten, je 100 bei jeder der sechs Temperaturen, gleichem $\hat{\sigma}$ und dem Quantil 1,96? Warum schrumpft das Vorhersageintervall nicht gegen null? [3 P]

(b) Fünf Tagschichten von Linie 2 aus dem zweiten Jahr (ausgedacht) prüfen die Gerade aus Aufgabe 1 gegen das Vergleichsmodell „Mittelwert der sechs Schichten aus Aufgabe 1“, also 3,0 %. Die Schichten hatten 21, 26, 22, 27 und 25 °C und die Quoten 2,5; 3,3; 2,4; 2,6 und 3,3 %. Berechne MAE und RMSE beider Modelle. Welches Modell gewinnt nach welchem Maß, und warum widersprechen sich die Maße? Welches Maß passt, wenn eine große Fehlprognose teurer ist als mehrere kleine? Was spricht gegen eine Entscheidung allein mit diesen Schichten? [2 P]

(c) Ein Polynom fünften Grades in der Temperatur geht durch alle sechs Punkte aus Aufgabe 1. Wie groß sind SSE, R^2 und $\hat{\sigma}^2$? Warum ist es trotzdem das schlechtere Modell? [1 P]

Die Werksleitung überlegt, Halle 1 zu kühlen. Der Graph zeigt die Annahmen der Qualitätssicherung zur Quote von Linie 1: K ist die Temperatur des Kühlschmierstoffs an den Drehmaschinen, Z die Zahl der Zusatzprüfungen, die sie nach einer Schicht bei Hitze oder viel Ausschuss anordnet.



(d) Die Werksleitung will mit einer Regression der Quote auf die Temperatur die Wirkung einer Kühlung abschätzen. Welche der Größen Schicht, Auslastung, K und Z muss das Modell enthalten, welche darf es enthalten, welche nicht? Begründe mit dem Graphen. [2 P]

Aufgabe 6 (⋆) Die Formel der ausgelassenen Variable

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 7, Lerneinheit 2

Das lange Modell hat die Koeffizienten $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ und die Residuen e_i, das kurze ohne x_2 die Steigung $\tilde{\beta}_1 = \sum_i (x_{1i} - \bar{x}_1)\, y_i / \sum_i (x_{1i} - \bar{x}_1)^2$. (a) Begründe mit den Normalgleichungen des langen Modells, dass $\sum_i (x_{1i} - \bar{x}_1)\, e_i = 0$ ist. (b) Setze $y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + e_i$ ein und zeige $\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}$, wobei $\hat{\delta}$ die Steigung der Regression von x_2 auf x_1 ist. (c) Zeige: Ist x_1 eine 0-1-Variable, sind $\tilde{\beta}_1$ und $\hat{\delta}$ die Unterschiede der Gruppenmittel von y und x_2. Das rechtfertigt die Rechnung in Aufgabe 2(d).

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Kleinste Quadrate von Hand

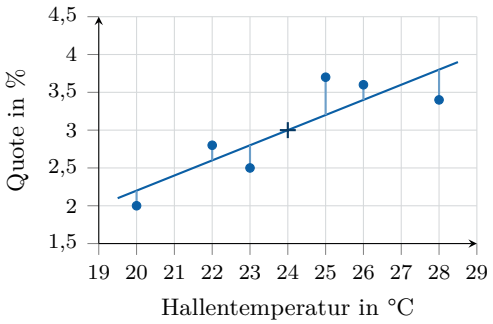
(a) Die partiellen Ableitungen müssen null sein:

$$\frac{\partial Q}{\partial \beta_0} = -2\sum_i (y_i - \beta_0 - \beta_1 x_i) = 0, \qquad \frac{\partial Q}{\partial \beta_1} = -2\sum_i x_i\,(y_i - \beta_0 - \beta_1 x_i) = 0,$$

also die **Normalgleichungen** $\sum_i y_i = n\beta_0 + \beta_1 \sum_i x_i$ und $\sum_i x_i y_i = \beta_0 \sum_i x_i + \beta_1 \sum_i x_i^2$. Die Hesse-Matrix $2\left(\begin{smallmatrix} n & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 \end{smallmatrix}\right)$ hat oben links $2n > 0$ und die Determinante $4(n\sum_i x_i^2 - (\sum_i x_i)^2) = 4n\sum_i (x_i - \bar{x})^2 > 0$, sobald nicht alle x_i gleich sind. Sie ist positiv definit, es ist ein **Minimum**. An der Lösung ist $y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = e_i$, die Gleichungen lauten also $\boxed{\sum_i e_i = 0}$ und $\boxed{\sum_i x_i e_i = 0}$. Die erste geteilt durch n ergibt $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$: Die Gerade geht durch $(\bar{x}, \bar{y})$. Mit $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ wird die zweite zu $\sum_i x_i\,(y_i - \bar{y} - \hat{\beta}_1 (x_i - \bar{x})) = 0$. Weil $\sum_i (y_i - \bar{y}) = \sum_i (x_i - \bar{x}) = 0$ ist, darf man x_i durch $x_i - \bar{x}$ ersetzen und erhält die Formel für $\hat{\beta}_1$.

(b) $\bar{x} = 144/6 = 24\,°\text{C}$ und $\bar{y} = 18{,}0/6 = 3{,}0\,\%$. Die Abweichungen sind -4, -2, -1, 1, 2, 4 und $-1{,}0$; $-0{,}2$; $-0{,}5$; 0,7; 0,6; 0,4. Die Produkte 4,0; 0,4; 0,5; 0,7; 1,2 und 1,6 ergeben 8,4, die Quadrate der x-Abweichungen 42. Also $\hat{\beta}_1 = 8{,}4/42 = \boxed{0{,}2}$ und $\hat{\beta}_0 = 3{,}0 - 0{,}2 \cdot 24 = \boxed{-1{,}8}$.

Die Vorhersagen sind 2,2; 2,6; 2,8; 3,2; 3,4 und 3,8, die Residuen $-0{,}2$; 0,2; $-0{,}3$; 0,5; 0,2 und $-0{,}4$. Sie ergeben die Summe 0, und $\sum_i x_i e_i = -4 + 4{,}4 - 6{,}9 + 12{,}5 + 5{,}2 - 11{,}2 = 0$. **Deutung**: Je Grad wärmer hatten diese Schichten im Mittel 0,2 Prozentpunkte mehr Ausschuss. $\hat{\beta}_0 = -1{,}8\,\%$ ist der Wert der Geraden bei 0 °C, weit außerhalb der Daten und als Quote unmöglich. Er legt nur die Lage der Geraden fest. Alle 482 Tagschichten von Linie 2 im ersten Jahr ergeben 0,22 Prozentpunkte je Grad.



(c) $\text{SST} = \sum_i (y_i - \bar{y})^2 = 1{,}00 + 0{,}04 + 0{,}25 + 0{,}49 + 0{,}36 + 0{,}16 = \boxed{2{,}30}$, $\text{SSE} = \sum_i e_i^2 = 0{,}04 + 0{,}04 + 0{,}09 + 0{,}25 + 0{,}04 + 0{,}16 = \boxed{0{,}62}$ und $\text{SSR} = \sum_i (\hat{y}_i - \bar{y})^2 = 0{,}2^2 \cdot 42 = \boxed{1{,}68} = 2{,}30 - 0{,}62$. Also $R^2 = 1 - 0{,}62/2{,}30 \approx \boxed{0{,}7304}$ und $r = 8{,}4/\sqrt{42 \cdot 2{,}30} = 8{,}4/\sqrt{96{,}6} \approx \boxed{0{,}8547}$ mit $r^2 \approx 0{,}7304 = R^2$. Die Temperatur erklärt bei diesen sechs Schichten 73 % der Streuung, bei den 482 Tagschichten nur 7 %: Einzelne Schichtquoten streuen stark um die Gerade.

(d) Mit $e_i = y_i - \hat{y}_i$ ist $\text{SST} = \sum_i (e_i + \hat{y}_i - \bar{y})^2 = \text{SSE} + 2\sum_i e_i\,(\hat{y}_i - \bar{y}) + \text{SSR}$. Der mittlere Summand ist $2\hat{\beta}_1\left(\sum_i x_i e_i - \bar{x}\sum_i e_i\right) = 0$ nach (a). Mit $\text{SSR} = \hat{\beta}_1^2 \sum_i (x_i - \bar{x})^2$ und der Formel für $\hat{\beta}_1$ folgt

$$R^2 = \frac{\text{SSR}}{\text{SST}} = \frac{\left(\sum_i (x_i - \bar{x})(y_i - \bar{y})\right)^2}{\sum_i (x_i - \bar{x})^2 \cdot \sum_i (y_i - \bar{y})^2} = \boxed{r^2}.$$

Typischer Fehler

In (b) die Summen nicht zentrieren: $\sum_i x_i y_i / \sum_i x_i^2 = 440{,}4/3.498 \approx 0{,}126$ ist die Steigung einer Geraden durch den Nullpunkt, als fehlte die Spalte aus Einsen.

Bewertung: (a) Normalgleichungen und Minimum 1 P, Summen der Residuen und Schwerpunkt 1 P, Formel für $\hat{\beta}_1$ 1 P. (b) Mittelwerte und Koeffizienten 1 P, Vorhersagen, Residuen und Summen 1 P, Deutung und Bild 1 P. (c) Quadratsummen 1 P, R^2 und r 1 P. (d) Zerlegung und $R^2 = r^2$ 1 P.

Lösung zu Aufgabe 2 Matrixform und Kategorien

(a) Mit den Spalten Einsen, u und L3 und $y = (2{,}5;\ 2{,}4;\ 2{,}9;\ 1{,}1;\ 1{,}6;\ 1{,}5)^\top$:

$$X = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 5 & 0 \\ 1 & 10 & 0 \\ 1 & -10 & 1 \\ 1 & -5 & 1 \\ 1 & 0 & 1 \end{pmatrix}, \qquad X^\top X = \boxed{\begin{pmatrix} 6 & 0 & 3 \\ 0 & 250 & -15 \\ 3 & -15 & 3 \end{pmatrix}}, \qquad X^\top y = \boxed{\begin{pmatrix} 12{,}0 \\ 22 \\ 4{,}2 \end{pmatrix}}.$$

Die Einträge sind $n = 6$, $\sum_i u_i = 0$, $\sum_i \mathrm{L3}_i = 3$, $\sum_i u_i^2 = 250$, $\sum_i u_i \mathrm{L3}_i = -15$ und $\sum_i \mathrm{L3}_i^2 = 3$, rechts $\sum_i y_i = 12{,}0$, $\sum_i u_i y_i = 12 + 29 - 11 - 8 = 22$ und die Summe der Quoten von Linie 3.

(b) Die Gleichungen lauten (I) $6\hat{\beta}_0 + 3\hat{\beta}_2 = 12{,}0$, (II) $250\hat{\beta}_1 - 15\hat{\beta}_2 = 22$ und (III) $3\hat{\beta}_0 - 15\hat{\beta}_1 + 3\hat{\beta}_2 = 4{,}2$. Aus (I) folgt $\hat{\beta}_2 = 4 - 2\hat{\beta}_0$, eingesetzt in (III)/3: $\hat{\beta}_0 - 5\hat{\beta}_1 + 4 - 2\hat{\beta}_0 = 1{,}4$, also $\hat{\beta}_0 = 2{,}6 - 5\hat{\beta}_1$ und $\hat{\beta}_2 = -1{,}2 + 10\hat{\beta}_1$. In (II): $250\hat{\beta}_1 + 18 - 150\hat{\beta}_1 = 22$, also $\hat{\beta}_1 = \boxed{0{,}04}$, $\hat{\beta}_0 = \boxed{2{,}4}$ und $\hat{\beta}_2 = \boxed{-0{,}8}$. **Deutung**: Eine Frühschicht von Linie 1 bei 85 % Auslastung hat im Modell 2,4 % Ausschuss. Bei gleicher Linie geht jeder Prozentpunkt Auslastung mit 0,04 Prozentpunkten mehr Ausschuss einher, 0,4 je 10 Prozentpunkte. Bei gleicher Auslastung liegt Linie 3 um 0,8 Prozentpunkte unter Linie 1.

(c) In jeder Zeile ist $\mathrm{L1}_i + \mathrm{L3}_i = 1$, die Spalte der Einsen ist die Summe zweier anderer. Die vier Spalten sind linear abhängig, X hat nur **Rang 3**, ebenso die 4×4-Matrix $X^\top X$, deren Determinante 0 ist. Unendlich viele β minimieren Q. Probe: Linie 1 hat $1{,}333 + 1{,}067 + 0{,}04\,u = 2{,}4 + 0{,}04\,u$, Linie 3 hat $1{,}333 + 0{,}267 + 0{,}04\,u = 1{,}6 + 0{,}04\,u$, genau wie in (b) mit $2{,}4 - 0{,}8 = 1{,}6$. Jede Wahl $(2{,}4 - c;\ 0{,}04;\ c;\ c - 0{,}8)$ passt gleich gut. Bestimmt sind nur die Linienwerte 2,4 und 1,6 bei $u = 0$ und ihr Unterschied $0{,}267 - 1{,}067 = \boxed{-0{,}8}$. `lstsq` wählt den kürzesten Vektor, hier $c = 1{,}067$. Die beiden Werte sind Abstände zu der künstlichen Größe 1,333, die keine Linie beschreibt.

(d) Mit Linie 3 als Referenz: Achsenabschnitt $2{,}4 - 0{,}8 = \boxed{1{,}6}$, Steigung $\boxed{0{,}04}$, Koeffizient von L1 $\boxed{+0{,}8}$. Gleich bleiben Vorhersagen, Residuen, SSE, R^2 und die Steigung. Der Achsenabschnitt beschreibt jetzt Linie 3 bei 85 %, der Abstand wechselt das Vorzeichen. Ohne u: Linie 1 hat im Mittel $7{,}8/3 = 2{,}6$ %, Linie 3 $4{,}2/3 = 1{,}4$ %, also $\tilde{\beta}_2 = \boxed{-1{,}2}$. Die mittlere Auslastung liegt in Linie 3 bei $u = -5$, in Linie 1 bei 5, also $\hat{\delta} = -10$ und $\hat{\beta}_2 + \hat{\beta}_1\hat{\delta} = -0{,}8 + 0{,}04 \cdot (-10) = -1{,}2$. **Ein Drittel**, 0,4 von 1,2 Prozentpunkten, verschwindet bei gleicher Auslastung: So viel hängt rechnerisch an der geringeren Auslastung von Linie 3, eine Ursache belegt die Zerlegung nicht. Mit allen Schichten der Linien 1 und 3 zeigt sich dieselbe Richtung: −0,88 ohne und −0,79 mit Auslastung.

Zum Nachprüfen im Notebook:

```
X = np.array([[1, 0, 1, 0], [1, 5, 1, 0], [1, 10, 1, 0],
              [1, -10, 0, 1], [1, -5, 0, 1], [1, 0, 0, 1]], dtype=float)
y = np.array([2.5, 2.4, 2.9, 1.1, 1.6, 1.5])
print(np.linalg.matrix_rank(X), np.linalg.lstsq(X, y, rcond=None)[0].round(3))
X3 = X[:, [0, 1, 3]]
print(np.linalg.solve(X3.T @ X3, X3.T @ y).round(3))
```

liefert `3 [1.333 0.04  1.067 0.267]` und `[ 2.4   0.04 -0.8 ]`.

> **Typischer Fehler**
> In (d) $\hat{\delta}$ falsch herum nehmen, Linie 1 minus Linie 3: $-0{,}8 + 0{,}04 \cdot 10 = -0{,}4$ trifft den Unterschied der Linienmittel nicht. $\hat{\delta}$ ist die Steigung der Regression der ausgelassenen Größe u auf L3.

Bewertung: (a) X und $X^\top X$ 1 P, $X^\top y$ 1 P. (b) Lösung des Systems 1 P, Deutung 1 P. (c) Rang und Begründung 1 P, gleiche Vorhersagen und Deutung von `lstsq` 1 P. (d) neue Referenz 1 P, Verzerrung mit Anteil 1 P.

Lösung zu Aufgabe 3 Eine Regressionstabelle deuten

(a) **Achsenabschnitt**: Für eine Tagschicht von Linie 1 bei 21 °C und 85 % Auslastung sagt das Modell im Mittel 1,96 % Ausschuss voraus. **Linie 2**: Bei 21 °C und sonst gleicher Auslastung und Schichtart liegt Linie 2 um 0,64 Prozentpunkte über Linie 1. Wegen der Wechselwirkung gilt der Abstand nur bei 21 °C. **`ausl_z`**: Bei gleicher Linie, Temperatur und Schichtart gehen 10 Prozentpunkte mehr Auslastung mit $0{,}1 \cdot 5{,}0733 \approx \boxed{0{,}51}$ Prozentpunkten mehr Ausschuss einher. **`nacht`**: Eine Nachtschicht liegt bei gleicher Linie, Temperatur und Auslastung 0,74 Prozentpunkte über einer Tagschicht. R^2: Das Modell erklärt 12,7 % der Streuung der Schichtquoten, der Rest ist vor allem der Zufall der einzelnen Schicht. Wie genau die Koeffizienten sind, zeigen die Standardfehler, nicht R^2. Ob das Modell die richtige Form hat oder eine Ursache beschreibt, sagt R^2 auch nicht.

(b) Linie 1: $\boxed{0{,}2123}$ Prozentpunkte je Grad, Linie 2: $0{,}2123 + 0{,}0342 = \boxed{0{,}2465}$. Für die Wechselwirkung ist $t = 0{,}0342/0{,}0270 \approx \boxed{1{,}27} < 1{,}96$: **kein Nachweis**, dass sich die Steigungen unterscheiden. Gleichheit ist damit nicht gezeigt. Bei 25 °C ist `temp_z` $= 4$, Linie 2 liegt um $0{,}6421 + 4 \cdot 0{,}0342 \approx \boxed{0{,}78}$ Prozentpunkte über Linie 1. Für `nacht` ist $t = 0{,}7369/0{,}0639 \approx \boxed{11{,}53}$. Mit $2.894 - 6 = 2.888$ Freiheitsgraden ist das Quantil praktisch 1,960, das Intervall $0{,}7369 \pm 1{,}96 \cdot 0{,}0639 = 0{,}7369 \pm 0{,}1252$ reicht von $\boxed{0{,}612}$ bis $\boxed{0{,}862}$ Prozentpunkten. Nachts liegt die Quote bei sonst gleichen Größen deutlich höher.

(c) Mit `temp_z` = Temperatur − 21 und `ausl_z` = Auslastung − 0,85 wandert alles, was mit 21 und 0,85 multipliziert wird, in die Konstanten: $1{,}9614 - 21 \cdot 0{,}2123 - 0{,}85 \cdot 5{,}0733 = 1{,}9614 - 4{,}4583 - 4{,}3123 \approx \boxed{-6{,}81}$ und $0{,}6421 - 21 \cdot 0{,}0342 \approx \boxed{-0{,}08}$. Steigungen und `nacht` bleiben. Der Achsenabschnitt ist dann die Vorhersage für eine Tagschicht von Linie 1 bei 0 °C und Auslastung 0, der Koeffizient von Linie 2 der vorhergesagte Abstand der Linien bei 0 °C. Beides liegt weit außerhalb der Daten: Halle 1 hatte 18,9 bis 28,9 °C, die Auslastung lag zwischen 0,61 und 0,99. Eine negative Quote gibt es nicht, und der Abstand der Linien hätte sogar das andere Vorzeichen. statsmodels liefert mit den rohen Größen ebenfalls −6,81 und −0,08.

(d) Linie 1: $100\,(e^{0{,}0877} - 1) \approx \boxed{9{,}17\,\%}$ je Grad statt genähert 8,77 %. Linie 2: $b = 0{,}0877 + 0{,}0020 = 0{,}0897$, also $\boxed{9{,}38\,\%}$ statt 8,97 %. Nacht: $100\,(e^{0{,}3049} - 1) \approx \boxed{35{,}65\,\%}$ mehr Ausschuss statt genähert 30,49 %. Die Näherung reicht für $|b|$ bis etwa 0,1, bei 0,30 liegt sie schon gut 5

Prozentpunkte daneben. In Modell (1) geht die Temperatur additiv ein. Linie 2 hat mehr Ausschuss, derselbe relative Anstieg entspricht dort mehr Prozentpunkten: $0{,}2123/2{,}50 \approx 8{,}5\,\%$ und $0{,}2465/2{,}98 \approx 8{,}3\,\%$ des Linienmittels, fast gleich. Die Linienmittel sind Mittel der Schichtquoten, so wie die Regression jede Schicht gleich zählt. Die Quoten der Summen, 2,51 und 2,99 %, liegen fast gleich. Modell (2) lässt die 12 Schichten ohne Ausschuss weg, hier harmlos, in Linie 4 wären es 384 (Skript 3.4).

Typischer Fehler

In (c) nur die Temperatur zurückrechnen: $1{,}9614 - 21 \cdot 0{,}2123 \approx -2{,}50$ vergisst, dass auch die Auslastung zentriert war. In (b) die Wechselwirkung 0,0342 als Steigung von Linie 2 lesen.

Bewertung: (a) Achsenabschnitt und Linie 2 1 P, `ausl_z`, `nacht` und R^2 1 P. (b) Steigungen, t-Wert der Wechselwirkung und Abstand bei 25 °C 1 P, t-Wert und Intervall für `nacht` 1 P. (c) beide Werte 1 P, Deutung 1 P. (d) Prozente exakt und genähert 1 P, Vergleich mit Modell (1) 1 P.

Lösung zu Aufgabe 4 Residuen und Diagnose

(a) **A Trichter**: Die Streuung wächst mit der Vorhersage, wie bei Quoten aus Stückzahlen. Verletzt ist die konstante Varianz (Annahme 3). Die Koeffizienten bleiben unverzerrt, die klassischen Standardfehler stimmen nicht. Abhilfe: robuste Standardfehler (HC3), eine gewichtete Regression oder ein Log-Modell. **B Ausreißer**: Eine Schicht liegt 2,4 über der Geraden, alle anderen innerhalb von ±0,6. Das passt nicht zu normalverteilten Fehlern (Annahme 5) und ist oft ein Erfassungsfehler. Er vergrößert $\hat{\sigma}$ und damit die Standardfehler, mit hohem Hebel verschiebt er auch die Koeffizienten. Abhilfe: Cook-Abstand ansehen, die Erfassung prüfen, einen Fehler korrigieren statt die Schicht zu löschen. **C Krümmung**: Die Residuen sind an den Rändern positiv, in der Mitte negativ. Verletzt ist die Linearität (Annahme 1), Koeffizienten und Vorhersagen sind verzerrt, an den Rändern zu niedrig. Abhilfe: einen quadratischen Term oder einen Logarithmus aufnehmen, das Bild gegen jede Einflussgröße zeigt, welche. **D Zeitmuster**: Die Monatsmittel steigen im Sommer und fallen im Winter, eine Größe wie die Temperatur fehlt. Residuen desselben Monats hängen zusammen, verletzt ist die Unabhängigkeit (Annahme 4), die klassischen Standardfehler sind meist zu klein. Hängt die fehlende Größe mit den Einflussgrößen zusammen, ist auch der Erwartungswert null der Fehler verletzt (Annahme 2), dann sind die Koeffizienten verzerrt. Abhilfe: die Größe aufnehmen (Skript 5.3).

(b) Mit $\bar{x} = 24$ und $\sum_j (x_j - \bar{x})^2 = 42$: bei 20 und 28 °C ist $h_i = \frac{1}{6} + \frac{16}{42} = \frac{23}{42} \approx \boxed{0{,}548}$, bei 22 und 26 °C $\frac{11}{42} \approx 0{,}262$, bei 23 und 25 °C $\frac{8}{42} \approx 0{,}190$. Die Summe ist $2 \cdot (23 + 11 + 8)/42 = \boxed{2} = p + 1$, der Mittelwert $2/6 \approx 0{,}333$. Für 28 °C mit $e = -0{,}4$ ist

$$D = \frac{0{,}16}{2 \cdot 0{,}155} \cdot \frac{23/42}{(19/42)^2} \approx 0{,}5161 \cdot 2{,}6759 \approx \boxed{1{,}38}.$$

Deutung: Die Schicht bei 28 °C hat einen hohen Hebel und ein mittleres Residuum, ihr Cook-Abstand liegt über 1 und über $4/n \approx 0{,}67$. Ohne sie stiege die Steigung von 0,20 auf 0,28. Die Schicht bei 25 °C liegt nahe bei $\bar{x}$ und verschiebt die Gerade trotz des größten Residuums kaum. Vorgehen: Erfassung von Ausschuss, Stückzahl und Temperatur prüfen. Ein Fehler wird korrigiert, eine echte Schicht bleibt. Mit sechs Schichten hängt die Steigung an einzelnen Punkten, darum berichtest du sie mit und ohne diese Schicht.

(c) $\mathrm{VIF} = 1/(1 - R_j^2)$: eigene Temperatur $1/0{,}1212 \approx \boxed{8{,}25}$, Linie 2 $1/0{,}1227 \approx \boxed{8{,}15}$. Die Standardfehler beider Temperaturen wachsen um den Faktor $\sqrt{\mathrm{VIF}} \approx \boxed{2{,}9}$ gegenüber unkorrelierten Größen: Beide Logger messen fast dasselbe, sie korrelieren mit $r = 0{,}94$. Der Standardfehler

der eigenen Temperatur wächst um 0,0468/0,0180 = 2,60, passend zu $\sqrt{8{,}25/1{,}22} \approx 2{,}60$, denn schon ohne `temp_l2` hängt sie mit Schicht und Auslastung zusammen. **Vorhersagen** bleiben gleich gut, R^2 ändert sich nicht: Kollinearität macht Koeffizienten unsicher, Vorhersagen nicht. **Ins Modell** gehört die Temperatur am eigenen Logger, sie misst an der Linie (Datenblatt). `temp_l2` bringt nichts dazu, ihr Koeffizient ist 0,002 bei einem Standardfehler von 0,046. Der Grund zum Weglassen ist der Inhalt, nicht der VIF: Ein Confounder bliebe auch bei hohem VIF im Modell.

Typischer Fehler

In (c) durch R_j^2 statt durch $1 - R_j^2$ teilen: $1/0{,}8788 \approx 1{,}14$ sähe nach kaum Kollinearität aus. In (b) die Schicht mit dem größten Residuum für die einflussreichste halten.

Bewertung: (a) Zuordnung 1 P, verletzte Annahmen 1 P, Folgen und Abhilfe 1 P. (b) Hebelwerte, Summe und Cook-Abstand 1 P, Deutung und Vorgehen 1 P. (c) VIF und Faktoren 1 P, Vergleich der Standardfehler, Vorhersagen und Wahl der Temperatur 1 P.

Lösung zu Aufgabe 5 Vorhersage und Kausalität

(a) $\hat{y}_0 = -1{,}8 + 0{,}2 \cdot 27 = \boxed{3{,}6\,\%}$ und $\hat{\sigma} = \sqrt{0{,}155} \approx 0{,}3937$. Mit $\frac{1}{6} + \frac{(27-24)^2}{42} = \frac{16}{42} \approx 0{,}3810$ unter der Wurzel ist

$$\mathrm{SE}_{\text{Mittel}} = \sqrt{0{,}155 \cdot 0{,}3810} \approx 0{,}2430, \qquad \mathrm{SE}_{\text{einzeln}} = \sqrt{0{,}155 \cdot 1{,}3810} \approx 0{,}4627.$$

Mit $t_{4;\,0{,}975} = 2{,}776$ ist das Konfidenzintervall $3{,}6 \pm 0{,}675$, also $\boxed{2{,}93}$ bis $\boxed{4{,}27\,\%}$, und das Vorhersageintervall $3{,}6 \pm 1{,}284$, also $\boxed{2{,}32}$ bis $\boxed{4{,}88\,\%}$. Mit 600 Schichten ist $\sum_j (x_j - \bar{x})^2 = 100 \cdot 42 = 4.200$, unter der Wurzel steht $\frac{1}{600} + \frac{9}{4.200} = \frac{16}{4.200}$, ein Hundertstel. $\mathrm{SE}_{\text{Mittel}} \approx 0{,}0243$ ist ein Zehntel, die halbe Breite des Konfidenzintervalls ist $1{,}96 \cdot 0{,}0243 \approx \boxed{0{,}048}$, von 3,55 bis 3,65 %. Mit $\mathrm{SE}_{\text{einzeln}} = \sqrt{0{,}155 \cdot 1{,}0038} \approx 0{,}3944$ hat das Vorhersageintervall die halbe Breite $1{,}96 \cdot 0{,}3944 \approx \boxed{0{,}773}$, von 2,83 bis 4,37 %. Die 1 unter der Wurzel ist die Streuung der einzelnen Schicht um den Mittelwert. Auch bei genau bekannter Geraden schwankt jede Schicht mit σ, die halbe Breite geht gegen $1{,}96 \cdot 0{,}3937 \approx 0{,}77$.

(b) Gerade: Vorhersagen 2,4; 3,4; 2,6; 3,6 und 3,2, Fehler 0,1; −0,1; −0,2; −1,0 und 0,1. MAE = $1{,}5/5 = \boxed{0{,}30}$, RMSE = $\sqrt{1{,}07/5} = \sqrt{0{,}214} \approx \boxed{0{,}463}$. Mittelwert: Fehler −0,5; 0,3; −0,6; −0,4 und 0,3. MAE = $2{,}1/5 = \boxed{0{,}42}$, RMSE = $\sqrt{0{,}95/5} = \sqrt{0{,}19} \approx \boxed{0{,}436}$. Nach dem MAE gewinnt die Gerade, nach dem RMSE der Mittelwert: Der RMSE quadriert, und der eine große Fehler bei 27 °C trägt 1,00 der 1,07 zur Quadratsumme der Geraden bei. Ist eine große Fehlprognose teurer als mehrere kleine, passt der RMSE. Fünf Schichten sind aber selbst eine kleine Stichprobe, eine einzige kippt das Urteil. Prüfen sollte man mit allen Schichten des zweiten Jahres (Skript 6.3). Die Schicht mit 2,6 % liegt im Vorhersageintervall aus (a), aber unter dem Konfidenzintervall.

(c) Sechs Koeffizienten für sechs Punkte: SSE = $\boxed{0}$, $R^2 = \boxed{1}$, und $\hat{\sigma}^2 = 0/(6-5-1)$ ist **nicht definiert**, es gibt keine Standardfehler und Intervalle. Das Polynom lernt den Zufall der sechs Schichten auswendig, das ist **Überanpassung**. Für die fünf Schichten aus (b) hätte es MAE 0,47 und RMSE 0,55, schlechter als beide Modelle. Bei 21 °C sagt es 3,52 % voraus, mehr als bei 22 und 23 °C.

(d) **Schicht: muss hinein**, sie ist ein Confounder. Laut Graph wirkt sie auf die Temperatur (nachts kühler) und auf die Quote. Ohne sie misst der Temperaturkoeffizient über den Weg

Temperatur ← Schicht → Quote auch den Unterschied der Schichten. **Auslastung: darf hinein**, ist aber kein Confounder. Kein Pfeil führt von ihr zur Temperatur, und der Weg Temperatur ← Schicht → Auslastung → Quote ist mit der Schicht im Modell geschlossen. Sie senkt die Reststreuung. **K: nicht hinein**, ein Mediator auf dem Weg Temperatur → K → Quote. Kühlt das Werk die Halle, sinkt laut Graph auch K. Wer für K kontrolliert, nimmt diesen Teil der Wirkung heraus: Der Koeffizient beschreibt dann nur den Weg, der nicht über K läuft. **Z: nicht hinein**, eine gemeinsame Folge von Temperatur und Quote. Bei gleicher Zahl an Zusatzprüfungen haben heiße Schichten eher weniger Ausschuss, weil schon die Hitze die Prüfungen erklärt. Dieser Scheinzusammenhang drückt den Temperaturkoeffizienten nach unten. Auch das richtige Modell schätzt die Wirkung einer Kühlung nur, wenn der Graph stimmt, und beweisen können die Daten ihn nicht. Sicherer zeigt sie ein Versuch, der die Kühlung nach Zufallsplan schaltet (Skript 7.6).

Zum Nachprüfen im Notebook:

```
d6 = pd.DataFrame({"temp": [20, 22, 23, 25, 26, 28], "quote": [2.0, 2.8, 2.5, 3.7, 3.6, 3.4]})
m6 = smf.ols("quote ~ temp", data=d6).fit()
vh = m6.get_prediction(pd.DataFrame({"temp": [27]})).summary_frame(alpha=0.05)
print(vh.round(2).iloc[0, [0, 2, 3, 4, 5]].tolist())
print(m6.get_influence().cooks_distance[0].round(2))
```

liefert `[3.6, 2.93, 4.27, 2.32, 4.88]` und die Cook-Abstände aus Aufgabe 4(b), `[0.35 0.06 0.08 0.23 0.06 1.38]`.

> **Typischer Fehler**
>
> In (a) mit 1,96 statt $t_{4;\,0{,}975} = 2{,}776$ rechnen: Das Vorhersageintervall $3{,}6 \pm 0{,}907$ von 2,69 bis 4,51 % wäre zu schmal. Bei sechs Schichten ist das t-Quantil deutlich größer.

Bewertung: (a) $\hat{y}_0$ und beide Standardfehler 1 P, beide Intervalle 1 P, halbe Breiten mit 600 Schichten und Begründung 1 P. (b) MAE und RMSE beider Modelle 1 P, Deutung 1 P. (c) Kennzahlen und Überanpassung 1 P. (d) Schicht und Auslastung 1 P, K und Z 1 P.

Lösung zu Aufgabe 6 Die Formel der ausgelassenen Variable (Zusatz)

(a) Das lange Modell hat eine Normalgleichung je Spalte von X: $\sum_i e_i = 0$, $\sum_i x_{1i} e_i = 0$ und $\sum_i x_{2i} e_i = 0$ (wie in Aufgabe 1(a), jetzt mit drei Spalten). Also ist $\sum_i (x_{1i} - \bar{x}_1)\, e_i = \sum_i x_{1i} e_i - \bar{x}_1 \sum_i e_i = 0$.

(b) Mit $S_{11} = \sum_i (x_{1i} - \bar{x}_1)^2$, $\sum_i (x_{1i} - \bar{x}_1) = 0$ und $\sum_i (x_{1i} - \bar{x}_1)\, x_{1i} = S_{11}$ ist

$$\tilde{\beta}_1 = \frac{\sum_i (x_{1i} - \bar{x}_1)\,(\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + e_i)}{S_{11}} = \hat{\beta}_1 + \hat{\beta}_2 \frac{\sum_i (x_{1i} - \bar{x}_1)\, x_{2i}}{S_{11}} = \boxed{\hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}},$$

denn der Summand mit e_i ist null nach (a), und der Bruch ist die Steigung $\hat{\delta}$ der Regression von x_2 auf x_1. Das gilt exakt in jeder Stichprobe, ohne Annahme über die Fehler.

(c) Hat x_1 in n_1 Zeilen eine 1 und in n_0 eine 0, ist $\bar{x}_1 = n_1/n$ und $S_{11} = n_1(1 - n_1/n)^2 + n_0(n_1/n)^2 = n_1 n_0 / n$. Für jede Größe v mit den Gruppenmitteln $\bar{v}^{(1)}$ und $\bar{v}^{(0)}$ ist

$$\sum_i (x_{1i} - \bar{x}_1)\, v_i = n_1 \bar{v}^{(1)} - \frac{n_1}{n}\left(n_1 \bar{v}^{(1)} + n_0 \bar{v}^{(0)}\right) = \frac{n_1 n_0}{n}\left(\bar{v}^{(1)} - \bar{v}^{(0)}\right).$$

Geteilt durch S_{11} bleibt $\boxed{\bar{v}^{(1)} - \bar{v}^{(0)}}$, mit $v = y$ für $\tilde{\beta}_1$ und $v = x_2$ für $\hat{\delta}$. In Aufgabe 2 ist $x_1 =$ L3 und $x_2 = u$: $\hat{\delta} = -5 - 5 = -10$ und $\tilde{\beta}_1 = 1{,}4 - 2{,}6 = -1{,}2$.