Tutoriumsblatt 8

Klassifikation und Modellbewertung

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Wahrscheinlichkeiten, Odds und Log-Likelihood einer logistischen Regression von Hand rechnen und ihre Ableitung herleiten,
- Kennzahlen, ROC-Punkte, AUC, Kosten und Kalibrierung von Hand bestimmen, Auswertungen auf Leckage prüfen und Teilgruppen vergleichen.

So arbeitest du mit dem Blatt

Du programmierst nicht: Du rechnest mit dem Taschenrechner und begründest, Zwischenwerte genauer, als du sie angibst. Hängst du, rechnest du mit den Werten unter „Zur Kontrolle“ weiter. Werkszahlen stammen aus `daten/` und dem Skript, „ausgedacht“ heißt fiktiv. Eine Schicht ist wie in `sensordaten.csv` eine Maschine in einer Produktionsschicht, ein Ausfall heißt `ausfall_naechste` $= 1$. Gib Wahrscheinlichkeiten und Kennzahlen auf drei Nachkommastellen an, wenn nichts anderes steht. Zum Notebook: Aufgabe 1 gehört zu TODO 1; Aufgabe 2 zu 6; Aufgabe 3 zu 7 bis 9; Aufgabe 4 zu 10 und 12; Aufgabe 5 zu 2 bis 5 und 12.

Aufgabe 1 Logistische Regression von Hand

8 Punkte · etwa 18 Min.

Bezug: Modul 8, Lerneinheit 1 (Von der Geraden zur Wahrscheinlichkeit)

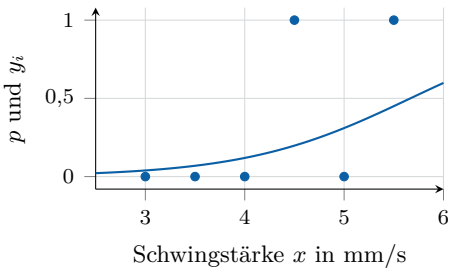
Die CNC-Drehmaschine M-03 fällt am häufigsten aus: Auf 17,7 % ihrer 717 Schichten im ersten Jahr folgte ein Ausfall. Die Instandhaltung hat mit diesen Schichten eine logistische Regression der Ausfallwahrscheinlichkeit p auf die Schwingstärke x in mm/s geschätzt, gerundet

$$\ln \frac{p}{1-p} = \eta = \beta_0 + \beta_1 u \qquad \text{mit} \quad u = x - 4, \quad \beta_0 = -2{,}0, \quad \beta_1 = 1{,}2.$$

η	$-3{,}2$	$-2{,}6$	$-2{,}0$	$-1{,}4$	$-0{,}8$	$-0{,}2$	$0{,}6$	$1{,}2$
e^{η}	0,04076	0,07427	0,13534	0,24660	0,44933	0,81873	1,82212	3,32012

Sechs Schichten von M-03 (ausgedacht) mit Schwingstärke x_i und Ausgang y_i. Modell A hat die Koeffizienten oben. Modell B lässt die Schwingung weg, $\beta_1 = 0$, und gibt jeder Schicht $p = 1/3$, die Ausfallquote der sechs Schichten.

x_i (mm/s)	3,0	3,5	4,0	4,5	5,0	5,5
y_i	0	0	0	1	0	1



(a) Berechne für 3, 4 und 5 mm/s den Logit, die Odds und die Ausfallwahrscheinlichkeit, jeweils auf vier Nachkommastellen. Was beschreibt β_0? [1 P]

(b) Um welchen Faktor ändern sich die Odds je mm/s und je 0,5 mm/s mehr Schwingung? Berechne die Verhältnisse der Wahrscheinlichkeiten von 3 auf 4 und von 4 auf 5 mm/s auf zwei Nachkommastellen. Warum weichen sie vom Odds-Verhältnis ab, und wann kaum? Bei welcher Schwingstärke sagt das Modell 50 % voraus? [2 P]

(c) Berechne für beide Modelle die Log-Likelihood $\ell = \sum_i \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right]$ der sechs Schichten auf drei Nachkommastellen. Welches Modell erklärt die sechs Ausgänge besser? Wievielmal so wahrscheinlich sind sie unter diesem Modell, auf eine Nachkommastelle? Zur Kontrolle: Unter A trägt die Schicht mit 4,5 mm/s $\ln 0{,}1978 \approx -1{,}620$ bei. [2 P]

(d) Zeige für $p = 1/(1 + e^{-\eta})$: $\frac{d}{d\eta} \ln p = 1 - p$ und $\frac{d}{d\eta} \ln(1 - p) = -p$. Leite damit $\partial \ell / \partial \beta_0 = \sum_i (y_i - p_i)$ und $\partial \ell / \partial \beta_1 = \sum_i (y_i - p_i)\, u_i$ her. Berechne beide für Modell A an den sechs Schichten auf zwei Nachkommastellen und deute die Vorzeichen. Zeige mit $\partial \ell / \partial \beta_0 = 0$, dass B unter allen Modellen mit $\beta_1 = 0$ die größte Log-Likelihood hat. Was folgt allgemein für die mittlere Wahrscheinlichkeit am Maximum? Zur Kontrolle: Unter A ist $\sum_i p_i \approx 1{,}19$. [3 P]

Aufgabe 2 Konfusionsmatrix und Basisrate

8 Punkte · etwa 16 Min.

Bezug: Modul 8, Lerneinheit 3 (Die Konfusionsmatrix)

Ein Modell der Instandhaltung gibt für 2.500 Schichten der Linie 1 bei einer festen Schwelle einen Alarm oder keinen (ausgedacht). Die Zeilen zeigen den wahren Ausgang, die Spalten die Entscheidung.

	Alarm	kein Alarm	Summe
Ausfall	120	80	200
kein Ausfall	230	2.070	2.300
Summe	350	2.150	2.500

(a) Lies TP, FP, FN und TN ab. Berechne Accuracy, Precision, Recall, Spezifität und F_1. Was bedeuten Precision und Recall für die Instandhaltung? [2 P]

(b) Mit der Basisrate $\pi = P(\text{Ausfall})$, dem Recall $r = P(\text{Alarm} \mid \text{Ausfall})$ und der Spezifität $s = P(\text{kein Alarm} \mid \text{kein Ausfall})$: Leite mit dem Satz von Bayes her, dass

$$\text{Precision} = \frac{r\,\pi}{r\,\pi + (1 - s)(1 - \pi)} \qquad \text{und} \qquad \frac{\text{Precision}}{1 - \text{Precision}} = \frac{r}{1 - s} \cdot \frac{\pi}{1 - \pi}.$$

Prüfe beide Formeln mit den Werten aus (a). Was sagt der Faktor $r/(1 - s)$? [2 P]

(c) An den Prüfmaschinen M-07 und M-13 fielen im zweiten Jahr nur 1,6 % der Schichten aus. Angenommen, das Modell hat dort denselben Recall und dieselbe Spezifität wie in (a). Berechne die Precision. Welche Spezifität bräuchte es dort bei gleichem Recall, damit jeder zweite Alarm ein Treffer ist? Zur Kontrolle: Die Odds der Precision sind 0,0976. [2 P]

(d) Zeige Accuracy $= \pi\, r + (1 - \pi)\, s$. Berechne die Accuracy des Modells und der Regel „nie Alarm“ für Linie 1 aus (a) und für die Prüfmaschinen aus (c). Was misst die Accuracy bei seltenen Ausfällen vor allem, und welche Kennzahlen nimmst du stattdessen? [2 P]

Aufgabe 3 ROC, AUC und Kosten

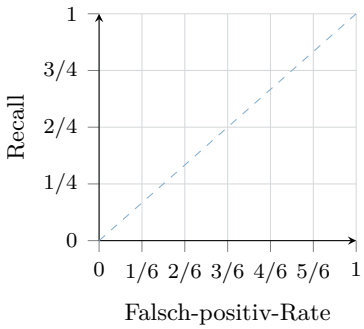
9 Punkte · etwa 20 Min.

Bezug: Modul 8, Lerneinheit 4 (Schwelle, ROC und Kosten)

Die Instandhaltung hat zehn Schichten der Linie 2 aus dem Oktober 2025 herausgesucht, darunter vier mit Ausfall (ausgedacht). p_i ist die Ausfallwahrscheinlichkeit des Modells, ein Alarm kommt bei $p_i \geq$ Schwelle.

p_i	0,42	0,35	0,28	0,22	0,16	0,12	0,09	0,06	0,04	0,02
y_i	1	0	1	1	0	0	1	0	0	0

(a) Stelle für jede der zehn Schwellen 0,42; 0,35; …; 0,02 TP und FP auf, dazu Recall, Falsch-positiv-Rate und Precision. Zeichne die ROC-Kurve ins Gitter. Zur Kontrolle: Bei der Schwelle 0,16 ist (Falsch-positiv-Rate; Recall) $= (1/3;\ 3/4)$. [2 P]



(b) Bestimme die AUC als Fläche unter der Kurve und durch Abzählen der Paare aus einem Ausfall und einer Schicht ohne Ausfall. Wie hängt das mit der Statistik U des Mann-Whitney-Tests zusammen? Wie groß wären U und AUC, wenn die Schicht mit Ausfall und 0,09 stattdessen 0,30 bekäme? [2 P]

(c) Unter den zehn Schichten sind 40 % Ausfälle, im Betrieb etwa 5 %. Rechne die Precision bei der Schwelle 0,22 mit Aufgabe 2(b) auf die Basisrate 0,05 um. Warum bleibt die ROC-Kurve dabei gleich? [1 P]

(d) Annahmen: Eine Inspektion kostet 350 €. Findet sie einen bevorstehenden Ausfall, kostet die geplante Reparatur 400 €, und der Ausfall entfällt. Ein verpasster Ausfall kostet rund 3.200 € (im ersten Jahr 106 Minuten Stillstand im Mittel, Skript 4.4, zu 30 € je Minute). Leite mit den Kosten der Felder TP, FP, FN und TN aus den erwarteten Kosten einer Schicht mit und ohne Alarm her, dass sich ein Alarm ab $p^* = C_{FP}/(C_{FP} + C_{FN})$ lohnt. Was sind hier C_{FP} und C_{FN}? Zur Kontrolle: $p^* = 0{,}125$. [2 P]

(e) Welche Schichten bekommen bei p^* einen Alarm? Berechne die erwarteten Kosten der zehn Schichten laut Modell für p^* und für die Schwelle 0,3, die ein Kollege für weniger Fehlalarme vorschlägt. Warum ist im Mittel keine Schwelle billiger als p^*, und was setzt das voraus? Zur Kontrolle: Laut Modell erwartest du 1,76 Ausfälle. [2 P]

Aufgabe 4 Kalibrierung und Gewichte

8 Punkte · etwa 18 Min.

Bezug: Modul 8, Lerneinheit 5 (Wahrscheinlichkeiten, denen man trauen kann)

Der Leitstand zeigt vier Warnstufen mit im ersten Jahr gelernten Ausfallwahrscheinlichkeiten p_k. Die Tabelle zeigt 2.100 Schichten der Linie 2 nach dem Sensortausch am 2. März 2026 (gerundet, ausgedacht).

Warnstufe k	1	2	3	4
Wahrscheinlichkeit p_k	0,02	0,06	0,12	0,30
Schichten n_k	700	500	500	400
Ausfälle o_k	14	10	30	76

(a) Stelle die Zuverlässigkeitstabelle auf: beobachtete Quote und erwartete Ausfälle $n_k p_k$ je Stufe, mittlere vorhergesagte und beobachtete Quote. Wo ist das Modell kalibriert? Welche Werte zeigst du bis zu einem neuen Training an? [2 P]

(b) Berechne den Brier-Score der Warnstufen auf vier Nachkommastellen, eine Stufe trägt $o_k(1-p_k)^2 + (n_k - o_k)\,p_k^2$ zur Summe bei. Vergleiche mit der Vorhersage 5,5 % für jede Schicht, der Basisrate von Linie 2 im ersten Jahr. Um wie viel Prozent ist das Modell besser, auf eine Nachkommastelle? Zur Kontrolle: Stufe 4 trägt 66,4 bei. [2 P]

(c) Ein Modell mit eigener Wahrscheinlichkeit q je Stufe schätzt ungewichtet $\hat{q} = o/m$, wenn im Training o von m Schichten der Stufe ausfallen (Aufgabe 1(d)). Zeige mit der Log-Likelihood der Stufe: Mit Gewicht w je Ausfall ist $\hat{q}_w = w\,o/(w\,o + m - o)$, die Odds werden mit w multipliziert, $p' = wp/(wp + 1 - p)$. Was heißt das für den Achsenabschnitt einer logistischen Regression? [2 P]

(d) Eine Kollegin gewichtet jeden Ausfall mit $w = 7$, dem Verhältnis C_{FN}/C_{FP} aus Aufgabe 3(d). Berechne p' für die vier Stufen. Zeige: $p' \geq 0{,}5$ gilt genau dann, wenn $p \geq p^* = 1/8$. Was heißt das für die Kalibrierung, und wie bekommst du p aus p' zurück? Welcher Schwelle für p entspricht 0,5 bei `class_weight="balanced"`, also $w = (1 - \pi)/\pi$? [2 P]

Aufgabe 5 Aufbau und Teilgruppen

7 Punkte · etwa 16 Min.

Bezug: Modul 8, Lerneinheiten 2 (Trainieren, validieren, testen) und 7 (Für wen funktioniert das Modell?)

(a) Das Modell soll am Ende einer Schicht einen Ausfall in der nächsten vorhersagen. Wo nichts anderes steht, wird mit dem ersten Jahr trainiert und mit dem zweiten geprüft. Liegt jeweils Leckage vor? Begründe mit dem Zeitpunkt, zu dem die Information bekannt ist, und nenne eine Korrektur.
A Merkmal: Mittel der Schwingstärke aus voriger, aktueller und nächster Schicht, je Maschine mit `rolling(3, center=True)`.
B Von 40 Kenngrößen aus den Messgrößen kommen die 5 ins Modell, die über beide Jahre am stärksten mit der Zielgröße korrelieren.
C Je Maschine kommen zufällig 80 % ihrer Schichten beider Jahre ins Training, 20 % in den Test.
D Merkmal: Schwingstärke der vorigen Schicht mit `groupby("maschine").shift(1)`. [3 P]

Das Modell im zweiten Jahr bei einer festen Schwelle für je 1.000 Schichten der Zerspanung und der Montage (gerundet, ausgedacht):

	Zerspanung			Montage		
	Alarm	kein	Summe	Alarm	kein	Summe
Ausfall	60	20	80	30	10	40
kein Ausfall	240	680	920	120	840	960

(b) Berechne für beide Gruppen Basisrate, Anteil der Schichten mit Alarm, Precision, Recall und Falsch-positiv-Rate. Was ist gleich, was nicht? [2 P]

(c) Zeige mit Aufgabe 2(b): $\text{FPR} = \text{Recall} \cdot \frac{\pi}{1-\pi} \cdot \frac{1-\text{Precision}}{\text{Precision}}$. Folgere: Bei verschiedenen Basisraten können Precision und beide Fehlerraten (Falsch-positiv-Rate und $1 - \text{Recall}$) nicht in beiden Gruppen zugleich gleich sein, außer die Precision ist 1 oder der Recall 0. Welche Precision hätte die Montage bei gleichem Recall mit der Falsch-positiv-Rate der Zerspanung? Wer entscheidet, welches Kriterium zählt? [2 P]

Aufgabe 6 (⋆) Die Zerlegung des Brier-Scores

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 8, Lerneinheit 5

In Stufe k haben n_k von n Schichten die Vorhersage p_k und die beobachtete Quote $\bar{o}_k$, alle zusammen $\bar{o}$. (a) Zeige: Die Stufe trägt $\sum_i (p_k - y_i)^2 = n_k\big[(p_k - \bar{o}_k)^2 + \bar{o}_k(1 - \bar{o}_k)\big]$ bei. (b) Folgere $B = \text{REL} - \text{RES} + \text{UNC}$ mit der Kalibrierung $\text{REL} = \frac{1}{n}\sum_k n_k(p_k - \bar{o}_k)^2$, der Auflösung $\text{RES} = \frac{1}{n}\sum_k n_k(\bar{o}_k - \bar{o})^2$ und der Unsicherheit $\text{UNC} = \bar{o}(1 - \bar{o})$. (c) Berechne die drei Teile für Aufgabe 4 und B mit $p_k = \bar{o}_k$. Was kann eine Rekalibrierung verbessern, was nicht?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Logistische Regression von Hand

(a) Bei 3 mm/s ist $u = -1$, $\eta = -2{,}0 + 1{,}2 \cdot (-1) = -3{,}2$, die Odds sind $e^{-3{,}2} = 0{,}0408$ und $p = 0{,}0408/1{,}0408 = \boxed{0{,}0392}$. Bei 4 mm/s: $\eta = -2{,}0$, Odds 0,1353, $p = 0{,}1353/1{,}1353 = \boxed{0{,}1192}$. Bei 5 mm/s: $\eta = -0{,}8$, Odds 0,4493, $p = 0{,}4493/1{,}4493 = \boxed{0{,}3100}$. β_0 ist der Logit bei 4 mm/s, wo $u = 0$ ist, nahe dem Median 4,02 mm/s von M-03 im ersten Jahr: Odds 0,1353, auf einen Ausfall kommen gut sieben Schichten ohne.

(b) Die Odds werden je mm/s mit $e^{1{,}2} = \boxed{3{,}320}$ multipliziert, je 0,5 mm/s mit $e^{0{,}6} = \boxed{1{,}822}$, also um 82,2 % erhöht. Die Wahrscheinlichkeit steigt von 3 auf 4 mm/s auf das $0{,}1192/0{,}0392 = \boxed{3{,}04}$-fache, von 4 auf 5 mm/s nur auf das $0{,}3100/0{,}1192 = \boxed{2{,}60}$-fache. Das Odds-Verhältnis gilt für $p/(1-p)$, nicht für p. Nur bei kleinem p ist $p/(1-p) \approx p$, so von 3 auf 4 mm/s mit 3,04 gegen 3,32. Je höher die Ausgangslage, desto kleiner das Verhältnis, denn p bleibt unter 1. **50 %** heißt Odds 1 und $\eta = 0$, also $u = 2{,}0/1{,}2$ und $x = 4 + 1{,}667 \approx \boxed{5{,}67\,\text{mm/s}}$. So hoch lagen im ersten Jahr 34 der 717 Schichten von M-03.

(c) Unter A ist $u_i = -1;\ -0{,}5;\ 0;\ 0{,}5;\ 1;\ 1{,}5$, also $\eta_i = -3{,}2;\ -2{,}6;\ -2{,}0;\ -1{,}4;\ -0{,}8;\ -0{,}2$ und mit $p = e^\eta/(1+e^\eta)$ ist $p_i = 0{,}0392;\ 0{,}0691;\ 0{,}1192;\ 0{,}1978;\ 0{,}3100;\ 0{,}4502$. Die Schichten ohne Ausfall tragen $\ln(1-p_i)$ bei, die mit Ausfall $\ln p_i$:

$$\ell_A = -0{,}040 - 0{,}072 - 0{,}127 - 1{,}620 - 0{,}371 - 0{,}798 = \boxed{-3{,}028}.$$

Unter B ist $\ell_B = 2\ln\frac{1}{3} + 4\ln\frac{2}{3} = -2{,}197 - 1{,}622 = \boxed{-3{,}819}$. **A erklärt die sechs Ausgänge besser**, seine Log-Likelihood ist größer. Unter A sind sie $e^{-3{,}028+3{,}819} = e^{0{,}791} \approx \boxed{2{,}2}$-mal so wahrscheinlich wie unter B, obwohl B das beste Modell ohne Schwingung für genau diese sechs Schichten ist, siehe (d).

(d) Mit $\ln p = -\ln(1+e^{-\eta})$ und $1 - p = e^{-\eta}/(1+e^{-\eta})$ ist

$$\frac{d}{d\eta}\ln p = \frac{e^{-\eta}}{1+e^{-\eta}} = 1 - p, \qquad \frac{d}{d\eta}\ln(1-p) = \frac{d}{d\eta}\big(-\eta - \ln(1+e^{-\eta})\big) = -1 + (1-p) = -p.$$

Eine Schicht trägt also $\partial\ell_i/\partial\eta_i = y_i(1-p_i) - (1-y_i)\,p_i = y_i - p_i$ bei. Mit $\partial\eta_i/\partial\beta_0 = 1$ und $\partial\eta_i/\partial\beta_1 = u_i$ folgt nach der Kettenregel $\boxed{\partial\ell/\partial\beta_0 = \sum_i (y_i - p_i)}$ und $\boxed{\partial\ell/\partial\beta_1 = \sum_i (y_i - p_i)\,u_i}$. Für A ist $\sum_i p_i = 1{,}1855$, also $\sum_i (y_i - p_i) = 2 - 1{,}1855 \approx \boxed{0{,}81}$. Mit $y_i - p_i = -0{,}0392;\ -0{,}0691;\ -0{,}1192;\ 0{,}8022;\ -0{,}3100;\ 0{,}5498$ ist

$$\sum_i (y_i - p_i)\,u_i = 0{,}0392 + 0{,}0346 + 0 + 0{,}4011 - 0{,}3100 + 0{,}8247 \approx \boxed{0{,}99}.$$

Deutung: Beide sind positiv. Auf diesen sechs Schichten stiege ℓ mit größerem β_0 und größerem β_1: Es gab mehr Ausfälle (2), als A erwartet (1,19), und sie lagen bei hoher Schwingung. **Modell B**: Mit $\beta_1 = 0$ haben alle Schichten dasselbe $q = 1/(1+e^{-\beta_0})$, und $\partial\ell/\partial\beta_0 = \sum_i (y_i - q) = 0$ ergibt $q = \bar{y} = 2/6 = 1/3$, also $\beta_0 = \ln\frac{1/3}{2/3} = \ln\frac{1}{2} \approx -0{,}693$. Wegen $\partial^2\ell/\partial\beta_0^2 = -\sum_i q\,(1-q) < 0$ ist das ein Maximum. **Allgemein** ist am Maximum eines Modells mit Achsenabschnitt $\sum_i p_i = \sum_i y_i$: Im Training ist die mittlere vorhergesagte Wahrscheinlichkeit gleich der Ausfallquote (Skript 1.3), bei M-03 mit den ungerundeten Koeffizienten 127 erwartete wie beobachtete Ausfälle.

Typischer Fehler

In (a) x statt $u = x - 4$ einsetzen: $\eta = -2{,}0 + 1{,}2 \cdot 5 = 4{,}0$ ergäbe bei 5 mm/s $p = 0{,}982$.

Bewertung: (a) Logit, Odds, Wahrscheinlichkeiten und β_0 1 P. (b) Odds-Verhältnisse und 50-%-Punkt 1 P, Verhältnisse der Wahrscheinlichkeiten und Erklärung 1 P. (c) beide Log-Likelihoods 1 P, Vergleich und Faktor 1 P. (d) Ableitungen und Kettenregel 1 P, Werte für A und Deutung 1 P, Modell B und mittlere Wahrscheinlichkeit 1 P.

Lösung zu Aufgabe 2 Konfusionsmatrix und Basisrate

(a) TP = 120, FP = 230, FN = 80, TN = 2.070. Accuracy = 2.190/2.500 = $\boxed{0{,}876}$, Precision = 120/350 = $\boxed{0{,}343}$, Recall = 120/200 = $\boxed{0{,}600}$, Spezifität = 2.070/2.300 = $\boxed{0{,}900}$ und $F_1 = 2 \cdot 120/(240 + 230 + 80) = 240/550 = \boxed{0{,}436}$. **Precision**: Gut jeder dritte Alarm findet einen bevorstehenden Ausfall, knapp zwei von drei Inspektionen finden nichts. **Recall**: 60 % der Ausfälle werden eine Schicht vorher erkannt, 40 % kommen ohne Warnung.

(b) Nach Bayes ist Precision = $P(\text{Ausfall} \mid \text{Alarm}) = r\,\pi / P(\text{Alarm})$ mit $P(\text{Alarm}) = r\,\pi + (1 - s)(1 - \pi)$ nach der totalen Wahrscheinlichkeit, denn ohne Ausfall kommt ein Alarm mit der Falsch-positiv-Rate $1 - s$. Mit $P(\text{kein Ausfall} \mid \text{Alarm}) = (1 - s)(1 - \pi)/P(\text{Alarm})$ kürzt sich $P(\text{Alarm})$ im Quotienten. **Probe** mit $\pi = 200/2.500 = 0{,}08$, $r = 0{,}6$ und $s = 0{,}9$: $0{,}048/(0{,}048 + 0{,}1 \cdot 0{,}92) = 0{,}048/0{,}140 = \boxed{0{,}343}$, die Odds sind $6 \cdot 0{,}08/0{,}92 = 0{,}5217$ und $0{,}5217/1{,}5217 = 0{,}343$. **Der Faktor** $r/(1 - s) = 6$ sagt, wievielmal so oft vor einem Ausfall ein Alarm kommt wie bei einer ruhigen Schicht. Er hängt nur an Modell und Schwelle, die Basisrate kommt über $\pi/(1 - \pi)$ dazu.

(c) Mit $\pi = 0{,}016$ ist $r\,\pi = 0{,}0096$ und $(1 - s)(1 - \pi) = 0{,}0984$, also Precision = $0{,}0096/0{,}108 \approx \boxed{0{,}089}$ mit den Odds $6 \cdot 0{,}016/0{,}984 = 0{,}0976$. Von 100 Alarmen fänden nur 9 einen Ausfall, bei gleichem Modell. Für jeden zweiten Treffer müssen die Odds 1 sein: $(1 - s) \cdot 0{,}984 = 0{,}0096$, also $1 - s = 0{,}00976$ und $s \approx \boxed{0{,}990}$. Bei 61,5-mal so vielen ruhigen Schichten wie Ausfällen dürfte weniger als 1 % von ihnen einen Alarm bekommen.

(d) Accuracy = $P(\text{Alarm und Ausfall}) + P(\text{kein Alarm und kein Ausfall}) = r\,\pi + s\,(1 - \pi)$, ein gewichtetes Mittel aus Recall und Spezifität. Linie 1: Modell $0{,}048 + 0{,}9 \cdot 0{,}92 = \boxed{0{,}876}$, „nie Alarm“ mit $r = 0$ und $s = 1$: $1 - \pi = \boxed{0{,}920}$. Prüfmaschinen: Modell $0{,}0096 + 0{,}9 \cdot 0{,}984 = \boxed{0{,}895}$, „nie Alarm“ $\boxed{0{,}984}$. Die Regel, die keinen Ausfall findet, liegt beide Male vorn: Bei seltenen Ausfällen ist die Accuracy fast die Spezifität und belohnt das Nichtstun. Stattdessen nimmst du Precision und Recall oder gleich die Kosten (Aufgabe 3).

Typischer Fehler

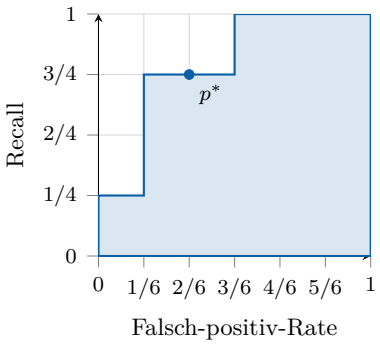
In (b) die Spezifität statt der Falsch-positiv-Rate einsetzen: $0{,}048/(0{,}048 + 0{,}9 \cdot 0{,}92) \approx 0{,}055$ läge sogar unter der Basisrate 0,08. In (a) Precision und Recall vertauschen.

Bewertung: (a) Felder, Accuracy und Precision 1 P, Recall, Spezifität, F_1 und Deutung 1 P. (b) Herleitung mit Bayes 1 P, Odds-Form, Probe und Deutung des Faktors 1 P. (c) Precision 1 P, nötige Spezifität 1 P. (d) Formel 1 P, vier Werte und Deutung 1 P.

Lösung zu Aufgabe 3 ROC, AUC und Kosten

(a) Senkst du die Schwelle, kommt bei jedem Ausfall ein TP dazu, sonst ein FP. Recall ist TP/4, die Falsch-positiv-Rate FP/6, die Precision TP/(TP + FP). Sie steigt und fällt beim Senken der Schwelle.

Schwelle	TP	FP	Recall	FPR	Precision
0,42	1	0	0,25	0	1
0,35	1	1	0,25	0,167	0,500
0,28	2	1	0,50	0,167	0,667
0,22	3	1	0,75	0,167	0,750
0,16	3	2	0,75	0,333	0,600
0,12	3	3	0,75	0,500	0,500
0,09	4	3	1	0,500	0,571
0,06	4	4	1	0,667	0,500
0,04	4	5	1	0,833	0,444
0,02	4	6	1	1	0,400



(b) **Fläche**: Streifen der Breite 1/6, 2/6 und 3/6 in den Höhen 1/4, 3/4 und 1, also AUC $= \frac{1}{24} + \frac{6}{24} + \frac{12}{24} = \frac{19}{24} \approx \boxed{0{,}792}$. **Paare**: Von $4 \cdot 6 = 24$ Paaren gewinnt der Ausfall mit 0,42 alle 6, die mit 0,28 und 0,22 je 5, der mit 0,09 drei, zusammen $\boxed{19}$, also 19/24 wie die Fläche. Die Zahl der gewonnenen Paare ist die Statistik U des Mann-Whitney-Tests aus Modul 6, AUC $= U/(n_1 n_0)$, Gleichstände zählen halb. **Mit 0,30** liegt dieser Ausfall über 5 statt 3 Schichten ohne Ausfall, also $U = 6+5+5+5 = \boxed{21}$ und AUC $= 21/24 = \boxed{0{,}875}$. Jeder Wert über 0,16 und unter 0,35 ergäbe dasselbe: Die AUC zählt nur die Reihenfolge, für Kosten und p^* zählt die Höhe (Aufgabe 4).

(c) Bei 0,22 ist $r = 0{,}75$ und die Falsch-positiv-Rate 1/6, der Faktor aus Aufgabe 2(b) also $0{,}75 \cdot 6 = 4{,}5$. Probe mit 40 %: Odds $4{,}5 \cdot 0{,}4/0{,}6 = 3$, Precision 0,75 wie in der Tabelle. Mit 5 %: Odds $4{,}5 \cdot 0{,}05/0{,}95 = 0{,}2368$, Precision $0{,}2368/1{,}2368 \approx \boxed{0{,}191}$ statt 0,75. Recall und Falsch-positiv-Rate werden innerhalb der Ausfälle und innerhalb der ruhigen Schichten gezählt und hängen nicht von der Mischung ab: Die ROC-Kurve bleibt, die Precision nicht.

(d) Kosten der Felder: **TP** $350 + 400 = 750$ € (Inspektion und Reparatur, kein Ausfall), **FP** 350 €, **FN** 3.200 €, **TN** 0 €. Mit Alarm kostet die Schicht im Mittel $p \cdot 750 + (1-p) \cdot 350 = 350 + 400\,p$ €, ohne Alarm $p \cdot 3.200$ €. Allgemein lohnt sich ein Alarm, wenn

$$p\,c_{TP} + (1-p)\,c_{FP} < p\,c_{FN} + (1-p)\,c_{TN} \;\Leftrightarrow\; (1-p)\,C_{FP} < p\,C_{FN} \;\Leftrightarrow\; p > \frac{C_{FP}}{C_{FP} + C_{FN}} = p^*$$

mit $C_{FP} = c_{FP} - c_{TN} = \boxed{350\,€}$, den Mehrkosten eines Fehlalarms gegenüber einer ruhigen Schicht ohne Alarm, und $C_{FN} = c_{FN} - c_{TP} = 3.200 - 750 = \boxed{2.450\,€}$, den Mehrkosten eines verpassten gegenüber einem erkannten Ausfall. Also $p^* = 350/2.800 = \boxed{0{,}125}$, dort kosten beide Entscheidungen 400 €.

(e) Einen Alarm bekommen die **fünf** Schichten mit 0,42 bis 0,16, drei davon fielen aus. Erwartete Kosten laut Modell, $350 + 400\,p_i$ mit Alarm und $3.200\,p_i$ ohne, mit den Summen 1,43 und 0,77 der p_i mit Alarm, 0,33 und 0,99 ohne:

$$K(p^*) = 5 \cdot 350 + 400 \cdot 1{,}43 + 3.200 \cdot 0{,}33 = 1.750 + 572 + 1.056 = \boxed{3.378\,€},$$
$$K(0{,}3) = 2 \cdot 350 + 400 \cdot 0{,}77 + 3.200 \cdot 0{,}99 = 700 + 308 + 3.168 = \boxed{4.176\,€}.$$

Die Schwelle 0,3 kostet im Mittel 798 € mehr: Für die Schichten mit 0,28, 0,22 und 0,16 kostet ein Alarm 462, 438 und 414 €, kein Alarm erwartet 896, 704 und 512 €. **Begründung**:

Die erwarteten Kosten sind eine Summe über die Schichten, und mit p^* kostet jede Schicht $\min(350{+}400\,p_i;\ 3.200\,p_i)$, das Kleinste, was für sie möglich ist. Bei 0,12 stehen 398 gegen 384 €, kein Alarm ist knapp richtig. **Voraussetzung**: Die p_i sind kalibriert, und die Kostenannahmen stimmen.

Zum Nachprüfen im Notebook:

```
from sklearn.metrics import roc_curve, roc_auc_score
from scipy import stats
p = np.array([0.42, 0.35, 0.28, 0.22, 0.16, 0.12, 0.09, 0.06, 0.04, 0.02])
y = np.array([1, 0, 1, 1, 0, 0, 1, 0, 0, 0])
fpr, tpr, schwellen = roc_curve(y, p, drop_intermediate=False)
print((fpr * 6).round().astype(int).tolist(), (tpr * 4).round().astype(int).tolist())
u = stats.mannwhitneyu(p[y == 1], p[y == 0]).statistic
p30 = np.where(p == 0.09, 0.30, p)
print(u, round(roc_auc_score(y, p), 4), round(roc_auc_score(y, p30), 4))
kosten = [(350 + 400 * p[p >= s]).sum() + 3200 * p[p < s].sum() for s in [0.125, 0.3]]
print(np.round(kosten, 2).tolist())
```

liefert `[0, 0, 1, 1, 1, 2, 3, 3, 4, 5, 6] [0, 1, 1, 2, 3, 3, 3, 4, 4, 4, 4]`, `19.0 0.7917 0.875` und `[3378.0, 4176.0]`.

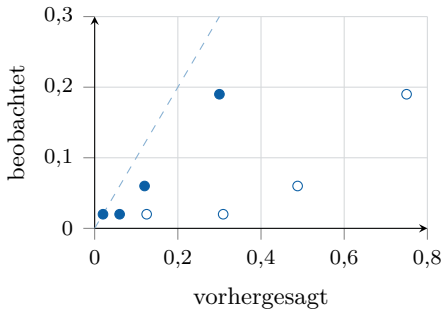
> **Typischer Fehler**
>
> In (d) die Reparatur in c_{TP} vergessen: $C_{FN} = 3.200 - 350 = 2.850$ € ergäbe $p^* = 350/3.200 \approx 0{,}109$. Ein erkannter Ausfall kostet Inspektion und Reparatur, nur der Stillstand entfällt.

Bewertung: (a) Tabelle 1 P, ROC-Kurve 1 P. (b) AUC als Fläche und aus den Paaren 1 P, Mann-Whitney und geänderte Schicht 1 P. (c) Umrechnung und Begründung 1 P. (d) Kosten der Felder 1 P, Herleitung von p^* mit C_{FP} und C_{FN} 1 P. (e) Alarme und beide erwarteten Kosten 1 P, Begründung und Voraussetzung 1 P.

Lösung zu Aufgabe 4 Kalibrierung und Gewichte

(a) Beobachtete Quoten $\bar{o}_k = o_k/n_k$: $14/700 = 0{,}02$, $10/500 = 0{,}02$, $30/500 = 0{,}06$ und $76/400 = 0{,}19$. Erwartet sind $n_k p_k = 14$, 30, 60 und 120 Ausfälle, beobachtet 14, 10, 30 und 76. Vorhergesagt sind im Mittel $224/2.100 = \boxed{0{,}107}$, beobachtet $130/2.100 = \boxed{0{,}062}$.

Kalibriert ist nur Stufe 1. Stufe 2 liegt dreimal so hoch wie beobachtet, Stufe 3 doppelt, Stufe 4 um gut die Hälfte. Die Quoten steigen aber von Stufe 2 bis 4, die Reihenfolge stimmt, nur die Höhe nicht (Skript 7.2). **Anzeigen** solltest du die beobachteten Quoten $\boxed{0{,}02;\ 0{,}02;\ 0{,}06;\ 0{,}19}$, also mit Daten nach dem Tausch rekalibrieren (Skript 5.4). Dann stimmen auch erwartete Kosten und Faustformel. Im Bild: Stufen gefüllt, gewichtet aus (d) leer.



(b) Stufe 1 trägt $14 \cdot 0{,}98^2 + 686 \cdot 0{,}02^2 = 13{,}72$ bei, Stufe 2 $10 \cdot 0{,}94^2 + 490 \cdot 0{,}06^2 = 10{,}60$, Stufe 3 $30 \cdot 0{,}88^2 + 470 \cdot 0{,}12^2 = 30{,}00$ und Stufe 4 $76 \cdot 0{,}70^2 + 324 \cdot 0{,}30^2 = 66{,}40$, zusammen 120,72. Der Brier-Score ist $120{,}72/2.100 \approx \boxed{0{,}0575}$. Mit der Basisrate: $(130 \cdot 0{,}945^2 + 1.970 \cdot 0{,}055^2)/2.100 = 122{,}05/2.100 \approx \boxed{0{,}0581}$. Das Modell ist nur um $1 - 120{,}72/122{,}05 \approx \boxed{1{,}1\,\%}$ besser. Auf einer Skala bis 1 klingt 0,0575 gut, erst der Vergleich mit der Basisrate zeigt, dass die Warnstufen kaum mehr leisten. Wie viel davon an der Kalibrierung liegt, zeigt Aufgabe 6.

(c) Mit Gewicht w zählt jeder Ausfall w-mal, die Stufe hat die Log-Likelihood $\ell_w(q) = w\,o \ln q + (m-o)\ln(1-q)$. Aus

$$\ell_w'(q) = \frac{w\,o}{q} - \frac{m-o}{1-q} = 0 \iff w\,o\,(1-q) = (m-o)\,q \iff \boxed{\hat{q}_w = \frac{w\,o}{w\,o + m - o}},$$

und $\ell_w''(q) = -w\,o/q^2 - (m-o)/(1-q)^2 < 0$, also ein Maximum. Mit $w = 1$ folgt $\hat{q} = o/m$. Die Odds sind $\hat{q}_w/(1-\hat{q}_w) = w\,o/(m-o) = w \cdot \hat{q}/(1-\hat{q})$. Teilst du Zähler und Nenner durch m und setzt $p = o/m$, folgt $\boxed{p' = \frac{wp}{wp + 1 - p}}$. **Achsenabschnitt**: Der Logit wächst überall um $\ln w$, aus $\beta_0 + \beta_1 x_1 + \ldots$ wird $\beta_0 + \ln w + \beta_1 x_1 + \ldots$ Passt das Modell, verschiebt sich bei vielen Daten also fast nur der Achsenabschnitt, um etwa $\ln w$ (Skript 5.3).

(d) Mit $w = 7$: Stufe 1 $0{,}14/(0{,}14 + 0{,}98) = \boxed{0{,}125}$, Stufe 2 $0{,}42/1{,}36 = \boxed{0{,}309}$, Stufe 3 $0{,}84/1{,}72 = \boxed{0{,}488}$, Stufe 4 $2{,}1/2{,}8 = \boxed{0{,}750}$. **Schwelle**: $p' \geq 0{,}5$ heißt Odds $7\,p/(1-p) \geq 1$, also $7p \geq 1 - p$ und $p \geq 1/8 = p^*$. Gewichten mit C_{FN}/C_{FP} und die Schwelle 0,5 treffen dieselben Entscheidungen wie das ungewichtete Modell mit p^*. **Kalibrierung**: p' ist keine Ausfallwahrscheinlichkeit mehr, Stufe 4 zeigt 75 % bei beobachteten 19 %. Brier-Score und erwartete Kosten mit p' wären falsch. **Zurück**: Odds durch w teilen, $p = p'/(p' + w\,(1-p'))$, etwa $0{,}75/(0{,}75 + 7 \cdot 0{,}25) = 0{,}30$. **balanced**: Mit $w = (1-\pi)/\pi$ gilt $p' \geq 0{,}5$ genau für $p \geq 1/(1+w) = \boxed{\pi}$, die Basisrate im Training. Wer Wahrscheinlichkeiten braucht, lässt die Daten ungewichtet und verschiebt die Schwelle.

Zum Nachprüfen im Notebook:

```
from sklearn.linear_model import LogisticRegression
X = np.eye(4)[np.repeat([0, 1, 2, 3], 100)]
y = np.concatenate([np.r_[np.ones(k), np.zeros(100 - k)] for k in [2, 6, 12, 30]])
for w in [1, 7]:
    lr = LogisticRegression(solver="newton-cholesky", C=1e6, fit_intercept=False,
                            class_weight={0: 1, 1: w}).fit(X, y)
    print(lr.predict_proba(np.eye(4))[:, 1].round(3))
```

liefert `[0.02 0.06 0.12 0.3 ]` und `[0.125 0.309 0.488 0.75 ]`: je Stufe 100 Trainingsschichten mit den Quoten p_k, gewichtet die Werte aus (d).

> **Typischer Fehler**
>
> In (d) die Wahrscheinlichkeit statt der Odds mit w multiplizieren: $7 \cdot 0{,}30 = 2{,}1$ ist keine Wahrscheinlichkeit.

Bewertung: (a) Quoten, erwartete Ausfälle und Mittelwerte 1 P, Deutung und neue Werte 1 P. (b) Brier-Score 1 P, Vergleich mit der Basisrate 1 P. (c) gewichtete Schätzung 1 P, Odds und Achsenabschnitt 1 P. (d) p' und Schwelle 1 P, Kalibrierung, Rückrechnung und balanced 1 P.

Lösung zu Aufgabe 5 Aufbau und Teilgruppen

(a) **A: Leckage.** Mit `center=True` steckt die Schwingstärke der nächsten Schicht im Merkmal, am Ende der aktuellen Schicht unbekannt und aus genau der Schicht, deren Ausfall vorhergesagt wird. Korrektur: `rolling(3)` ohne `center`, aktuelle und zwei vorige Schichten.
B: Leckage durch Vorverarbeitung auf allen Daten. Die Auswahl kennt die Ausfälle des Testjahres, zufällig passende Kenngrößen sehen im Test zu gut aus. Korrektur: nur mit dem ersten Jahr auswählen, in der Kreuzvalidierung je Falte als Schritt der Pipeline.
C: Leckage durch zufällige Teilung. Nachbarschichten mit eng verwandter Schwingstärke liegen in Training und Test, das Training enthält Schichten nach den Testschichten, etwa

nach dem Sensortausch. Der Test zeigt nicht, wie das Modell im nächsten Jahr abschneidet. Korrektur: nach der Zeit teilen, Einstellungen mit `TimeSeriesSplit` wählen.
D: keine Leckage. Die vorige Schicht ist am Ende der aktuellen bekannt, die Teilung folgt der Zeit. Den fehlenden Wert der ersten Schicht je Maschine ersetzt die Pipeline mit dem Median des Trainings.

(b) **Zerspanung**: Basisrate 80/1.000 = $\boxed{0{,}080}$, Alarme 300/1.000 = 0,300, Precision 60/300 = $\boxed{0{,}200}$, Recall 60/80 = $\boxed{0{,}750}$, Falsch-positiv-Rate 240/920 ≈ $\boxed{0{,}261}$. **Montage**: Basisrate $\boxed{0{,}040}$, Alarme 150/1.000 = 0,150, Precision 30/150 = $\boxed{0{,}200}$, Recall 30/40 = $\boxed{0{,}750}$, Falsch-positiv-Rate 120/960 = $\boxed{0{,}125}$. Precision und Recall sind gleich, also auch der Anteil verpasster Ausfälle von 0,25. Die FPR ist in der Zerspanung gut doppelt so hoch.

(c) Aus Aufgabe 2(b) mit $1-s = \text{FPR}$: $\frac{\text{Precision}}{1-\text{Precision}} = \frac{\text{Recall}}{\text{FPR}} \cdot \frac{\pi}{1-\pi}$, nach FPR aufgelöst die Formel. Probe: $0{,}75 \cdot \frac{0{,}08}{0{,}92} \cdot 4 = 0{,}261$ und $0{,}75 \cdot \frac{0{,}04}{0{,}96} \cdot 4 = 0{,}125$. **Folgerung**: Bei gleicher Precision und gleichem Recall ist die FPR proportional zu $\pi/(1-\pi)$, bei verschiedenen Basisraten also verschieden, hier um den Faktor $\frac{0{,}08/0{,}92}{0{,}04/0{,}96} \approx 2{,}09$. Ausnahmen: Bei Precision 1 gibt es keine Fehlalarme, die FPR ist überall 0. Bei Recall 0 ist die Precision 0 oder nicht definiert, die Formel gilt dann nicht. **Montage mit der FPR der Zerspanung**: Odds der Precision $\frac{0{,}75}{240/920} \cdot \frac{0{,}04}{0{,}96} = 2{,}875 \cdot 0{,}0417 \approx 0{,}1198$, Precision ≈ $\boxed{0{,}107}$ statt 0,200. **Entscheidung**: Gleiche Precision heißt, ein Alarm bedeutet überall dasselbe Risiko, gleiche Fehlerraten heißen, Ausfälle und ruhige Schichten werden überall gleich oft falsch eingeordnet. Das Kriterium legen Instandhaltung und Werksleitung vor dem Modell fest, bei Maschinen nach den Kosten. Bei Modellen über Menschen ist es eine Frage der Fairness, im Werk mit dem Betriebsrat (Skript 7.3).

> **Typischer Fehler**
> In (b) die Falsch-positiv-Rate als FP/(TP + FP) rechnen: 240/300 = 120/150 = 0,8 ist 1 − Precision, der Anteil der Fehlalarme unter den Alarmen, nicht unter den ruhigen Schichten.

Bewertung: (a) A 1 P, B 1 P, C und D 1 P. (b) Kennzahlen beider Gruppen 1 P, Vergleich 1 P. (c) Formel und Folgerung 1 P, Precision der Montage und Entscheidung 1 P.

Lösung zu Aufgabe 6 Die Zerlegung des Brier-Scores (Zusatz)

(a) Die Stufe hat $o_k = n_k \bar{o}_k$ Ausfälle und $n_k - o_k$ ruhige Schichten, also

$$\sum_i (p_k - y_i)^2 = n_k\left[\bar{o}_k(1-p_k)^2 + (1-\bar{o}_k)\,p_k^2\right] = n_k\left[p_k^2 - 2p_k\bar{o}_k + \bar{o}_k\right] = n_k\left[(p_k-\bar{o}_k)^2 + \bar{o}_k - \bar{o}_k^2\right].$$

(b) Mit $\sum_k n_k = n$ und $\sum_k n_k\bar{o}_k = n\bar{o}$ ist $\sum_k n_k(\bar{o}_k-\bar{o})^2 = \sum_k n_k\bar{o}_k^2 - n\bar{o}^2$, also $\sum_k n_k\,\bar{o}_k(1-\bar{o}_k) = n\bar{o} - \sum_k n_k\bar{o}_k^2 = n\,\text{UNC} - n\,\text{RES}$. Die Summe von (a) über alle Stufen, durch n geteilt, ist $B = \text{REL} + \text{UNC} - \text{RES}$.

(c) Mit $\bar{o} = 130/2.100 = 0{,}0619$: REL = $(0 + 500 \cdot 0{,}04^2 + 500 \cdot 0{,}06^2 + 400 \cdot 0{,}11^2)/2.100 = 7{,}44/2.100 \approx \boxed{0{,}0035}$, RES = $(1.200 \cdot 0{,}0419^2 + 500 \cdot 0{,}0019^2 + 400 \cdot 0{,}1281^2)/2.100 \approx 8{,}67/2.100 \approx \boxed{0{,}0041}$ und UNC = $0{,}0619 \cdot 0{,}9381 \approx \boxed{0{,}0581}$. Zusammen 0,0035 − 0,0041 + 0,0581 = 0,0575 wie in Aufgabe 4(b). Mit $p_k = \bar{o}_k$ fällt REL weg: $B = \text{UNC} - \text{RES} = 113{,}28/2.100 \approx \boxed{0{,}0539}$, um 7,2 % besser als die Basisrate in Aufgabe 4(b). Rekalibrieren (Skript 5.4) entfernt nur REL. Die Auflösung, wie gut die Stufen Risiken trennen, bleibt, die Unsicherheit liegt an den Daten.