Tutoriumsblatt 9

Bäume, Ensembles und Feature Engineering

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Teilungen, Gini-Unreinheiten und Boosting-Runden von Hand rechnen und herleiten,
- die Streuung von Wäldern abschätzen, Leckage finden, Modelle fair wählen und deuten.

So arbeitest du mit dem Blatt

Du programmierst nicht, du rechnest mit dem Taschenrechner und begründest, Zwischenwerte genauer, als du sie angibst. Hängst du, rechne mit den Werten unter „Zur Kontrolle“ weiter. Werkszahlen stammen aus `daten/` und dem Skript, „ausgedacht“ heißt fiktiv. Eine Charge ist eine Ladung des Härteofens M-10, in Toleranz heißt 52 bis 58 HRC, eine Schicht ist eine Maschine in einer Produktionsschicht. Gib Ergebnisse auf zwei bis drei Nachkommastellen an. Zum Notebook: Aufgabe 1 gehört zu TODO 1 bis 3; Aufgabe 2 zu 4 und 5; Aufgabe 3 zu 6 und 7; Aufgabe 4 zu 8 und 9; Aufgabe 5 zu 10 bis 13.

Aufgabe 1 Ein Baum von Hand

9 Punkte · etwa 20 Min.

Bezug: Modul 9, Lerneinheit 1 (Ein Baum, der Fragen stellt)

Sechs Chargen mit schnellem Transfer (ausgedacht). Ein Stumpf teilt sie nach dem Kohlenstoff, links L mit $x_i \le s$, rechts R.

Kohlenstoff x_i (%)	0,42	0,43	0,44	0,46	0,47	0,49
Härte y_i (HRC)	54,6	55,8	55,2	57,0	58,8	57,0

(a) Mit dem Mittel $\bar{y}$ aller n Chargen und $Q_0 = \sum_i (y_i - \bar{y})^2$: Zeige, dass für jede Schwelle s

$$Q(s) = Q_0 - V(s), \qquad V(s) = n_L(\bar{y}_L - \bar{y})^2 + n_R(\bar{y}_R - \bar{y})^2 = D_L^2 \, \frac{n}{n_L \, n_R}$$

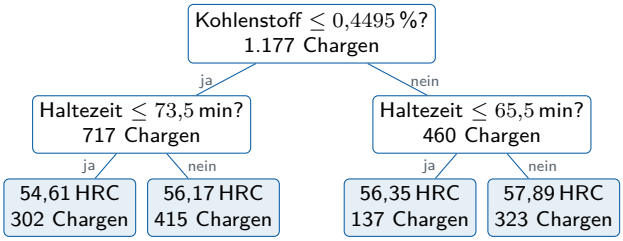
mit $D_L = \sum_{i \in L}(y_i - \bar{y})$. Tipp: Zerlege $y_i - \bar{y} = (y_i - \bar{y}_L) + (\bar{y}_L - \bar{y})$. Berechne $Q(s)$ für alle fünf Schwellen zwischen benachbarten Werten. Welche wählt der Stumpf, und was sagt er links und rechts voraus? Zur Kontrolle: $Q_0 = 11{,}52$ und $Q(0{,}425) = 7{,}632$. [3 P]

(b) Ein Klassifikationsbaum fragt nur, ob eine Charge in Toleranz liegt. Berechne die Gini-Unreinheit $G = 2p(1-p)$ ungeteilt und die gewichtete Unreinheit der Teilungen bei 0,45 und 0,465. Welche der fünf Schwellen wählt er, und warum eine andere als in (a)? [2 P]

(c) Ohne Grenze teilt ein Baum, bis jedes Blatt rein ist. Wie viele Blätter hätte er für die Chargen aus (a), wie groß wäre Q? Angenommen, die Härte streut bei gleichen Einstellungen unabhängig mit der Varianz σ^2 um ein Mittel μ, und ein Blatt sagt das Mittel seiner m Trainingschargen voraus. Zeige: Für eine neue Charge mit diesen Einstellungen ist der erwartete quadrierte Fehler $\sigma^2(1 + 1/m)$. Was ergibt sich als Wurzel für $m = 1$ und $m = 20$ mit $\sigma = 1{,}1$ HRC? Was folgt für den voll gewachsenen Baum aus Skript 1.4 mit 1.328 Blättern für 1.410 Chargen? [2 P]

Der linke Teil des Baums der Tiefe 3 aus Skript 1.4, gelernt mit den Chargen des ersten Jahres mit Transfer bis 19,15 s, und vier neue Chargen (ausgedacht):

	Ofen (°C)	Halten (min)	Kohlenst. (%)	Transfer (s)
K1	868	62	0,438	12,4
K2	874	70	0,476	15,2
K3	861	80	0,442	14,6
K4	879	60	0,462	10,2



(d) Welche Härte sagt der Baum für K1 bis K4 voraus, und liegen sie danach in Toleranz? Welche Spalten braucht er nicht, und für welche Chargen gilt er? Auf wie vielen Chargen des ersten Jahres beruht die Vorhersage für K2? [2 P]

Aufgabe 2 Bagging, Random Forest und Out-of-Bag

7 Punkte · etwa 15 Min.

Bezug: Modul 9, Lerneinheit 2 (Viele Bäume: Bagging und Random Forest)

Ein Wald sagt für eine feste Charge das Mittel $\bar{T} = \frac{1}{B}\sum_{b=1}^{B} T_b$ seiner B Bäume voraus. Über die Bootstrap-Stichproben ist jede Vorhersage T_b zufällig, alle mit derselben Varianz σ^2 und je zwei mit der Korrelation ρ.

(a) Zeige $\mathrm{Var}(\bar{T}) = \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2$. Was ergibt sich für $\rho = 0$, für $\rho = 1$ und für $B \to \infty$? [2 P]

(b) Angenommen, beim Bagging (`max_features=6`) ist $\sigma^2 = 1{,}0\,\mathrm{HRC}^2$ wie bei einem tiefen Baum in Skript 2.2 und $\rho = 0{,}3$, beim Random Forest mit `max_features=2` ist $\sigma^2 = 1{,}4\,\mathrm{HRC}^2$ und $\rho = 0{,}1$ (ausgedacht). Berechne $\mathrm{Var}(\bar{T})$ für $B = 10$, $B = 50$ und $B \to \infty$. Ab wie vielen Bäumen ist der zweite Teil jeweils höchstens ein Zehntel des ersten? Was bewirkt `max_features`, und was zeigt die Formel nicht? Zur Kontrolle: Random Forest mit $B = 10$: $0{,}266\,\mathrm{HRC}^2$. [2 P]

(c) Der Wald aus Skript 2.4 hat $B = 200$ Bäume für $n = 1.410$ Chargen. Eine Charge fehlt in einer Bootstrap-Stichprobe mit der Wahrscheinlichkeit $q = (1 - 1/n)^n \approx 0{,}368$ (Modul 5). Für wie viele Bäume ist sie im Mittel out of bag, also nicht in der Stichprobe? Mit nur $B = 10$: Wie wahrscheinlich ist eine Charge in keinem Baum out of bag, wie viele erwartest du so, ab welchem B weniger als eine? Wie groß ist mit den Werten des Random Forest aus (b) die Varianz der Out-of-Bag-Vorhersage einer Charge bei $B = 200$, verglichen mit dem ganzen Wald? Zur Kontrolle: $0{,}632^{10} \approx 0{,}0102$. [2 P]

(d) Bei der Härterei trifft die Out-of-Bag-Schätzung das zweite Jahr genau (0,828 und 0,828, Skript 2.4), bei den Sensordaten liegt die Out-of-Bag-AUC um 0,010 bis 0,016 darüber (Skript 4.4). Nenne zwei verschiedene Gründe für diese Lücke. Welchen davon beseitigt eine Validierung mit den letzten drei Monaten des ersten Jahres wie in Skript 3.3, welchen nicht? [1 P]

Aufgabe 3 Boosting von Hand

8 Punkte · etwa 18 Min.

Bezug: Modul 9, Lerneinheit 3 (Boosting: aus Fehlern lernen)

Sechs Chargen mit schnellem Transfer (ausgedacht). Gradient Boosting mit Stümpfen und der Lernrate $\nu = 0{,}5$ startet mit $f_0 = \bar{y}$. In Runde m passt ein Stumpf h_m die Residuen $r_i = y_i - f_{m-1}(x_i)$ an, jedes Blatt sagt das Mittel der Residuen darin voraus, und $f_m = f_{m-1} + \nu\, h_m$.

Haltezeit x_i (min)	50	60	70	80	90	100
Härte y_i (HRC)	53,6	54,8	56,3	56,6	57,2	57,5

(a) Runde 1: Berechne f_0, die Residuen und $\sum_i r_i^2$. Da die Residuen die Summe 0 haben, ist nach Aufgabe 1(a) $V(s) = S_L^2\, n/(n_L\, n_R)$ mit der Summe S_L der Residuen links. Finde den besten Stumpf unter allen fünf Schwellen, seine Blattwerte und f_1. Zur Kontrolle: $V(65) = 9{,}72$. [3 P]

(b) Warum haben auch die Residuen nach Runde 1 die Summe 0? Rechne Runde 2: Residuen, bester Stumpf, Blattwerte, f_2 und $\sum_i (y_i - f_2(x_i))^2$. Warum teilt der Stumpf jetzt an einer anderen Stelle? Zur Kontrolle: Nach Runde 1 ist $\sum_i r_i^2 = 4{,}05$. [2 P]

(c) Zeige für einen solchen Stumpf h: $\sum_i (r_i - \nu h_i)^2 = \sum_i r_i^2 - \nu(2-\nu)\sum_i h_i^2$ und $\sum_i h_i^2 = V(s)$. Bestätige damit die Quadratsummen nach beiden Runden. Was heißt das für $\nu = 1$ und für $\nu = 2$? [2 P]

(d) Wie groß wäre $\sum_i r_i^2$ nach Runde 1 mit $\nu = 0{,}1$? Wie viele Runden bräuchte $\nu = 0{,}1$, um 4,05 zu erreichen, wenn der Stumpf jedes Mal bei 65 min teilte? Warum stoppt man trotzdem nach einer Validierung mit späteren Daten (Skript 3.3)? [1 P]

Aufgabe 4 Rollierende Merkmale und Leckage

8 Punkte · etwa 17 Min.

Bezug: Modul 9, Lerneinheit 4 (Merkmale bauen: Feature Engineering)

Schwingstärke zweier Drehmaschinen in mm/s (ausgedacht), sortiert wie `sensordaten.csv`: Auf M-03 folgt M-09 derselben Schicht.

Schicht	1	2	3	4	5	6
M-03	3,6	3,8	3,5	3,7	4,5	4,7
M-09	2,5	2,7	2,6	2,4	2,6	3,4

Der Normalwert ist wie in Skript 4.1 der Median der drei vorigen eigenen Schichten:

```
g = daten.groupby("maschine")["vibration_mm_s"]
normal = g.transform(lambda x: x.shift(1).rolling(3).median())
daten["rel"] = daten["vibration_mm_s"] / normal - 1
```

(a) Berechne Normalwert und `rel` für beide Maschinen in allen sechs Schichten, `rel` in Prozent auf eine Nachkommastelle. Warum fehlen beide in den Schichten 1 bis 3? Wo fällt eine Maschine auf? Zur Kontrolle: M-09 in Schicht 6: +30,8 %. [3 P]

(b) Vier Kolleginnen bauen es anders:

```
normal_a = g.transform(lambda x: x.rolling(3).median())                  # A
normal_b = g.transform(lambda x: x.rolling(3, center=True).median())     # B
normal_c = daten["vibration_mm_s"].shift(1).rolling(3).median()          # C
daten["vibration_mm_s"] = daten.groupby("maschine")["vibration_mm_s"].bfill()   # D
```

Welchen Normalwert liefern A, B und C für M-03 in Schicht 5 und 6? D füllt vorher Sensorausfälle: Was setzt es ein, wenn bei M-09 der Wert aus Schicht 5 fehlt? Prüfe für jede Fassung: Nutzt sie Information, die am Ende der Schicht unbekannt ist (Leckage), oder ist es ein anderer Fehler? Findet ihn der Abschneidetest (Skript 4.3)? Wie korrigierst du? [4 P]

(c) Nach dem Sensortausch an Linie 2 am 2. März 2026 lag die Schwingung von M-01 in den zwei Monaten danach im Median um gut ein Fünftel höher als in den zwei davor. Angenommen, nach einem Tausch liegen alle Werte um denselben Faktor $c > 0$ höher. Zeige, dass `rel` gleich bleibt, sobald das Fenster nur neue Werte enthält. Wie groß ist `rel` in der ersten Schicht danach bei $c = 1{,}2$ und sonst normaler Schwingung? [1 P]

Aufgabe 5 Auswahl und Deutung

8 Punkte · etwa 20 Min.

Bezug: Modul 9, Lerneinheiten 5 (Hyperparameter fair wählen), 6 (Was das Modell gelernt hat) und 7 (Wann gewinnen Bäume, wann nicht?)

Ein Baum für die Härte, kreuzvalidiert mit `TimeSeriesSplit(n_splits=5)` im ersten Jahr: mittlerer RMSE und Streuung (Standardabweichung) über die Falten in HRC.

`max_depth`	3	4	5	6	8	10
RMSE	1,886	1,806	1,674	1,662	1,683	1,724
Streuung	0,088	0,122	0,077	0,087	0,108	0,147

(a) Wähle nach der Regel eines Standardfehlers die einfachste Einstellung, deren RMSE den besten Wert um höchstens dessen Standardfehler (Streuung/$\sqrt{5}$) übersteigt. Warum ist der beste Wert 1,662 für die Einstellung, die ihn erreicht, eher zu optimistisch? [2 P]

(b) Gemessen wurden für K1 bis K4 aus Aufgabe 1(d) 55,0; 58,3; 55,7 und 56,9 HRC. Berechne den mittleren quadrierten Fehler (MSE) des Baums auf zwei Nachkommastellen. Vertausche den Kohlenstoff zyklisch, K1 bekommt den Wert von K2, K2 den von K3, K3 den von K4 und K4 den von K1, sage neu voraus und berechne den MSE. Die Permutations-Wichtigkeit ist der Anstieg des MSE. Berechne sie ebenso für die Haltezeit. Wie wichtig sind Ofentemperatur und Transferzeit? Was ergäbe für den Kohlenstoff der Tausch von K1 mit K3 und K2 mit K4? Zur Kontrolle: Ohne Vertauschen ist der MSE 0,21. [2 P]

(c) Berechne an K1 bis K4 die partielle Abhängigkeit des Baums vom Kohlenstoff bei 0,44 und 0,46 %, also das Mittel der vier Vorhersagen mit diesem Wert, und die ICE-Kurven. Was zeigen sie über das Modell? Warum springt K2 stärker als die anderen? [2 P]

(d) Im ersten Jahr dauerte der längste Transfer 31,6 s. Der Baum der Tiefe 2 aus Skript 1.3 sagt über 22,85 s immer 48,29 HRC voraus. Ein lineares Modell mit Knickmerkmal (Skript 4.5), nur mit der Transferzeit t im ersten Jahr angepasst, lautet gerundet $\hat{y} = 56{,}2 - 1{,}1 \cdot \max(t - 18;\ 0)$. Was sagen beide für 34 und 40 s voraus? Gemessen wurden im zweiten Jahr bei 34,1 und 34,2 s je 42,0 HRC, bei 40,0 s 36,7 und 35,1 HRC. Vergleiche, erkläre und folgere. [2 P]

Aufgabe 6 (⋆) Gini und Varianz

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 9, Lerneinheit 1

Kodiere „in Toleranz“ als $y_i = 1$, sonst $y_i = 0$. (a) Zeige: Bei n Chargen mit dem Anteil p in Toleranz ist $\sum_i (y_i - p)^2 = n\,p\,(1-p)$, also $G = \frac{2}{n}\sum_i (y_i - \bar{y})^2$. (b) Folgere: Die gewichtete Gini-Unreinheit einer Teilung ist $2\,Q(s)/n$ mit $Q(s)$ wie in Aufgabe 1(a), für die 0-1-Werte. Was heißt das für einen Regressionsbaum auf diesen Werten? (c) Prüfe das an Aufgabe 1 bei 0,45 und 0,465. Ist auch die gewichtete Entropie $-\sum_k p_k \log_2 p_k$ ein Vielfaches von $Q(s)$?

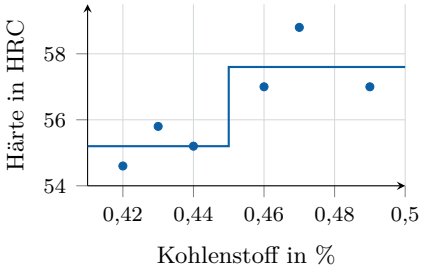
Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Ein Baum von Hand

(a) In L ist $\sum_{i\in L}(y_i-\bar y)^2=\sum_{i\in L}(y_i-\bar y_L)^2+2(\bar y_L-\bar y)\sum_{i\in L}(y_i-\bar y_L)+n_L(\bar y_L-\bar y)^2$, und die mittlere Summe ist 0. Ebenso in R. Zusammen ist $Q_0=Q(s)+n_L(\bar y_L-\bar y)^2+n_R(\bar y_R-\bar y)^2$. Wegen $n_L(\bar y_L-\bar y)=D_L$ und $n_R(\bar y_R-\bar y)=D_R=-D_L$, denn alle Abweichungen summieren sich zu 0, ist $V(s)=D_L^2/n_L+D_L^2/n_R=D_L^2\,n/(n_L\,n_R)$. **Rechnung**: $\bar y=338{,}4/6=56{,}4$, Abweichungen $-1{,}8$; $-0{,}6$; $-1{,}2$; $0{,}6$; $2{,}4$; $0{,}6$, also $Q_0=3{,}24+0{,}36+1{,}44+0{,}36+5{,}76+0{,}36=11{,}52$.

s	n_L	D_L	$n/(n_Ln_R)$	$V(s)$	$Q(s)$
0,425	1	−1,8	6/5	3,888	7,632
0,435	2	−2,4	6/8	4,320	7,200
0,45	3	−3,6	6/9	8,640	2,880
0,465	4	−3,0	6/8	6,750	4,770
0,48	5	−0,6	6/5	0,432	11,088



Der Stumpf wählt $\boxed{s=0{,}45\,\%}$ mit $Q=\boxed{2{,}88}$ und sagt links $165{,}6/3=\boxed{55{,}2\,\text{HRC}}$, rechts $172{,}8/3=\boxed{57{,}6\,\text{HRC}}$ voraus. Der Baum des Skripts teilt die 1.177 Chargen mit schnellem Transfer fast an derselben Stelle, bei 0,4495 %.

(b) Nur die Charge mit 58,8 HRC ist zu hart, die anderen fünf liegen in Toleranz. Ungeteilt ist $p=5/6$ und $G=2\cdot\frac{5}{6}\cdot\frac{1}{6}=\boxed{0{,}278}$. Bei 0,45 ist links $G_L=0$, rechts liegen 2 von 3 in Toleranz, $G_R=2\cdot\frac{2}{3}\cdot\frac{1}{3}=0{,}444$, gewichtet $\frac{3}{6}\cdot 0+\frac{3}{6}\cdot 0{,}444=\boxed{0{,}222}$. Bei 0,465 ist links $G_L=0$, rechts 1 von 2, $G_R=0{,}5$, gewichtet $\frac{2}{6}\cdot 0{,}5=\boxed{0{,}167}$. Die übrigen Schwellen ergeben 0,267 (0,425), 0,250 (0,435) und 0,267 (0,48). Der Klassifikationsbaum wählt also $\boxed{0{,}465}$ und sagt rechts die Wahrscheinlichkeit 0,5 voraus. **Warum**: Für die Toleranz zählt nur drinnen oder draußen, 57,0 HRC zählt wie 55,2. 0,465 trennt die einzige Charge außerhalb mit nur einer Nachbarin ab. Für die Härte zählt der Abstand, ab 0,46 % liegen alle deutlich höher.

(c) Sechs Blätter, eine Charge je Blatt, denn benachbarte Chargen haben immer verschiedene Härten, und $\boxed{Q=0}$. **Herleitung**: Mit $y_0=\mu+\varepsilon_0$ und $\bar y_m=\mu+\bar\varepsilon$, $\mathrm{Var}(\bar\varepsilon)=\sigma^2/m$ und ε_0 unabhängig von $\bar\varepsilon$ ist $E(y_0-\bar y_m)^2=\mathrm{Var}(\varepsilon_0-\bar\varepsilon)=\sigma^2+\sigma^2/m=\sigma^2(1+1/m)$. Als Wurzel: $m=1$: $1{,}1\cdot\sqrt{2}\approx\boxed{1{,}56\,\text{HRC}}$, $m=20$: $1{,}1\cdot\sqrt{1{,}05}\approx\boxed{1{,}13\,\text{HRC}}$. **Folgerung**: Beim voll gewachsenen Baum enthalten 1.256 der 1.328 Blätter eine einzige Charge. Er sagt meist eine einzelne verrauschte Messung voraus, verdoppelt so die Fehlervarianz und hat das Rauschen auswendig gelernt: Überanpassung. Im Training ist sein Fehler 0, im zweiten Jahr sein RMSE 1,71 HRC. Abhilfe: `min_samples_leaf` oder `max_depth` begrenzen, in Skript 1.4 bringen 20 Chargen je Blatt im zweiten Jahr $R^2=0{,}74$ statt 0,67, oder viele Bäume mitteln.

(d) K1: 0,438 % ≤ 0,4495 % und 62 min ≤ 73,5 min, also $\boxed{54{,}61}$ HRC. K2: 0,476 % und 70 min > 65,5 min, also $\boxed{57{,}89}$. K3: 0,442 % ≤ 0,4495 %, aber 80 min > 73,5 min, also $\boxed{56{,}17}$. K4: 0,462 % und 60 min ≤ 65,5 min, also $\boxed{56{,}35}$. Laut Baum liegen **alle vier in Toleranz**, K2 knapp unter 58 HRC. Ofentemperatur und Transferzeit braucht dieser Teil **nicht**, die Transferzeit entscheidet nur, ob er gilt: **nur für Chargen mit Transfer bis 19,15 s** wie K1 bis K4. Für K2 sagt er das Mittel von **323** Chargen voraus. Bei viel Kohlenstoff teilt er schon bei 65,5 min, bei wenig erst bei 73,5 min.

Typischer Fehler

In (b) die Unreinheiten der Teile ungewichtet mitteln: Bei 0,465 ergäbe $(0+0{,}5)/2 = 0{,}25$ statt 0,167, und 0,425 und 0,48 schienen mit $(0+0{,}32)/2 = 0{,}16$ am besten, denn ein Teil mit einer Charge ist immer rein. Jeder Teil zählt mit seinem Anteil.

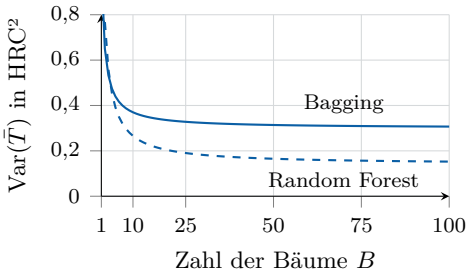
Bewertung: (a) Herleitung 1 P, Tabelle 1 P, Wahl und Vorhersagen 1 P. (b) Gini ungeteilt und bei 0,45 1 P, bei 0,465, Wahl und Begründung 1 P. (c) Blätter, Q und Herleitung 1 P, Zahlen und Folgerung 1 P. (d) vier Vorhersagen und Toleranz 1 P, unnötige Spalten, Gültigkeit und 323 Chargen 1 P.

Lösung zu Aufgabe 2 Bagging, Random Forest und Out-of-Bag

(a) $\operatorname{Var}\left(\sum_b T_b\right) = \sum_b \operatorname{Var}(T_b) + \sum_{b\neq c} \operatorname{Cov}(T_b, T_c) = B\sigma^2 + B(B-1)\rho\sigma^2$. Durch B^2 geteilt: $\operatorname{Var}(\bar{T}) = \frac{\sigma^2}{B} + \frac{B-1}{B}\rho\sigma^2 = \boxed{\rho\sigma^2 + \frac{1-\rho}{B}\sigma^2}$. $\rho = 0$: σ^2/B, das Quadrat des Standardfehlers eines Mittels aus Modul 5, unabhängige Bäume. $\rho = 1$: σ^2, alle Bäume gleich, Mitteln bringt nichts. $B \to \infty$: $\rho\sigma^2$, der zweite Teil verschwindet, der erste bleibt.

(b) Bagging: $\rho\sigma^2 = 0{,}3$ und $(1-\rho)\sigma^2 = 0{,}7$, also $0{,}3 + 0{,}07 = \boxed{0{,}37}$ bei $B = 10$, $0{,}3 + 0{,}014 = \boxed{0{,}314}$ bei $B = 50$ und $\boxed{0{,}3}$ im Grenzfall. Random Forest: 0,14 und 1,26, also $\boxed{0{,}266}$, $0{,}14 + 0{,}0252 \approx \boxed{0{,}165}$ und $\boxed{0{,}14}$. Ein Zehntel heißt $(1-\rho)/(B\rho) \leq 0{,}1$, also $B \geq 10(1-\rho)/\rho$: beim Bagging $B \geq 23{,}3$, also **24 Bäume**, beim Random Forest **90 Bäume**.

`max_features`: Weniger Merkmale je Teilung machen die Bäume unähnlicher, ρ und $\rho\sigma^2$ sinken. Dafür wird jeder Baum schlechter: σ^2 steigt und, was die Formel nicht zeigt, die Verzerrung. Sie beschreibt nur die Streuung, nicht den Fehler des mittleren Modells. In Skript 2.3 fällt das Bestimmtheitsmaß mit einem Merkmal je Teilung auf 0,698, mit allen sechs sind es 0,838.



(c) Im Mittel ist eine Charge für $200 \cdot 0{,}368 = \boxed{73{,}6}$ Bäume out of bag, im Wald des Skripts für 73,7, je nach Charge zwischen 48 und 98. Mit $B = 10$ ist sie in keinem Baum out of bag, wenn sie in allen zehn Stichproben vorkommt: $0{,}632^{10} \approx \boxed{0{,}0102}$. Erwartet sind $1.410 \cdot 0{,}0102 \approx \boxed{14}$ Chargen ohne Out-of-Bag-Vorhersage, scikit-learn warnt dann „Some inputs do not have OOB scores“ (mit `random_state=0` sind es 14). Weniger als eine heißt $1.410 \cdot 0{,}632^B < 1$, also $B > \ln 1.410/(-\ln 0{,}632) = 7{,}251/0{,}459 \approx 15{,}8$, **ab 16 Bäumen**. Die Out-of-Bag-Vorhersage mittelt nur etwa 73,6 Bäume: $0{,}14 + 1{,}26/73{,}6 \approx \boxed{0{,}157}$ HRC² statt $0{,}14 + 1{,}26/200 \approx 0{,}146$. Als kleinerer Wald ist sie etwas ungenauer, die Schätzung eher leicht pessimistisch.

(d) **Nachbarschaft**: Jede Charge ist ein eigener Vorgang, Schichten derselben Maschine hängen zeitlich zusammen: Ein Baum, der eine Schicht nicht gesehen hat, kennt meist die Schichten davor und danach. **Änderungen** im zweiten Jahr wie den Sensortausch an Linie 2 kennt keine Schätzung aus dem ersten Jahr. Die Validierung mit Juli bis September beseitigt den ersten Grund, fast keine Prüfschicht hat dann Nachbarn im Training, den zweiten nicht.

Typischer Fehler

In (c) $0{,}368^{10}$ statt $0{,}632^{10}$ rechnen: $0{,}368^{10} \approx 0{,}00005$ ist die Wahrscheinlichkeit, in allen zehn Bäumen out of bag zu sein, also in keiner Stichprobe vorzukommen.

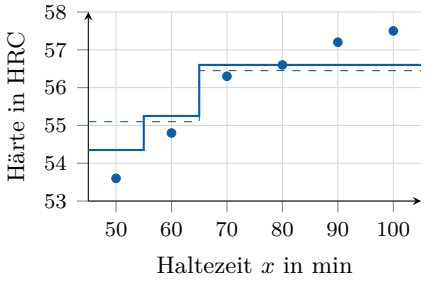
Bewertung: (a) Herleitung 1 P, Sonderfälle 1 P. (b) Varianzen und Baumzahlen 1 P, `max_features` und Grenze der Formel 1 P. (c) 73,6 Bäume und $B = 10$ 1 P, 16 Bäume und Out-of-Bag-Varianz 1 P. (d) Gründe und Einordnung 1 P.

Lösung zu Aufgabe 3 Boosting von Hand

(a) $f_0 = 336{,}0/6 = \boxed{56{,}0}$, Residuen $-2{,}4$; $-1{,}2$; $0{,}3$; $0{,}6$; $1{,}2$; $1{,}5$ mit $\sum_i r_i^2 = 5{,}76 + 1{,}44 + 0{,}09 + 0{,}36 + 1{,}44 + 2{,}25 = \boxed{11{,}34}$. Links aufsummiert ist $S_L = -2{,}4$; $-3{,}6$; $-3{,}3$; $-2{,}7$; $-1{,}5$ und $V(s) = 6 \cdot 5{,}76/5 = 6{,}912$; $6 \cdot 12{,}96/8 = 9{,}72$; $6 \cdot 10{,}89/9 = 7{,}26$; $6 \cdot 7{,}29/8 = 5{,}4675$; $6 \cdot 2{,}25/5 = 2{,}7$ für 55, 65, 75, 85 und 95 min. Der Stumpf teilt bei $\boxed{65\,\text{min}}$ mit den Blattwerten $-3{,}6/2 = -1{,}8$ und $3{,}6/4 = 0{,}9$. Also $f_1 = 56{,}0 - 0{,}9 = \boxed{55{,}1}$ für 50 und 60 min und $56{,}0 + 0{,}45 = \boxed{56{,}45}$ für 70 bis 100 min.

(b) Die neue Summe ist $\sum_i r_i - \nu \sum_i h_i$ mit $\sum_i h_i = \sum_i r_i = 0$, denn jedes Blatt sagt das Mittel seiner Residuen voraus. Die neuen Residuen sind $-1{,}5$; $-0{,}3$; $-0{,}15$; $0{,}15$; $0{,}75$; $1{,}05$ mit $\sum_i r_i^2 = 4{,}05$. $S_L = -1{,}5$; $-1{,}8$; $-1{,}95$; $-1{,}8$; $-1{,}05$ ergibt $V = 2{,}7$; $2{,}43$; $2{,}535$; $2{,}43$; $1{,}323$. Der Stumpf teilt bei $\boxed{55\,\text{min}}$ mit den Blattwerten $-1{,}5$ und $1{,}5/5 = 0{,}3$. Also $f_2 = 55{,}1 - 0{,}75 = \boxed{54{,}35}$ bei 50 min, $55{,}1 + 0{,}15 = \boxed{55{,}25}$ bei 60 min und $56{,}45 + 0{,}15 = \boxed{56{,}6}$ ab 70 min, mit $\sum_i (y_i - f_2(x_i))^2 = \boxed{2{,}025}$.

Warum anders: Gewählt wird das größte $V(s)$. Bei 65 min bleiben nach Runde 1 nur die halben Blattmittel $-0{,}9$ und $0{,}45$, dieselbe Teilung brächte ein Viertel von 9,72, $6 \cdot 1{,}8^2/8 = 2{,}43$. Links liegen $-1{,}5$ und $-0{,}3$ weit auseinander: Die Charge mit 50 min allein abzutrennen bringt $6 \cdot 1{,}5^2/5 = 2{,}7$. Im Bild: f_1 gestrichelt, f_2 durchgezogen.



(c) Ausmultipliziert ist $\sum_i (r_i - \nu h_i)^2 = \sum_i r_i^2 - 2\nu \sum_i r_i h_i + \nu^2 \sum_i h_i^2$. In einem Blatt mit dem Mittel $\bar{r}$ der Residuen ist $\sum r_i h_i = \bar{r} \sum r_i = n_{\text{Blatt}}\, \bar{r}^2 = \sum h_i^2$, also $\sum_i r_i h_i = \sum_i h_i^2$ und $\boxed{\sum_i (r_i - \nu h_i)^2 = \sum_i r_i^2 - \nu(2 - \nu) \sum_i h_i^2}$. Dabei ist $\sum_i h_i^2 = n_L \bar{r}_L^2 + n_R \bar{r}_R^2 = V(s)$ wie in Aufgabe 1(a) mit $\bar{r} = 0$. **Probe**: $11{,}34 - 0{,}75 \cdot 9{,}72 = 11{,}34 - 7{,}29 = 4{,}05$ und $4{,}05 - 0{,}75 \cdot 2{,}7 = 2{,}025$. $\nu = 1$: $\nu(2 - \nu) = 1$, die ganze Verringerung $V(s)$ in einem Schritt. $\nu = 2$: kein Fortschritt, die Residuen $r_i - 2\bar{r}$ springen auf die andere Seite. Nur $0 < \nu < 2$ verringert den Fehler, am stärksten $\nu = 1$.

(d) Mit $\nu(2 - \nu) = 0{,}19$ ist $\sum_i r_i^2 = 11{,}34 - 0{,}19 \cdot 9{,}72 \approx \boxed{9{,}49}$. Teilt der Stumpf immer bei 65 min, schrumpfen die Blattmittel der Residuen je Runde um den Faktor 0,9, nach k Runden ist $\sum_i r_i^2 = Q(65) + 0{,}81^k \cdot 9{,}72$ mit $Q(65) = 11{,}34 - 9{,}72 = 1{,}62$. Aus $1{,}62 + 0{,}81^k \cdot 9{,}72 \le 4{,}05$ folgt $0{,}81^k \le 0{,}25$ und $k \ge \ln 0{,}25 / \ln 0{,}81 \approx 6{,}58$, also $\boxed{7\ \text{Runden}}$ statt einer. Mit jeder Runde passt sich das Modell enger an, irgendwann dem Rauschen. Die Runde mit dem kleinsten Fehler auf späteren Daten begrenzt das, in Skript 3.3 sind es 195, 68 und 13 Runden bei den Lernraten 0,03, 0,1 und 0,3.

Typischer Fehler

In (b) den zweiten Stumpf wieder an $y_i - f_0$ statt an $y_i - f_1(x_i)$ anpassen: Er teilte wieder bei 65 min, und Runde 2 wiederholte nur Runde 1.

Zum Nachprüfen im Notebook:

```
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import GradientBoostingRegressor
x = np.array([50, 60, 70, 80, 90, 100.0]).reshape(-1, 1)
y = np.array([53.6, 54.8, 56.3, 56.6, 57.2, 57.5])
f = np.full(6, y.mean())
for runde in [1, 2]:
    st = DecisionTreeRegressor(max_depth=1, random_state=0).fit(x, y - f)
    f = f + 0.5 * st.predict(x)
    print(st.tree_.threshold[0], round(((y - f) ** 2).sum(), 3))
gb = GradientBoostingRegressor(n_estimators=2, learning_rate=0.5, max_depth=1,
                               random_state=0).fit(x, y)
print(f.round(2), np.allclose(gb.predict(x), f))
```

liefert `65.0 4.05`, `55.0 2.025` und `[54.35 55.25 56.6  56.6  56.6  56.6 ] True`.

Bewertung: (a) Start, Residuen und Quadratsumme 1 P, Schwellen und Wahl 1 P, Blattwerte und f_1 1 P. (b) Summe 0 und Residuen 1 P, Stumpf, f_2 und Begründung 1 P. (c) Herleitung 1 P, Probe und $\nu = 1$, $\nu = 2$ 1 P. (d) Rechnung und Begründung 1 P.

Lösung zu Aufgabe 4 Rollierende Merkmale und Leckage

(a) Für Schicht 4, 5 und 6 nimmt der Median die drei vorigen eigenen Werte: M-03 hat die Normalwerte $\boxed{3{,}6;\ 3{,}7;\ 3{,}7}$ aus (3,6; 3,8; 3,5), (3,8; 3,5; 3,7) und (3,5; 3,7; 4,5), die Abweichungen $3{,}7/3{,}6 - 1 = \boxed{+2{,}8\,\%}$, $4{,}5/3{,}7 - 1 = \boxed{+21{,}6\,\%}$ und $4{,}7/3{,}7 - 1 = \boxed{+27{,}0\,\%}$. M-09 hat dreimal $\boxed{2{,}6}$ aus (2,5; 2,7; 2,6), (2,7; 2,6; 2,4) und (2,6; 2,4; 2,6), die Abweichungen $\boxed{-7{,}7\,\%}$, $\boxed{0{,}0\,\%}$ und $3{,}4/2{,}6 - 1 = \boxed{+30{,}8\,\%}$. **Schicht 1 bis 3**: `rolling(3)` braucht drei Werte, und nach `shift(1)` hat Schicht 3 erst zwei Vorgänger, je Maschine gezählt. **Auffällig** sind M-03 ab Schicht 5 und M-09 in Schicht 6. Den ersten hohen Wert übergeht der Median: Für Schicht 6 bleibt der Normalwert von M-03 bei 3,7.

(b) **A** liefert 3,7 und $\boxed{4{,}5}$: In Schicht 6 steckt die aktuelle Schicht im eigenen Vergleichswert, die Abweichung fällt von 27,0 auf 4,4 %. **Keine Leckage**, die aktuelle Schicht ist am Ende der Schicht bekannt, aber ein Fehler: Ein anhaltender Anstieg wirkt eine Schicht früher normal als richtig gebaut. Der Abschneidetest findet ihn nicht. Korrektur: `shift(1)`.
B liefert $\boxed{4{,}5}$ aus (3,7; 4,5; 4,7) und für Schicht 6 nichts, denn dafür bräuchte es Schicht 7. **Leckage**: Das mittige Fenster nimmt die nächste Schicht auf, im Betrieb ist jede aktuelle Schicht die letzte. Der Abschneidetest findet sie: Endet die Tabelle nach Schicht 5, fehlt dort der Wert. Korrektur: ohne `center`, mit `shift(1)`.
C liefert $\boxed{2{,}6}$ aus (2,6; 3,7; 2,4) und 2,6 aus (2,4; 4,5; 2,6), Abweichungen 73,1 und 80,8 %: Das Fenster läuft über die Zeilen der Datei, also über M-09. **Keine Leckage**, alle Zeilen davor sind am Ende der Schicht bekannt, aber ein Fehler: falsche Maschine, M-03 wirkt dauernd auffällig. Der Abschneidetest findet ihn nicht. Korrektur: `groupby("maschine")`. In der Datei stehen zwischen zwei Zeilen von M-03 sogar 19 andere Maschinen.
D setzt $\boxed{3{,}4}$ aus Schicht 6 ein, dann ist `rel` schon in Schicht 5 bei +30,8 %. **Leckage**: Der Anstieg der nächsten Schicht erscheint eine Schicht zu früh. Der Abschneidetest findet sie nur, wenn eine Lücke direkt vor dem Stichtag liegt, frühere werden mit Werten vor dem Stichtag gefüllt. Im Werk fehlt die Schwingung in 96 von 28.920 Schichten, wenig, aber im Betrieb nicht berechenbar. Korrektur: Lücken in der Pipeline mit dem Median des Trainings füllen oder je Maschine mit `ffill()` den letzten bekannten Wert nehmen.

(c) Für $c > 0$ ist der Median von $c\,x_{t-3}, c\,x_{t-2}, c\,x_{t-1}$ gleich c mal dem Median, also $\frac{c\,x_t}{c\,m_t} - 1 = \frac{x_t}{m_t} - 1$: Der Faktor kürzt sich, sobald alle drei Werte im Fenster vom neuen Sensor stammen, hier spätestens nach drei Schichten. In der ersten Schicht danach stammt nur x_t vom neuen

Sensor: $\frac{1{,}2\,m_t}{m_t} - 1 = \boxed{+20\,\%}$, ein Ausschlag ohne Änderung an der Maschine. Mit 30 Schichten im Fenster dauert der Übergang länger (Skript 4.2).

Zum Nachprüfen im Notebook:

```
v = [3.6, 2.5, 3.8, 2.7, 3.5, 2.6, 3.7, 2.4, 4.5, 2.6, 4.7, 3.4]
daten = pd.DataFrame({"maschine": ["M-03", "M-09"] * 6, "vibration_mm_s": v})
g = daten.groupby("maschine")["vibration_mm_s"]
richtig = g.transform(lambda x: x.shift(1).rolling(3).median())
a = g.transform(lambda x: x.rolling(3).median())
b = g.transform(lambda x: x.rolling(3, center=True).median())
c = daten["vibration_mm_s"].shift(1).rolling(3).median()
tab = pd.DataFrame({"richtig": richtig, "A": a, "B": b, "C": c})
print(tab[daten["maschine"] == "M-03"].tail(2))
print((daten["vibration_mm_s"] / richtig - 1).round(3).tolist()[6:])
```

liefert für die Zeilen 8 und 10 (M-03, Schicht 5 und 6) `3.7 3.7 4.5 2.6` und `3.7 4.5 NaN 2.6`, dann `[0.028, -0.077, 0.216, 0.0, 0.27, 0.308]`.

> **Typischer Fehler**
>
> In (a) den Mittelwert statt des Medians nehmen: Für M-03 in Schicht 6 ergäbe $(3{,}5 + 3{,}7 + 4{,}5)/3 = 3{,}9$ statt 3,7. Der hohe Wert aus Schicht 5 zöge ihn mit, die Abweichung fiele auf 20,5 %.

Bewertung: (a) Normalwerte 1 P, Abweichungen 1 P, fehlende Werte und Deutung 1 P. (b) jeweils mit Wert, Einordnung, Abschneidetest und Korrektur A 1 P, B 1 P, C 1 P, D 1 P. (c) Herleitung und 20 % 1 P.

Lösung zu Aufgabe 5 Auswahl und Deutung

(a) Am besten ist Tiefe 6 mit 1,662. Ihr Standardfehler ist $0{,}087/\sqrt{5} \approx 0{,}039$, die Grenze $1{,}662 + 0{,}039 = 1{,}701$. Darunter liegen Tiefe 5 (1,674), 6 und 8 (1,683). Die einfachste ist $\boxed{\text{Tiefe 5}}$ mit 32 statt 64 Blättern, im zweiten Jahr haben beide einen RMSE von 1,589 HRC. **Optimistisch**: Die sechs Mittelwerte sind Schätzungen mit zufälligem Fehler, ihre Standardfehler liegen zwischen 0,03 und 0,07. Gewählt wird die kleinste, also gerade die, deren Fehler in diesen Falten eher nach unten ausfiel. Die Abstände zu Tiefe 5 und 8, 0,012 und 0,021, sind kleiner als ein Standardfehler. Je mehr Einstellungen, desto stärker, wie bei vielen Tests (Modul 6). Ehrlich prüft erst das zweite Jahr, einmal.

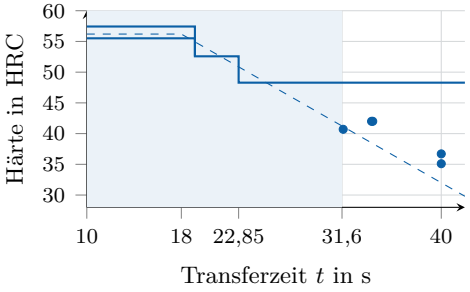
(b) Vorhersagen wie in Aufgabe 1(d), Fehler 0,39; 0,41; −0,47; 0,55, also $\text{MSE} = (0{,}1521 + 0{,}1681 + 0{,}2209 + 0{,}3025)/4 = 0{,}8436/4 \approx \boxed{0{,}21}$. **Kohlenstoff vertauscht**: K1 (0,476 %; 62 min) bekommt 56,35, K2 (0,442 %; 70 min) 54,61, K3 (0,462 %; 80 min) 57,89, K4 (0,438 %; 60 min) 54,61. Fehler −1,35; 3,69; −2,19; 2,29, $\text{MSE} = 25{,}4788/4 \approx 6{,}37$, Wichtigkeit $6{,}37 - 0{,}21 = \boxed{6{,}16\,\text{HRC}^2}$. **Haltezeit vertauscht**: K1 (70 min) bekommt 54,61, K2 (80 min) 57,89, K3 (60 min) 54,61, K4 (62 min) 56,35. Fehler 0,39; 0,41; 1,09; 0,55, $\text{MSE} = 1{,}8108/4 \approx 0{,}45$, Wichtigkeit $\boxed{0{,}24\,\text{HRC}^2}$. **Ofentemperatur und Transferzeit**: $\boxed{0}$, der Baum fragt nicht nach ihnen. Die Transferzeit, in Skript 6.2 das wichtigste Merkmal, ist hier unwichtig: K1 bis K4 liegen alle unter 19,15 s und bleiben vertauscht im linken Teil. Wichtigkeit beschreibt Modell und Daten. **Tausch K1 mit K3, K2 mit K4**: Alle bleiben auf ihrer Seite von 0,4495 %, der MSE bleibt, die Wichtigkeit wäre 0. Eine einzelne Vertauschung kann täuschen: Man mittelt über `n_repeats` und braucht viele ungesehene Prüfchargen.

(c) Mit 0,44 % sagt der Baum für K1, K2 und K4 je 54,61 voraus, für K3 mit 80 min 56,17: $220{,}00/4 = \boxed{55{,}00}$. Mit 0,46 % bekommen K1 und K4 je 56,35, K2 und K3 je 57,89: $228{,}48/4 =$

$\boxed{57{,}12}$, Unterschied $\boxed{2{,}12}$ HRC. **ICE-Kurven**: K1 und K4 springen um 1,74, K3 um 1,72, K2 um 3,28 HRC. Sie laufen nicht parallel: Im Modell steckt eine **Wechselwirkung** von Kohlenstoff und Haltezeit. K2 liegt mit 70 min unter 73,5 min, bei wenig Kohlenstoff also im Blatt mit 54,61, und über 65,5 min, bei viel Kohlenstoff im Blatt mit 57,89. Die partielle Abhängigkeit mittelt die Sprünge, $(1{,}74 + 3{,}28 + 1{,}72 + 1{,}74)/4 = 2{,}12$, und verdeckt das. Beides beschreibt das Modell, nicht den Ofen (Skript 6.4).

(d) Der Baum sagt für 34 und 40 s $\boxed{48{,}29}$ HRC voraus, das Mittel der 78 Chargen des ersten Jahres über 22,85 s, für jede noch so lange Transferzeit.

Das lineare Modell: $56{,}2 - 1{,}1 \cdot 16 = \boxed{38{,}6}$ und $56{,}2 - 1{,}1 \cdot 22 = \boxed{32{,}0}$ HRC. Gemessen sind bei 34 s im Mittel 42,0, bei 40 s 35,9 HRC. Der Baum liegt um 6,3 und 12,4 HRC zu hoch, das lineare Modell um 3,4 und 3,9 zu tief. **Erklärung**: Jenseits der Trainingswerte landen alle Chargen im äußersten Blatt, der Baum bleibt stehen. Das lineare Modell setzt seine Steigung fort.



Hier passt das besser, bei 60 s sagte es aber 10,0 HRC voraus. Keines der Modelle kennt den Bereich ohne Daten. **Folgerung**: Chargen außerhalb des Trainingsbereichs kennzeichnen statt vorhersagen, mit Daten aus diesem Bereich neu lernen oder einen Versuch planen. Im Bild: Baum aus Skript 1.3 für Kohlenstoff über und bis 0,4495 %, lineares Modell gestrichelt, Messungen über 31,6 s.

Typischer Fehler

In (c) die partielle Abhängigkeit an einer mittleren Charge ausrechnen: Bei der mittleren Haltezeit 68 min sagt der Baum 54,61 und 57,89 voraus, ein Unterschied von 3,28 statt 2,12. Die partielle Abhängigkeit mittelt die Vorhersagen, nicht die Merkmale.

Bewertung: (a) Standardfehler, Grenze und Wahl 1 P, Begründung 1 P. (b) MSE ohne und mit vertauschtem Kohlenstoff 1 P, Wichtigkeiten und Deutung 1 P. (c) partielle Abhängigkeit 1 P, ICE-Kurven und Deutung 1 P. (d) Vorhersagen und Vergleich 1 P, Erklärung und Folgerung 1 P.

Lösung zu Aufgabe 6 Gini und Varianz (Zusatz)

(a) np Chargen mit $y_i = 1$ tragen je $(1-p)^2$ bei, $n(1-p)$ mit $y_i = 0$ je p^2: $n\big[p(1-p)^2 + (1-p)p^2\big] = n\,p\,(1-p)\big[(1-p)+p\big] = n\,p\,(1-p)$. Mit $\bar{y} = p$ ist also $G = 2p(1-p) = \frac{2}{n}\sum_i (y_i - \bar{y})^2$, das Doppelte der mittleren quadrierten Abweichung.

(b) Gewichtet ist $\frac{n_L}{n} G_L + \frac{n_R}{n} G_R = \frac{n_L}{n} \cdot \frac{2}{n_L} Q_L + \frac{n_R}{n} \cdot \frac{2}{n_R} Q_R = \frac{2}{n}(Q_L + Q_R) = \boxed{\frac{2\,Q(s)}{n}}$. Ein Regressionsbaum auf den 0-1-Werten ordnet die Schwellen also genauso wie ein Klassifikationsbaum mit Gini, wählt dieselben Teilungen und sagt im Blatt dasselbe voraus: das Mittel der 0-1-Werte, den Anteil in Toleranz.

(c) Bei 0,45 ist $Q = 0 + 3 \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{2}{3}$ und $2Q/6 = 0{,}222$, bei 0,465 ist $Q = 0 + 2 \cdot \frac{1}{2} \cdot \frac{1}{2} = 0{,}5$ und $2Q/6 = 0{,}167$, wie in Aufgabe 1(b). **Entropie**: Bei 0,45 hat der rechte Teil $-\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} \approx 0{,}918$, gewichtet $\boxed{0{,}459}$. Bei 0,465 hat er 1, gewichtet $\boxed{0{,}333}$. Auch sie wählt 0,465, ist aber kein Vielfaches von $Q(s)$: $0{,}459/0{,}667 \approx 0{,}69$, $0{,}333/0{,}5 \approx 0{,}67$. Sie kann anders teilen als Gini, meist führen beide zu ähnlichen Bäumen (Skript 1.2).