Tutoriumsblatt 10

Unüberwachtes Lernen

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Abstände, Lloyd-Schritte, Silhouetten, Verschmelzungen und Kernpunkte von Hand rechnen,
- Hauptkomponenten und Mahalanobis-Abstände herleiten, Gruppen und Ausreißer ohne Zielgröße prüfen.

So arbeitest du mit dem Blatt

Du programmierst nicht, du rechnest mit dem Taschenrechner und begründest, Zwischenwerte genauer, als du sie angibst. Hängst du, rechne mit den Werten unter „Zur Kontrolle“ weiter. Ein Zyklus ist ein Bearbeitungsvorgang eines der Fräszentren M-01 und M-02 an Linie 2, gemessen von der Messbox (`zyklen.csv`). Werkszahlen stammen aus `daten/` und dem Skript, „ausgedacht“ heißt fiktiv. Gib Ergebnisse auf zwei bis drei Nachkommastellen an. Zum Notebook: Aufgabe 1 gehört zu TODO 1 und 2; Aufgabe 2 zu 3 bis 6; Aufgabe 3 zu 8 und 9; Aufgabe 4 zu 10; Aufgabe 5 zu 7 und 11 bis 13.

Aufgabe 1 Abstände und Skalierung

7 Punkte · etwa 16 Min.

Bezug: Modul 10, Lerneinheit 1 (Ähnlich heißt nah)

Vier Zyklen (ausgedacht) mit drei Merkmalen. Über alle 8.420 bereinigten Zyklen streuen die Merkmale mit den Standardabweichungen in der letzten Zeile (Skript 1.4, auf zwei geltende Ziffern gerundet).

Zyklus	Dauer (s)	Energie (kWh)	Kühlmittel (bar)
A	700	2,0	6,2
B	766	1,6	37,0
C	788	2,3	6,6
D	436	0,9	6,0
s	220	1,0	8,8

(a) Berechne die euklidischen Abstände von A zu B, C und D in den Rohwerten. Welcher Zyklus ist der nächste Nachbar von A? Welchen Anteil an $d(\mathrm{A},\mathrm{B})^2$ hat die Dauer? [2 P]

(b) Standardisiere mit $z = (x - \bar{x})/s$. Zeige, dass der Mittelwert $\bar{x}$ für den Abstand zweier Zyklen keine Rolle spielt, und berechne die drei Abstände von A neu. Welcher Zyklus ist jetzt der nächste Nachbar? Welcher Zyklus ist A in Dauer und Energie ähnlich, gehört aber vermutlich zu einem anderen Programm, und woran siehst du das? Zur Kontrolle: $d(\mathrm{A},\mathrm{D}) = 1{,}628$. [3 P]

(c) Fünf Zyklen eines Loses haben den Kühlmitteldruck 5,9; 6,1; 6,3; 6,5 und 6,7 bar. Berechne die z-Werte (Standardabweichung mit dem Nenner n wie `StandardScaler`) und die robusten Werte $(x - \text{Median})/\text{IQR}$ mit den Quartilen 6,1 und 6,5 bar. Ein Messfehler ersetzt 6,7 durch 42,6 bar; so hoch liegt der Druck in `zyklen.csv` nur in der Gruppe mit hohem Kühlmitteldruck. Rechne beides neu. Welche Skalierung ist robuster, und was heißt das für Abstände? Zur Kontrolle: Mit dem Messfehler ist $s = 14{,}56$ bar. [2 P]

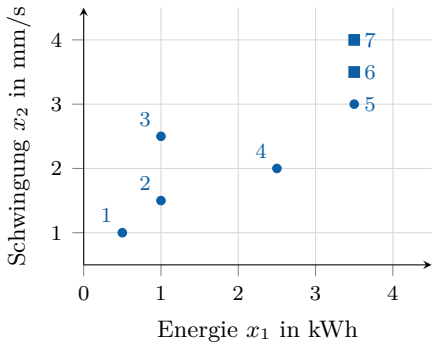
Aufgabe 2 k-Means von Hand

10 Punkte · etwa 22 Min.

Bezug: Modul 10, Lerneinheit 2 (k-Means und die Zahl der Gruppen)

Sieben Zyklen (ausgedacht) mit Energie x_1 in kWh und Schwingung x_2 in mm/s. Beide Merkmale streuen in `zyklen.csv` ähnlich stark (1,01 kWh und 0,83 mm/s), deshalb rechnest du hier ohne Skalierung. k-Means mit $k = 2$ startet bei den Zyklen 6 und 7.

Zyklus	1	2	3	4	5	6	7
x_1	0,5	1,0	1,0	2,5	3,5	3,5	3,5
x_2	1,0	1,5	2,5	2,0	3,0	3,5	4,0



(a) Rechne zwei Runden des Lloyd-Algorithmus: jeden Zyklus dem nächsten Mittelpunkt zuordnen, dann die Mittelpunkte neu berechnen. Gib nach jeder Runde die Gruppen, die Mittelpunkte und die Inertia W an. Ändert eine dritte Runde etwas? Zur Kontrolle: Nach Runde 1 liegen die Mittelpunkte bei (2,0; 2,25) und (3,5; 4,0). [3 P]

(b) Sei $W^*(k)$ die kleinste Inertia, die mit k Gruppen möglich ist. Zeige $W^*(k+1) \le W^*(k)$, solange k kleiner als die Zahl der verschiedenen Punkte ist. Wie groß ist $W^*(1)$ für die sieben Zyklen, wie groß $W^*(7)$? Gilt die Ungleichung auch für die Inertia, die `KMeans` nach einem einzigen Start meldet? [2 P]

(c) Berechne für die Einteilung nach Runde 2 die Silhouette $s = (b - a)/\max(a, b)$ der Zyklen 4 und 6. Was sagen die beiden Werte? [3 P]

(d) Mit den sieben Zyklen im Array `P` gibt der Code

```
eins = KMeans(n_clusters=2, init=P[[5, 6]], n_init=1, max_iter=1).fit(P)
print(eins.cluster_centers_.tolist(), eins.labels_, eins.inertia_)
```

`[[2.0, 2.25], [3.5, 4.0]] [0 0 0 0 1 1 1] 8.0` aus. Die Mittelpunkte sind die aus Runde 1, die Gruppen nicht. Woher kommen `labels_` und die Inertia 8,0? Ordne 8,0 in die Folge der Inertia-Werte aus (a) ein, beginnend mit der Summe der quadrierten Abstände zu den Startpunkten. [2 P]

Aufgabe 3 Hierarchisch und nach Dichte

9 Punkte · etwa 20 Min.

Bezug: Modul 10, Lerneinheit 3 (Hierarchisch und nach Dichte)

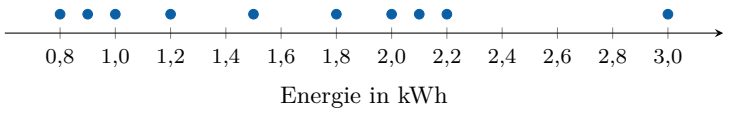
Fünf Maschinen der Halle 1, beschrieben durch standardisierte Profile aus Schwingung, Lagertemperatur über der Halle und Stromaufnahme. Die euklidischen Abstände der Profile (ausgedacht):

	M-01	M-02	M-11	M-12	M-04
M-01	0	0,4	1,2	1,8	3,5
M-02	0,4	0	0,8	1,5	3,2
M-11	1,2	0,8	0	1,0	2,6
M-12	1,8	1,5	1,0	0	2,4
M-04	3,5	3,2	2,6	2,4	0

(a) Verschmelze mit Single Linkage, bis eine Gruppe übrig ist. Gib jede Verschmelzung mit ihrer Höhe an. [2 P]

(b) Verschmelze ebenso mit Complete Linkage. Skizziere beide Dendrogramme und schneide sie bei der Höhe 1,5. Welche Gruppen entstehen? Warum bildet Single Linkage eine Kette? Zur Kontrolle: Die zweite Verschmelzung mit Complete Linkage liegt bei 1,0. [3 P]

Zehn Zyklen (ausgedacht) mit der Energie in kWh auf einer Achse. DBSCAN mit `eps=0.25` und `min_samples=3`. Ein Kernpunkt hat im Radius `eps` mindestens `min_samples` Punkte, sich selbst mitgezählt.



(c) Zähle für jeden Zyklus die Punkte im Radius 0,25. Welche Zyklen sind Kernpunkte, welche Randpunkte, welche Rauschen? Wie viele Gruppen findet DBSCAN? [3 P]

(d) Was ändert sich mit `eps=0.15` und mit `eps=0.35`? Was folgt für die Wahl von `eps`? [1 P]

Aufgabe 4 Hauptkomponenten von Hand

6 Punkte · etwa 13 Min.

Bezug: Modul 10, Lerneinheit 4 (Hauptkomponenten: wenige Richtungen)

Energie und Schwingung der 8.420 Zyklen korrelieren mit $r = 0{,}74$. Gerundet ist die Energie im Mittel 1,6 kWh mit der Standardabweichung 1,0 kWh, die Schwingung 2,5 mm/s mit 0,8 mm/s. Standardisiert ist die Kovarianzmatrix die Korrelationsmatrix

$$R = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}.$$

(a) Berechne die Eigenwerte und Eigenvektoren von R allgemein und für $r = 0{,}74$. Welchen Anteil der Varianz trägt die erste Hauptkomponente? [2 P]

(b) Ein Zyklus braucht 3,0 kWh und schwingt mit 2,9 mm/s. Berechne seine z-Werte, seine Werte auf beiden Hauptkomponenten und den Punkt, den die erste Komponente allein für ihn liefert, in z-Werten und in Werkseinheiten. Was misst die zweite Komponente? Zur Kontrolle: Der Wert auf der ersten Komponente ist 1,344. [2 P]

(c) Ohne Skalierung: Die Dauer streut mit 220 s, die Energie mit 1,0 kWh, die Korrelation ist 0,95. Stelle die Kovarianzmatrix S auf. Zeige mit $\lambda_1 = \max_{\|v\|=1} v^\top S v$, dass der größte Eigenwert mindestens 48.400 ist, und schätze den Anteil der ersten Komponente nach unten ab. Was ändert sich, wenn du die Dauer in Stunden angibst? [2 P]

Aufgabe 5 Ausreißer und Prüfen

8 Punkte · etwa 17 Min.

Bezug: Modul 10, Lerneinheiten 5 (Ausreißer finden) und 6 (Gruppen prüfen ohne Zielgröße)

In der Gruppe der langen Zyklen sei der Mittelpunkt $\mu = (18\ \text{min};\ 4{,}0\ \text{kWh})$ in Dauer und Energie, mit der Kovarianzmatrix (ausgedacht, angelehnt an das Profil in Skript 2.5)

$$S = \begin{pmatrix} 1 & 0{,}4 \\ 0{,}4 & 0{,}25 \end{pmatrix}, \qquad d^2(x) = (x-\mu)^\top S^{-1} (x-\mu).$$

Quantile der χ^2-Verteilung mit 2 Freiheitsgraden: 0,95: 5,991; 0,99: 9,210; 0,999: 13,816.

(a) Berechne die Korrelation und S^{-1} von Hand. Zyklus Z1 dauert 20 min und braucht 4,8 kWh, Zyklus Z2 dauert 17 min und braucht 5,0 kWh. Berechne für beide den euklidischen Abstand zu μ und d^2. Welcher liegt euklidisch näher, welcher nach d^2? Zur Kontrolle: S^{-1} hat oben links 25/9. [3 P]

(b) Welcher Zyklus ist bei der Grenze 0,999 auffällig? Warum fiele Z2 weniger auf, wenn Mittelpunkt und Kovarianzmatrix klassisch aus einer Gruppe geschätzt würden, in der einige Zyklen wie Z2 stecken? Was macht die Minimum Covariance Determinant anders? [2 P]

Zehn Zyklen aus den Wochen ab dem 14. September (ausgedacht): Programm laut Leitstand gegen die Gruppe aus k-Means.

Programm	Gruppe 0	Gruppe 1
Lagerdeckel	4	0
Gehäuse klein	0	4
Warmlauf	2	0

(c) Berechne aus der Kreuztabelle den Rand-Index, den Anteil der gleich behandelten Paare, und den bereinigten Rand-Index. Welche Paare behandeln die beiden Einteilungen verschieden? [2 P]

(d) Ein Verfahren markiert 45 Zyklen, 27 davon liegen in einer Schicht mit passender Meldung in `stoerungen.csv`. Die Basisrate ist 10,3 % (Skript 5.5). Wie viele Treffer erwartest du bei zufälliger Markierung? Deute den Anteil wie die Precision in Modul 8. [1 P]

Aufgabe 6 (⋆) Die Schwelle mit zwei Freiheitsgraden

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 10, Lerneinheit 5

Mit 2 Freiheitsgraden hat die χ^2-Verteilung die Dichte $f(c) = \frac{1}{2}\, e^{-c/2}$ für $c \geq 0$. (a) Zeige $P(\chi^2 > c) = e^{-c/2}$ und leite die drei Quantile aus Aufgabe 5 her. (b) Wie wahrscheinlich ist bei normalverteilter Gruppe ein Wert d^2 mindestens so groß wie bei Z1 und Z2? (c) Die robuste Schätzung markiert in der Gruppe der 907 langen Zyklen mit vier Merkmalen 36 Zyklen über dem 0,999-Quantil (Skript 5.3). Wie viele erwartest du bei normalverteilten Daten? Was folgt daraus?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Abstände und Skalierung

(a) Differenzen zu A: B (66; −0,4; 30,8), C (88; 0,3; 0,4), D (−264; −1,1; −0,2).

$$d(\mathrm{A},\mathrm{B}) = \sqrt{4.356 + 0{,}16 + 948{,}64} = \sqrt{5.304{,}8} = \boxed{72{,}83}, \quad d(\mathrm{A},\mathrm{C}) = \sqrt{7.744{,}25} = \boxed{88{,}00},$$

$$d(\mathrm{A},\mathrm{D}) = \sqrt{69.697{,}25} = \boxed{264{,}00}.$$

Nächster Nachbar ist **B**. Die Dauer trägt $4.356/5.304{,}8 = \boxed{82{,}1\,\%}$ zu $d(\mathrm{A},\mathrm{B})^2$ bei, der Kühlmitteldruck 17,9 %, die Energie fast nichts. Eine Sekunde zählt so viel wie eine Kilowattstunde oder ein bar.

(b) $z_x - z_y = \frac{x-\bar{x}}{s} - \frac{y-\bar{x}}{s} = \frac{x-y}{s}$, der Mittelwert hebt sich auf. Jede Differenz wird also nur durch s geteilt: B (0,3; −0,4; 3,5), C (0,4; 0,3; 0,045), D (−1,2; −1,1; −0,023).

$$d(\mathrm{A},\mathrm{B}) = \sqrt{0{,}09 + 0{,}16 + 12{,}25} = \boxed{3{,}536}, \quad d(\mathrm{A},\mathrm{C}) = \sqrt{0{,}252} = \boxed{0{,}502},$$

$$d(\mathrm{A},\mathrm{D}) = \sqrt{1{,}44 + 1{,}21 + 0{,}0005} = \sqrt{2{,}651} = \boxed{1{,}628}.$$

Jetzt ist **C** der nächste Nachbar, B der fernste. **B** gehört vermutlich zu einem anderen Programm: ähnliche Dauer, aber 37,0 statt gut 6 bar Kühlmitteldruck, wie das Kühlmittelprogramm mit 37,9 bar in Skript 2.5. D gehört ebenfalls nicht zu A: Er ist kurz und leicht wie das kurze Programm in Skript 2.5 und unterscheidet sich in Dauer und Energie gemeinsam, das zeigen schon die Rohwerte.

(c) Ohne Messfehler: $\bar{x} = 6{,}3$ und $s = \sqrt{(0{,}16 + 0{,}04 + 0 + 0{,}04 + 0{,}16)/5} = \sqrt{0{,}08} = 0{,}283$. Robust: Median 6,3, IQR $= 6{,}5 - 6{,}1 = 0{,}4$. Mit 42,6 bar: $\bar{x} = 67{,}4/5 = 13{,}48$ und $s = \sqrt{1.060{,}168/5} = 14{,}56$, Median und Quartile bleiben gleich.

Druck (bar)	5,9	6,1	6,3	6,5	6,7 bzw. 42,6
z ohne Messfehler	−1,414	−0,707	0	0,707	1,414
robust ohne Messfehler	−1	−0,5	0	0,5	1
z mit Messfehler	−0,521	−0,507	−0,493	−0,479	2,000
robust mit Messfehler	−1	−0,5	0	0,5	90,75

Mit dem Messfehler liegen die vier normalen Werte nur noch 0,014 statt 0,707 auseinander, um den Faktor $14{,}56/0{,}283 \approx 51$ zusammengedrückt, und der Messfehler wirkt mit $z = 2{,}0$ harmlos. Robust behalten die normalen Werte ihre Abstände.
Robuster ist die Skalierung mit Median und IQR: Die normalen Werte bleiben unverändert, der Messfehler fällt auf. Für Abstände heißt das aber auch: 90,75 Einheiten in einem Merkmal bestimmen jeden Abstand zu diesem Zyklus allein. Also erst Messfehler prüfen und entfernen wie in Skript 1.3, dann skalieren.

Typischer Fehler

In (c) die Standardabweichung mit dem Nenner $n - 1$ rechnen: Dann ist $s = 0{,}316$ statt 0,283 und $z = \pm 1{,}265$ statt $\pm 1{,}414$. `StandardScaler` teilt durch n, für Abstände ändert das nur einen gemeinsamen Faktor.

Bewertung: (a) drei Abstände 1 P, Nachbar und Anteil 1 P. (b) Mittelwert hebt sich auf 1 P, drei Abstände 1 P, Nachbar und Programm 1 P. (c) z-Werte und robuste Werte mit und ohne Messfehler 1 P, Einordnung 1 P.

Lösung zu Aufgabe 2 k-Means von Hand

(a) **Runde 1**: Zu (3,5; 3,5) und (3,5; 4,0) hat Zyklus 5 die quadrierten Abstände 0,25 und 1, Zyklus 4 3,25 und 5, die Zyklen 1 bis 3 liegen ebenfalls näher am ersten. Gruppen $\{1,\dots,6\}$ und $\{7\}$, Mittelpunkte $(12/6;\ 13{,}5/6) = \boxed{(2{,}0;\ 2{,}25)}$ und $\boxed{(3{,}5;\ 4{,}0)}$. Quadrierte Abstände zum neuen Mittelpunkt 3,8125; 1,5625; 1,0625; 0,3125; 2,8125; 3,8125 und 0, also $W = \boxed{13{,}375}$.
Runde 2: Zyklus 5 hat zu (2,0; 2,25) den quadrierten Abstand 2,8125, zu (3,5; 4,0) nur 1, Zyklus 6 3,8125 gegen 0,25. Zyklus 4 bleibt mit 0,3125 gegen 5. Gruppen $\{1,2,3,4\}$ und $\{5,6,7\}$, Mittelpunkte $\boxed{(1{,}25;\ 1{,}75)}$ und $\boxed{(3{,}5;\ 3{,}5)}$, quadrierte Abstände 1,125; 0,125; 0,625; 1,625 und 0,25; 0; 0,25, also $W = \boxed{4{,}0}$.
Runde 3: Jeder Zyklus liegt schon am nächsten Mittelpunkt, nichts ändert sich. Ausprobieren aller 63 Einteilungen in zwei Gruppen zeigt: 4,0 ist hier auch das globale Minimum.

(b) Nimm die beste Einteilung mit k Gruppen. Weil es mehr als k verschiedene Punkte gibt, liegt ein Punkt x nicht auf seinem Mittelpunkt. Mache ihn zur eigenen Gruppe mit sich selbst als Mittelpunkt: Sein Beitrag fällt von $\|x-\mu\|^2 > 0$ auf 0, die übrigen ändern sich nicht, und neu gemittelt sinkt die Restgruppe höchstens weiter. Also $W^*(k+1) < W^*(k)$, erst recht $\leq$. $W^*(1)$ ist die Summe der quadrierten Abstände zum Gesamtmittel $(15{,}5/7;\ 17{,}5/7) = (2{,}214;\ 2{,}5)$: $45{,}25 - 15{,}5^2/7 + 50{,}75 - 17{,}5^2/7 = 10{,}929 + 7{,}0 = \boxed{17{,}929}$. $W^*(7) = \boxed{0}$, jeder Zyklus allein.
Nach einem Start nein: Lloyd endet in einem lokalen Optimum. Mit $k+1$ Gruppen kann ein ungünstiger Start über dem Ergebnis für k landen, deshalb `n_init` und Vergleiche nur mit vielen Starts.

(c) **Zyklus 4** (2,5; 2,0): zu 1, 2, 3 die Abstände $\sqrt{5}$, $\sqrt{2{,}5}$, $\sqrt{2{,}5}$, also $a = (2{,}236 + 1{,}581 + 1{,}581)/3 = 1{,}799$. Zu 5, 6, 7: $\sqrt{2}$, $\sqrt{3{,}25}$, $\sqrt{5}$, also $b = (1{,}414 + 1{,}803 + 2{,}236)/3 = 1{,}818$. $s = (1{,}818 - 1{,}799)/1{,}818 = \boxed{0{,}010}$.
Zyklus 6 (3,5; 3,5): $a = (0{,}5 + 0{,}5)/2 = 0{,}5$, $b = (\sqrt{15{,}25} + \sqrt{10{,}25} + \sqrt{7{,}25} + \sqrt{3{,}25})/4 = (3{,}905 + 3{,}202 + 2{,}693 + 1{,}803)/4 = 2{,}901$, $s = (2{,}901 - 0{,}5)/2{,}901 = \boxed{0{,}828}$.
Zyklus 6 liegt eng in seiner Gruppe und weit von der anderen, gut getrennt. Zyklus 4 liegt auf der Grenze: Im Mittel ist er der fremden Gruppe fast so nah wie der eigenen. Für die Fräszentren hieße das: ein Zyklus zwischen zwei Programmen, den man sich einzeln ansieht.

(d) `KMeans` rechnet nach dem letzten Mittelschritt noch eine Zuordnung, damit `labels_` zu `cluster_centers_` passen. Zu (2,0; 2,25) gehören dann die Zyklen 1 bis 4, zu (3,5; 4,0) die Zyklen 5 bis 7. `inertia_` gilt für diese Zuordnung: $3{,}8125+1{,}5625+1{,}0625+0{,}3125+1+0{,}25+0 = \boxed{8{,}0}$. Die Folge ist $\boxed{36{,}25 \to 13{,}375 \to 8{,}0 \to 4{,}0}$: Abstände zu den Startpunkten, nach dem Mitteln, nach der zweiten Zuordnung, nach dem zweiten Mitteln. Jeder Teilschritt senkt W oder lässt es gleich.

Zum Nachprüfen im Notebook:

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_samples
P = np.array([[0.5, 1.0], [1.0, 1.5], [1.0, 2.5], [2.5, 2.0],
              [3.5, 3.0], [3.5, 3.5], [3.5, 4.0]])
eins = KMeans(n_clusters=2, init=P[[5, 6]], n_init=1, max_iter=1).fit(P)
km = KMeans(n_clusters=2, init=P[[5, 6]], n_init=1).fit(P)
print(eins.cluster_centers_.tolist(), eins.inertia_)
print(km.cluster_centers_.tolist(), km.inertia_)
print(silhouette_samples(P, km.labels_).round(3))
```

liefert `[[2.0, 2.25], [3.5, 4.0]] 8.0`, `[[1.25, 1.75], [3.5, 3.5]] 4.0` und `[0.615 0.659 0.49  0.01  0.714 0.828 0.768]`.

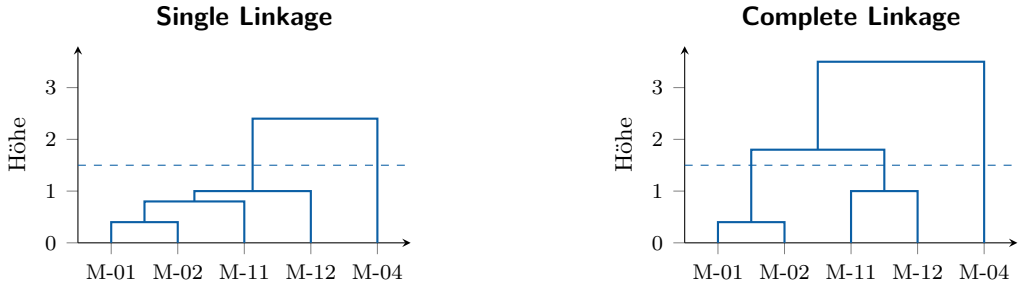
> **Typischer Fehler**
>
> In (c) für b den Abstand zum fremden Mittelpunkt nehmen statt des mittleren Abstands zu den fremden Zyklen: Für Zyklus 4 ergäbe $\|(2{,}5;\ 2{,}0) - (3{,}5;\ 3{,}5)\| = 1{,}803$, und a wäre ebenso falsch. Die Silhouette mittelt Abstände zwischen Zyklen.

Bewertung: (a) Runde 1 1 P, Runde 2 1 P, beide Inertia-Werte und Runde 3 1 P. (b) Beweis 1 P, $W^*(1)$, $W^*(7)$ und ein Start 1 P. (c) Zyklus 4 1 P, Zyklus 6 1 P, Deutung 1 P. (d) Zuordnung und 8,0 1 P, Folge 1 P.

Lösung zu Aufgabe 3 Hierarchisch und nach Dichte

(a) **Single Linkage**, kleinster Abstand zwischen zwei Gruppen: M-01 und M-02 bei $\boxed{0{,}4}$. Dann $\min(1{,}2;\ 0{,}8) = 0{,}8$: M-11 kommt dazu bei $\boxed{0{,}8}$. Dann $\min(1{,}8;\ 1{,}5;\ 1{,}0) = 1{,}0$: M-12 bei $\boxed{1{,}0}$. Zuletzt $\min(3{,}5;\ 3{,}2;\ 2{,}6;\ 2{,}4) = 2{,}4$: M-04 bei $\boxed{2{,}4}$.

(b) **Complete Linkage**, größter Abstand: M-01 und M-02 bei $\boxed{0{,}4}$. Dann ist {M-01, M-02} zu M-11 $\max(1{,}2;\ 0{,}8) = 1{,}2$, zu M-12 1,8, und M-11 zu M-12 1,0: M-11 und M-12 bei $\boxed{1{,}0}$. Dann {M-01, M-02} zu {M-11, M-12} $\max(1{,}2;\ 1{,}8;\ 0{,}8;\ 1{,}5) = 1{,}8$, zu M-04 3,5, {M-11, M-12} zu M-04 $\max(2{,}6;\ 2{,}4) = 2{,}6$: Verschmelzung bei $\boxed{1{,}8}$, zuletzt M-04 bei $\boxed{3{,}5}$.



Schnitt bei 1,5 (gestrichelt): Single Linkage liefert $\boxed{\{\text{M-01, M-02, M-11, M-12}\},\ \{\text{M-04}\}}$, Complete Linkage $\boxed{\{\text{M-01, M-02}\},\ \{\text{M-11, M-12}\},\ \{\text{M-04}\}}$. **Kette**: Single Linkage braucht nur ein nahes Paar. M-11 liegt zwischen M-01, M-02 und M-12, über die Glieder 0,4, 0,8 und 1,0 hängen M-01 und M-12 zusammen, obwohl sie 1,8 auseinander liegen. Complete Linkage verlangt, dass alle Paare nah sind.

(c) Im Radius 0,25 liegen für 0,8 bis 3,0 der Reihe nach $\boxed{3;\ 3;\ 4;\ 2;\ 1;\ 2;\ 4;\ 3;\ 3;\ 1}$ Punkte. **Kernpunkte** mit mindestens 3: 0,8; 0,9; 1,0; 2,0; 2,1; 2,2. **Randpunkte**: 1,2 liegt 0,2 neben dem Kernpunkt 1,0, und 1,8 liegt 0,2 neben 2,0. **Rauschen**: 1,5 hat zum nächsten

Kernpunkt 0,5, und 3,0 ist allein. DBSCAN findet $\boxed{2\text{ Gruppen}}$, $\{0{,}8;\ 0{,}9;\ 1{,}0;\ 1{,}2\}$ und $\{1{,}8;\ 2{,}0;\ 2{,}1;\ 2{,}2\}$, und $\boxed{2}$ Rauschpunkte.

(d) `eps=0.15`: Nur 0,9 und 2,1 sind Kernpunkte, die Gruppen schrumpfen auf je drei Zyklen, 1,2 und 1,8 werden Rauschen: $\boxed{4}$ Rauschpunkte. `eps=0.35`: Die Lücken von 0,3 um 1,5 werden überbrückt, alles von 0,8 bis 2,2 verschmilzt zu $\boxed{1}$ Gruppe, nur 3,0 bleibt Rauschen. **Folgerung**: `eps` hat die Einheit der Merkmale, kleine Werte machen mehr Rauschen, große verschmelzen Gruppen über Brücken. Wähle es aus der k-Abstands-Grafik und auf skalierten Merkmalen.

Zum Nachprüfen im Notebook:

```
from scipy.cluster.hierarchy import linkage, fcluster
from scipy.spatial.distance import squareform
from sklearn.cluster import DBSCAN
D = np.array([[0, 0.4, 1.2, 1.8, 3.5], [0.4, 0, 0.8, 1.5, 3.2], [1.2, 0.8, 0, 1.0, 2.6],
              [1.8, 1.5, 1.0, 0, 2.4], [3.5, 3.2, 2.6, 2.4, 0]])
for m in ["single", "complete"]:
    L = linkage(squareform(D), method=m)
    print(m, L[:, 2].tolist(), fcluster(L, t=1.5, criterion="distance"))
x = np.array([0.8, 0.9, 1.0, 1.2, 1.5, 1.8, 2.0, 2.1, 2.2, 3.0]).reshape(-1, 1)
for eps in [0.15, 0.25, 0.35]:
    print(eps, DBSCAN(eps=eps, min_samples=3).fit(x).labels_)
```

liefert die Höhen `[0.4, 0.8, 1.0, 2.4]` mit `[1 1 1 1 2]` und `[0.4, 1.0, 1.8, 3.5]` mit `[1 1 2 2 3]`, dann `[ 0  0  0 -1 -1 -1  1  1  1 -1]`, `[ 0  0  0  0 -1  1  1  1  1 -1]` und `[ 0  0  0  0  0  0  0  0  0 -1]`.

> **Typischer Fehler**
>
> In (c) den Punkt selbst nicht mitzählen: Dann hätten nur 1,0 und 2,0 mindestens drei Nachbarn, 0,8; 0,9; 2,1 und 2,2 würden Randpunkte. Die Gruppen blieben hier gleich, die Kernpunkte nicht. scikit-learn zählt den Punkt selbst mit.

Bewertung: (a) vier Verschmelzungen mit Höhen 2 P. (b) Complete Linkage 1 P, Dendrogramme und Schnitt 1 P, Kette 1 P. (c) Zählung 1 P, Kern, Rand und Rauschen 1 P, Gruppen 1 P. (d) beide Werte und Folgerung 1 P.

Lösung zu Aufgabe 4 Hauptkomponenten von Hand

(a) $\det(R-\lambda I) = (1-\lambda)^2 - r^2 = 0$ ergibt $\lambda = 1 \pm r$. Für $\lambda = 1+r$ ist $(R-\lambda I)v = r(-v_1+v_2;\ v_1-v_2) = 0$, also $v = (1;\ 1)/\sqrt{2}$, für $\lambda = 1-r$ ebenso $v = (1;\ -1)/\sqrt{2}$. Mit $r = 0{,}74$: $\boxed{\lambda_1 = 1{,}74}$ und $\boxed{\lambda_2 = 0{,}26}$, Eigenvektoren mit den Einträgen $\pm 0{,}707$. Anteil $\lambda_1/(\lambda_1+\lambda_2) = (1+r)/2 = \boxed{87\,\%}$. Die Summe der Eigenwerte ist die Spur 2, die Zahl der standardisierten Merkmale.

(b) $z = ((3{,}0-1{,}6)/1{,}0;\ (2{,}9-2{,}5)/0{,}8) = \boxed{(1{,}4;\ 0{,}5)}$. Werte: $(1{,}4+0{,}5)/\sqrt{2} = \boxed{1{,}344}$ und $(1{,}4-0{,}5)/\sqrt{2} = \boxed{0{,}636}$. Die erste Komponente allein liefert $1{,}344 \cdot (1;\ 1)/\sqrt{2} = (0{,}95;\ 0{,}95)$, in Werkseinheiten $1{,}6 + 0{,}95 \cdot 1{,}0 = \boxed{2{,}55\,\text{kWh}}$ und $2{,}5 + 0{,}95 \cdot 0{,}8 = \boxed{3{,}26\,\text{mm/s}}$. Der quadrierte Fehler $0{,}45^2 + 0{,}45^2 = 0{,}405 = 0{,}636^2$ ist der Anteil auf der zweiten Komponente. Sie misst, ob ein Zyklus für seine Schwingung viel Energie braucht: hier 0,45 Standardabweichungen mehr Energie und weniger Schwingung als auf der Diagonale.

(c) $S = \begin{pmatrix} 48.400 & 209 \\ 209 & 1 \end{pmatrix}$ mit $0{,}95 \cdot 220 \cdot 1{,}0 = 209$. Mit $v = (1;\ 0)$ ist $v^\top S v = 48.400$, also $\lambda_1 \geq 48.400$. Die Spur ist $\lambda_1 + \lambda_2 = 48.401$, der Anteil also mindestens $48.400/48.401 = \boxed{99{,}998\,\%}$. Genau: $\det S = 48.400 - 209^2 = 4.719$, $\lambda_2 = 4.719/\lambda_1 \approx 0{,}0975$. Die erste Komponente ist fast nur die Dauer, weil Sekunden quadriert große Zahlen ergeben, nicht weil die Dauer wichtiger ist. **In Stunden**: $\text{Var} = (220/3.600)^2 \approx 0{,}0037\,\text{h}^2$, jetzt ist $\lambda_1 \geq 1$ von der Energie, und die erste Komponente ist fast nur die Energie. Das Ergebnis hängt an der Einheit, deshalb vorher standardisieren.

> **Typischer Fehler**
> In (b) die Rohwerte 3,0 und 2,9 auf die Eigenvektoren projizieren: $(3{,}0 + 2{,}9)/\sqrt{2} = 4{,}172$. Die Hauptkomponenten gehören zu den standardisierten Merkmalen, erst Mittel abziehen und durch s teilen.

Bewertung: (a) Herleitung 1 P, Zahlen und Anteil 1 P. (b) z-Werte und Komponentenwerte 1 P, Rückrechnung und Deutung 1 P. (c) S, Schranke und Anteil 1 P, Einheit 1 P.

Lösung zu Aufgabe 5 Ausreißer und Prüfen

(a) Korrelation $0{,}4/(1 \cdot 0{,}5) = \boxed{0{,}8}$. $\det S = 0{,}25 - 0{,}16 = 0{,}09$, also

$$S^{-1} = \frac{1}{0{,}09} \begin{pmatrix} 0{,}25 & -0{,}4 \\ -0{,}4 & 1 \end{pmatrix} = \frac{1}{9} \begin{pmatrix} 25 & -40 \\ -40 & 100 \end{pmatrix}.$$

Z1: $x - \mu = (2;\ 0{,}8)$, euklidisch $\sqrt{4{,}64} = \boxed{2{,}154}$, $d^2 = (25 \cdot 4 - 2 \cdot 40 \cdot 1{,}6 + 100 \cdot 0{,}64)/9 = 36/9 = \boxed{4{,}0}$.
Z2: $x - \mu = (-1;\ 1)$, euklidisch $\sqrt{2} = \boxed{1{,}414}$, $d^2 = (25 + 80 + 100)/9 = 205/9 = \boxed{22{,}78}$.
Euklidisch liegt Z2 näher, nach d^2 liegt Z1 näher. Der euklidische Abstand mischt hier Minuten und Kilowattstunden und ist wie in Aufgabe 1 nur ein grober Vergleich. Z1 folgt aber der Korrelation, länger und mehr Energie, Z2 widerspricht ihr: kürzer, aber 1 kWh mehr. Diese Kombination ist in der Gruppe selten.

(b) Bei 0,999 ist die Grenze 13,816: **Z2** ist mit 22,78 auffällig, Z1 mit 4,0 liegt sogar unter dem 0,95-Quantil 5,991. **Klassisch**: Mittelpunkt und Kovarianz werden aus allen Zyklen geschätzt. Zyklen wie Z2 ziehen den Mittelpunkt zu sich, blähen die Varianz der Energie auf und senken die Korrelation. Dann liegt Z2 in Einheiten dieser Streuung näher, die auffälligsten Zyklen verdecken sich selbst. Die **Minimum Covariance Determinant** schätzt Mittelpunkt und Kovarianz nur aus dem dichtesten Teil der Zyklen, dem mit der kleinsten Determinante, und bleibt so eng um den Kern.

(c) $\binom{10}{2} = 45$ Paare. Gemeinsam in Zelle: $\binom{4}{2} + \binom{4}{2} + \binom{2}{2} = 13$. Zeilen: $6+6+1 = 13$, Spalten (6 und 4 Zyklen): $15+6 = 21$. Gleich behandelt sind $45 - 13 - 21 + 2 \cdot 13 = 37$ Paare, $\text{RI} = 37/45 = \boxed{0{,}822}$.
Erwartet $E = 13 \cdot 21/45 = 6{,}067$, $\text{ARI} = (13 - 6{,}067)/(17 - 6{,}067) = \boxed{0{,}634}$. **Verschieden behandelt**: die $4 \cdot 2 = 8$ Paare aus einem Lagerdeckel und einem Warmlauf. k-Means legt sie zusammen, der Leitstand trennt sie.

(d) Zufällig erwartet $45 \cdot 0{,}103 \approx \boxed{4{,}6}$ Treffer. Der Anteil $27/45 = \boxed{60\,\%}$ ist wie eine Precision, das $0{,}60/0{,}103 \approx 5{,}8$-Fache der Basisrate. Ohne Basisrate wäre er nicht deutbar. Ein Treffer heißt nicht, dass dieser Zyklus die Störung zeigt, die Meldung kann einen anderen Zyklus der Schicht betreffen, und ein Ausreißer ist nicht automatisch eine Störung.

Zum Nachprüfen im Notebook:

```
from scipy.spatial.distance import mahalanobis
from scipy.stats import chi2
from sklearn.metrics import rand_score, adjusted_rand_score
S = np.array([[1.0, 0.4], [0.4, 0.25]])
VI = np.linalg.inv(S)
print([round(float(mahalanobis(z, [18, 4.0], VI)) ** 2, 2) for z in ([20, 4.8], [17, 5.0])])
print(chi2.ppf([0.95, 0.99, 0.999], df=2).round(3))
programm = ["Lagerdeckel"] * 4 + ["Gehäuse klein"] * 4 + ["Warmlauf"] * 2
gruppe = [0] * 4 + [1] * 4 + [0] * 2
print(round(rand_score(programm, gruppe), 3), round(adjusted_rand_score(programm, gruppe), 3))
```

liefert `[4.0, 22.78]`, `[ 5.991  9.21  13.816]` und `0.822 0.634`.

> **Typischer Fehler**
> In (a) S^{-1} ohne Vorzeichenwechsel neben der Diagonale rechnen: Mit $+40/9$ ergäbe sich für Z1 $d^2 = 292/9 = 32{,}44$ und für Z2 $45/9 = 5{,}0$, die Bewertung kehrte sich um.

Bewertung: (a) Korrelation und S^{-1} 1 P, Z1 1 P, Z2 und Vergleich 1 P. (b) Grenze 1 P, klassisch und robust 1 P. (c) Rand-Index 1 P, bereinigt und Paare 1 P. (d) Erwartung und Deutung 1 P.

Lösung zu Aufgabe 6 Die Schwelle mit zwei Freiheitsgraden (Zusatz)

(a) $P(\chi^2 > c) = \int_c^\infty \frac{1}{2} e^{-t/2}\,dt = \big[-e^{-t/2}\big]_c^\infty = e^{-c/2}$. Aus $e^{-q/2} = 1 - p$ folgt $q_p = -2\ln(1-p)$: $-2\ln 0{,}05 = 5{,}991$, $-2\ln 0{,}01 = 9{,}210$ und $-2\ln 0{,}001 = 13{,}816$, wie in der Tabelle.

(b) Z1: $e^{-4/2} = e^{-2} \approx \boxed{0{,}135}$, etwa jeder siebte Zyklus liegt so weit oder weiter außen. Z2: $e^{-22{,}78/2} \approx \boxed{1{,}1 \cdot 10^{-5}}$, etwa einer von 88.000.

(c) Das 0,999-Quantil lässt bei jeder Zahl von Freiheitsgraden 0,1 % darüber: $907 \cdot 0{,}001 \approx \boxed{0{,}9}$, also etwa einer. Markiert sind 36, rund 40-mal so viele. Die Gruppe ist nicht normalverteilt, sie hat Zyklen, die nicht zu ihr passen. Genau die sucht die Ausreißersuche. Die Grenze bleibt eine Konvention, ihre Annahme ist eine Vereinfachung.