Tutoriumsblatt 12

Experimente und A/B-Tests

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- potenzielle Ergebnisse, Selektionsverzerrung und Regression zur Mitte an kleinen Beispielen rechnen, Zuteilungen aufzählen und exakte p-Werte bestimmen,
- Varianzen von Differenzen, CUPED, Stichprobenumfänge, Teststärke, Designeffekt und Holm herleiten und rechnen, Peeking und Prozentangaben beurteilen.

So arbeitest du mit dem Blatt

Du programmierst nicht, du rechnest mit dem Taschenrechner und begründest, Zwischenwerte genauer, als du sie angibst. Hängst du, rechne mit den Werten unter „Zur Kontrolle“ weiter. Im Werkversuch an M-04 (`schleifversuch.csv`) läuft in jeder Schicht ein Los mit der bisherigen Scheibe A und eines mit der neuen Scheibe B, die Rauheit Ra steht in µm, kleiner ist besser. Im A/B-Test des Ersatzteilportals (`portal_konten.csv`, `portal_sitzungen.csv`) wird je Konto zugeteilt, ein Konto hat mehrere Sitzungen. Werkszahlen stammen aus `daten/` und dem Skript, „ausgedacht“ heißt fiktiv. Runde Ergebnisse auf drei bis vier gültige Ziffern. Zum Notebook: Aufgabe 1 gehört zu TODO 1; Aufgabe 2 zu 2, 5 und 8; Aufgabe 3 zu 3, 4, 6 und 10; Aufgabe 4 zu 7 und 9; Aufgabe 5 zu 11 bis 13.

Aufgabe 1 Potenzielle Ergebnisse und Regression zur Mitte 8 Punkte · etwa 17 Min.

Bezug: Modul 12, Lerneinheiten 1 (Vorher-nachher ist kein Nachweis) und 2 (Randomisieren und planen)

Sechs Konten des Ersatzteilportals mit ihrem Umsatz in vier Wochen in hundert Euro, ohne den Knopf „Schnell nachbestellen“ $Y_i(0)$ und mit Knopf $Y_i(1)$ (ausgedacht). Beide Zeilen kennt man nur in einem ausgedachten Beispiel.

Konto i	1	2	3	4	5	6
$Y_i(0)$	12	4	9	2	7	1
$Y_i(1)$	13	6	9	5	8	6

(a) Berechne die Wirkungen $\tau_i = Y_i(1) - Y_i(0)$ und die mittlere Wirkung $\bar{\tau}$. Der Vertrieb schaltet den Knopf nur für die drei umsatzstärksten Konten frei, die Konten 1, 3 und 5. Welchen Unterschied der Mittel zeigt der Vergleich mit den anderen drei Konten? Zerlege ihn in die mittlere Wirkung bei den behandelten Konten und die Selektionsverzerrung, den Unterschied der $Y(0)$-Mittel beider Gruppen. Zur Kontrolle: Der Vergleich zeigt 7,667, also 766,7 €. [3 P]

(b) Wie viele Zuteilungen von drei der sechs Konten gibt es, und in wie vielen davon ist ein bestimmtes Konto behandelt? Zeige damit, dass der beobachtete Unterschied im Mittel über alle gleich wahrscheinlichen Zuteilungen genau $\bar{\tau}$ ist. Welchen Unterschied zeigt die Zuteilung an die drei umsatzschwächsten Konten? [2 P]

(c) Zwei Maschinen (ausgedacht) stehen auf Dauer im Mittel 800 und 1.200 Minuten im Monat still. Dazu kommt jeden Monat unabhängig ein Zufall von +300 oder −300 Minuten, je mit Wahrscheinlichkeit 1/2. Die Instandhaltung nimmt sich jeden Monat die Maschine mit dem

meisten Stillstand vor, ändert aber nichts. Bestimme über die vier gleich wahrscheinlichen Fälle den erwarteten Stillstand der ausgewählten Maschine im Auswahlmonat und im Folgemonat. Wie groß ist der Rückgang bei einem Zufall von ±600 Minuten, wie groß ganz ohne Zufall? Wie prüft die Instandhaltung eine Maßnahme an den Spitzenreitern fair? Zur Kontrolle: Im Auswahlmonat sind es im Mittel 1.250 Minuten. [3 P]

Aufgabe 2 Zuteilungen aufzählen und exakte p-Werte

8 Punkte · etwa 17 Min.

Bezug: Modul 12, Lerneinheiten 2 (Randomisieren und planen) und 3 (Den Werkversuch auswerten)

(a) Ein Versuch hat $2n$ Lose. Wie viele Zuteilungen sind möglich, wenn vollständig randomisiert n Lose die Scheibe B bekommen, und wie viele, wenn in n Schichten mit je zwei Losen innerhalb jeder Schicht gelost wird? Begründe, warum ein exakter zweiseitiger Permutationstest nie einen kleineren p-Wert liefert als 2 geteilt durch die Zahl der Zuteilungen. Wie viele Schichten braucht es mindestens, damit dieser kleinste p-Wert höchstens 0,05 ist, und wie viele Lose vollständig randomisiert? Wie viele Zuteilungen erlaubte der Werkversuch mit 60 Schichten? [2 P]

(b) In einem Vorversuch (ausgedacht) laufen vier Lose aus derselben Charge nacheinander, per Zufall bekommen zwei davon B. Die Rauheit beträgt 0,42 und 0,44 µm mit A und 0,37 und 0,40 µm mit B. Zähle alle Zuteilungen auf, berechne für jede den Unterschied der Mittel B minus A und den exakten zweiseitigen p-Wert. [2 P]

Vier Schichten aus einem Blockversuch an M-04 (ausgedacht), Ra in µm. Unter der Nullhypothese hätte jede Schicht ihre zwei Werte auch andersherum bekommen können.

Schicht	1	2	3	4
A	0,44	0,37	0,47	0,39
B	0,41	0,35	0,43	0,40

(c) Berechne die Differenzen $d_i = \mathrm{Ra}_{B,i} - \mathrm{Ra}_{A,i}$ und ihr Mittel. Zähle alle Vorzeichenmuster auf, die die Nullhypothese erlaubt, und bestimme den exakten zweiseitigen p-Wert. Zur Kontrolle: Das Mittel der Differenzen ist $-0{,}02$ µm. [3 P]

(d) Ein Rechner mischt die acht Lose aus (c) über alle Schichten: Von den 70 Aufteilungen in vier Lose B und vier Lose A erreichen 40 einen Unterschied von mindestens 0,02 µm in eine der beiden Richtungen. Welcher p-Wert folgt? Warum ist er größer als in (c), und warum ist diese Auswertung hier falsch? [1 P]

Aufgabe 3 Gepaart gegen ungepaart und CUPED

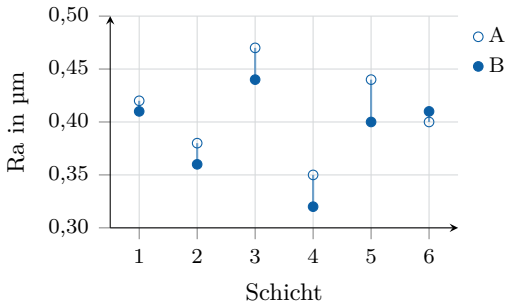
9 Punkte · etwa 20 Min.

Bezug: Modul 12, Lerneinheiten 3 (Den Werkversuch auswerten) und 4 (Genauer messen mit Blöcken und Kovariaten)

(a) Leite für zwei Zufallsgrößen A und B mit Standardabweichungen σ_A, σ_B und Korrelation ρ her: $\mathrm{Var}(B - A) = \sigma_A^2 + \sigma_B^2 - 2\rho\,\sigma_A\sigma_B$. Was folgt für $\rho = 0$, was für $\sigma_A = \sigma_B$ und ρ nahe 1? [2 P]

Sechs Schichten aus dem Werkversuch (ausgedacht), Ra in µm:

Schicht	1	2	3	4	5	6
A	0,42	0,38	0,47	0,35	0,44	0,40
B	0,41	0,36	0,44	0,32	0,40	0,41



(b) Werte zuerst ungepaart aus: Berechne die Mittel und die Stichprobenvarianzen s_A^2 und s_B^2, dann den Standardfehler $\sqrt{s_A^2/6 + s_B^2/6}$ der Differenz der Mittel und t. Vergleiche mit $t_{0{,}975;\,10} = 2{,}228$. Zur Kontrolle: $s_A^2 = s_B^2 = 0{,}00184\,\mu\text{m}^2$. [2 P]

(c) Werte gepaart aus: Differenzen d_i, Standardabweichung s_d, Standardfehler und t, Vergleich mit $t_{0{,}975;\,5} = 2{,}571$. Die Kovarianz von A und B über die Schichten ist $0{,}00168\,\mu\text{m}^2$. Berechne die Korrelation r und prüfe s_d^2 mit (a). Wie viele Lose je Scheibe bräuchte ein ungepaarter Versuch für denselben Standardfehler? [2 P]

(d) Im Portal sei Y der Umsatz eines Kontos im Versuch und X sein Umsatz in den vier Wochen davor. Zeige, dass die Varianz von $Y - \theta\,(X - \bar{X})$ bei $\theta = \operatorname{Cov}(Y, X)/\operatorname{Var}(X)$ minimal ist und dann $(1 - \rho^2)\operatorname{Var}(Y)$ beträgt; behandle $\bar{X}$ als fest. Warum ändert die Korrektur den Erwartungswert des Unterschieds B minus A nicht? Für einen Folgetest (ausgedacht) gilt $s_Y = 2.000\,€$, $s_X = 1.600\,€$ und $\operatorname{Cov}(Y, X) = 1.920.000\,€^2$. Berechne θ, ρ, die Standardabweichung nach CUPED und um wie viel Prozent weniger Konten für denselben Standardfehler reichen. [3 P]

Aufgabe 4 Stichprobenumfang, Teststärke und Klumpen

8 Punkte · etwa 17 Min.

Bezug: Modul 12, Lerneinheiten 2 (Randomisieren und planen) und 5 (Der A/B-Test im Portal)

Rechne zweiseitig mit $\alpha = 5\,\%$ und den Tabellenwerten $z_{0{,}975} = 1{,}96$, $z_{0{,}80} = 0{,}84$, $\Phi(0{,}04) = 0{,}516$ und $\Phi(1{,}04) = 0{,}851$. Die Teststärke ist $\Phi(\delta/\text{SE} - z_{0{,}975})$, die Gegenrichtung ist vernachlässigt.

(a) Ein Folgeversuch an M-04 (ausgedacht) prüft eine weitere Scheibe gepaart in Schichten. Aus einem Vorversuch ist die Standardabweichung der Differenzen je Schicht $\sigma_d = 0{,}03\,\mu\text{m}$, der kleinste relevante Effekt ist $0{,}015\,\mu\text{m}$. Wie viele Schichten braucht der Versuch für 80 % Teststärke? Die Fertigung gibt nur 16 Schichten frei. Welche Teststärke hat der Versuch dann für $0{,}015\,\mu\text{m}$, und welchen MDE erreicht er mit 80 %? Welche Teststärke hätten 36 Schichten? Zur Kontrolle: Mit 16 Schichten ist der Standardfehler $0{,}0075\,\mu\text{m}$. [3 P]

(b) Im Portal ist B inzwischen die Startseite, die Bestellquote je Sitzung liegt bei 15 %. Ein Folgetest soll einen Anstieg auf 18 % erkennen. Wie viele Sitzungen je Gruppe verlangt die Formel für zwei Anteile, wenn die Sitzungen unabhängig wären? [2 P]

(c) Zugeteilt wird je Konto. Ein Konto hat in vier Wochen im Mittel $m = 7$ Sitzungen (Skript 5.3), zwei Sitzungen desselben Kontos korrelieren mit ICC $= 0{,}1$. Berechne den Designeffekt $1 + (m - 1)\,\text{ICC}$ und die nötigen Sitzungen und Konten je Gruppe. Was ergibt er bei ICC $= 0$ und bei ICC $= 1$, und was heißt das? Wie viele Konten braucht es, wenn der Test acht Wochen läuft und jedes Konto 14 Sitzungen hat? Wohin geht die Zahl der Konten bei sehr vielen Sitzungen je Konto? Rechne mit dem ungerundeten Ergebnis aus (b) weiter. Zur Kontrolle: (b) ergibt 2.396,4 Sitzungen, der Designeffekt ist 1,6. [3 P]

Aufgabe 5 Viele Tests, Peeking und Prozentpunkte

7 Punkte · etwa 16 Min.

Bezug: Modul 12, Lerneinheiten 6 (Fallstricke: Peeking, Teilgruppen, Klumpen) und 7 (Entscheiden)

Der Plan des Folgetests nennt vorab sechs Nebenkennzahlen. Nach dem Test liegen diese p-Werte vor (ausgedacht).

Nebenkennzahl	p
Suchen ohne Treffer je Sitzung	0,030
Abbrüche im Warenkorb	0,009
Zeit bis zur Bestellung	0,21
Anrufe bei der Hotline	0,48
Teile je Bestellung	0,006
Rücksendungen	0,012

(a) Wende das Verfahren von Holm mit $\alpha = 5\,\%$ an. Welche Kennzahlen sind danach deutlich, und wie lauten die bereinigten p-Werte? Wie viele wären es ohne Korrektur, wie viele mit Bonferroni? [2 P]

(b) Wie groß ist bei k unabhängigen Tests ohne jede Wirkung die Wahrscheinlichkeit mindestens eines falschen Treffers? Rechne für $k = 10$ und $k = 20$ und gib die erwartete Zahl falscher Treffer an. [1 P]

(c) Ein Test sieht einmal nach, wenn die Hälfte der Konten da ist, und dann am Ende. Die Beiträge der Konten seien unabhängig mit Mittel 0 und Varianz σ^2, S_t die Summe der ersten n_t Beiträge und $z_t = S_t/(\sigma\sqrt{n_t})$. Zeige $\mathrm{Corr}(z_s, z_t) = \sqrt{n_s/n_t}$ für $n_s \le n_t$. Der Test bricht ab, sobald bei einem der zwei Blicke $|z| > 1{,}96$ ist. Welche Fehlerrate hätte er, wenn beide Blicke mit Korrelation 1 zusammenhingen, und welche bei unabhängigen Blicken? Warum hebt das Nachsehen die Fehlerrate weniger als unabhängige Tests, aber deutlich? Zur Kontrolle: Die Korrelation ist 0,707. [2 P]

(d) Der Bericht zum Folgetest (ausgedacht) meldet die Bestellquote mit 15,0 % in A und 16,8 % in B, 95-%-Intervall der Differenz 0,6 bis 3,0 Prozentpunkte. Gib den Unterschied in Prozentpunkten und als relativen Anstieg in Prozent an und rechne das Intervall in relative Werte um. Was vernachlässigt diese Umrechnung? Bei Neukunden (ausgedacht) liegt die Quote in A bei 6 %, der Unterschied ist ebenfalls 1,8 Prozentpunkte. Wie groß ist dort der relative Anstieg, und warum nennt ein Bericht beide Angaben? [2 P]

Aufgabe 6 (⋆) Woher der Designeffekt kommt

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 12, Lerneinheit 5

Ein Konto hat m Sitzungen mit Ergebnissen $Y_1, \dots, Y_m$, jede mit Varianz σ^2. Je zwei Sitzungen desselben Kontos korrelieren mit ICC, Sitzungen verschiedener Konten sind unabhängig. (a) Zeige $\mathrm{Var}(\bar{Y}) = \sigma^2/m \cdot [1 + (m-1)\,\mathrm{ICC}]$ für das Mittel eines Kontos und folgere, dass das Mittel über K Konten gegenüber Km unabhängigen Sitzungen den Designeffekt $1 + (m-1)\,\mathrm{ICC}$ hat. (b) Wie vielen unabhängigen Sitzungen entspricht ein Konto mit $m = 7$ und $\mathrm{ICC} = 0{,}1$? (c) Wohin geht das für $m \to \infty$, und was folgt für Tests mit sehr aktiven Konten?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Potenzielle Ergebnisse und Regression zur Mitte

(a) τ_i: 1; 2; 0; 3; 1; 5, Summe 12, also $\bar{\tau} = 12/6 = \boxed{2}$, im Mittel 200 € mehr Umsatz. Beobachtet werden $Y(1)$ der Konten 1, 3, 5 mit Mittel $(13+9+8)/3 = 10$ und $Y(0)$ der Konten 2, 4, 6 mit Mittel $(4+2+1)/3 = 2{,}333$. Der Vergleich zeigt $10 - 2{,}333 = \boxed{7{,}667}$, also 766,7 €, fast das Vierfache der mittleren Wirkung. Ohne Knopf hätten die Konten 1, 3, 5 im Mittel $(12+9+7)/3 = 9{,}333$ erreicht:

$$10 - 2{,}333 = (10 - 9{,}333) + (9{,}333 - 2{,}333) = 0{,}667 + 7.$$

Der erste Teil ist die Wirkung bei den Behandelten, $(1+0+1)/3 = \boxed{0{,}667}$, der zweite die Selektionsverzerrung $\boxed{7}$. Fast der ganze Unterschied stammt daher, dass starke Konten ausgewählt wurden, nicht vom Knopf.

(b) $\binom{6}{3} = \boxed{20}$ Zuteilungen. Ein bestimmtes Konto ist behandelt, wenn die zwei übrigen Plätze aus den fünf anderen Konten kommen: $\binom{5}{2} = \boxed{10}$, in den anderen 10 ist es Kontrolle. Über alle Zuteilungen g gemittelt:

$$\frac{1}{20}\sum_g \Big[\frac{1}{3}\sum_{i\in g} Y_i(1) - \frac{1}{3}\sum_{i\notin g} Y_i(0)\Big] = \frac{10}{20\cdot 3}\Big[\sum_i Y_i(1) - \sum_i Y_i(0)\Big] = \frac{1}{6}\sum_i \tau_i = \bar{\tau}.$$

Zufällige Zuteilung trifft $\bar{\tau} = 2$ im Mittel, die einzelne Zuteilung nicht. Die drei umsatzschwächsten Konten 2, 4, 6 mit Knopf: $(6+5+6)/3 - 9{,}333 = 5{,}667 - 9{,}333 = \boxed{-3{,}667}$. Die 20 Schätzungen reichen von $-3{,}667$ bis 7,667.

(c) Die vier Fälle (Stillstand M1, M2 im Auswahlmonat):

M1	M2	ausgewählt, Auswahlmonat	Folgemonat im Mittel
500	900	M2 mit 900	1.200
500	1.500	M2 mit 1.500	1.200
1.100	900	M1 mit 1.100	800
1.100	1.500	M2 mit 1.500	1.200

Auswahlmonat: $(900 + 1.500 + 1.100 + 1.500)/4 = \boxed{1.250}$ Minuten. Folgemonat: $(3 \cdot 1.200 + 800)/4 = \boxed{1.100}$ Minuten. Ohne jede Maßnahme sinkt der Stillstand der ausgewählten Maschine um $\boxed{150}$ Minuten, 12 %. Grund: Ausgewählt wird auch nach Pech. Der Zufall der ausgewählten Maschine ist im Mittel $(-300 + 300 + 300 + 300)/4 = +150$, im Folgemonat ist er im Mittel 0, übrig bleibt die dauerhafte Stufe.
Bei ±600: Fälle 200/600, 200/1.800, 1.400/600, 1.400/1.800, ausgewählt 600, 1.800, 1.400, 1.800, im Mittel 1.400, im Folgemonat wieder 1.100: Rückgang $\boxed{300}$ Minuten. Ohne Zufall wird immer M2 mit 1.200 gewählt und bleibt bei 1.200: Rückgang $\boxed{0}$. Je größer der Zufall gegenüber dem dauerhaften Unterschied, desto stärker die Regression zur Mitte.
Fair prüfen: Unter den ausgewählten Spitzenreitern per Zufall die Hälfte behandeln und die andere Hälfte als Vergleichsgruppe ohne Maßnahme führen. Beide Gruppen fallen dann gleich stark zur Mitte zurück, der Unterschied zeigt nur die Maßnahme.

Typischer Fehler

In (b) die Zuteilungen als geordnete Auswahl zählen: $6 \cdot 5 \cdot 4 = 120$ statt 20. Für die Zuteilung zählt nur, welche Konten den Knopf bekommen, nicht in welcher Reihenfolge sie gezogen werden; jede Gruppe kommt in $3! = 6$ Reihenfolgen vor.

Bewertung: (a) Wirkungen und $\bar{\tau}$ 1 P, beobachteter Unterschied 1 P, Zerlegung 1 P. (b) Zahl der Zuteilungen und Mittel über alle 1 P, umsatzschwächste Konten 1 P. (c) vier Fälle und beide Erwartungswerte 1 P, Rückgang bei ± 600 und ohne Zufall 1 P, faire Prüfung 1 P.

Lösung zu Aufgabe 2 Zuteilungen aufzählen und exakte p-Werte

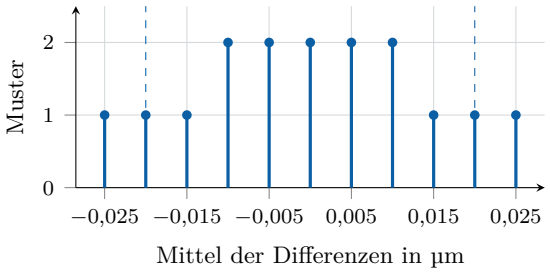
(a) Vollständig randomisiert: $\boxed{\binom{2n}{n}}$ Zuteilungen; in Schichten: je Schicht zwei Möglichkeiten, $\boxed{2^n}$. Zu jeder Zuteilung gibt es ein Spiegelbild, bei dem alle Etiketten getauscht sind: Der Unterschied wechselt nur das Vorzeichen. Die beobachtete Zuteilung und ihr Spiegelbild erreichen beide den beobachteten Betrag, also ist $p \geq 2$/Zahl der Zuteilungen, mit Gleichheit, wenn außer ihr und ihrem Spiegelbild keine Zuteilung diesen Betrag erreicht. In Schichten: $2/2^n \leq 0{,}05$ heißt $2^n \geq 40$, also $\boxed{n = 6 \text{ Schichten}}$ mit $2/64 = 0{,}031$ (fünf Schichten: $2/32 = 0{,}0625$). Vollständig: $\binom{6}{3} = 20$ reicht nicht, $\binom{8}{4} = 70$ mit $2/70 = 0{,}029$ reicht: $\boxed{8 \text{ Lose}}$. Der Werkversuch erlaubte $2^{60} \approx \boxed{1{,}15 \cdot 10^{18}}$ Zuteilungen, vollständig randomisiert wären es $\binom{120}{60} \approx 9{,}66 \cdot 10^{34}$. Schichten erlauben weniger Zuteilungen, dafür vergleicht jede innerhalb der Schicht.

(b) Die vier Werte summieren sich zu 1,63. Mit der Summe S_B der zwei B-Werte ist der Unterschied $S_B/2 - (1{,}63 - S_B)/2 = S_B - 0{,}815$:

B-Lose	0,42/0,44	0,42/0,37	0,42/0,40	0,44/0,37	0,44/0,40	0,37/0,40
B minus A	0,045	−0,025	0,005	−0,005	0,025	−0,045

Beobachtet ist die letzte Zuteilung mit $-0{,}045$ µm. Mindestens so extrem sind sie selbst und ihr Spiegelbild: $p = 2/6 = \boxed{0{,}333}$. Das ist schon der kleinste mögliche Wert: Mit vier Losen kann kein Ergebnis unter $1/3$ fallen.

(c) d_i: $-0{,}03$; $-0{,}02$; $-0{,}04$; $+0{,}01$, Mittel $-0{,}08/4 = \boxed{-0{,}02}$ µm. Es gibt $2^4 = 16$ Vorzeichenmuster für die Beträge 0,03, 0,02, 0,04 und 0,01. Mindestens so extrem heißt $|\sum \pm |d_i|| \geq 0{,}08$. Alle vier gleich gerichtet ergibt $\pm 0{,}10$, nur die 0,01 umgedreht ergibt $\pm 0{,}08$; jede andere Wahl dreht 0,02, 0,03 oder 0,04 um und landet bei höchstens 0,06 im Betrag. Also 4 von 16: $p = \boxed{0{,}25}$. Die Verteilung der 16 Mittel:



(d) $p = 40/70 = \boxed{0{,}571}$. Über alle Schichten gemischt geht der große Unterschied zwischen den Schichten, 0,35 bis 0,47 µm, in jede Aufteilung ein und überdeckt die kleinen Differenzen innerhalb der Schichten. Falsch ist die Auswertung, weil im Versuch innerhalb der Schichten

gelost wurde: Aufteilungen, die beiden Losen einer Schicht dieselbe Scheibe geben, waren nie möglich. Die Permutation folgt der Zuteilung.

Zum Nachprüfen im Notebook:

```
import itertools
a = np.array([0.44, 0.37, 0.47, 0.39])
b = np.array([0.41, 0.35, 0.43, 0.40])
muster = np.array(list(itertools.product([1, -1], repeat=4)))
gepaart = (muster * (b - a)).mean(axis=1)
werte = np.r_[a, b]
ungepaart = np.array([werte[list(g)].mean() - np.delete(werte, list(g)).mean()
                      for g in itertools.combinations(range(8), 4)])
for perm in [gepaart, ungepaart]:
    print(len(perm), int((np.abs(perm) >= 0.02 - 1e-9).sum()))
```

liefert `16 4` und `70 40`.

> **Typischer Fehler**
> In (c) nur die Muster zählen, die genau den beobachteten Betrag 0,02 haben: 2 von 16, also $p = 0{,}125$. Der p-Wert zählt alle Muster, die mindestens so extrem sind, hier auch die zwei mit $\pm 0{,}025$.

Bewertung: (a) beide Anzahlen und kleinster p-Wert 1 P, Mindestzahlen und Werkversuch 1 P. (b) sechs Unterschiede 1 P, p-Wert 1 P. (c) Differenzen und Mittel 1 P, 16 Muster und Abzählung 1 P, p-Wert 1 P. (d) p-Wert und Begründung 1 P.

Lösung zu Aufgabe 3 Gepaart gegen ungepaart und CUPED

(a) Mit μ_A, μ_B als Erwartungswerten:

$$\operatorname{Var}(B-A) = E\big[\big((B-\mu_B)-(A-\mu_A)\big)^2\big] = \sigma_B^2 + \sigma_A^2 - 2\operatorname{Cov}(A,B) = \boxed{\sigma_A^2 + \sigma_B^2 - 2\rho\,\sigma_A\sigma_B},$$

denn $\operatorname{Cov}(A,B) = \rho\,\sigma_A\sigma_B$. Für $\rho = 0$ addieren sich die Varianzen, wie ungepaart. Für $\sigma_A = \sigma_B = \sigma$ ist $\operatorname{Var}(B-A) = 2\sigma^2(1-\rho)$, bei ρ nahe 1 fast 0: Was beide Lose einer Schicht gemeinsam haben, fällt in der Differenz heraus.

(b) Mittel A: $2{,}46/6 = 0{,}41$, B: $2{,}34/6 = 0{,}39$, Differenz $-0{,}02$ µm. Abweichungen in 0,01 µm: A 1; −3; 6; −6; 3; −1, B 2; −3; 5; −7; 1; 2, Quadratsummen je 92, also $s_A^2 = s_B^2 = 0{,}0092/5 = \boxed{0{,}00184}$. Standardfehler und t:

$$\mathrm{SE} = \sqrt{\frac{0{,}00184}{6} + \frac{0{,}00184}{6}} = \sqrt{0{,}000613} = \boxed{0{,}0248}, \qquad t = \frac{-0{,}02}{0{,}0248} = \boxed{-0{,}808}.$$

$|t| < 2{,}228$: Ungepaart ist kein Unterschied nachzuweisen ($p = 0{,}438$).

(c) d_i: −0,01; −0,02; −0,03; −0,03; −0,04; +0,01, Mittel −0,02. Abweichungen vom Mittel in 0,01 µm: 1; 0; −1; −1; −2; 3, Quadratsumme 16, also 0,0016 µm², $s_d^2 = 0{,}0016/5 = 0{,}00032$ und $s_d = 0{,}0179$.

$$\mathrm{SE} = \frac{0{,}0179}{\sqrt{6}} = \boxed{0{,}0073}, \qquad t = \frac{-0{,}02}{0{,}0073} = \boxed{-2{,}739}.$$

$|t| > 2{,}571$: Gepaart ist B deutlich glatter ($p = 0{,}041$). $r = 0{,}00168/\sqrt{0{,}00184 \cdot 0{,}00184} = \boxed{0{,}913}$, und mit (a): $0{,}00184 + 0{,}00184 - 2 \cdot 0{,}00168 = 0{,}00032 = s_d^2$. Der Standardfehler fällt mit $1/\sqrt{n}$, das Verhältnis der Varianzen ist $0{,}000613/0{,}0000533 = 11{,}5 = 1/(1-r)$. Ein ungepaarter Versuch bräuchte $6 \cdot 11{,}5 = \boxed{69}$ Lose je Scheibe statt sechs Schichten.

(d) Mit $\bar{X}$ als fester Zahl:

$$V(\theta) = \mathrm{Var}(Y) - 2\theta\,\mathrm{Cov}(Y,X) + \theta^2\,\mathrm{Var}(X), \qquad V'(\theta) = -2\,\mathrm{Cov}(Y,X) + 2\theta\,\mathrm{Var}(X) = 0.$$

Also $\theta^* = \mathrm{Cov}(Y,X)/\,\mathrm{Var}(X)$, ein Minimum, weil $V''(\theta) = 2\,\mathrm{Var}(X) > 0$. Eingesetzt: $V(\theta^*) = \mathrm{Var}(Y) - 2\,\mathrm{Cov}(Y,X)^2/\,\mathrm{Var}(X) + \mathrm{Cov}(Y,X)^2/\,\mathrm{Var}(X) = \mathrm{Var}(Y) - \mathrm{Cov}(Y,X)^2/\,\mathrm{Var}(X) = \mathrm{Var}(Y)\,[1-\rho^2]$ mit $\rho = \mathrm{Cov}(Y,X)/(\sigma_X\sigma_Y)$. Der Unterschied der korrigierten Mittel ist $(\bar{Y}_B - \bar{Y}_A) - \theta(\bar{X}_B - \bar{X}_A)$. X steht vor der Zuteilung fest, die Zuteilung ist zufällig, also ist $E(\bar{X}_B - \bar{X}_A) = 0$ und der Erwartungswert bleibt.
Zahlen: $\theta = 1.920.000/1.600^2 = \boxed{0{,}75}$, $\rho = 1.920.000/(2.000 \cdot 1.600) = \boxed{0{,}6}$, Varianz $(1 - 0{,}36) \cdot 2.000^2$, Standardabweichung $0{,}8 \cdot 2.000 = \boxed{1.600}$ €. Die nötige Zahl der Konten ist proportional zur Varianz: $\boxed{36\,\%}$ weniger Konten.

Zum Nachprüfen im Notebook:

```
from scipy import stats
a = np.array([0.42, 0.38, 0.47, 0.35, 0.44, 0.40])
b = np.array([0.41, 0.36, 0.44, 0.32, 0.40, 0.41])
for t in [stats.ttest_ind(b, a, equal_var=False), stats.ttest_rel(b, a)]:
    print(round(float(t.statistic), 3), round(float(t.pvalue), 3))
print(round(np.corrcoef(a, b)[0, 1], 3))
```

liefert `-0.808 0.438`, `-2.739 0.041` und `0.913`.

> **Typischer Fehler**
> In (c) den Standardfehler der Differenzen mit den zwölf Losen statt mit den sechs Schichten bilden: $0{,}0179/\sqrt{12} = 0{,}00516$ und $t = -3{,}87$. Je Schicht gibt es eine Differenz, gepaart ist die Schicht die Einheit.

Bewertung: (a) Herleitung 1 P, Sonderfälle 1 P. (b) Mittel und Varianzen 1 P, Standardfehler, t und Vergleich 1 P. (c) s_d, Standardfehler, t und Vergleich 1 P, r, Prüfung und Lose 1 P. (d) θ und Minimum 1 P, Erwartungswert 1 P, Zahlen 1 P.

Lösung zu Aufgabe 4 Stichprobenumfang, Teststärke und Klumpen

(a) Gepaart:

$$n \approx \frac{(1{,}96 + 0{,}84)^2\,\sigma_d^2}{\delta^2} = 7{,}84 \cdot \frac{0{,}03^2}{0{,}015^2} = 7{,}84 \cdot 4 = 31{,}36, \quad \text{also } \boxed{32 \text{ Schichten}}.$$

Mit 16 Schichten ist $\mathrm{SE} = 0{,}03/\sqrt{16} = 0{,}0075$ und $\delta/\mathrm{SE} = 2$, die Teststärke $\Phi(2 - 1{,}96) = \Phi(0{,}04) = \boxed{0{,}516}$, kaum besser als ein Münzwurf. Für 80 % muss $\delta/\mathrm{SE} = 1{,}96 + 0{,}84 = 2{,}8$ sein: $\mathrm{MDE} = 2{,}8 \cdot 0{,}0075 = \boxed{0{,}021}$ µm. Mit 36 Schichten ist $\mathrm{SE} = 0{,}005$, $\delta/\mathrm{SE} = 3$ und die Teststärke $\Phi(1{,}04) = \boxed{0{,}851}$.

(b) $0{,}15 \cdot 0{,}85 + 0{,}18 \cdot 0{,}82 = 0{,}1275 + 0{,}1476 = 0{,}2751$, und

$$n \approx \frac{7{,}84 \cdot 0{,}2751}{0{,}03^2} = \frac{2{,}157}{0{,}0009} = 2.396{,}4, \quad \text{also } \boxed{2.397 \text{ Sitzungen je Gruppe}}.$$

Mit ungerundeten Quantilen sind es 2.400.

(c) Designeffekt $1 + 6 \cdot 0{,}1 = \boxed{1{,}6}$. Sitzungen: $2.396{,}4 \cdot 1{,}6 = 3.834{,}3$, also $\boxed{3.835}$ je Gruppe; Konten: $3.834{,}3/7 = 547{,}8$, also $\boxed{548}$ je Gruppe. In vier Wochen kamen im Versuch 2.548 Konten (Skript 5.1), das reicht für zweimal 548.

ICC = 0: Designeffekt 1, die Sitzungen zählen wie unabhängige. ICC = 1: Designeffekt $m = 7$, alle Sitzungen eines Kontos sind gleich, ein Konto zählt wie eine Sitzung, es braucht 2.397 Konten.
Acht Wochen mit $m = 14$: Designeffekt $1 + 13 \cdot 0{,}1 = 2{,}3$, Sitzungen $2.396{,}4 \cdot 2{,}3 = 5.511{,}8$, Konten $5.511{,}8/14 = 393{,}7$, also $\boxed{394}$ je Gruppe. Doppelt so viele Sitzungen je Konto sparen nur 28 % der Konten. Allgemein braucht es $n\,[1 + (m-1)\,\mathrm{ICC}]/m$ Konten, für $m \to \infty$ geht das gegen $n \cdot \mathrm{ICC} = 2.396{,}4 \cdot 0{,}1 \approx \boxed{240}$ Konten. Darunter hilft keine Laufzeit: Es braucht mehr Konten, nicht mehr Sitzungen je Konto.

Zum Nachprüfen im Notebook:

```
from scipy.stats import norm
from statsmodels.stats.power import NormalIndPower
z_a, z_b = norm.ppf(0.975), norm.ppf(0.8)
print(round((z_a + z_b) ** 2 * 0.03 ** 2 / 0.015 ** 2, 1),
      [round(float(norm.cdf(0.015 / (0.03 / np.sqrt(n)) - z_a)), 3) for n in [16, 36]])
sigma = np.sqrt((0.15 * 0.85 + 0.18 * 0.82) / 2)
print(round(NormalIndPower().solve_power(0.03 / sigma, power=0.8, alpha=0.05), 1))
```

liefert `31.4 [0.516, 0.851]` und `2399.1`. Mit ungerundeten Quantilen sind es 31,4 statt 31,36 Schichten. Für die Anteile liefern eigene Formel und statsmodels mit ungerundeten Quantilen dasselbe, aufgerundet bleibt es bei 2.400 Sitzungen.

> **Typischer Fehler**
> In (c) die 2.397 Sitzungen ohne Designeffekt durch 7 teilen: 342,4, also 343 Konten je Gruppe. Das tut so, als wären sieben Sitzungen eines Kontos sieben Kunden; der Test hätte dann nicht die geplante Teststärke.

Bewertung: (a) Schichten 1 P, Teststärke und MDE bei 16 Schichten 1 P, Teststärke bei 36 Schichten 1 P. (b) Formel eingesetzt 1 P, Ergebnis 1 P. (c) Designeffekt, Sitzungen und Konten 1 P, Sonderfälle 1 P, 14 Sitzungen und Grenzwert 1 P.

Lösung zu Aufgabe 5 Viele Tests, Peeking und Prozentpunkte

(a) Sortiert und mit $0{,}05/(k - j + 1)$ verglichen:

Nebenkennzahl	p	Schwelle	deutlich	Faktor	bereinigt
Teile je Bestellung	0,006	0,0083	ja	6	0,036
Abbrüche im Warenkorb	0,009	0,0100	ja	5	0,045
Rücksendungen	0,012	0,0125	ja	4	0,048
Suchen ohne Treffer	0,030	0,0167	nein, Halt	3	0,09
Zeit bis zur Bestellung	0,21	0,0250	nein	2	0,42
Anrufe bei der Hotline	0,48	0,0500	nein	1	0,48

Nach Holm sind $\boxed{3}$ Kennzahlen deutlich: Teile je Bestellung, Abbrüche und Rücksendungen. Ohne Korrektur wären es 4, mit Bonferroni (alle gegen 0,0083) nur 1. Holm hält dieselbe Fehlerrate wie Bonferroni ein und lehnt nie weniger ab.

(b) $P(\text{mindestens ein Treffer}) = 1 - 0{,}95^k$: $k = 10$: $\boxed{0{,}401}$, $k = 20$: $\boxed{0{,}642}$. Erwartet sind $0{,}05\,k$ falsche Treffer, 0,5 und 1.

(c) Die Summe bis n_t ist $S_t = S_s + (S_t - S_s)$, der zweite Teil ist unabhängig von S_s. Also $\mathrm{Cov}(S_s, S_t) = \mathrm{Var}(S_s) = n_s\sigma^2$ und

$$\mathrm{Corr}(z_s, z_t) = \frac{n_s\sigma^2}{\sigma\sqrt{n_s} \cdot \sigma\sqrt{n_t}} = \sqrt{\frac{n_s}{n_t}}, \qquad \sqrt{0{,}5} = \boxed{0{,}707}.$$

Wären beide Blicke gleich (Korrelation 1), bliebe es bei 5 %, wären sie unabhängig, ergäbe sich $1-0{,}95^2 = 9{,}75\,\%$. Die Fehlerrate liegt also $\boxed{\text{zwischen 5 und } 9{,}75\,\%}$, genau gerechnet bei 8,3 %. Die Blicke teilen sich die Daten, deshalb steigt die Rate weniger als bei unabhängigen Tests. Jeder Blick ist aber eine weitere Chance: Schon ein Zwischenblick hebt sie von 5 auf 8,3 %, tägliches Nachsehen über 28 Tage in der A/A-Simulation des Skripts auf 23 %. Ausweg: Ende vorher festlegen oder ein sequenzielles Verfahren mit strengeren Grenzen.

(d) Unterschied $16{,}8 - 15{,}0 = \boxed{1{,}8 \text{ Prozentpunkte}}$, relativ $1{,}8/15{,}0 = \boxed{12\,\%}$. Relativ ist das Intervall $0{,}6/15{,}0 = 4\,\%$ bis $3{,}0/15{,}0 = 20\,\%$: $\boxed{4 \text{ bis } 20\,\%}$. Die Umrechnung teilt durch die Quote in A, als wäre sie bekannt, und vernachlässigt deren Unsicherheit; ein Bootstrap über Konten nimmt sie mit.
Neukunden: $1{,}8/6 = \boxed{30\,\%}$. Derselbe Unterschied in Prozentpunkten ist bei kleiner Ausgangsquote ein großer relativer Anstieg. Prozentpunkte sagen, wie viele von hundert Sitzungen zusätzlich bestellen, Prozent sagen, wie stark sich die Quote ändert. Erst beide Angaben zusammen mit der Ausgangsquote machen Tests vergleichbar.

Zum Nachprüfen im Notebook:

```
from statsmodels.stats.multitest import multipletests
p = [0.030, 0.009, 0.21, 0.48, 0.006, 0.012]
for verfahren in ["holm", "bonferroni"]:
    abgelehnt, bereinigt = multipletests(p, alpha=0.05, method=verfahren)[:2]
    print(verfahren, int(abgelehnt.sum()), bereinigt.round(3).tolist())
```

liefert `holm 3 [0.09, 0.045, 0.42, 0.48, 0.036, 0.048]` und
`bonferroni 1 [0.18, 0.054, 1.0, 1.0, 0.036, 0.072]`.

Bewertung: (a) Holm mit Schwellen und Halt 1 P, bereinigte p-Werte und Vergleich 1 P. (b) beide Wahrscheinlichkeiten und erwartete Zahl 1 P. (c) Korrelation hergeleitet 1 P, Grenzen und Begründung 1 P. (d) Prozentpunkte, Prozent und Intervall 1 P, Vernachlässigung und Neukunden 1 P.

Lösung zu Aufgabe 6 Woher der Designeffekt kommt (Zusatz)

(a) Die Varianz der Summe ist die Summe aller Varianzen und Kovarianzen: m Varianzen σ^2 und $m(m-1)$ Kovarianzen $\mathrm{ICC} \cdot \sigma^2$. Also

$$\mathrm{Var}(\bar{Y}) = \frac{1}{m^2}\left[m\sigma^2 + m(m-1)\,\mathrm{ICC}\,\sigma^2\right] = \frac{\sigma^2}{m}\left[1 + (m-1)\,\mathrm{ICC}\right].$$

Über K unabhängige Konten teilt sich das durch K: $\sigma^2/(Km) \cdot [1 + (m-1)\,\mathrm{ICC}]$. Km unabhängige Sitzungen hätten $\sigma^2/(Km)$, das Verhältnis ist der Designeffekt.

(b) Ein Konto trägt so viel wie $m/[1 + (m-1)\,\mathrm{ICC}] = 7/1{,}6 = \boxed{4{,}375}$ unabhängige Sitzungen.

(c) $m/[1 + (m-1)\,\mathrm{ICC}] \to 1/\mathrm{ICC} = \boxed{10}$. Ein Konto trägt nie mehr als zehn unabhängige Sitzungen, egal wie aktiv es ist. Sehr aktive Konten bringen viele Sitzungen, aber wenig zusätzliche Information. Wer sie als unabhängig zählt, macht den Standardfehler viel zu klein.