Tutoriumsblatt 13

Kausale Inferenz mit Beobachtungsdaten

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Störgrößen in Tabellen erkennen, stratifizieren und die Wirkung auf alle und auf die Geschulten von Hand berechnen, Pfade in Kausalgraphen aufzählen und Adjustierungsmengen begründen,
- Gewichte, gewichtete Mittel, standardisierte Differenzen, Differenz-in-Differenzen und E-Werte von Hand rechnen, Annahmen mit potenziellen Ergebnissen aufschreiben und Placebo-Ergebnisse beurteilen.

So arbeitest du mit dem Blatt

Du programmierst nicht, du rechnest mit dem Taschenrechner und begründest, Zwischenwerte genauer, als du sie angibst. Hängst du, rechne mit den Werten unter „Zur Kontrolle“ weiter. In `schulung.csv` stehen 124 Bedienende, 34 davon haben die Qualitätsschulung besucht; wer hinging, entschieden die Schichtleitungen. In `ruestvorgaenge.csv` steht jeder Rüstvorgang; an Linie 2 lief in der Woche ab dem 3. November 2025 ein Workshop zur Rüstzeitverkürzung, ab dem 12. Januar 2026 im ganzen Werk ein neues Auftragssystem. „Ausgedacht“ heißt fiktiv, ein Kausalgraph ist immer eine Annahme. Runde Ergebnisse auf drei bis vier gültige Ziffern. Zum Notebook: Aufgabe 1 gehört zu TODO 2 und 4; Aufgabe 2 zu 3 und 5; Aufgabe 3 zu 1 und 6 bis 9; Aufgabe 4 zu 10 und 11; Aufgabe 5 zu 12 und 13.

Aufgabe 1 Simpson-Umkehr und Stratifizieren

8 Punkte · etwa 17 Min.

Bezug: Modul 13, Lerneinheiten 1 (Ohne Zufall: das Problem der Störgrößen) und 3 (Adjustieren und was man nicht adjustieren darf)

60 Bedienende (ausgedacht), nach ihrer Fehlerquote 2025 in drei Stufen eingeteilt, mit der mittleren Fehlerquote 2026 in Prozent. Alle prüfen etwa gleich viele Teile, du darfst Quoten mit Personen gewichten.

	ungeschult		geschult	
Stufe 2025	Personen	Quote 2026	Personen	Quote 2026
niedrig	18	1,0	2	0,9
mittel	14	1,5	6	1,3
hoch	8	2,5	12	2,2

(a) Berechne die mittlere Fehlerquote 2026 der Geschulten und der Ungeschulten über alle Stufen und ihren Unterschied, dann den Unterschied geschult minus ungeschult in jeder Stufe. Woran liegt die Umkehr? Zur Kontrolle: Die Ungeschulten liegen bei 1,475 %. [3 P]

(b) Mittle die Unterschiede der Stufen einmal mit allen Personen je Stufe als Gewicht (Wirkung auf alle, ATE) und einmal mit den Geschulten je Stufe (Wirkung auf die Geschulten, ATT). Warum ist der ATT hier größer im Betrag? [3 P]

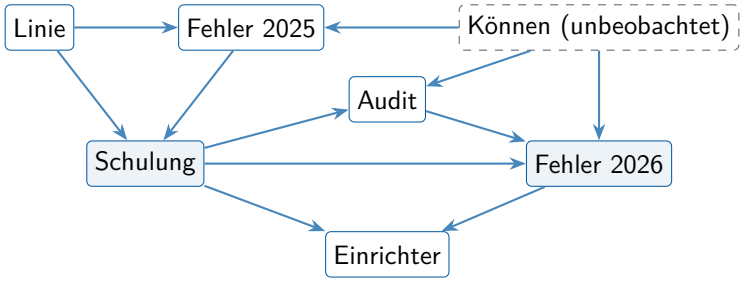
(c) Schätze, welche Fehlerquote die Geschulten ohne Schulung gehabt hätten, und zerlege den Unterschied aus (a) in ATT und Selektionsverzerrung. Welche Annahme steckt darin? Angenommen, die zwei Geschulten der Stufe niedrig fehlen. Welche der beiden Größen aus (b) lässt sich dann noch schätzen, und mit welchem Wert? [2 P]

Aufgabe 2 Pfade, Hintertüren und Adjustierungsmengen

8 Punkte · etwa 17 Min.

Bezug: Modul 13, Lerneinheiten 2 (Kausalgraphen zeichnen) und 3 (Adjustieren und was man nicht adjustieren darf)

Ein vereinfachter, ausgedachter Graph der Schulung. Er nimmt an: 2025 liefen an einigen Linien neue Produkte an; das hob dort die Fehler 2025, und von diesen Linien wurden mehr Leute geschickt. 2026 wirkt die Linie nicht mehr auf die Fehler. Das Können wirkt auf die Fehler beider Jahre und auf die Abweichungen im Prüfaudit, gemessen hat es niemand. Erfahrung und Schicht fehlen hier, im Skript gehören sie dazu.



(a) Zähle alle Pfade von der Schulung zu den Fehlern 2026 auf, egal in welche Richtung die Pfeile zeigen. Gib für jeden an, ob er ein Hintertürpfad ist, welche Rolle seine inneren Knoten spielen (Gabel, Kette, Collider) und ob er ohne Adjustierung offen ist. Zur Kontrolle: Es gibt acht Pfade, vier davon sind Hintertürpfade. [3 P]

(b) Prüfe mit dem Hintertürkriterium die Mengen {Fehler 2025}, {Linie} und {Fehler 2025, Linie}. Welche reicht? Erkläre, warum die Fehler 2025 allein nicht reichen, obwohl sie beide offenen Hintertüren schließen. [2 P]

Vier Vorschläge für die rechte Seite der Poisson-Regression aus dem Skript (Abschnitt 3.2), ohne Ausgabe:

```
plaene = {"A": "schulung + log_quote_2025",
          "B": "schulung + log_quote_2025 + C(linie)",
          "C": "schulung + log_quote_2025 + C(linie) + audit_abweichungen",
          "D": "schulung + C(linie) + einrichter_2026"}
for name, rechts in plaene.items():
    print(name, verhaeltnis(rechts))
```

(c) Beurteile jeden Vorschlag am Graphen, ohne zu rechnen: Welche Pfade sind jeweils offen, und schätzt der Vorschlag die gesamte Wirkung der Schulung? [2 P]

(d) Angenommen, eine Schichtleiterin berichtet, sie habe vor allem Leute geschickt, die sie für besonders lernfähig hielt (Pfeil Können → Schulung). Welche Pfade kommen hinzu, und warum schließt sie keine Menge aus gemessenen Größen? [1 P]

Aufgabe 3 Gewichte, Pseudopopulation und Balance

9 Punkte · etwa 20 Min.

Bezug: Modul 13, Lerneinheit 4 (Propensity Score: Gewichten und Matchen)

Acht Bedienende (ausgedacht) mit Schulung T, Propensity Score e aus einem Modell mit mehreren Störgrößen, Fehlerquote 2025 x und Fehlerquote 2026 y, beide in Prozent.

Person	1	2	3	4	5	6	7	8
T	0	0	0	0	1	1	1	1
e	0,2	0,2	0,6	0,8	0,2	0,4	0,8	0,8
x	1,0	1,2	1,6	2,0	1,4	1,6	2,2	2,6
y	0,8	1,2	1,8	2,2	1,4	1,4	1,6	2,0

(a) Berechne die Gewichte für den ATE, $w_i = T_i/e_i + (1 - T_i)/(1 - e_i)$, ihre Summe je Gruppe, die gewichteten Mittel von y und den ATE. Vergleiche mit dem ungewichteten Unterschied. Zur Kontrolle: Die Gewichte summieren sich in jeder Gruppe zu 10. [3 P]

(b) Berechne die Gewichte für den ATT (Geschulte 1, Ungeschulte $e/(1 - e)$), das gewichtete Mittel der Ungeschulten und den ATT. [2 P]

(c) Berechne die standardisierte Differenz von x vor und nach der Gewichtung für den ATE, im Nenner mit den ungewichteten Stichprobenvarianzen beider Gruppen. Ist x danach ausgeglichen? Zur Kontrolle: Der Nenner ist 0,5. [2 P]

(d) Zeige unter bedingter Austauschbarkeit $E[TY/e(X)] = E[Y(1)]$ und $E[T/e(X)] = 1$, und erkläre damit das Wort Pseudopopulation. Eine neunte Person, ungeschult, hat $e = 0{,}95$ und $y = 2{,}6$. Wie ändern sich ihr Gewicht, das gewichtete Mittel der Ungeschulten und der ATE? Was folgt für Neigungswerte nahe 0 oder 1? [2 P]

Aufgabe 4 Differenz-in-Differenzen und parallele Trends

8 Punkte · etwa 17 Min.

Bezug: Modul 13, Lerneinheiten 5 (Differenz-in-Differenzen) und 6 (Annahmen prüfen: Trends, Placebos, Sensitivität)

Typische Rüstdauer in Minuten (ausgedacht), das geometrische Mittel $e^{\overline{\log \text{Dauer}}}$, vor dem Workshop (Mai bis Oktober 2025) und danach (Dezember 2025 bis Mai 2026).

	vorher	nachher
Linie 2	62,5	55,0
Linien 1 und 3	45,0	49,5

(a) Berechne auf der Log-Skala vorher-nachher an Linie 2 und an den Vergleichslinien, die Differenz der Differenzen und den Faktor auf die Dauer. Welche Dauer hätte Linie 2 nachher ohne Workshop gehabt, wenn sie sich wie die Vergleichslinien um denselben Faktor geändert hätte, und wie viele Minuten macht der Workshop dann aus? Rechne zum Vergleich die Differenz der Differenzen direkt in Minuten und erkläre, warum die beiden Minutenwerte verschieden sind. Zur Kontrolle: $\ln 62{,}5 = 4{,}1352$. [3 P]

(b) Es sei $Y(0)$ die logarithmierte Dauer ohne Workshop, $Y(1)$ mit Workshop. Schreibe die Annahme paralleler Trends mit potenziellen Ergebnissen auf und zeige, dass die Differenz der Differenzen der Erwartungswerte dann die Wirkung an Linie 2 nach dem Workshop ist. Welcher Term kommt hinzu, wenn die Annahme nicht gilt? [2 P]

(c) Das Modell sei $\log(\text{Dauer}_{lt}) = \alpha_l + \delta_t + \tau D_{lt} + \varepsilon_{lt}$; das neue Auftragssystem steckt in δ_t, weil es alle Linien trifft. Zeige, was vorher-nachher an Linie 2 und was die Differenz der Differenzen im Mittel schätzen. Wie groß ist der Anteil von δ_t in der Tabelle, und was wäre, wenn das System nur Linie 2 verlangsamt hätte? [1 P]

Abstand von Linie 2 zu den anderen Linien auf der Log-Skala je Monat vor dem Workshop (ausgedacht).

Abstand	Mai	Jun	Jul	Aug	Sep	Okt
Linie 2 minus Linie 1	0,26	0,24	0,27	0,25	0,24	0,26
Linie 2 minus Linie 3	0,09	0,11	0,10	0,08	0,11	0,10
Linie 2 minus Linie 4	0,50	0,49	0,46	0,44	0,43	0,40

(d) Berechne für jede Linie die mittlere Änderung des Abstands je Monat als (Okt minus Mai)/5. Welche Linien taugen als Vergleich? Die Mitten der Zeiträume vorher und nachher liegen sieben Monate auseinander. Um wie viel verzerrt Linie 4 die Differenz der Differenzen, wenn sich ihr Trend fortsetzt, und in welche Richtung? [2 P]

Aufgabe 5 E-Wert, Placebos und ehrliche Aussagen

7 Punkte · etwa 16 Min.

Bezug: Modul 13, Lerneinheiten 6 (Annahmen prüfen: Trends, Placebos, Sensitivität) und 7 (Ehrlich berichten)

Ein zweiter Schulungsdurchgang (ausgedacht) wird wie im Skript ausgewertet: Poisson-Regression mit allen Störgrößen, Verhältnis der Fehlerraten 0,75 mit 95-%-Intervall 0,60 bis 0,96. Der E-Wert für ein Verhältnis $RR > 1$ ist $E = RR + \sqrt{RR\,(RR-1)}$, für $RR < 1$ setzt du vorher $1/RR$ ein.

(a) Berechne den E-Wert für 0,75 und für die obere Grenze 0,96. Welchen E-Wert hat die Grenze eines Intervalls von 0,70 bis 1,05? Zur Kontrolle: Für 0,96 ist $1/RR = 1{,}0417$. [2 P]

(b) Was sagen die beiden E-Werte aus (a) über eine unbeobachtete Störgröße wie die Lernbereitschaft? Könnte eine Störgröße, die mit Schulung und Fehlerrate je im Verhältnis 1,5 zusammenhängt, die Schätzung ganz erklären? Könnte sie das Intervall an 1 bringen? [1 P]

(c) Ordne zwei Prüfungen ein (ausgedacht). Erstens: Ein erfundener Workshop-Zeitpunkt im Juni 2025 ergibt mit den Daten vor dem Workshop −0,024 mit Standardfehler 0,032. Zweitens: Dieselbe Regression wie für die 0,75, aber mit den Materialfehlern als Ergebnis, die laut Fehlerursache nicht auf die Person zurückgehen. Für die zweite Prüfung denk dir zwei mögliche Ergebnisse: Fall 1 ergibt 0,98 (0,90 bis 1,07), Fall 2 ergibt 0,85 (0,76 bis 0,95). Was folgt jeweils für die Schätzung 0,75? [2 P]

(d) Beurteile jede Aussage mit einem Satz. (1) „Der E-Wert von 2 beweist, dass keine unbeobachtete Störgröße die Wirkung erklärt.“ (2) „Vor dem Workshop liefen die Linien 1 bis 3 parallel, also gelten parallele Trends auch danach.“ (3) „Ein unauffälliger Placebo-Zeitpunkt zeigt, dass das Verfahren an diesem erfundenen Zeitpunkt keine deutliche Wirkung vortäuscht; parallele Trends nach dem Workshop beweist er nicht.“ (4) „Ein 95-%-Intervall, das 1 einschließt, zeigt, dass die Schulung nicht wirkt.“ [2 P]

Aufgabe 6 (⋆) Woher der E-Wert kommt

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 13, Lerneinheit 6

Eine unbeobachtete Störgröße U hänge mit der Schulung im Verhältnis RR_{TU} und mit der Fehlerrate im Verhältnis RR_{UY} zusammen. Dann kann sie ein Verhältnis höchstens um den Bias-Faktor $B = RR_{TU}\,RR_{UY}/(RR_{TU}+RR_{UY}-1)$ verschieben (VanderWeele und Ding 2017). (a) Setze $RR_{TU} = RR_{UY} = E$ und zeige: B erreicht $RR' = 1/RR$ genau bei $E = RR' + \sqrt{RR'(RR'-1)}$. (b) Um welchen Faktor verschiebt eine Störgröße mit $RR_{TU} = RR_{UY} = 1{,}5$ höchstens? Wohin rücken dann 0,75 und die Grenze 0,96? (c) Reicht eine Störgröße mit $RR_{TU} = 4$ und $RR_{UY} = 1{,}2$, um 0,75 auf 1 zu schieben? Was folgt für einzelne starke Zusammenhänge?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Simpson-Umkehr und Stratifizieren

(a) Mit den Personen gewichtet: ungeschult $(18 \cdot 1{,}0 + 14 \cdot 1{,}5 + 8 \cdot 2{,}5)/40 = 59/40 = 1{,}475$, geschult $(2 \cdot 0{,}9 + 6 \cdot 1{,}3 + 12 \cdot 2{,}2)/20 = 36/20 = 1{,}8$. Insgesamt liegen die Geschulten um $1{,}8 - 1{,}475 = \boxed{+0{,}325}$ Prozentpunkte schlechter. Je Stufe: niedrig $0{,}9 - 1{,}0 = -0{,}1$, mittel $1{,}3 - 1{,}5 = -0{,}2$, hoch $2{,}2 - 2{,}5 = -0{,}3$: In $\boxed{\text{jeder Stufe besser}}$. Grund: 12 der 20 Geschulten (60 %) stammen aus der Stufe hoch, aber nur 8 der 40 Ungeschulten (20 %). Die Stufe 2025 hängt mit der Auswahl und mit der Fehlerquote 2026 zusammen, sie ist eine Störgröße.

(b) ATE, jede Stufe mit 20 Personen: $(20 \cdot (-0{,}1) + 20 \cdot (-0{,}2) + 20 \cdot (-0{,}3))/60 = \boxed{-0{,}2}$ Prozentpunkte. ATT: $(2 \cdot (-0{,}1) + 6 \cdot (-0{,}2) + 12 \cdot (-0{,}3))/20 = -5/20 = \boxed{-0{,}25}$. Der ATT ist größer im Betrag, weil die Geschulten vor allem in der Stufe hoch stehen, wo die Schulung am meisten bringt. Der ATE gibt allen Stufen dasselbe Gewicht.

(c) Ohne Schulung hätten die Geschulten die Quoten der Ungeschulten ihrer Stufe gehabt: $(2 \cdot 1{,}0 + 6 \cdot 1{,}5 + 12 \cdot 2{,}5)/20 = 41/20 = 2{,}05$, und

$$1{,}8 - 1{,}475 = (1{,}8 - 2{,}05) + (2{,}05 - 1{,}475) = -0{,}25 + 0{,}575.$$

ATT $-0{,}25$ plus Selektionsverzerrung $\boxed{0{,}575}$ Prozentpunkte. Annahme: Innerhalb jeder Stufe ist die Schulung so gut wie zufällig (bedingte Austauschbarkeit), es gibt keine weitere Störgröße. Ohne Geschulte in der Stufe niedrig fehlt dort der Vergleich, der $\boxed{\text{ATE ist nicht schätzbar}}$ (Überlappung verletzt). Der ATT braucht nur Stufen mit Geschulten: $(6 \cdot (-0{,}2) + 12 \cdot (-0{,}3))/18 = -4{,}8/18 = \boxed{-0{,}267}$.

Zum Nachprüfen im Notebook:

```
stufen_hand = pd.DataFrame({"u": [1.0, 1.5, 2.5], "g": [0.9, 1.3, 2.2], "n_u": [18, 14, 8],
                            "n_g": [2, 6, 12]}, index=["niedrig", "mittel", "hoch"])
d = stufen_hand["g"] - stufen_hand["u"]
naiv = (np.average(stufen_hand["g"], weights=stufen_hand["n_g"])
        - np.average(stufen_hand["u"], weights=stufen_hand["n_u"]))
print(round(naiv, 3), round(np.average(d, weights=stufen_hand["n_u"] + stufen_hand["n_g"]), 3),
      round(np.average(d, weights=stufen_hand["n_g"]), 3))
```

liefert `0.325 -0.2 -0.25`.

> **Typischer Fehler**
>
> In (b) die Unterschiede mit den Ungeschulten je Stufe gewichten: $(18 \cdot (-0{,}1) + 14 \cdot (-0{,}2) + 8 \cdot (-0{,}3))/40 = -0{,}175$. Das ist die Wirkung bei den Ungeschulten, nicht bei den Geschulten. Das Gewicht legt fest, für wen die Wirkung gilt.

Bewertung: (a) beide Mittel und Unterschied 1 P, Unterschiede je Stufe 1 P, Grund der Umkehr 1 P. (b) ATE 1 P, ATT 1 P, Begründung 1 P. (c) Quote ohne Schulung und Zerlegung 1 P, Annahme und fehlende Stufe 1 P.

Lösung zu Aufgabe 2 Pfade, Hintertüren und Adjustierungsmengen

(a) Abkürzungen: T Schulung, Y Fehler 2026, F Fehler 2025, L Linie, K Können, A Audit, R Einrichter.

	Pfad	Hintertür	innere Knoten	offen
1	$T \to Y$	nein	keine	ja
2	$T \to A \to Y$	nein	A Kette (Mediator)	ja
3	$T \to A \leftarrow K \to Y$	nein	A Collider, K Gabel	nein
4	$T \to R \leftarrow Y$	nein	R Collider	nein
5	$T \leftarrow F \leftarrow K \to Y$	ja	F Kette, K Gabel	ja
6	$T \leftarrow F \leftarrow K \to A \to Y$	ja	F Kette, K Gabel, A Kette	ja
7	$T \leftarrow L \to F \leftarrow K \to Y$	ja	L Gabel, F Collider, K Gabel	nein
8	$T \leftarrow L \to F \leftarrow K \to A \to Y$	ja	L Gabel, F Collider, K Gabel, A Kette	nein

8 Pfade, davon 4 Hintertürpfade (5 bis 8), offen sind ohne Adjustierung die Hintertüren 5 und 6. Die Pfade 3 und 4 beginnen mit einem Pfeil aus T, tragen aber keine Wirkung, weil ein Collider sie schließt.

(b) {Fehler 2025}: schließt 5 und 6 (F ist dort Kette), öffnet aber 7 und 8, weil F dort Collider ist und L, K nicht festgehalten sind: reicht nicht. {Linie}: 5 und 6 bleiben offen, reicht nicht. {Fehler 2025, Linie}: 5 und 6 schließt F, 7 und 8 schließt L als Gabel; beide standen vor der Schulung fest: $\{F, L\}$ reicht. Wer die Fehler 2025 festhält, vergleicht Leute mit gleichen Fehlern 2025; an einer Linie mit neuen Produkten heißt das besseres Können. Dieser Zusammenhang läuft über die Linie zur Schulung und über das Können zu den Fehlern 2026, die Linie schneidet ihn ab.

(c) A: offen sind 1, 2, 7 und 8; F ohne L öffnet die Hintertüren 7 und 8, verzerrt. B: offen sind 1 und 2, richtig, geschätzt ist die gesamte Wirkung. C: offen sind 1 und 3. Das Audit ist eine Folge der Schulung; es schneidet den Teil der Wirkung über Pfad 2 ab und öffnet Pfad 3 als Collider, geschätzt ist weder die gesamte noch eine saubere direkte Wirkung. D: offen sind 1 bis 6. Der Einrichter öffnet Pfad 4 als Collider und Pfad 3, weil er eine Folge des Colliders Audit ist; ohne F sind zudem die Hintertüren 5 und 6 offen.

(d) Neu sind $T \leftarrow K \to Y$ und $T \leftarrow K \to A \to Y$, zwei Hintertürpfade mit K als Gabel. Auf ihnen liegen weder F noch L; schließen könnte sie nur K selbst (das Audit liegt nur auf einem und ist eine Folge der Schulung). K ist nicht gemessen, also bleibt die Verzerrung. Was bleibt, ist abzuschätzen, wie stark sie sein müsste: der E-Wert aus Aufgabe 5.

Zum Nachprüfen im Notebook, mit `pfade` und `collider` aus dem Skript:

```
graph_hand = [("Linie", "Schulung"), ("Linie", "Fehler 2025"), ("Fehler 2025", "Schulung"),
              ("Können", "Fehler 2025"), ("Können", "Fehler 2026"), ("Können", "Audit"),
              ("Schulung", "Audit"), ("Audit", "Fehler 2026"), ("Schulung", "Fehler 2026"),
              ("Schulung", "Einrichter"), ("Fehler 2026", "Einrichter")]
alle = pfade(graph_hand, "Schulung", "Fehler 2026")
hinten = [p for p in alle if (p[1], p[0]) in graph_hand]
print(len(alle), len(hinten), sorted(len(collider(graph_hand, p)) for p in hinten))
```

liefert `8 4 [0, 0, 1, 1]`: zwei der vier Hintertüren haben einen Collider.

> **Typischer Fehler**
>
> In (b) {Fehler 2025} für ausreichend halten, weil die Fehler 2025 auf allen vier Hintertüren liegen. Auf den Pfaden 7 und 8 ist F ein Collider: Festhalten öffnet sie. Für jeden Knoten der Menge zählt seine Rolle auf dem jeweiligen Pfad.

Bewertung: (a) alle acht Pfade 1 P, Art 1 P, Rollen und offen oder geschlossen 1 P. (b) drei Mengen geprüft 1 P, Collider F erklärt 1 P. (c) A und B 1 P, C und D 1 P. (d) neue Pfade und Begründung 1 P.

Lösung zu Aufgabe 3 Gewichte, Pseudopopulation und Balance

(a) Gewichte (ATT für (b) gleich mit):

Person	1	2	3	4	5	6	7	8
w^{ATE}	1,25	1,25	2,5	5	5	2,5	1,25	1,25
w^{ATT}	0,25	0,25	1,5	4	1	1	1	1

Summen: ungeschult $1{,}25+1{,}25+2{,}5+5=10$, geschult $5+2{,}5+1{,}25+1{,}25=10$. Gewichtete Mittel: geschult $\bar{y}_1^w=(5\cdot 1{,}4+2{,}5\cdot 1{,}4+1{,}25\cdot 1{,}6+1{,}25\cdot 2{,}0)/10=15/10=1{,}5$, ungeschult $\bar{y}_0^w=(1{,}25\cdot 0{,}8+1{,}25\cdot 1{,}2+2{,}5\cdot 1{,}8+5\cdot 2{,}2)/10=18/10=1{,}8$. ATE $=1{,}5-1{,}8=\boxed{-0{,}3}$ Prozentpunkte. Ungewichtet: $6{,}4/4-6{,}0/4=1{,}6-1{,}5=\boxed{+0{,}1}$, die Geschulten sähen schlechter aus.

(b) Ungeschulte mit $e/(1-e)$: 0,25; 0,25; 1,5; 4, Summe 6.

$$\bar{y}_0^{\text{ATT}}=\frac{0{,}25\cdot 0{,}8+0{,}25\cdot 1{,}2+1{,}5\cdot 1{,}8+4\cdot 2{,}2}{6}=\frac{12}{6}=2{,}0,\qquad \text{ATT}=1{,}6-2{,}0=\boxed{-0{,}4}.$$

Die Ungeschulten werden so gewichtet, dass sie den Geschulten gleichen: Person 4 mit $e=0{,}8$ zählt vierfach. Der ATT ist größer im Betrag, weil die Geschulten mit vielen Fehlern 2025 am meisten gewinnen.

(c) Mittel $\bar{x}_1=7{,}8/4=1{,}95$, $\bar{x}_0=5{,}8/4=1{,}45$. Quadratsummen der Abweichungen: geschult $0{,}3025+0{,}1225+0{,}0625+0{,}4225=0{,}91$, ungeschult $0{,}2025+0{,}0625+0{,}0225+0{,}3025=0{,}59$, also $s_1^2=0{,}91/3=0{,}3033$ und $s_0^2=0{,}59/3=0{,}1967$. Nenner $\sqrt{(0{,}3033+0{,}1967)/2}=\sqrt{0{,}25}=0{,}5$:

$$d_{\text{vorher}}=\frac{1{,}95-1{,}45}{0{,}5}=\boxed{1{,}0},\qquad d_{\text{nachher}}=\frac{\bar{x}_1^w-\bar{x}_0^w}{0{,}5}=\frac{1{,}7-1{,}675}{0{,}5}=\boxed{0{,}05}$$

mit $\bar{x}_1^w=(7+4+2{,}75+3{,}25)/10=1{,}7$ und $\bar{x}_0^w=(1{,}25+1{,}5+4+10)/10=1{,}675$. Unter 0,1, also ausgeglichen.

(d) Mit dem Satz vom iterierten Erwartungswert, $TY=TY(1)$, bedingter Austauschbarkeit und $e(X)=E[T\mid X]>0$ (Überlappung):

$$E\Big[\frac{TY}{e(X)}\Big]=E\Big[\frac{E[TY(1)\mid X]}{e(X)}\Big]=E\Big[\frac{E[T\mid X]\,E[Y(1)\mid X]}{e(X)}\Big]=E\big[E[Y(1)\mid X]\big]=E[Y(1)],$$

und ebenso $E[T/e(X)]=E[e(X)/e(X)]=1$. Die Geschulten, mit $1/e$ gewichtet, stehen im Mittel für alle n Personen und haben die Verteilung von X aller Personen, ebenso die Ungeschulten mit $1/(1-e)$: zwei Pseudopopulationen, die sich nur in der Schulung unterscheiden. Hier summieren sich die Gewichte je Gruppe zu 10 statt 8, bei acht Personen ist das Zufall.
Neunte Person: Gewicht $1/0{,}05=\boxed{20}$, mehr als alle anderen Ungeschulten zusammen. Mittel der Ungeschulten $(18+20\cdot 2{,}6)/(10+20)=70/30=2{,}333$, ATE $=1{,}5-2{,}333=\boxed{-0{,}833}$ statt $-0{,}3$. Eine Person stellt zwei Drittel der ungeschulten Pseudopopulation. Bei e nahe 0 oder 1 gibt es kaum Vergleichspersonen, die Gewichte werden riesig und die Schätzung instabil; bei $e=1$ ist sie gar nicht definiert. Deshalb Überlappung prüfen, große Gewichte kürzen oder die Frage auf Personen mit Überlappung einschränken und das berichten.

Zum Nachprüfen im Notebook, mit `smd` aus dem Skript:

```
e = np.array([0.2, 0.2, 0.6, 0.8, 0.2, 0.4, 0.8, 0.8])
t = np.array([0, 0, 0, 0, 1, 1, 1, 1])
x = np.array([1.0, 1.2, 1.6, 2.0, 1.4, 1.6, 2.2, 2.6])
y = np.array([0.8, 1.2, 1.8, 2.2, 1.4, 1.4, 1.6, 2.0])
w_ate, w_att = t / e + (1 - t) / (1 - e), t + (1 - t) * e / (1 - e)
g, u = t == 1, t == 0
ate = np.average(y[g], weights=w_ate[g]) - np.average(y[u], weights=w_ate[u])
att = y[g].mean() - np.average(y[u], weights=w_att[u])
print(round(ate, 3), round(att, 3), round(smd(x, t), 3), round(smd(x, t, w_ate), 3))
```

liefert `-0.3 -0.4 1.0 0.05`.

> **Typischer Fehler**
>
> In (a) die gewichteten Summen durch die Zahl der Personen teilen statt durch die Summe der Gewichte: $15/4 = 3{,}75$ und $18/4 = 4{,}5$, Quoten weit über allen Werten der Tabelle. Ein gewichtetes Mittel teilt durch die Summe der Gewichte.

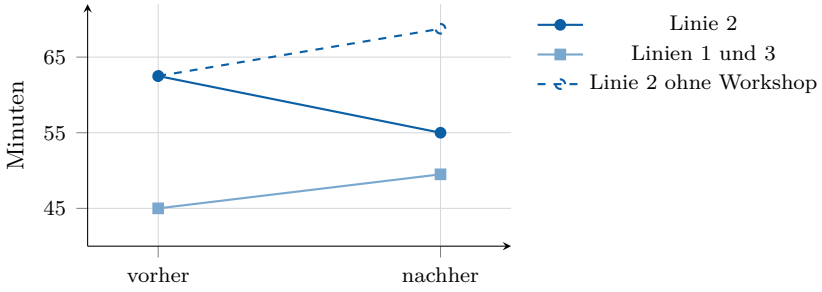
Bewertung: (a) Gewichte und Summen 1 P, gewichtete Mittel 1 P, ATE und Vergleich 1 P. (b) Gewichte und Mittel 1 P, ATT 1 P. (c) Varianzen und Nenner 1 P, beide Differenzen und Urteil 1 P. (d) Herleitung 1 P, neunte Person und Folgerung 1 P.

Lösung zu Aufgabe 4 Differenz-in-Differenzen und parallele Trends

(a) Logarithmen: $\ln 62{,}5 = 4{,}1352$, $\ln 55 = 4{,}0073$, $\ln 45 = 3{,}8067$, $\ln 49{,}5 = 3{,}9020$.

$$\underbrace{(4{,}0073 - 4{,}1352)}_{\ln 0{,}88 = -0{,}1278} - \underbrace{(3{,}9020 - 3{,}8067)}_{\ln 1{,}1 = 0{,}0953} = \boxed{-0{,}2231}, \qquad e^{-0{,}2231} = \frac{55/62{,}5}{49{,}5/45} = \frac{0{,}88}{1{,}1} = \boxed{0{,}8}.$$

Ein Rüstvorgang an Linie 2 dauert nach dem Workshop 20 % kürzer, als er ohne gedauert hätte. Ohne Workshop: $62{,}5 \cdot 1{,}1 = \boxed{68{,}75}$ Minuten, der Workshop macht $55 - 68{,}75 = \boxed{-13{,}75}$ Minuten aus. Direkt in Minuten: $(55 - 62{,}5) - (49{,}5 - 45) = -7{,}5 - 4{,}5 = \boxed{-12}$ Minuten. Der Unterschied kommt von der Annahme: Auf der Log-Skala ändern sich beide Gruppen ohne Workshop um denselben Faktor, in Minuten um denselben Betrag. Beides zugleich gilt bei verschiedenen Niveaus nicht. Bremsen wie das Auftragssystem verlängern Rüstvorgänge eher um einen Anteil, das spricht für die Log-Skala.



(b) Mit B für Linie 2 und V für die Vergleichslinien lautet die Annahme paralleler Trends

$$E[Y_{\text{nach}}(0) - Y_{\text{vor}}(0) \mid B] = E[Y_{\text{nach}}(0) - Y_{\text{vor}}(0) \mid V].$$

Beobachtet ist $Y(1)$ nur bei B nachher, sonst $Y(0)$. Ergänzt um $\pm E[Y_{\text{nach}}(0) \mid B]$:

$$\begin{aligned}&(E[Y_{\text{nach}}(1) \mid B] - E[Y_{\text{vor}}(0) \mid B]) - (E[Y_{\text{nach}}(0) \mid V] - E[Y_{\text{vor}}(0) \mid V]) \\ &\quad = \underbrace{E[Y_{\text{nach}}(1) - Y_{\text{nach}}(0) \mid B]}_{\text{Wirkung an Linie 2}} + \underbrace{\Delta_B - \Delta_V}_{\text{Abweichung}},\end{aligned}$$

mit $\Delta_G = E[Y_{\text{nach}}(0) - Y_{\text{vor}}(0) \mid G]$. Unter parallelen Trends ist $\Delta_B = \Delta_V$, übrig bleibt $\boxed{\text{die Wirkung an Linie 2 nachher}}$. Sonst kommt die Abweichung $\Delta_B - \Delta_V$ der Trends hinzu.

(c) Gemittelt über die Zeiträume: vorher-nachher an Linie 2 ist $\tau + (\bar{\delta}_{\text{nach}} - \bar{\delta}_{\text{vor}})$, an den Vergleichslinien $\bar{\delta}_{\text{nach}} - \bar{\delta}_{\text{vor}}$, die Differenz $\boxed{\tau}$; α_l fällt in jeder Differenz heraus. In der Tabelle ist $\bar{\delta}_{\text{nach}} - \bar{\delta}_{\text{vor}} \approx 0{,}0953$, also $-0{,}1278 = -0{,}2231 + 0{,}0953$: Vorher-nachher unterschätzt die Wirkung um die Bremse, die alle Linien traf. Träfe das System nur Linie 2, wäre es kein Teil von δ_t; die Differenz der Differenzen schriebe die Bremse dem Workshop zu und unterschätzte ihn ebenfalls.

(d) Linie 1: $(0{,}26 - 0{,}26)/5 = \boxed{0}$, Linie 3: $(0{,}10 - 0{,}09)/5 = \boxed{0{,}002}$, Linie 4: $(0{,}40 - 0{,}50)/5 = \boxed{-0{,}02}$ je Monat. Die Linien 1 und 3 laufen parallel zu Linie 2 und taugen, ihre Schwankungen von $\pm 0{,}02$ haben keine Richtung. Linie 4 wird jeden Monat um 0,02 langsamer als Linie 2. Setzt sich das fort, schrumpft der Abstand über sieben Monate um $7 \cdot 0{,}02 = \boxed{0{,}14}$ auch ohne Workshop: Die Differenz der Differenzen mit Linie 4 fällt um 0,14 zu negativ aus, Faktor $e^{-0{,}14} = 0{,}869$. Der Workshop sähe um 13 % besser aus, als er ist. Eine Ausgleichsgerade durch die Abstände gibt dieselben Steigungen fast genau.

Zum Nachprüfen im Notebook, die vier Mittelwerte als Regression mit Wechselwirkung:

```
vier = pd.DataFrame({"minuten": [62.5, 55.0, 45.0, 49.5], "linie_2": [1, 1, 0, 0],
                     "nachher": [0, 1, 0, 1]})
m = smf.ols("np.log(minuten) ~ linie_2 * nachher", data=vier).fit()
print(round(m.params["linie_2:nachher"], 4), round(np.exp(m.params["linie_2:nachher"]), 3))
```

liefert `-0.2231 0.8`. Vier Mittelwerte, vier Koeffizienten: Die Regression gibt sie genau wieder.

> **Typischer Fehler**
>
> In (a) die Wirkung als vorher-nachher an Linie 2 angeben: −0,1278, Faktor 0,88, also 12 % statt 20 %. Die Vergleichslinien wurden in derselben Zeit langsamer; ohne sie zählt die gemeinsame Bremse gegen den Workshop.

Bewertung: (a) Logarithmen und Differenz der Differenzen 1 P, Faktor und Dauer ohne Workshop 1 P, Minuten und Vergleich der Skalen 1 P. (b) Annahme formal 1 P, Zerlegung 1 P. (c) beide Erwartungswerte und Folgerung 1 P. (d) Steigungen und Wahl 1 P, Verzerrung mit Richtung 1 P.

Lösung zu Aufgabe 5 E-Wert, Placebos und ehrliche Aussagen

(a) $1/0{,}75 = 4/3 = 1{,}333$ und $E = \frac{4}{3} + \sqrt{\frac{4}{3} \cdot \frac{1}{3}} = \frac{4}{3} + \frac{2}{3} = \boxed{2}$. Für die Grenze ist $1/0{,}96 = 1{,}0417$ und $E = 1{,}0417 + \sqrt{1{,}0417 \cdot 0{,}0417} = 1{,}0417 + 0{,}2083 = \boxed{1{,}25}$. Schließt das Intervall 1 ein, wie 0,70 bis 1,05, ist der E-Wert der Grenze $\boxed{1}$: Schon ohne jede Störgröße ist kein Unterschied gesichert.

(b) Um die Schätzung 0,75 auf 1 zu schieben, müsste eine unbeobachtete Störgröße über die gemessenen hinaus mit der Schulung und mit der Fehlerrate je mindestens im Verhältnis 2 zusammenhängen. Für die Grenze 0,96 reicht je 1,25. Mit je 1,5: Die Schätzung erklärt sie $\boxed{\text{nicht}}$ $(1{,}5 < 2)$, das Intervall $\boxed{\text{kann sie an 1 bringen}}$ $(1{,}5 > 1{,}25)$. Ob es eine so starke Lernbereitschaft neben den Fehlern 2025 gibt, beantworten Fachleute im Werk, nicht die Daten.

(c) Placebo-Zeitpunkt: $z = -0{,}024/0{,}032 = -0{,}75$, $\boxed{\text{unauffällig}}$; vor dem Workshop täuscht das Verfahren keine Wirkung vor. Das stützt die parallelen Trends, beweist sie aber nicht.

Placebo-Ergebnis: Auf Materialfehler kann die Schulung nicht wirken. Fall 1 liegt nah an 1 und schließt 1 ein: $\boxed{\text{kein Hinweis}}$ auf eine übersehene Störgröße. Fall 2 schließt 1 aus: Geschulte und Ungeschulte unterscheiden sich in etwas, das auch Fehler ohne eigene Ursache senkt, etwa ruhigere Prüfplätze. Dann steckt dieselbe Verzerrung vermutlich auch in der 0,75. Grob bereinigt, falls sie gleich stark wirkt: $0{,}75/0{,}85 = 0{,}882$. Ehrlich ist dann: Wirkung unsicher, Störgröße suchen.

(d) (1) Falsch: Der E-Wert sagt, wie stark eine Störgröße sein müsste, nicht, dass es keine gibt. (2) Falsch: Nach dem Workshop ist $Y(0)$ an Linie 2 nicht beobachtbar; parallele Verläufe vorher machen die Annahme nur plausibel. (3) Richtig: Mehr leistet ein Placebo nicht; $Y(0)$ an Linie 2 nach dem Workshop bleibt unbeobachtbar. (4) Falsch: Ein solches Intervall heißt nur, dass die Daten auch „keine Wirkung“ nicht ausschließen; es kann zugleich eine deutliche Wirkung enthalten. Berichtet werden Schätzung und Intervall, etwa 0,75 mit 0,60 bis 0,96, nicht ein Urteil ja oder nein.

Typischer Fehler

In (a) die Formel direkt mit 0,75 rechnen: $0{,}75 \cdot (0{,}75 - 1) < 0$, die Wurzel ist nicht definiert. Unter 1 zuerst den Kehrwert nehmen.

Bewertung: (a) E-Wert der Schätzung 1 P, der Grenze und des Intervalls mit 1 1 P. (b) Deutung und Urteil für 1,5 1 P. (c) Placebo-Zeitpunkt 1 P, Placebo-Ergebnis beide Fälle 1 P. (d) Aussagen (1) und (2) 1 P, Aussagen (3) und (4) 1 P.

Lösung zu Aufgabe 6 Woher der E-Wert kommt (Zusatz)

(a) Mit $RR_{TU} = RR_{UY} = E$ ist $B = E^2/(2E - 1)$. Aus $B = RR'$ folgt $E^2 - 2RR'\,E + RR' = 0$, also

$$E = RR' \pm \sqrt{RR'^2 - RR'} = RR' + \sqrt{RR'(RR' - 1)},$$

denn nur das Pluszeichen gibt $E \geq 1$. Für 0,75: $3E^2 - 8E + 4 = 0$ mit den Lösungen 2 und $2/3$, der E-Wert ist 2.

(b) $B = 1{,}5 \cdot 1{,}5/(1{,}5 + 1{,}5 - 1) = 2{,}25/2 = \boxed{1{,}125}$. Die Schätzung rückt höchstens auf $0{,}75 \cdot 1{,}125 = \boxed{0{,}844}$, bleibt also unter 1. Die Grenze rückt auf $0{,}96 \cdot 1{,}125 = \boxed{1{,}08}$, das Intervall könnte 1 einschließen. Das passt zu Aufgabe 5 (b).

(c) $B = 4 \cdot 1{,}2/(4 + 1{,}2 - 1) = 4{,}8/4{,}2 = \boxed{1{,}143} < 4/3$: reicht nicht, $0{,}75 \cdot 1{,}143 = 0{,}857$. Ein starker Zusammenhang mit der Schulung allein genügt nicht, die Störgröße muss auch mit den Fehlern stark zusammenhängen. Der E-Wert ist die kleinste Stärke, die beide Zusammenhänge zugleich haben müssen.