Tutoriumsblatt 14

Projektwerkstatt zu zweit

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 6

Nach diesem Blatt kannst du

- Prüfregeln aus der `LIESMICH.md` ableiten, Datenfehler finden und den Datenqualitätsbericht schreiben,
- Regel und Modell mit Konfusionsmatrix, Precision, Recall und Kosten vergleichen und Leckage in Analyseplänen erkennen,
- vorher-nachher, Differenz-in-Differenzen und Placebo von Hand rechnen und Regression zur Mitte erklären,
- einen Versuch mit Blöcken auswerten, die Zuteilung prüfen und den Nutzen einer Kovariate beziffern,
- Netto, Wahrscheinlichkeit für Gewinn und Anmeldegrenzen mit der Normalapproximation rechnen und Sätze für die Entscheidungsvorlage schreiben.

So arbeitest du mit dem Blatt

Wiederholung der Module 2 bis 13 wie zur Klausurvorbereitung, verankert in eurem Abschlussprojekt: Aufgaben 1 bis 3, 5 (a), (b), (d) und die Zusatzaufgabe spielen in Track B (Nordwerk), Aufgabe 4, der Vorschlag P3 in Aufgabe 2 und Aufgabe 5 (c) in Track A (Datenfabrik Karlsruhe e.V.). Alle Zahlen sind ausgedachte Beispielwerte im Stil der Übungspakete, keine Ergebnisse eines Pakets. Du programmierst nicht, du rechnest mit dem Taschenrechner und begründest; rechne Zwischenwerte genauer, als du sie angibst. Hängst du, rechne mit den Werten unter „Zur Kontrolle“ weiter. Werte der Standardnormalverteilung: $\Phi(0{,}37) = 0{,}644$, $\Phi(0{,}66) = 0{,}745$, $\Phi(0{,}88) = 0{,}811$, $\Phi(1{,}645) = 0{,}950$. Bezug zur Vorlage: Aufgabe 1 gehört zu Schritt 1, Aufgabe 2 zu Schritt 3, Aufgaben 3 und 4 zu Schritt 2 und 4, Aufgabe 5 zu Schritt 5. Rechnet erst allein und erklärt euch dann gegenseitig die Lösungen: Im Abnahmegespräch erklärt jede Person auch die Analyse der anderen.

Aufgabe 1 Daten prüfen und Prüfregeln

7 Punkte · etwa 17 Min.

Bezug: Modul 2, Lerneinheit 4 (Split-Apply-Combine: gruppieren und aggregieren); Modul 3, Lerneinheiten 4 (Fehlende Werte: MCAR, MAR, MNAR und was Löschen anrichtet), 5 (Ausreißer und Plausibilität: IQR, MAD und Fachregeln) und 6 (Datenprüfungen als Tests und das Datenblatt)

Ein Auszug aus `maschinentage.csv` (ausgedacht, Dezimalzahlen mit Komma, ohne die Spalten `ausfall_morgen`, `alarm` und `inspektion_min`). Ein leeres Feld ist im Auszug leer gelassen. Der 21. Februar 2026 ist ein Samstag.

Zeile	datum	maschine	laufzeit_h	vibration_mm_s	lagertemp_c	strom_pct	stillstand_min
1	2026-02-20	M-06	24	1,74	27,9	81,6	0
2	2026-02-20	M-07	24	1,02	26,8	82,3	0
3	2026-02-20	M 14	24	2,08	33,4	82,9	15
4	2026-02-21	M-06	8	1,69	27,5	80,8	0,75
5	2026-02-21	M-14	8		33,1	82,6	5
6	2026-02-22	M-07	8	0,98	26,9	81,9	0
7	2026-02-23	M-06	24	1,81	28,2	82,4	1,5
8	2026-02-23	M-07	16	1,05	27,1	82,0	10
9	2026-02-23	M-14	24	2,03	32,8	83,0	20
10	2026-02-23	M-14	24	2,03	32,8	83,0	20

Vier Sätze aus der `LIESMICH.md`: (1) „`maschinentage.csv`: eine Zeile je Maschine und Produktionstag“, (2) „`maschine`: Kennung `M-01` bis `M-20`“, (3) „`stillstand_min`: ungeplanter Stillstand durch technische Störungen an diesem Tag in Minuten, auf 5 gerundet“, (4) „`laufzeit_h`: geplante Laufzeit an diesem Tag in Stunden (24 an Werktagen, 8 an Samstagen mit Frühschicht)“. Person A hat in der Vorlage schon vier Prüfregeln geschrieben, `auszug` ist der Auszug:

```
regel("eine Zeile je Maschine und Tag", auszug.duplicated())
regel("Kennung M-NN", ~auszug["maschine"].str.fullmatch(r"M-\d\d"))
regel("Stillstand auf 5 gerundet", auszug["stillstand_min"] % 5 != 0)
regel("Schwingung vorhanden", auszug["vibration_mm_s"].isna())
```

(a) Welche Zeilen des Auszugs meldet jede der vier Regeln? Welche Probleme fängt keine von ihnen? Schreibe dafür Regeln aus den Sätzen (1) und (4). Warum prüft die erste Regel weniger, als Satz (1) verlangt, und wie lautet sie richtig? Zur Kontrolle: Zusammen melden die vier Regeln fünf Zeilen. [3 P]

(b) Schreibe den Datenqualitätsbericht für den Auszug in Stichworten, so wie ihn `melde` sammelt: je Problem den Umfang und den Umgang mit Begründung. Rechne die Kommazahlen in Minuten um. Was spricht bei Zeile 6 für ein verschobenes Datum? [2 P]

(c) Für den Rollout vergleicht ihr zwei Maschinen ohne Pilot im Jahr vor dem Pilot mit 252 Produktionstagen (ausgedacht): M-17 hat 228 Zeilen mit zusammen 4.845 Minuten Stillstand, M-18 alle 252 Zeilen mit zusammen 5.040 Minuten. Welche Maschine steht nach der Summe, welche nach dem Mittel je Maschinentag mehr still? Welcher Vergleich trägt, unter welcher Annahme über die fehlenden Tage, und was meldet ihr dazu im Bericht? [2 P]

Aufgabe 2 Vorhersage ehrlich bewerten

8 Punkte · etwa 18 Min.

Bezug: Modul 8, Lerneinheiten 2 (Trainieren, validieren, testen), 3 (Die Konfusionsmatrix) und 4 (Schwelle, ROC und Kosten); Modul 9, Lerneinheit 4 (Merkmale bauen: Feature Engineering)

Analyse 1 in Track B. Im zeitlichen Test (ausgedacht: 2.000 Maschinentage ohne Pilotbetrieb ab 1. Oktober 2025) folgt an 140 Tagen am nächsten Produktionstag ein Ausfall. Die Regel des

Warnsystems schlägt an 125 Tagen an, 55 davon vor einem Ausfall. Euer Modell, eine logistische Regression, schlägt bei der Schwelle 0,15 an 250 Tagen an, 84 davon vor einem Ausfall. Ein Jahr hat 252 Produktionstage, eine Kurzinspektion kostet 400 Euro, eine Minute ungeplanter Stillstand 20 Euro.

(a) Stelle für Regel und Modell die Konfusionsmatrix auf (TP, FP, FN, TN) und berechne Precision, Recall und Alarmquote. Vergleiche die Precision mit der Basisrate. Wie viele Inspektionen kostet ein gefundener Ausfall? Zur Kontrolle: Die Regel hat den Recall 0,393. [3 P]

(b) Wie viele Alarme je Maschine und Jahr und welche Inspektionskosten ergeben Regel und Modell? Was kostet jeder zusätzlich gefundene Ausfall des Modells an Inspektionen, und wie viele Minuten Stillstand müsste eine Inspektion vor einem zusätzlich gefundenen Ausfall im Mittel verhindern, damit das Modell die Regel schlägt? Welche Zahl aus Analyse 2 fehlt für diese Rechnung? [3 P]

Drei Vorschläge für den Analyseplan von Analyse 1:

P1	Track B: alle Maschinentage mischen und 20 % zufällig als Test ziehen.
P2	Track B: Training bis 30. September 2025 und dazu die Tage der Pilotmaschinen im laufenden Pilot, damit das Modell die Inspektionen kennt; Test ab 1. Oktober 2025 ohne Pilotbetrieb.
P3	Track A: Merkmal bisherige Teilnahmequote, berechnet mit der Zeile darunter.

```
anm["quote"] = anm.groupby("person")["erschienen"].transform("mean")
```

(c) Welche Vorschläge haben eine Leckage? Begründe jeweils und gib die Korrektur an. [2 P]

Aufgabe 3 Wirkung aus Beobachtungsdaten

9 Punkte · etwa 20 Min.

Bezug: Modul 5, Lerneinheit 5 (Bootstrap); Modul 12, Lerneinheit 1 (Vorher-nachher ist kein Nachweis); Modul 13, Lerneinheiten 5 (Differenz-in-Differenzen) und 6 (Annahmen prüfen: Trends, Placebos, Sensitivität)

Analyse 2 in Track B. Ungeplanter Stillstand in Minuten je Maschinentag, Quartalsmittel (ausgedacht) der acht Pilotmaschinen und der zwölf übrigen. Ausgewählt wurden die acht Maschinen mit dem meisten Stillstand im 4. Quartal 2025. Der Pilot läuft seit dem 12. Januar 2026, am 2. März 2026 kam an allen Maschinen ein neuer Schmierstoff. Rechne mit dem einfachen Mittel der Quartalswerte.

Quartal	4/2024	1/2025	2/2025	3/2025	4/2025	1/2026	2/2026	3/2026
Pilot	21,5	20,5	20,0	22,0	25,0	18,5	17,5	18,0
Vergleich	19,0	18,5	17,0	19,5	17,0	19,5	19,0	20,0

Das 1. Quartal 2026 zählt ab dem Pilotstart.

(a) Berechne vorher-nachher nur an den Pilotmaschinen (4. Quartal 2025 gegen die drei Quartale ab Pilotstart), absolut und relativ, und die Differenz-in-Differenzen mit dem 4. Quartal 2025 als Vorperiode, so wie die Vorgabe im `PLAN` der Vorlage. [2 P]

(b) Berechne die Differenz-in-Differenzen mit der Vorperiode 1. Oktober 2024 bis 30. September 2025 (ohne Auswahlquartal), die Basis (Pilot nachher minus Schätzung) und die relative Wirkung. Was bedeutet die Basis? Zur Kontrolle: Die Pilotmaschinen liegen in dieser Vorperiode bei 21,0 Minuten. [2 P]

(c) Erkläre, warum die drei Schätzungen so weit auseinanderliegen. Zerlege den Unterschied der beiden Differenz-in-Differenzen in einen Teil der Pilotmaschinen und einen Teil der Vergleichsmaschinen. Welche Vorperiode schreibt ihr in den Analyseplan, und warum legt ihr sie fest, bevor ihr Ergebnisse anschaut? [3 P]

(d) Mit `did` (Bootstrap über Maschinen, 2.000 Ziehungen) ergibt (b) das 95-%-Intervall $[-8{,}3;\ 0{,}3]$; zieht man stattdessen einzelne Maschinentage, kommt $[-7{,}1;\ -0{,}9]$ heraus. Ein Placebo mit erfundenem Start am 1. April 2025 (nur Daten bis 30. September 2025, Vorperiode die zwei Quartale davor) ergibt das Intervall $[-4{,}5;\ 5{,}5]$. Rechne die Schätzung des Placebos aus der Tabelle nach. Was zeigt das Placebo, was zeigt es nicht? Welches der beiden Intervalle gehört in die Entscheidungsvorlage? [2 P]

Aufgabe 4 Versuch mit Blöcken

8 Punkte · etwa 17 Min.

Bezug: Modul 6, Lerneinheiten 5 (Teststärke und Stichprobengröße) und 6 (Viele Tests); Modul 12, Lerneinheiten 4 (Genauer messen mit Blöcken und Kovariaten), 5 (Der A/B-Test im Portal) und 6 (Fallstricke: Peeking, Teilgruppen, Klumpen)

Analyse 2 in Track A. Im Sommersemester 2026 bekam jede Anmeldung per Münzwurf am Vorabend eine Erinnerung oder nicht. Vier Veranstaltungen (ausgedacht):

	mit Erinnerung		ohne Erinnerung	
Veranstaltung	angemeldet	erschienen	angemeldet	erschienen
Workshop	30	24	20	15
Vortrag	40	26	40	24
Stammtisch	15	6	25	8
Hackathon	35	21	25	13

(a) Berechne die einfache Differenz der Teilnahmequoten (mit minus ohne Erinnerung) über alle Anmeldungen und die Differenz je Veranstaltung. Mittle die Differenzen je Veranstaltung mit der Zahl der Anmeldungen als Gewicht (Veranstaltung als Block). Warum ist die einfache Differenz größer? Zur Kontrolle: Ohne Erinnerung erscheinen 60 von 110. [3 P]

(b) Prüfe den Anteil der Anmeldungen mit Erinnerung gegen 50 % mit der Normalapproximation (z-Wert und zweiseitiger p-Wert). Warum gehört diese Prüfung vor jede Auswertung? [2 P]

(c) Die bisherige Teilnahmequote der Person hängt mit dem Erscheinen zusammen, die Korrelation ist $\rho = 0{,}3$. Um welchen Faktor sinken mit ihr als Kovariate die Varianz und der Standardfehler der Schätzung? Ein zweiter Versuch soll 3 Prozentpunkte bei einer Teilnahmequote um 60 % mit 80 % Teststärke finden und braucht dafür je Gruppe $n = (1{,}96 + 0{,}84)^2 \cdot 2\,p\,(1-p)/\delta^2$ Anmeldungen. Wie viele sind es zusammen ohne und mit der Kovariate (je Gruppe aufgerundet), und wie viele Semester mit je etwa 1.800 Anmeldungen? Wie groß müsste ρ sein, um die Zahl zu halbieren? [2 P]

(d) Person B schlägt vor, nach der Auswertung acht Untergruppen durchzurechnen (Typ, Mitglied, Vorlauf und weitere) und jede mit $p < 0{,}05$ in die Entscheidungsvorlage zu schreiben. Wie wahrscheinlich ist bei acht unabhängigen Tests ohne jede Wirkung mindestens ein $p < 0{,}05$? Was gehört stattdessen in den Analyseplan? [1 P]

Aufgabe 5 Entscheidung unter Unsicherheit

8 Punkte · etwa 18 Min.

Bezug: Modul 5, Lerneinheiten 1 (Zufall im Werk: Binomial, Poisson, Exponential, Normal) und 2 (Simulieren statt rechnen: Monte Carlo); Modul 6, Lerneinheit 7 (Signifikant ist nicht relevant); Modul 12, Lerneinheit 7 (Entscheiden)

Schritt 5 in Track B mit der Wirkung aus Aufgabe 3: relativ $-18\,\%$, 95-%-Intervall $-38\,\%$ bis $+1\,\%$. Für die Normalapproximation sei die relative Wirkung r normalverteilt mit Mittel $-0{,}18$ und Standardabweichung $0{,}10$. Netto je Maschine und Jahr wie in `rollout_B`: $N = -r \cdot G \cdot 20 - A \cdot 400 - 5.000$ Euro mit Grundstillstand G in Minuten je Jahr und A Alarmen je Jahr. Zwei Maschinen ohne Pilot (ausgedacht): M-01 mit $G = 6.000$ und $A = 15$, M-19 mit $G = 3.000$ und $A = 20$.

(a) Berechne für beide Maschinen Erwartungswert und Standardabweichung von N und das 95-%-Intervall mit der Normalapproximation. Ab welcher relativen Wirkung lohnt sich jede der beiden Maschinen? Zur Kontrolle: Für M-01 ist die Standardabweichung 12.000 Euro. [2 P]

(b) Berechne die Wahrscheinlichkeit für Gewinn, $P(N > 0)$. Formuliere zwei Entscheidungsregeln, eine mit der Schätzung, eine mit der unteren Intervallgrenze, und wende beide an. Welche nimmst du, und warum? Welche Annahme von `rollout_B` prüft ihr mit Analyse 1? [2 P]

(c) Track A: Ein Vortragsraum hat 60 Plätze, die Teilnahmequote ohne Erinnerung ist 0,60; mit Erinnerung rechne mit 6 Prozentpunkten mehr (gerundet aus Aufgabe 4). Die Zahl X der Erschienenen von N Angemeldeten sei binomialverteilt und durch die Normalverteilung genähert, das Risiko ist $P(X \geq 60{,}5)$. Bestimme das größte N mit Risiko höchstens $5\,\%$, also $z = (60{,}5 - Np)/\sqrt{Np\,(1-p)} \geq 1{,}645$, ohne und mit Erinnerung. Setze $u = \sqrt{N}$ oder probiere. Warum sinkt die Grenze mit Erinnerung, und warum ist das Risiko eher zu klein geschätzt? [3 P]

(d) Ein Entwurf der Entscheidungsvorlage enthält den Satz „Das Warnsystem senkt den Stillstand um $28\,\%$ und lohnt sich deshalb an allen Maschinen.“ Was ist daran schwach? Schreibe ihn mit den Zahlen dieses Blatts neu. [1 P]

Aufgabe 6 (⋆) Länger messen oder jetzt entscheiden?

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 5, Lerneinheit 4 (Der Standardfehler), und Modul 12, Lerneinheit 7 (Entscheiden)

Der Pilot läuft seit 186 Produktionstagen. (a) Wie lange müsste er nach der Faustregel $1/\sqrt{n}$ insgesamt laufen, damit die Breite des Intervalls aus Aufgabe 3 etwa halbiert wird, und wie viele Jahre wären das noch? (b) Was kostet das Warten im Erwartungswert, wenn vier Maschinen wie M-01 aus Aufgabe 5 so lange auf den Rollout warten? (c) Warum ist die Faustregel hier zu optimistisch, und wie ließe sich die Unsicherheit schneller verkleinern?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Daten prüfen und Prüfregeln

(a) Die vier Regeln melden: `duplicated()` Zeile 10, die Kennung Zeile 3 („M 14“), der Stillstand die Zeilen 4 und 7 (0,75 und 1,5), die Schwingung Zeile 5 (leeres Feld). Zusammen $\boxed{5 \text{ Zeilen}}$. Keine Regel fängt $\boxed{\text{Zeilen 6 und 8}}$: einen Sonntag und 16 Stunden an einem Montag. Satz (1) spricht von Produktionstagen, Satz (4) kennt nur Werktage mit 24 und Samstage mit 8 Stunden; ein Sonntag ist kein Produktionstag:

```
wt = pd.to_datetime(auszug["datum"]).dt.dayofweek   # 5 Samstag, 6 Sonntag
regel("nur Produktionstage", wt == 6)
soll = np.where(wt == 5, 8, 24)
regel("Laufzeit 24 oder 8", (auszug["laufzeit_h"] != soll) & (wt < 6))
auszug["maschine"] = auszug["maschine"].str.replace(" ", "-")
regel("eine Zeile je Maschine und Tag", auszug.duplicated(["datum", "maschine"]))
```

Die drei Regeln melden im Auszug je eine Zeile: 6, 8 und 10.

`duplicated()` vergleicht alle Spalten und findet nur exakte Kopien. Satz (1) verlangt mehr: Jedes Paar aus Datum und Maschine darf nur einmal vorkommen, auch wenn sich ein Messwert unterscheidet. Deshalb prüft die richtige Regel nur `["datum", "maschine"]`, und zwar nach dem Vereinheitlichen der Kennung. Sonst gelten „M 14“ und „M-14“ am selben Tag als zwei Maschinen.

(b) Der Bericht, so wie ihn `melde` sammelt:

Problem	Umfang	Umgang
Kennung „M 14“ statt „M-14“	1 Zeile (Zeile 3)	in `M-14` umbenennen; die Messwerte passen zu M-14.
Stillstand als Kommazahl, also in Stunden	2 Zeilen von M-06 (Zeilen 4, 7)	Zeitraum der Maschine bestimmen, alle Werte darin mal 60 und auf 5 runden: $0{,}75 \cdot 60 = \boxed{45}$, $1{,}5 \cdot 60 = \boxed{90}$ Minuten.
Schwingung fehlt (leeres Feld)	1 Zeile (Zeile 5)	fehlend lassen, nicht mit 0 füllen; die Zeile und ihr Stillstand bleiben gültig.
Datum an einem Sonntag	1 Zeile (Zeile 6)	M-07 fehlt am Samstag, die Zeile hat 8 Stunden wie ein Samstag: vermutlich verschoben. Ursache klären, dann auf den 21. Februar setzen, sonst ausschließen.
Laufzeit 16 Stunden an einem Montag	1 Zeile (Zeile 8)	behalten und melden; Stillstand ist nur bei gleicher Laufzeit vergleichbar, also mit und ohne solche Tage rechnen.
exakt doppelte Zeile	1 Zeile (Zeile 10)	eine Kopie löschen, sonst zählt der Tag doppelt.

Ist der Sonntag ein verschobener Samstag, bleiben nach der Bereinigung $\boxed{9}$ Zeilen, je Maschine und Tag eine.

(c) Summe: M-17 mit 4.845 Minuten liegt unter M-18 mit 5.040. Mittel je Maschinentag: M-17 $4.845/228 = \boxed{21{,}25}$, M-18 $5.040/252 = \boxed{20{,}0}$ Minuten. M-17 steht also je Tag länger still; hochgerechnet auf 252 Tage wären es $21{,}25 \cdot 252 = 5.355$ Minuten. Die Summe täuscht, weil bei M-17 für 24 Tage gar nichts gezählt ist. Das Mittel trägt, wenn die fehlenden Tage nichts mit dem Stillstand zu tun haben (MCAR). Fehlen gerade Tage mit langem Stillstand, etwa weil an einem Tag mit Ausfall niemand die Daten erfasst hat (MNAR), ist auch das Mittel zu niedrig. Im Bericht steht: Lücke von 24 Tagen bei M-17, wann sie liegt, und dass alle Vergleiche Mittel je Maschinentag nutzen.

Typischer Fehler

Nur die beiden Kommazahlen umrechnen und den Rest von M-06 so lassen. Im betroffenen Zeitraum steht der ganze Stillstand der Maschine in Stunden; eine 5 hieße dort 300 Minuten und fiele keiner Regel auf. Ebenso falsch: das leere Feld mit 0 füllen oder die ganze Zeile löschen. Eine Schwingung von 0 gibt es an einer laufenden Maschine nicht, und mit der Zeile ginge der Stillstand des Tages verloren.

Bewertung: (a) gemeldete Zeilen der vier Regeln 1 P, Regeln für Sonntag und Laufzeit 1 P, erste Regel mit Begründung und Korrektur 1 P. (b) alle sechs Probleme mit Umfang und Umrechnungen 1 P, begründeter Umgang 1 P. (c) Summe und Mittel 1 P, Annahme und Meldung 1 P.

Lösung zu Aufgabe 2 Vorhersage ehrlich bewerten

(a) Basisrate $140/2.000 = 7\,\%$, ohne Ausfall 1.860 Tage.

	TP	FP	FN	TN
Regel	55	70	85	1.790
Modell	84	166	56	1.694

Regel: Precision $55/125 = \boxed{0{,}44}$, Recall $55/140 = \boxed{0{,}393}$, Alarmquote $125/2.000 = 6{,}25\,\%$. Modell: Precision $84/250 = \boxed{0{,}336}$, Recall $84/140 = \boxed{0{,}6}$, Alarmquote $250/2.000 = 12{,}5\,\%$. Zufällige Alarme hätten die Precision 0,07; die Regel trifft $0{,}44/0{,}07 = 6{,}3$-mal so oft, das Modell 4,8-mal. Je gefundenem Ausfall kostet die Regel $125/55 = 2{,}27$ Inspektionen, das Modell $250/84 = 2{,}98$.

(b) Je Maschine und Jahr: Regel $0{,}0625 \cdot 252 = \boxed{15{,}75}$ Alarme, $15{,}75 \cdot 400 = 6.300$ Euro; Modell $0{,}125 \cdot 252 = \boxed{31{,}5}$ Alarme, 12.600 Euro. Das Modell bringt $250 - 125 = 125$ zusätzliche Alarme für $84 - 55 = 29$ zusätzliche Treffer, also $125/29 = 4{,}31$ Inspektionen oder $4{,}31 \cdot 400 = \boxed{1.724}$ Euro je zusätzlich gefundenem Ausfall. Das lohnt sich nur, wenn eine Inspektion vor einem zusätzlich gefundenen Ausfall im Mittel mehr als $1.724/20 = \boxed{86{,}2}$ Minuten ungeplanten Stillstand verhindert. Es fehlt genau diese Zahl: wie viel Stillstand eine Inspektion nach einem Alarm verhindert. Sie kommt aus Analyse 2; die Vorhersage sagt nur, wo ein Ausfall droht.

(c) **P1: Leckage.** Benachbarte Tage derselben Maschine landen in Training und Test, das Modell kennt Tage nach dem Testtag, und der Median der 20 Vortage überlappt. Die AUC fällt zu gut aus. Korrektur: zeitlich teilen wie in der Vorlage, Training bis 30. September 2025, Test danach. **P2: Leckage.** Die Pilottage ab dem 12. Januar 2026 liegen im Testzeitraum, das Training kennt also die Zukunft, etwa den neuen Schmierstoff. Dazu verändert die Inspektion nach jedem Alarm die Zielgröße: Nach hoher Schwingung folgt seltener ein Ausfall, das Modell lernt einen schwächeren Zusammenhang, als ihn Maschinen ohne Warnsystem haben. Korrektur: Tage im Pilotbetrieb aus Training und Test lassen. **P3: Leckage.** Das Mittel über alle Anmeldungen der Person enthält spätere Anmeldungen und sogar das Erscheinen der Zeile selbst, die Zielgröße steckt im Merkmal. Korrektur: nur frühere Anmeldungen, $(\text{bisher erschienen} + 1)/(\text{bisher angemeldet} + 2)$:

```
anm = anm.sort_values("datum")          # Tag der Veranstaltung
g = anm.groupby("person")["erschienen"]
bisher_da = g.cumsum() - anm["erschienen"]
bisher_n = g.cumcount()
anm["quote"] = (bisher_da + 1) / (bisher_n + 2)
```

Für eine Person, die bei drei Veranstaltungen nacheinander 1, 0 und 1 hatte, liefert der Vorschlag P3 dreimal 0,667, die Korrektur $\boxed{0{,}5;\ 0{,}667;\ 0{,}5}$.

> **Typischer Fehler**
> In (b) die Kosten je Treffer des Modells nehmen: $250 \cdot 400/84 = 1.190$ Euro. Für die Wahl zwischen Regel und Modell zählt, was die zusätzlichen 125 Alarme an zusätzlichen Treffern bringen, und das sind 1.724 Euro je Treffer.

Bewertung: (a) beide Konfusionsmatrizen 1 P, Precision, Recall und Alarmquote 1 P, Basisrate und Inspektionen je Treffer 1 P. (b) Alarme und Kosten je Jahr 1 P, Kosten je zusätzlichem Treffer und Minuten 1 P, fehlende Zahl aus Analyse 2 1 P. (c) P1 und P2 1 P, P3 mit Korrektur 1 P.

Lösung zu Aufgabe 3 Wirkung aus Beobachtungsdaten

(a) Mittel ab Pilotstart: Pilot $(18{,}5+17{,}5+18{,}0)/3 = 18{,}0$, Vergleich $(19{,}5+19{,}0+20{,}0)/3 = 19{,}5$. Vorher-nachher: $18{,}0 - 25{,}0 = \boxed{-7{,}0}$ Minuten, relativ $-7{,}0/25{,}0 = \boxed{-28\,\%}$. Mit dem 4. Quartal 2025 als Vorperiode:

$$(18{,}0 - 25{,}0) - (19{,}5 - 17{,}0) = -7{,}0 - 2{,}5 = \boxed{-9{,}5}\ \text{Minuten je Maschinentag.}$$

(b) Vorperiode: Pilot $(21{,}5+20{,}5+20{,}0+22{,}0)/4 = 21{,}0$, Vergleich $(19{,}0+18{,}5+17{,}0+19{,}5)/4 = 18{,}5$.

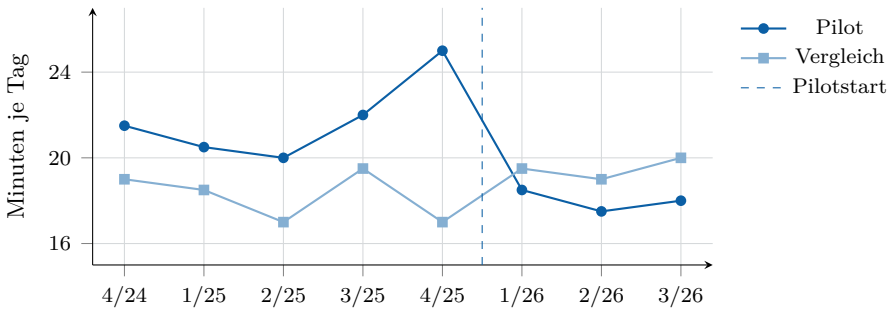
$$(18{,}0 - 21{,}0) - (19{,}5 - 18{,}5) = -3{,}0 - 1{,}0 = \boxed{-4{,}0}, \qquad \text{Basis} = 18{,}0 - (-4{,}0) = 22{,}0,$$

relative Wirkung $-4{,}0/22{,}0 = \boxed{-18{,}2\,\%}$. Die Basis ist der Stand, den die Pilotmaschinen nachher ohne Pilot gehabt hätten, wenn sie sich wie die Vergleichsmaschinen entwickelt hätten: $21{,}0 + 1{,}0 = 22{,}0$ Minuten.

(c) Die Pilotmaschinen wurden ausgewählt, weil ihr Stillstand im 4. Quartal 2025 hoch war. Ein Teil davon war Zufall, der sich danach nicht wiederholt: Regression zur Mitte. Die Pilotmaschinen lagen im Auswahlquartal 4,0 Minuten über ihrem Stand davor, die Vergleichsmaschinen als die übrigen 1,5 Minuten darunter. Vorher-nachher schreibt dem Pilot zudem alles zu, was im Werk gleichzeitig geschah, etwa den Schmierstoff. Zerlegung:

$$-9{,}5 - (-4{,}0) = \underbrace{(21{,}0 - 25{,}0)}_{\text{Pilot}} - \underbrace{(18{,}5 - 17{,}0)}_{\text{Vergleich}} = -4{,}0 - 1{,}5 = \boxed{-5{,}5}.$$

In den Analyseplan gehört die Vorperiode ohne Auswahlquartal, 1. Oktober 2024 bis 30. September 2025, begründet mit der Auswahlregel aus der `LIESMICH.md`. Die Vorgabe der Vorlage ist nur ein Startwert und wird ersetzt, bevor Ergebnisse da sind; wer erst rechnet und dann wählt, sucht sich unbewusst die Zahl aus, die ihm gefällt. Eine spätere Änderung käme als gekennzeichneter Nachtrag mit Grund in `ANALYSEPLAN.md`.



(d) Placebo: Pilot $(20{,}0+22{,}0)/2-(21{,}5+20{,}5)/2 = 21{,}0-21{,}0 = 0$, Vergleich $(17{,}0+19{,}5)/2-(19{,}0+18{,}5)/2 = 18{,}25-18{,}75 = -0{,}5$, Schätzung $0-(-0{,}5) = \boxed{+0{,}5}$. Das Intervall schließt 0 ein: Vor der Auswahl liefen beide Gruppen etwa parallel, und das Verfahren täuscht dort keine Wirkung vor. Es zeigt nicht, dass die Trends nach dem Start parallel bleiben, und es sieht die Auswahl im 4. Quartal 2025 gar nicht. In die Entscheidungsvorlage gehört $\boxed{[-8{,}3;\ 0{,}3]}$, der Bootstrap über Maschinen. Zugeteilt wurden Maschinen, und die Tage einer Maschine hängen zusammen: Ein langer Ausfall zieht sich über mehrere Tage, jede Maschine hat ihr eigenes Niveau. Unabhängig sind nur die 20 Maschinen. Der Bootstrap über Tage tut so, als gäbe es tausende unabhängige Beobachtungen, sein Intervall ist zu schmal und schließt 0 fälschlich aus.

Zum Nachprüfen im Notebook, die Quartalsmittel als Tabelle:

```
q = pd.DataFrame({"pilot": [21.5, 20.5, 20.0, 22.0, 25.0, 18.5, 17.5, 18.0],
                  "vergleich": [19.0, 18.5, 17.0, 19.5, 17.0, 19.5, 19.0, 20.0]})
dd = lambda vor, nach: (q.loc[nach].mean() - q.loc[vor].mean()).pipe(
    lambda d: d["pilot"] - d["vergleich"])
print(dd([4], [5, 6, 7]), dd([0, 1, 2, 3], [5, 6, 7]), dd([0, 1], [2, 3]))
```

liefert `-9.5 -4.0 0.5`.

> **Typischer Fehler**
>
> Die relative Wirkung auf den Stand vorher beziehen: $-4{,}0/21{,}0 = -19{,}0\,\%$. Die Vorlage bezieht sie auf die Basis von 22,0 Minuten, den Stand ohne Pilot im selben Zeitraum; auch die Vergleichsmaschinen standen nachher länger still.

Bewertung: (a) vorher-nachher absolut und relativ 1 P, Differenz-in-Differenzen mit dem Auswahlquartal 1 P. (b) Differenz-in-Differenzen 1 P, Basis, relative Wirkung und Bedeutung 1 P. (c) Regression zur Mitte erklärt 1 P, Zerlegung 1 P, Wahl der Vorperiode im Analyseplan 1 P. (d) Placebo gerechnet und gedeutet 1 P, Bootstrap über Maschinen begründet 1 P.

Lösung zu Aufgabe 4 Versuch mit Blöcken

(a) Mit Erinnerung $24+26+6+21 = 77$ von $30+40+15+35 = 120$, also 64,17 %; ohne $15+24+8+13 = 60$ von 110, also 54,55 %. Einfache Differenz $\boxed{+9{,}6}$ Prozentpunkte. Je Veranstaltung: Workshop $80-75 = 5$, Vortrag $65-60 = 5$, Stammtisch $40-32 = 8$, Hackathon $60-52 = 8$ Prozentpunkte. Gewichtet mit 50, 80, 40 und 60 Anmeldungen:

$$\frac{50\cdot 5+80\cdot 5+40\cdot 8+60\cdot 8}{230} = \frac{1.450}{230} = \boxed{+6{,}3}\ \text{Prozentpunkte.}$$

Der Münzwurf hat ungleich verteilt: Beim Workshop mit hoher Teilnahme bekamen 60 % eine Erinnerung, beim Stammtisch mit niedriger nur 37,5 %. Die einfache Differenz vergleicht deshalb zum Teil Workshop gegen Stammtisch. Innerhalb einer Veranstaltung fällt dieser Unterschied weg.

(b) Anteil $120/230 = 52{,}2\,\%$. Unter 50 % erwartet man 115 mit Standardabweichung $\sqrt{230\cdot 0{,}25} = 7{,}58$:

$$z = \frac{120-115}{7{,}58} = \boxed{0{,}66}, \qquad p = 2\,(1-\Phi(0{,}66)) = 2\cdot 0{,}255 = \boxed{0{,}51}.$$

Kein Hinweis auf einen Zuteilungsfehler. Die Prüfung gehört vor jede Auswertung, weil ein Sample Ratio Mismatch meist einen Fehler zeigt, etwa Anmeldungen, die in einer Gruppe verloren gehen. Dann wäre jede Differenz verzerrt, so gut sie auch gerechnet ist.

(c) Varianz mal $1-\rho^2 = 1-0{,}09 = \boxed{0{,}91}$, Standardfehler mal $\sqrt{0{,}91} = 0{,}954$, also 4,6 % schmalere Intervalle. Ohne Kovariate je Gruppe $7{,}84 \cdot 0{,}48/0{,}0009 = 4.181{,}3$, aufgerundet 4.182, zusammen $\boxed{8.364}$ Anmeldungen. Mit Kovariate $4.181{,}3 \cdot 0{,}91 = 3.805{,}0$, aufgerundet 3.806, zusammen $\boxed{7.612}$, also 752 weniger. Das sind $8.364/1.800 = 4{,}6$ gegen $7.612/1.800 = 4{,}2$ Semester. Halbieren verlangt $1-\rho^2 = 0{,}5$, also $\rho = \sqrt{0{,}5} = \boxed{0{,}707}$. Eine Kovariate hilft so viel, wie sie erklärt.

(d) $1-0{,}95^8 = 1-0{,}663 = \boxed{0{,}337}$, ein Drittel. Wer so sucht, findet fast immer einen „Erfolg“. In den Analyseplan gehören vorher: eine Hauptkennzahl (Erscheinen je Anmeldung), die Auswertung mit Veranstaltung als Block und der bisherigen Teilnahmequote als Kovariate, höchstens eine oder zwei begründete Untergruppen wie der Vorlauf, eine Korrektur wie Holm, und der Hinweis, dass alles Weitere nur Hinweise für einen nächsten Versuch sind.

> **Typischer Fehler**
> In (c) den Standardfehler mit $1-\rho^2$ multiplizieren. Der Faktor gilt für die Varianz und damit für die nötige Zahl der Anmeldungen; der Standardfehler sinkt nur um $\sqrt{1-\rho^2}$.

Bewertung: (a) einfache Differenz 1 P, gewichtete Differenz 1 P, Begründung 1 P. (b) z-Wert und p-Wert 1 P, Begründung 1 P. (c) Faktoren und Anmeldungen 1 P, Semester und ρ für die Hälfte 1 P. (d) Wahrscheinlichkeit und Analyseplan 1 P.

Lösung zu Aufgabe 5 Entscheidung unter Unsicherheit

(a) M-01: Einsparung im Mittel $0{,}18 \cdot 6.000 \cdot 20 = 21.600$, feste Kosten $15 \cdot 400 + 5.000 = 11.000$, also $E[N] = \boxed{10.600}$ Euro. Standardabweichung $0{,}10 \cdot 6.000 \cdot 20 = 12.000$, Intervall $10.600 \pm 1{,}96 \cdot 12.000 = [-12.920;\ 34.120]$. Lohnend ab $11.000/120.000 = 9{,}2\,\%$ Wirkung. M-19: $0{,}18 \cdot 3.000 \cdot 20 = 10.800$, feste Kosten $20 \cdot 400 + 5.000 = 13.000$, $E[N] = \boxed{-2.200}$ Euro. Standardabweichung 6.000, Intervall $-2.200 \pm 11.760 = [-13.960;\ 9.560]$. Lohnend erst ab $13.000/60.000 = 21{,}7\,\%$, mehr als die Schätzung.

(b) M-01: $z = 10.600/12.000 = 0{,}88$, $P(N>0) = \Phi(0{,}88) = \boxed{0{,}81}$. M-19: $z = -2.200/6.000 = -0{,}37$, $P(N>0) = 1-\Phi(0{,}37) = \boxed{0{,}36}$. Regel mit Schätzung: ausrollen, wenn $E[N] > 0$; das trifft M-01, nicht M-19. Regel mit Intervallgrenze: ausrollen, wenn die untere Grenze über 0 liegt; das trifft keine. Musterentscheidung: die Schätzung zusammen mit $P(N>0)$, offen gesagt. Das Warnsystem kostet 5.000 Euro im Jahr und lässt sich abschalten, ein Fehlgriff ist begrenzt und umkehrbar; die untere Grenze würde jede Entscheidung blockieren, solange der Pilot so klein ist. Wer die Intervallgrenze nimmt, bekommt volle Punkte, wenn er das begründet. `rollout_B` nimmt dieselbe relative Wirkung für alle Maschinen an. Mit Analyse 1 prüft ihr, ob sich Ausfälle an M-01 und M-19 ähnlich gut vorhersagen lassen, etwa über die AUC je Maschinentyp.

(c) Ohne Erinnerung, $p = 0{,}60$: Mit $u = \sqrt{N}$ wird die Bedingung zu $0{,}6\,u^2 + 1{,}645 \cdot \sqrt{0{,}24}\,u - 60{,}5 \le 0$, also

$$u \le \frac{-0{,}8059 + \sqrt{0{,}8059^2 + 4 \cdot 0{,}6 \cdot 60{,}5}}{2 \cdot 0{,}6} = \frac{-0{,}8059 + 12{,}0768}{1{,}2} = 9{,}3924, \qquad N \le 88{,}2.$$

Probe: $N = 88$ gibt $Np = 52{,}8$, $\sqrt{21{,}12} = 4{,}596$, $z = 7{,}7/4{,}596 = 1{,}675$; $N = 89$ gibt $z = 7{,}1/4{,}622 = 1{,}536 < 1{,}645$. Grenze $\boxed{88}$ Anmeldungen. Mit Erinnerung, $p = 0{,}66$: $1{,}645 \cdot \sqrt{0{,}2244} = 0{,}7793$, $u \le (-0{,}7793 + 12{,}6620)/1{,}32 = 9{,}0021$, $N \le 81{,}0$. Probe: $N = 81$ gibt $z = 7{,}04/4{,}263 = 1{,}651$, $N = 82$ gibt $z = 6{,}38/4{,}290 = 1{,}487$. Grenze $\boxed{81}$. Mit Erinnerung kommen von jeder Anmeldung mehr Personen, für dieselben 60 Plätze reichen weniger

Anmeldungen; erwartet werden an der Grenze 52,8 und 53,5 Personen. Das Risiko ist eher zu klein geschätzt, weil die Binomialverteilung Unabhängigkeit annimmt. Wetter, Prüfungen oder ein beliebtes Thema verschieben die Quote aller Angemeldeten einer Veranstaltung gemeinsam; dafür hat `anmeldegrenze` die Verschiebung je Veranstaltung. Auch p selbst ist nur geschätzt.

(d) Schwach: 28 % ist vorher-nachher und enthält Regression zur Mitte und den Schmierstoff; ein Intervall fehlt; „senkt“ behauptet eine Wirkung, die vorher-nachher nicht trägt; „an allen Maschinen“ widerspricht der Rechnung für M-19. Musterantwort: „Empfehlung: das Warnsystem auf Maschinen mit hohem Grundstillstand wie M-01 ausrollen, auf M-19 nicht. Nach der Differenz-in-Differenzen-Schätzung mit einer Vorperiode ohne Auswahlquartal lag der ungeplante Stillstand der Pilotmaschinen um 4,0 Minuten je Maschinentag unter dem Stand ohne Pilot, etwa 18 % (95-%-Intervall −8,3 bis 0,3 Minuten), falls die Trends ohne Pilot parallel gelaufen wären. Gilt an M-01 dieselbe Wirkung wie im Pilot, ergibt das dort im Mittel 10.600 Euro Netto im Jahr, mit einer Wahrscheinlichkeit von etwa 81 % für einen Gewinn.“

Zum Nachprüfen im Notebook, mit Normalapproximation und Monte Carlo:

```
from scipy import stats
r = np.random.default_rng(14).normal(-0.18, 0.10, 200_000)
for g, a in [(6000, 15), (3000, 20)]:
    netto = -r * g * 20 - a * 400 - 5000
    print(round(stats.norm.cdf(netto.mean() / netto.std()), 2), round((netto > 0).mean(), 2))
```

liefert `0.81 0.81` und `0.36 0.36`.

> **Typischer Fehler**
>
> In (a) die Standardabweichung ohne die 20 Euro je Minute rechnen oder die festen Kosten hineinnehmen. Feste Beträge verschieben N, sie streuen nicht; nur der Teil mit r streut.

Bewertung: (a) Erwartungswerte 1 P, Standardabweichungen, Intervalle und Schwellen 1 P. (b) Wahrscheinlichkeiten 1 P, beide Regeln mit begründeter Wahl und Annahme 1 P. (c) Grenze ohne Erinnerung 1 P, mit Erinnerung 1 P, beide Begründungen 1 P. (d) Schwächen und neuer Satz 1 P.

Lösung zu Aufgabe 6 Länger messen oder jetzt entscheiden? (Zusatz)

(a) Die Breite fällt wie $1/\sqrt{n}$. Halbieren heißt $1/\sqrt{4}$, also die vierfache Zeit: $4 \cdot 186 = \boxed{744}$ Produktionstage nach dem Start, 558 mehr. Bei 252 Produktionstagen im Jahr sind das noch $558/252 = \boxed{2{,}2}$ Jahre, bis Ende 2028.

(b) Vier Maschinen mit je 10.600 Euro im Erwartungswert: $4 \cdot 10.600 \cdot 2{,}214 = \boxed{93.900}$ Euro, die in der Wartezeit im Mittel entgehen. Mit 19 % Wahrscheinlichkeit lohnt sich das System an M-01 nicht; das Warten spart dann Geld. Der Erwartungswert spricht klar für eine Entscheidung ohne so langes Warten.

(c) Die Faustregel gilt, wenn alle Beobachtungen unabhängig sind und mit der Zeit mehr werden. Hier bleiben es 8 Pilot- und 12 Vergleichsmaschinen, und die Vorperiode ändert sich nicht. Längeres Messen glättet nur das Rauschen der Tage, die Unterschiede zwischen den Maschinen bleiben. Schneller hilft ein stufenweiser Rollout mit Losentscheid: Die übrigen Maschinen bekommen das Warnsystem in zufälliger Reihenfolge, je eine Gruppe pro Quartal. Das ist ein randomisierter Versuch wie in Modul 12 ohne Regression zur Mitte, und jede Maschine bekommt das System ohnehin.