Tutoriumsblatt 1

Python-Crashkurs: Werksdaten verarbeiten

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 6

Nach diesem Blatt kannst du

- Python-Ausdrücke von Hand auswerten, ihren Typ bestimmen und Kommazahlen richtig vergleichen,
- Schleifen über Listen und Dictionaries im Schreibtischtest Zeile für Zeile verfolgen,
- Mittelwert, Standardabweichung und Median von Hand berechnen und die passende Kennzahl begründen,
- in einem Traceback Fehlerstelle und eigentliche Ursache unterscheiden,
- herleiten, warum die Stichprobenvarianz durch $n - 1$ teilt.

So arbeitest du mit dem Blatt

Bearbeite die Aufgaben der Reihe nach, die Schwierigkeit steigt. Du führst keinen Code aus, sondern verfolgst ihn von Hand (Schreibtischtest) und prüfst deine Vorhersagen danach im Notebook. Taschenrechner erlaubt, runde Endergebnisse auf zwei Nachkommastellen. Code ist Python 3 wie in Colab, Ausgaben gibst du so an, wie `print` sie zeigt. `MELDUNGEN` ist die Liste der 24 Störungsmeldungen der fiktiven Nordwerk GmbH. Bezug zum Notebook: Aufgabe 1 gehört zu TODO 1, Aufgabe 2 zu TODO 2 bis 4 und 6, Aufgabe 3 und 5 zu TODO 7, Aufgabe 4 zu TODO 8.

Aufgabe 1 Typen, Ausdrücke und Gleitkomma

7 Punkte · etwa 15 Min.

Bezug: Modul 1, Lerneinheit 1 (Notebook, Werte und Typen)

(a) Gib für jeden Ausdruck den Wert und den Typ an, so wie Python ihn auswertet.

```
1  14400 / 60        4  "45" + "60"
2  325 // 60         5  "M-03" == "m-03".upper()
3  325 % 60          6  0.1 * 3 == 0.3
```

Was sagen dir die Ausdrücke 2 und 3 über die 325 Minuten Stillstand der CNC-Drehmaschine M-03? [3 P]

(b) Python speichert Kommazahlen im Binärsystem. Die Nachkommastellen einer Zahl $0 < x < 1$ im Binärsystem findest du mit dem Verdopplungsverfahren: Verdopple x. Die Stelle vor dem Komma (0 oder 1) ist die nächste Binärziffer, mit dem Rest nach dem Komma rechnest du weiter. Bestimme so die ersten acht binären Nachkommastellen von 0,1 und zeige, dass sich ein Muster endlos wiederholt. Welche der Zahlen 0,5, 0,375 und 0,2 kann der Rechner exakt speichern? Begründe mit einer allgemeinen Regel. [2 P]

(c) Sage die Ausgabe voraus und erkläre sie. Zur Info: `math.isclose(a, b)` prüft standardmäßig, ob $|a - b| \leq 10^{-9} \cdot \max(|a|, |b|)$ ist.

```python
import math
summe = 0
for i in range(10):
    summe = summe + 0.1
print(summe == 1.0, math.isclose(summe, 1.0))
```

Warum prüft der Selbsttest zu TODO 1 die Stundenzahl mit `isclose`, während beim Gesamtstillstand von 1210 Minuten ein Vergleich mit `==` genügt? [2 P]

Aufgabe 2 Tabellen und Akkumulator im Schreibtischtest

9 Punkte · etwa 19 Min.

Bezug: Modul 1, Lerneinheiten 2 bis 4 (Listen, Dictionaries und Tabellen; Akkumulator-Muster; Funktionen)

Die folgende Zelle wird in einer frischen Laufzeit ausgeführt:

```python
MELDUNGEN = [   # Auszug aus den Nordwerk-Daten
    {"id": "S-001", "maschine": "M-03", "stillstand_min": 45},
    {"id": "S-002", "maschine": "M-01", "stillstand_min": 20},
    {"id": "S-003", "maschine": "M-06", "stillstand_min": 35},
    {"id": "S-004", "maschine": "M-05", "stillstand_min": 240},
    {"id": "S-005", "maschine": "M-03", "stillstand_min": 60},
    {"id": "S-006", "maschine": "M-02", "stillstand_min": 25},
]
je_maschine = {}
laengste = 0
for m in MELDUNGEN[1:5]:
    k = m["maschine"]
    je_maschine[k] = je_maschine.get(k, 0) + m["stillstand_min"]
    if m["stillstand_min"] > laengste:
        laengste = m["stillstand_min"]
        laengste_id = m["id"]
print(len(je_maschine), je_maschine.get("M-03"), laengste_id)
```

(a) Welche Meldungen durchläuft die Schleife? Begründe ihre Anzahl mit der Slicing-Regel. [1 P]

(b) Verfolge die Schleife und fülle die Tabelle mit den Werten am Ende jedes Durchlaufs. [3 P]

Durchlauf	`m["id"]`	`k`	`je_maschine`	`laengste`	`laengste_id`
1					
2					
3					
4					

(c) Was gibt die letzte Zeile aus? Warum steht dort für M-03 nicht 105? [1 P]

(d) Jemand ändert den Ausschnitt zu `MELDUNGEN[5:5]` und führt die Zelle in einer frischen Laufzeit aus. Was passiert? Was erscheint stattdessen, wenn in derselben Laufzeit vorher schon die Originalzelle gelaufen ist? Welche Zeile vor der Schleife macht die Zelle robust? [2 P]

(e) Was gibt `m03 = [45, 60, 35]; kopie = m03; kopie.append(90); print(len(m03), m03[-1])` aus? Erkläre mit dem Bild „Etikett statt Kästchen“ aus der Lerneinheit. [1 P]

(f) In allen 24 Meldungen stand das CNC-Fräszentrum M-01 insgesamt $20 + 70 + 25$ Minuten still. Berechne seine Verfügbarkeit $V = (T_{\text{geplant}} - T_{\text{Stillstand}})/T_{\text{geplant}}$ mit $T_{\text{geplant}} = 14\,400$ min und gib sie in Prozent mit zwei Nachkommastellen an. Um wie viele Prozentpunkte liegt sie über der von M-03 (97,74 %)? [1 P]

Aufgabe 3 Statistik von Hand: Spät- gegen Frühschicht

8 Punkte · etwa 17 Min.

Bezug: Modul 1, Lerneinheiten 5 und 6 (Statistik von Hand; Verschiebungssatz)

In der Spätschicht gab es neun Störungen mit diesen Stillständen in Minuten:

Meldung	S-002	S-005	S-006	S-011	S-012	S-016	S-020	S-022	S-024
x_i	20	60	25	70	30	10	25	45	75

(a) Berechne den Mittelwert $\bar{x}$. [1 P]

(b) Lege eine Tabelle mit $x_i - \bar{x}$ und $(x_i - \bar{x})^2$ an. Kontrolliere mit der Summe der Abweichungen. Berechne die Quadratsumme, die Stichprobenvarianz s^2 und die Standardabweichung s. [3 P]

(c) Prüfe die Quadratsumme mit dem Verschiebungssatz $\sum_i (x_i - \bar{x})^2 = \sum_i x_i^2 - n\bar{x}^2$. Welchen Wert liefert die Formel mit Nenner n statt $n - 1$, also `statistics.pstdev`? Um welchen Faktor unterscheiden sich beide? [2 P]

(d) Bestimme den Median der Spätschicht. Die Frühschicht hatte neun Störungen mit 45, 240, 15, 40, 90, 55, 40, 20 und 55 Minuten: Mittelwert $\approx 66{,}7$, Median 45, ohne S-004 Mittelwert 45 und Median 42,5. Dauert eine typische Störung in der Frühschicht länger? Welche Kennzahl beantwortet das fair? Welche Kennzahl braucht dagegen die Planung, die den Gesamtstillstand als „Kennzahl mal Anzahl“ hochrechnet? [2 P]

Aufgabe 4 Tracebacks deuten

8 Punkte · etwa 16 Min.

Bezug: Modul 1, Lerneinheit 7 (Tracebacks lesen und systematisch debuggen)

Eine Zelle soll den mittleren Stillstand der elektrischen Störungen berechnen:

```
def mittelwert(werte):
    return sum(werte) / len(werte)

def mittel_je_kategorie(daten, kat):
    dauern = [m["stillstand_min"] for m in daten if m["kategorie"] == kat]
    return mittelwert(dauern)

print(mittel_je_kategorie(MELDUNGEN, "Elektrisch"))
```

Python bricht mit diesem (vereinfachten) Traceback ab:

```
ZeroDivisionError                         Traceback (most recent call last)
<ipython-input-7> in <cell line: 0>()
----> 8 print(mittel_je_kategorie(MELDUNGEN, "Elektrisch"))

<ipython-input-7> in mittel_je_kategorie(daten, kat)
      5     dauern = [m["stillstand_min"] for m in daten if m["kategorie"] == kat]
----> 6     return mittelwert(dauern)

<ipython-input-7> in mittelwert(werte)
----> 2     return sum(werte) / len(werte)

ZeroDivisionError: division by zero
```

(a) Lies den Traceback von unten nach oben: Wie lauten Fehlertyp und Grund? In welcher Zeile ist Python gescheitert? Gib die Aufrufkette in der Reihenfolge an, in der die Aufrufe passiert sind. [2 P]

(b) Was steht im Moment des Fehlers in `werte`, und warum? Wo liegt die eigentliche Ursache? Wie hättest du das mit dem Schritt „nachsehen“ bestätigt? Nenne die eine Änderung, die den Fehler behebt, und die Ausgabe danach. In den Daten haben die elektrischen Störungen 20, 240, 30, 55, 40 und 75 Minuten. [3 P]

(c) Jemand schlägt vor, `mittelwert` so zu ändern, dass sie für eine leere Liste 0 zurückgibt. Beurteile den Vorschlag. [1 P]

(d) Zwei weitere Abbrüche. Nenne jeweils die Ursache und deinen ersten Schritt.

(i) Nach einer Mittagspause führst du eine Zelle aus, die mit diesen Zeilen abbricht:

```
----> 1 print(len(MELDUNGEN))
NameError: name 'MELDUNGEN' is not defined
```

(ii) Die Meldungen wurden diesmal aus der CSV-Datei eingelesen. Eine Filterschleife bricht so ab:

```
----> 3     if m["stillstand_min"] > 30:
TypeError: '>' not supported between instances of 'str' and 'int'
```

[2 P]

Aufgabe 5 Warum durch $n-1$?

8 Punkte · etwa 19 Min.

Bezug: Modul 1, Lerneinheit 6 (Warum durch $n-1$? Erwartungstreue)

Seien $X_1, \dots, X_n$ unabhängig und identisch verteilt mit $\mathbb{E}[X_i] = \mu$ und $\mathrm{Var}(X_i) = \sigma^2$, und sei $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$. Aus der Lerneinheit darfst du die Zerlegung

$$\sum_{i=1}^{n}(X_i - \mu)^2 = \sum_{i=1}^{n}(X_i - \bar{X})^2 + n\,(\bar{X} - \mu)^2$$

verwenden. Die Lerneinheit ging über den Verschiebungssatz, hier gehst du den Weg über diese Zerlegung.

(a) Zeige $\mathbb{E}[\bar{X}] = \mu$ und $\mathrm{Var}(\bar{X}) = \sigma^2/n$. Nenne die Rechenregeln, die du benutzt, und markiere die Stelle, an der die Unabhängigkeit eingeht. [2 P]

(b) Bilde auf beiden Seiten der Zerlegung den Erwartungswert und folgere $\mathbb{E}\big[\sum_i (X_i - \bar{X})^2\big] = (n-1)\,\sigma^2$. Begründe jeden Schritt. Was folgt daraus für s^2? [3 P]

(c) Exakte Probe ohne Simulation: In einem vereinfachten Modell dauert eine Störung mit Wahrscheinlichkeit $\frac{1}{2}$ genau 10 Minuten und mit Wahrscheinlichkeit $\frac{1}{2}$ genau 40 Minuten.

(i) Berechne μ und σ^2.

(ii) Für $n = 2$ gibt es vier gleich wahrscheinliche Stichproben (x_1, x_2). Berechne für jede $\bar{x}$, die Quadratsumme, s^2 (Nenner $n-1$) und den Schätzer mit Nenner n. Bilde jeweils den Erwartungswert über die vier Stichproben und vergleiche mit (b).

(iii) Ist auch $s = \sqrt{s^2}$ erwartungstreu für σ? Rechne nach. [3 P]

Aufgabe 6 (⋆) Mittelwert und Median als Optimierer

Zusatz · etwa 10 Min.

Bezug: Vertiefung, geht über Modul 1 hinaus (Bezug: Lerneinheiten 5 und 6)

Für die Spätschicht-Daten $x_1, \ldots, x_9$ aus Aufgabe 3 betrachtest du zwei Fehlermaße für einen Bezugswert c: $f(c) = \sum_i (x_i - c)^2$ und $g(c) = \sum_i |x_i - c|$.

(a) Zeige mit der Ableitung, dass f genau bei $c = \bar{x}$ minimal ist. Berechne $f(30)$ ohne neue Summe, nur mit der Zerlegung aus Aufgabe 5 und der Quadratsumme aus Aufgabe 3.

(b) Berechne $g(30)$ und $g(40)$. Warum ist g beim Median kleiner als beim Mittelwert? Überlege, wie sich g ändert, wenn du c vom Median aus um 1 verschiebst.

(c) Bei der Erfassung wird aus 75 versehentlich 750. Wie ändern sich Mittelwert und Median? Was heißt das für die Wahl der Kennzahl?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Typen, Ausdrücke und Gleitkomma

(a) Werte und Typen:

Nr.	Wert	Typ	Begründung
1	`240.0`	`float`	`/` liefert immer eine Kommazahl
2	`5`	`int`	ganzzahlige Division
3	`25`	`int`	Rest der Division
4	`'4560'`	`str`	`+` verkettet Texte, es wird nicht gerechnet
5	`True`	`bool`	`"m-03".upper()` ergibt `"M-03"`
6	`False`	`bool`	`0.1 * 3` ergibt `0.30000000000000004`

Ausdrücke 2 und 3 zerlegen 325 Minuten in $5 \cdot 60 + 25$: M-03 stand $\boxed{5\text{ h }25\text{ min}}$ still.

(b) Verdopplungsverfahren für 0,1:

Schritt	1	2	3	4	5	6	7	8
verdoppelt	0,2	0,4	0,8	1,6	1,2	0,4	0,8	1,6
Ziffer	0	0	0	1	1	0	0	1
Rest	0,2	0,4	0,8	0,6	0,2	0,4	0,8	0,6

Also $0{,}1 = \boxed{0{,}00011001\ldots_2}$. Nach Schritt 5 ist der Rest wieder 0,2 wie nach Schritt 1. Ab dort wiederholen sich die Ziffern 0011 endlos: $0{,}1 = 0{,}0\overline{0011}_2$. Der Rechner hat nur endlich viele Stellen und muss runden. Die ersten acht Stellen ergeben erst $\frac{1}{16} + \frac{1}{32} + \frac{1}{256} = 0{,}09765625$. Regel: Ein gekürzter Bruch $\frac{p}{q}$ hat genau dann eine endliche Binärdarstellung, wenn q eine Zweierpotenz ist, denn jedes Verdoppeln kann nur einen Faktor 2 im Nenner wegkürzen. $0{,}5 = \frac{1}{2} = 0{,}1_2$ und $0{,}375 = \frac{3}{8} = 0{,}011_2$ sind exakt, $0{,}2 = \frac{1}{5} = 0{,}\overline{0011}_2$ ist es nicht.

(c) Ausgabe: `False True`. Jede Addition verwendet die schon gerundete 0,1 und rundet das Ergebnis erneut. Die kleinen Fehler sammeln sich im Akkumulator, am Ende ist `summe` gleich `0.9999999999999999`. Die Abweichung von etwa $1{,}1 \cdot 10^{-16}$ ist viel kleiner als die Toleranz 10^{-9}, deshalb liefert `isclose` `True`. Die Stundenzahl 14 400/60 ist ein `float`, und Rechnungen mit Kommazahlen können solche Reste enthalten. Die Stillstände sind ganze Zahlen (`int`), und Summen ganzer Zahlen sind in Python exakt. Deshalb genügt dort `==`. Hinweis: Die eingebaute Funktion `sum` addiert Kommazahlen ab Python 3.12 mit einem kompensierten Verfahren, das die Rundungsfehler der Zwischensummen mitführt. Deshalb liefert `sum([0.1] * 10)` dort `1.0`, bis Python 3.11 dagegen wie die Schleife `0.9999999999999999`. Den Darstellungsfehler von 0,1 beseitigt das Verfahren nicht: `sum([0.1] * 3) == 0.3` bleibt `False`. Die Schleife rundet nach jeder Addition und zeigt den Fehler unverfälscht.

Typischer Fehler

Ausdruck 4 als `105` oder als `TypeError` ansehen. Ein `TypeError` entsteht nur bei Text plus Zahl wie in `"45" + 60`. Zwei Texte werden verkettet. Ebenso häufig: `14400 / 60` als `int` 240 angeben.

Bewertung: (a) je Ausdruck ½ P für Wert und Typ zusammen. Die Deutung 5 h 25 min ist Teil von Ausdruck 2 und 3. (b) acht Ziffern mit Periode 1 P, Regel mit Einordnung der drei Zahlen 1 P. (c) Ausgabe mit Erklärung 1 P, Unterschied `int` und `float` 1 P.

Lösung zu Aufgabe 2 Tabellen und Akkumulator im Schreibtischtest

(a) `MELDUNGEN[1:5]` enthält die Indizes $1, 2, 3, 4$, also S-002 bis S-005. Der Start ist dabei, das Ende nicht, die Länge ist $5 - 1 = \boxed{4}$. S-001 (Index 0) und S-006 (Index 5) fehlen.

(b) Zustand am Ende jedes Durchlaufs:

Durchlauf	`m["id"]`	`k`	`je_maschine`	`laengste`	`laengste_id`
1	`'S-002'`	`'M-01'`	`{'M-01': 20}`	20	`'S-002'`
2	`'S-003'`	`'M-06'`	`{'M-01': 20, 'M-06': 35}`	35	`'S-003'`
3	`'S-004'`	`'M-05'`	`{..., 'M-05': 240}`	240	`'S-004'`
4	`'S-005'`	`'M-03'`	`{..., 'M-05': 240, 'M-03': 60}`	240	`'S-004'`

In Durchlauf 4 ist $60 > 240$ falsch, `laengste` und `laengste_id` bleiben. Jede Maschine kommt im Ausschnitt nur einmal vor, deshalb liefert `get` jedes Mal den Standardwert 0.

(c) Ausgabe: `4 60 S-004`. Vier Schlüssel, für M-03 nur die 60 Minuten aus S-005, denn S-001 mit 45 Minuten liegt nicht im Ausschnitt.

(d) `MELDUNGEN[5:5]` ist leer (Länge $5 - 5 = 0$), der Schleifenrumpf läuft nie. `print` wertet zuerst seine Argumente aus: `len` ergibt 0, `get` ergibt `None`, aber `laengste_id` wurde nie zugewiesen. Ergebnis: `NameError: name 'laengste_id' is not defined`, ohne jede Ausgabe. Lief die Originalzelle vorher, kennt die Laufzeit `laengste_id` noch mit dem alten Wert. Dann erscheint `0 None S-004`: kein Fehler, aber eine falsche Antwort. Robust wird die Zelle mit `laengste_id = None` vor der Schleife.

(e) Ausgabe: `4 90`. `kopie = m03` legt keine neue Liste an, sondern klebt ein zweites Etikett an dieselbe Liste. `append` verändert diese eine Liste, also sieht man die 90 auch über den Namen `m03`.

(f) $T_{\text{Stillstand}} = 115$ min, also

$$V_{\text{M-01}} = \frac{14\,400 - 115}{14\,400} = \frac{14\,285}{14\,400} \approx 0{,}99201 = \boxed{99{,}20\,\%}.$$

Das sind $99{,}20\,\% - 97{,}74\,\% = \boxed{1{,}46}$ Prozentpunkte mehr als bei M-03. Wer mit den gerundeten Werten 99,2 % und 97,7 % aus der Lerneinheit rechnet und 1,5 erhält, bekommt ebenfalls den Punkt.

> **Typischer Fehler**
>
> Den Ausschnitt `[1:5]` als „Meldung 1 bis 5“ lesen und mit S-001 beginnen. Dann stünden für M-03 105 Minuten im Dictionary. Der Index ist der Abstand vom Listenanfang, und das Ende des Ausschnitts gehört nicht dazu.

Bewertung: (a) 1 P. (b) je Durchlauf ¾ P, ein Folgefehler aus (a) wird nur einmal abgezogen. (c) 1 P. (d) `NameError` mit Begründung 1 P, alter Wert und Abhilfe 1 P. (e) 1 P. (f) 1 P.

Lösung zu Aufgabe 3 Statistik von Hand: Spät- gegen Frühschicht

(a) $\sum_i x_i = 360$, $n = 9$, also $\bar{x} = 360/9 = \boxed{40}$ Minuten.

(b) Abweichungstabelle, die letzte Spalte brauchst du in (c):

Meldung	x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	x_i^2
S-002	20	−20	400	400
S-005	60	20	400	3600
S-006	25	−15	225	625
S-011	70	30	900	4900
S-012	30	−10	100	900
S-016	10	−30	900	100
S-020	25	−15	225	625
S-022	45	5	25	2025
S-024	75	35	1225	5625
Summe	360	0	4400	18 800

Die Abweichungen summieren sich zu 0, die Rechnung ist also stimmig. Quadratsumme 4400 min^2,

$$s^2 = \frac{4400}{9-1} = \boxed{550 \text{ min}^2}, \qquad s = \sqrt{550} \approx \boxed{23{,}45 \text{ min}}.$$

(c) Verschiebungssatz: $\sum_i x_i^2 - n\bar{x}^2 = 18\,800 - 9 \cdot 1600 = 18\,800 - 14\,400 = 4400$. Stimmt. Mit Nenner n: $\sqrt{4400/9} = \sqrt{488{,}9} \approx \boxed{22{,}11 \text{ min}}$. Der Faktor ist $\sqrt{(n-1)/n} = \sqrt{8/9} \approx 0{,}94$, die Formel mit n liefert also knapp 6 % weniger.

(d) Sortiert: 10, 20, 25, 25, **30**, 45, 60, 70, 75. Der Median ist der fünfte Wert, $\boxed{30}$ Minuten. Typische Störung: Der Median ist robust und vergleicht fair. Er liegt in der Frühschicht bei 45, in der Spätschicht bei 30 Minuten, typische Frühschicht-Störungen dauern also länger. Die Mittelwerte (66,7 gegen 40) übertreiben den Unterschied: Allein S-004 macht 240 der 600 Frühschicht-Minuten aus (40 %). Ohne diesen Ausfall sinkt der Mittelwert auf 45, der Median kaum (42,5). Hochrechnung: Hier ist der Mittelwert richtig, denn Mittelwert mal Anzahl ergibt genau die Summe: $66{,}7 \cdot 9 \approx 600$ Minuten. Mit dem Median kämen nur $45 \cdot 9 = 405$ Minuten heraus. Lange Ausfälle wie S-004 sind echter Stillstand und gehören in die Summe.

> **Typischer Fehler**
>
> Durch $n = 9$ statt durch $n - 1 = 8$ teilen (22,11 statt 23,45) oder die Wurzel vergessen und 550 als Standardabweichung angeben. 550 ist die Varianz, ihre Einheit ist Minuten zum Quadrat.

Bewertung: (a) 1 P. (b) Tabelle mit Kontrollsumme 1 P, s^2 1 P, s 1 P. (c) Verschiebungssatz 1 P, Wert mit Nenner n und Faktor 1 P. (d) Median und Vergleich mit Begründung 1 P, Hochrechnung mit Mittelwert 1 P.

Lösung zu Aufgabe 4 Tracebacks deuten

(a) Letzte Zeile: `ZeroDivisionError: division by zero`. Gescheitert ist Python in Zeile 2 in `mittelwert`, bei `sum(werte) / len(werte)`, weil `len(werte)` null ist. Aufrufkette in zeitlicher Reihenfolge: Zeile 8 der Zelle ruft `mittel_je_kategorie` auf, deren Zeile 6 ruft `mittelwert` auf, dort scheitert Zeile 2.

(b) In `werte` steht die leere Liste `[]`, denn `werte` ist dasselbe Objekt wie `dauern`. Der Filter in Zeile 5 findet keine Meldung, weil die Kategorie in den Daten `"elektrisch"` heißt und Textvergleiche Groß- und Kleinschreibung unterscheiden. Die eigentliche Ursache steht also in Zeile 8 (im Argument), nicht in Zeile 2, wo es kracht. Nachsehen: In `mittel_je_kategorie` vor dem `return` `print(dauern)` oder `print(len(dauern))` einfügen, das zeigt `[]` beziehungsweise `0`. Eine Änderung: in Zeile 8 `"elektrisch"` schreiben. Dann ist $\bar{x} = 460/6$, Ausgabe `76.66666666666667`, also $\boxed{76{,}67\ \text{min}}$.

(c) Keine gute Idee. Der Mittelwert einer leeren Liste ist nicht definiert. Mit 0 würde die Zelle behaupten, elektrische Störungen dauerten im Mittel 0 Minuten. Der Tippfehler bliebe unbemerkt, und die falsche Zahl landet still in einem Bericht oder später in der Antwort eines Agenten. Besser: Der Fehler darf auftreten, oder die Funktion prüft die leere Liste und meldet das deutlich. Auch eine Antwort, die das Verschleiern des Fehlers als Hauptproblem nennt, gibt den vollen Punkt.

(d) (i) Colab hat die Laufzeit nach der Pause getrennt, die Zelle mit den Daten ist in dieser Sitzung nicht gelaufen. Erster Schritt: *Laufzeit, Alle ausführen* oder die Datenzelle erneut ausführen.

(ii) Aus der CSV-Datei kommt `stillstand_min` als Text, etwa `"45"`, und Text lässt sich nicht mit der Zahl 30 vergleichen. Nachsehen mit `type(m["stillstand_min"])` zeigt `str`. Abhilfe: beim Einlesen umwandeln, `int(m["stillstand_min"])`.

> **Typischer Fehler**
> Die Stelle mit dem untersten Pfeil für die Ursache halten und dort reparieren, etwa mit einer Abfrage auf leere Listen. Der Traceback zeigt, wo Python scheitert. Die Ursache kann weiter oben in der Aufrufkette liegen, hier im Argument der Zelle.

Bewertung: (a) Fehlertyp und Zeile 1 P, Aufrufkette 1 P. (b) Inhalt `[]` mit Begründung 1 P, Ursache in Zeile 8 und Nachsehen 1 P, Reparatur mit Ergebnis 1 P. (c) 1 P. (d) je Fall 1 P.

Lösung zu Aufgabe 5 Warum durch $n-1$?

(a) Linearität des Erwartungswerts: $\mathbb{E}[\bar{X}] = \frac{1}{n}\sum_i \mathbb{E}[X_i] = \frac{1}{n}\cdot n\mu = \boxed{\mu}$. Für die Varianz gelten $\operatorname{Var}(aY) = a^2 \operatorname{Var}(Y)$ und, *weil die X_i unabhängig sind*, $\operatorname{Var}\left(\sum_i X_i\right) = \sum_i \operatorname{Var}(X_i)$:

$$\operatorname{Var}(\bar{X}) = \frac{1}{n^2}\operatorname{Var}\Big(\sum_{i=1}^{n} X_i\Big) = \frac{1}{n^2}\sum_{i=1}^{n}\operatorname{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \boxed{\frac{\sigma^2}{n}}.$$

(b) Erwartungswert der Zerlegung, wegen der Linearität summandenweise:

$$\underbrace{\sum_{i=1}^{n}\mathbb{E}\big[(X_i-\mu)^2\big]}_{=n\sigma^2} = \mathbb{E}\Big[\sum_{i=1}^{n}(X_i-\bar{X})^2\Big] + n\,\underbrace{\mathbb{E}\big[(\bar{X}-\mu)^2\big]}_{=\sigma^2/n}.$$

Links: $\mathbb{E}[(X_i-\mu)^2] = \operatorname{Var}(X_i) = \sigma^2$ nach Definition der Varianz, n Summanden. Rechts: Wegen $\mathbb{E}[\bar{X}] = \mu$ aus (a) ist $\mathbb{E}[(\bar{X}-\mu)^2] = \operatorname{Var}(\bar{X}) = \sigma^2/n$. Umstellen:

$$\mathbb{E}\Big[\sum_{i=1}^{n}(X_i-\bar{X})^2\Big] = n\sigma^2 - n\cdot\frac{\sigma^2}{n} = \boxed{(n-1)\,\sigma^2}, \qquad \text{also} \quad \mathbb{E}[s^2] = \frac{(n-1)\,\sigma^2}{n-1} = \sigma^2.$$

s^2 ist erwartungstreu. Der Term $n(\bar{X}-\mu)^2$ ist genau der Teil der Streuung, den das Stichprobenmittel „verschluckt“, weil es aus denselben Daten stammt. Im Mittel ist das ein σ^2, deshalb fehlt ein Summand.

(c) (i) $\mu = \frac{10+40}{2} = \boxed{25}$, $\sigma^2 = \frac{(10-25)^2+(40-25)^2}{2} = \frac{225+225}{2} = \boxed{225}$, also $\sigma = 15$.

(ii) Die vier Stichproben, jede mit Wahrscheinlichkeit $\frac{1}{4}$:

(x_1, x_2)	$\bar{x}$	Quadratsumme	s^2 (Nenner 1)	Nenner 2	s
$(10, 10)$	10	0	0	0	0
$(10, 40)$	25	450	450	225	21,21
$(40, 10)$	25	450	450	225	21,21
$(40, 40)$	40	0	0	0	0
Erwartungswert		225	$\boxed{225}$	$\boxed{112{,}5}$	$\boxed{10{,}61}$

Die Quadratsumme hat den Erwartungswert $225 = (2-1)\cdot\sigma^2$, genau wie in (b). s^2 trifft $\sigma^2 = 225$ im Mittel exakt. Der Schätzer mit Nenner n liefert nur $112{,}5 = \frac{n-1}{n}\sigma^2 = \frac{1}{2}\sigma^2$.

(iii) Nein: $\mathbb{E}[s] = \frac{2\cdot 21{,}21}{4} \approx 10{,}61 < \sigma = 15$. Der Mittelwert der Wurzeln ist nicht die Wurzel des Mittelwerts. Erwartungstreu ist s^2, nicht s, und bei kleinen Stichproben ist die Verzerrung von s deutlich.

Typischer Fehler

In (b) $\mathbb{E}[(\bar{X}-\mu)^2] = \sigma^2$ setzen, als wäre $\bar{X}$ eine einzelne Beobachtung. Dann käme $(n-n)\sigma^2 = 0$ heraus. Der Mittelwert schwankt weniger, seine Varianz ist σ^2/n.

Bewertung: (a) $\mathbb{E}[\bar{X}]$ ½ P, $\mathrm{Var}(\bar{X})$ mit markierter Unabhängigkeit 1½ P. (b) linke Seite 1 P, rechte Seite mit Bezug auf (a) 1 P, Ergebnis und Folgerung für s^2 1 P. (c) (i) ½ P, (ii) Tabelle und Vergleich 2 P, (iii) ½ P.

Lösung zu Aufgabe 6 Mittelwert und Median als Optimierer (Zusatz)

(a) $f'(c) = -2\sum_i (x_i - c) = -2(\sum_i x_i - nc) = 0 \iff c = \frac{1}{n}\sum_i x_i = \bar{x}$. Wegen $f''(c) = 2n > 0$ ist das ein Minimum. Die Zerlegung aus Aufgabe 5 gilt für jeden Bezugswert c statt μ: $f(30) = \sum_i (x_i - \bar{x})^2 + n(\bar{x} - 30)^2 = 4400 + 9\cdot 100 = \boxed{5300}$.

(b) Abstände zu 30: 10, 30, 5, 40, 0, 20, 5, 15 und 45, Summe $g(30) = \boxed{170}$. Abstände zu 40: 20, 20, 15, 30, 10, 30, 15, 5 und 35, Summe $g(40) = \boxed{180}$. Beim Median 30 liegen vier Werte darunter, vier darüber, und einer ist gleich 30. Verschiebst du c um 1 nach oben, wachsen fünf Abstände um 1 und vier schrumpfen um 1, g steigt um 1. Nach unten ist es genauso. Der Median minimiert also die Summe der Beträge, der Mittelwert die Summe der Quadrate.

(c) Mittelwert: $(360 - 75 + 750)/9 = \boxed{115}$ Minuten statt 40. Median: weiterhin $\boxed{30}$, denn 750 liegt wie 75 oberhalb der Mitte. Ein einzelner Erfassungsfehler verschiebt den Mittelwert beliebig weit, den Median nicht. Für eine „typische“ Dauer bei möglichen Ausreißern oder Tippfehlern ist der Median die robustere Wahl. Dieselbe Idee kehrt in Modul 3 wieder: Welche Größe ein Modell lernt, hängt davon ab, welchen Fehler es minimiert.