Tutoriumsblatt 3

ML-Intuition: Lernen heißt Optimieren

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- die MSE und ihren Gradienten für eine Gerade von Hand auswerten und mit den Normalgleichungen vergleichen,
- die Konvergenzbedingung $0 < \eta < 2/\lambda_{\max}$ herleiten und Verlustkurven damit deuten,
- Sigmoid, Softmax und Cross-Entropy berechnen und mit dem Gradienten $p - y$ arbeiten,
- Backpropagation in einem kleinen Netz vollständig von Hand durchführen,
- Overfitting in einem Trainingsprotokoll erkennen und die Wirkung von Weight Decay berechnen.

So arbeitest du mit dem Blatt

Bearbeite die Aufgaben der Reihe nach. Aufgabe 2 nutzt die Daten aus Aufgabe 1, Aufgabe 4 den Gradienten $p - y$ aus Aufgabe 3. Hilfsmittel: Taschenrechner und das Formelblatt der Lerneinheiten. Rechne Zwischenergebnisse mit vier, Endergebnisse mit drei Nachkommastellen. log ist immer der natürliche Logarithmus. Wo „Zur Kontrolle“ steht, kannst du mit dem angegebenen Wert weiterrechnen, falls du hängst. Alle Messwerte und Protokolle sind fiktive Beispieldaten. Bezug zum Notebook: Aufgabe 1 liefert die Theorie zu TODO 1 bis 4, Aufgabe 2 zu Abschnitt A4, Aufgabe 3 zu TODO 6, Aufgabe 4 zu TODO 5 und 8, Aufgabe 5 zu Abschnitt C4 und den Bonusaufgaben.

Aufgabe 1 Lineare Regression von Hand

8 Punkte · etwa 17 Min.

Bezug: Modul 3, Lerneinheiten 1 bis 3 (Modell und Loss, Ableitung und Gradient, Normalgleichungen)

An der Teilewaschanlage M-08 der Nordwerk GmbH notiert die Instandhaltung je Stunde die Zahl der gewaschenen Körbe x und den Energieverbrauch y in kWh:

Körbe x_i	0	1	2	3
Energie y_i in kWh	1	3	4	6

Modell: $\hat{y} = wx + b$ mit $\theta = (w, b)$, Residuen $r_i = y_i - (wx_i + b)$, Loss $L(w, b) = \frac{1}{n}\sum_{i=1}^{n} r_i^2$. Du startest bei $\theta_0 = (w_0; b_0) = (1; 1)$.

(a) Berechne die Vorhersagen, die Residuen und die MSE $L(1, 1)$. [2 P]

(b) Berechne $\partial L/\partial w$ und $\partial L/\partial b$ an der Stelle θ_0 mit den Formeln aus Lerneinheit 2. Was sagen dir die Vorzeichen über die Lage der Geraden? [2 P]

(c) Führe einen Gradientenschritt mit $\eta = 0{,}1$ aus und berechne den neuen Loss $L(w_1, b_1)$. Zur Kontrolle: $\nabla L(\theta_0) = (-4{,}5;\ -2)$. [2 P]

(d) Stelle die Normalgleichungen $X^\top X\,\theta = X^\top y$ mit der Designmatrix $X = [x\ \ \mathbf{1}]$ auf, löse sie und berechne L^*. Vergleiche dann die Richtung von $-\nabla L(\theta_0)$ mit $\theta^* - \theta_0$. Zeigt der negative Gradient zum Minimum? Was fällt dir an b_1 aus (c) auf? [2 P]

Aufgabe 2 Lernrate und Konvergenz

9 Punkte · etwa 19 Min.

Bezug: Modul 3, Lerneinheit 3 (Gradientenabstieg und Lernrate)

Für die MSE der linearen Regression gilt $L(\theta) = \frac{1}{n}\|y - X\theta\|^2$ und $\nabla L(\theta) = -\frac{2}{n}X^\top(y - X\theta)$. Das Minimum θ^* erfüllt die Normalgleichungen $X^\top X\,\theta^* = X^\top y$. Gradientenabstieg rechnet $\theta_{k+1} = \theta_k - \eta\,\nabla L(\theta_k)$. Den Abstand zum Minimum nennst du $e_k = \theta_k - \theta^*$.

(a) Zeige $\nabla L(\theta) = H\,(\theta - \theta^*)$ mit $H = \frac{2}{n}X^\top X$ und folgere daraus $e_{k+1} = (I - \eta H)\,e_k$. [2 P]

(b) Sei v ein Eigenvektor von H zum Eigenwert $\lambda > 0$ und $e_k = c_k\,v$ mit einer Zahl c_k. Zeige $e_{k+1} = (1 - \eta\lambda)\,c_k\,v$. Für welche η schrumpft der Fehler in Richtung v? Begründe damit die Bedingung $0 < \eta < 2/\lambda_{\max}$. [2 P]

(c) Für die Daten aus Aufgabe 1 ist $H = \left(\begin{smallmatrix} 7 & 3 \\ 3 & 2 \end{smallmatrix}\right)$. Berechne beide Eigenwerte und die größte Lernrate, für die Gradientenabstieg noch konvergiert. Mit welchem Faktor wird der Fehler in den beiden Eigenrichtungen pro Schritt multipliziert, wenn du wie in Aufgabe 1 mit $\eta = 0{,}1$ rechnest? [2 P]

(d) Drei Läufe auf denselben Daten starten bei $\theta_0 = (1;\,1)$, mit den Lernraten 0,02, 0,2 und 0,25 in unbekannter Reihenfolge. Die Tabelle zeigt den Loss $L(\theta_k)$; das Minimum ist $L^* = 0{,}05$.

Schritt k	0	1	2	5	10	20	50
Lauf A	1,5	0,7250	0,3650	0,0832	0,0513	0,0501	0,0500
Lauf B	1,5	1,0557	0,7483	0,2860	0,0926	0,0559	0,0524
Lauf C	1,5	1,8047	2,1753	3,8356	9,980	68,42	22 325

Zur Kontrolle: $\lambda_{\max} \approx 8{,}405$ und $\lambda_{\min} \approx 0{,}595$.

(i) Ordne die Läufe den Lernraten zu und begründe mit den Faktoren $1 - \eta\lambda$ aus (b) und (c).

(ii) Der Loss ist quadratisch im Fehler. Wächst der Fehler pro Schritt mit dem Faktor q, wächst der Loss auf Dauer ungefähr mit q^2. Prüfe das für Lauf C mit den Werten bei $k = 20$ und $k = 50$.

(iii) Lauf B liegt nach 50 Schritten immer noch über L^*. Erkläre das mit dem Faktor in der flachen Richtung. [3 P]

Aufgabe 3 Sigmoid, Softmax und Cross-Entropy

8 Punkte · etwa 17 Min.

Bezug: Modul 3, Lerneinheiten 4 und 5 (Logistische Regression und Sigmoid, Softmax und Cross-Entropy)

Ein logistisches Modell schätzt, ob die Spindel der CNC-Drehmaschine M-03 in der nächsten Schicht ausfällt ($y = 1$) oder nicht ($y = 0$). Die Eingabe x ist die standardisierte Vibration. Es gilt $z = wx + b$, $p = \sigma(z) = \frac{1}{1+e^{-z}}$ und $\ell = -\big[\,y\log p + (1-y)\log(1-p)\,\big]$ mit $w = 3$ und $b = -1$.

(a) In einer Schicht mit $x = 1$ fiel die Spindel nicht aus. Berechne z, p, ℓ sowie $\partial\ell/\partial w$ und $\partial\ell/\partial b$. In welche Richtung ändern sich w und b bei einem Gradientenschritt, und warum ist das hier sinnvoll? [2 P]

(b) Zeige $\sigma(-z) = 1 - \sigma(z)$. Folgere, dass für $y = 0$ gilt $\ell = \log\left(1 + e^{z}\right)$, und prüfe die Formel an (a). Wie wächst ℓ für großes z, also bei einem Modell, das sicher, aber falsch liegt? [2 P]

(c) Ein zweites Modell ordnet Störungen den Klassen mechanisch, elektrisch und Kühlung zu. Für eine Meldung liefert es die Logits $z = (\log 6;\ \log 3;\ 0) \approx (1{,}792;\ 1{,}099;\ 0)$. Berechne die Softmax ohne Taschenrechner. Wie groß ist die Cross-Entropy, wenn die Störung elektrisch war? Wie groß wäre sie, wenn sie mechanisch gewesen wäre? [2 P]

(d) Berechne für (c) mit der richtigen Klasse elektrisch den Gradienten $\partial \ell / \partial z_k = p_k - \mathbf{1}[k = y]$. Welche Logits steigen bei einem Schritt gegen den Gradienten, welche sinken? Zeige allgemein, dass sich die Komponenten des Gradienten zu null summieren, und erkläre, warum das zur Verschiebungsinvarianz der Softmax passt. [2 P]

Aufgabe 4 Backpropagation in einem Mini-Netz

9 Punkte · etwa 20 Min.

Bezug: Modul 3, Lerneinheit 6 (Neuronales Netz und Backpropagation)

Ein Mini-Netz schätzt aus zwei standardisierten Sensorwerten $x = (x_1;\ x_2)^{\top}$ die Ausfallwahrscheinlichkeit einer Maschine. Es hat zwei versteckte ReLU-Neuronen und eine Sigmoid-Ausgabe mit binärer Cross-Entropy:

$$a = W_1 x + b_1, \qquad h = \mathrm{ReLU}(a), \qquad z = W_2 h + b_2, \qquad p = \sigma(z),$$
$$\ell = -\big[\, y \log p + (1 - y) \log(1 - p) \,\big].$$

Die Parameter sind (W_2 ist eine Zeile)

$$W_1 = \begin{pmatrix} 1 & -1 \\ 0{,}5 & 0{,}5 \end{pmatrix}, \qquad b_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \qquad W_2 = (2;\ 1), \qquad b_2 = -1{,}5.$$

Das Trainingsbeispiel ist $x = (1;\ 2)^{\top}$ mit $y = 1$.

(a) Wie viele Parameter hat das Netz? Rechne vorwärts: a, h, z, p und ℓ. [2 P]

(b) Rückwärts durch die Ausgabeschicht: Begründe $\partial \ell / \partial z = p - y$ und berechne $\partial \ell / \partial W_2$ und $\partial \ell / \partial b_2$. Zur Kontrolle: $\ell = \log 2 \approx 0{,}693$. [2 P]

(c) Rückwärts durch die versteckte Schicht: Berechne $\partial \ell / \partial h$, $\partial \ell / \partial a$, $\partial \ell / \partial W_1 = \frac{\partial \ell}{\partial a}\, x^{\top}$ (eine 2×2-Matrix) und $\partial \ell / \partial b_1$. Prüfe, dass jeder Gradient dieselbe Form wie sein Parameter hat. Zur Kontrolle: $\partial \ell / \partial h = (-1;\ -0{,}5)^{\top}$. [3 P]

(d) Führe für alle neun Parameter einen Gradientenschritt mit $\eta = 0{,}1$ aus und rechne erneut vorwärts. Wie groß sind p und ℓ jetzt? [1 P]

(e) Mehrere Einträge der Gradienten aus (b) und (c) sind null. Welche, und warum? Was passiert, wenn das für alle Trainingsbeispiele gilt? [1 P]

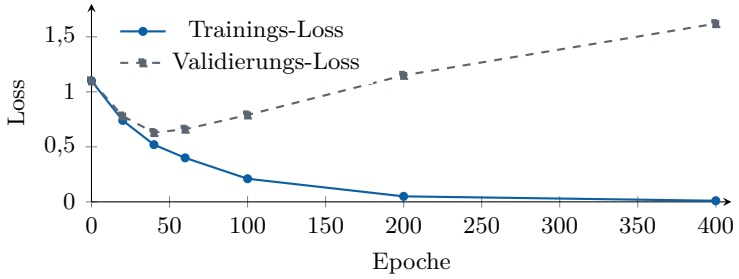
Aufgabe 5 Overfitting deuten

6 Punkte · etwa 14 Min.

Bezug: Modul 3, Lerneinheit 7 (Overfitting und Generalisierung)

Ein Netz ordnet Störungen den Klassen mechanisch, elektrisch und Kühlung zu. Es trainiert auf 45 Fällen und wird auf 15 Validierungsfällen geprüft. So sieht sein (fiktives) Trainingsprotokoll aus:

Epoche	0	20	40	60	100	200	400
Trainings-Loss	1,10	0,74	0,52	0,40	0,21	0,05	0,01
Validierungs-Loss	1,10	0,78	0,63	0,66	0,79	1,15	1,62
Trainingsgenauigkeit in %	33	64	78	87	96	100	100
Validierungsgenauigkeit in %	33	67	80	80	73	73	67



(a) Ab wann lernt das Netz auswendig? Nenne zwei Belege aus dem Protokoll. Bei welcher der protokollierten Epochen würdest du mit Early Stopping die Parameter behalten, und wie viele der 15 Validierungsfälle sind dort richtig eingeordnet? [2 P]

(b) Zwischen Epoche 40 und 400 steigt der Validierungs-Loss auf mehr als das Doppelte, die Validierungsgenauigkeit sinkt dagegen nur um zwei der 15 Fälle. Rechne an zwei Validierungsfällen nach, wie das zusammenpasst. Das Netz gibt die Wahrscheinlichkeiten (mechanisch; elektrisch; Kühlung) aus:

Fall	richtige Klasse	Epoche 40	Epoche 400
1	Kühlung	(0,45; 0,15; 0,40)	(0,90; 0,02; 0,08)
2	mechanisch	(0,60; 0,25; 0,15)	(0,97; 0,02; 0,01)

Berechne für beide Zeitpunkte die Cross-Entropy beider Fälle, ihren Mittelwert und die Genauigkeit auf diesen zwei Fällen. Deute das Ergebnis. [2 P]

(c) Weight Decay ergänzt den Gradienten um $\lambda\theta$ (hier ist $\lambda > 0$ die Stärke der Regularisierung, kein Eigenwert wie in Aufgabe 2). Zeige, dass ein Gradientenschritt dann $\theta_{k+1} = (1 - \eta\lambda)\,\theta_k - \eta\,\nabla L(\theta_k)$ lautet. Ein Gewicht hat den Wert 2, und sein Datengradient ist in allen Schritten null, weil es auf den Trainingsdaten nichts verbessert. Wie groß ist es nach einem und nach 100 Schritten mit $\eta = 0{,}1$ und $\lambda = 0{,}05$? Warum hilft dieser Effekt gegen Overfitting? [2 P]

Aufgabe 6 (⋆) Merkmale zentrieren

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 3, Lerneinheit 3 (Konditionierung und Standardisierung)

Du verschiebst in Aufgabe 1 die Eingabe um ihren Mittelwert: $x' = x - \bar{x}$ und $\hat{y} = w\,x' + b'$.

(a) Zeige, dass jede Gerade $wx + b$ auch als $wx' + b'$ mit $b' = b + w\bar{x}$ geschrieben werden kann. Welcher Startwert θ_0' entspricht $\theta_0 = (1;\,1)$?

(b) Berechne $H' = \frac{2}{n} X'^{\top} X'$ mit $X' = [x' \;\; \mathbf{1}]$, die Eigenwerte, die größte zulässige Lernrate und die Konditionszahl $\lambda_{\max}/\lambda_{\min}$. Vergleiche mit Aufgabe 2.

(c) Führe ab θ_0' einen Gradientenschritt mit $\eta = 0{,}4$ aus. Was fällt dir an w_1 auf? Erkläre es mit den Faktoren $1 - \eta\lambda$.

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Lineare Regression von Hand

(a) Mit $w_0 = b_0 = 1$ ist $\hat{y}_i = x_i + 1$:

x_i	y_i	$\hat{y}_i$	r_i	r_i^2	$r_i x_i$
0	1	1	0	0	0
1	3	2	1	1	1
2	4	3	1	1	2
3	6	4	2	4	6
		Summe	4	6	9

$$L(1,1) = \tfrac{1}{4} \cdot 6 = \boxed{1{,}5}.$$

(b) Aus der Tabelle: $\sum_i r_i = 4$ und $\sum_i r_i x_i = 9$. Mit $n = 4$:

$$\frac{\partial L}{\partial w} = -\frac{2}{n}\sum_i r_i x_i = -\frac{2}{4} \cdot 9 = \boxed{-4{,}5}, \qquad \frac{\partial L}{\partial b} = -\frac{2}{n}\sum_i r_i = -\frac{2}{4} \cdot 4 = \boxed{-2}.$$

Beide Komponenten sind negativ: Der Loss sinkt, wenn du w und b vergrößerst. Das passt zum Bild, denn alle Residuen sind ≥ 0, die Gerade liegt also nirgends über den Punkten. Die Ableitung nach w ist betragsmäßig größer, weil die großen Residuen bei großen x_i liegen.

(c) Schritt gegen den Gradienten:

$$w_1 = 1 - 0{,}1 \cdot (-4{,}5) = 1{,}45, \qquad b_1 = 1 - 0{,}1 \cdot (-2) = 1{,}2.$$

Neue Vorhersagen $\hat{y}_i = 1{,}45\,x_i + 1{,}2$: (1,2; 2,65; 4,1; 5,55). Residuen (−0,2; 0,35; −0,1; 0,45), Quadrate (0,04; 0,1225; 0,01; 0,2025) mit Summe 0,375. Also

$$L(1{,}45;\ 1{,}2) = \tfrac{0{,}375}{4} = \boxed{0{,}094} \quad \text{(genau 0,09375)}.$$

Ein einziger Schritt senkt den Loss von 1,5 auf ein Sechzehntel.

(d) Mit $\sum x_i^2 = 14$, $\sum x_i = 6$, $n = 4$, $\sum x_i y_i = 0 + 3 + 8 + 18 = 29$ und $\sum y_i = 14$:

$$X^\top X = \begin{pmatrix} 14 & 6 \\ 6 & 4 \end{pmatrix}, \qquad X^\top y = \begin{pmatrix} 29 \\ 14 \end{pmatrix}, \qquad \begin{aligned} 14w + 6b &= 29 \\ 6w + 4b &= 14. \end{aligned}$$

Determinante $14 \cdot 4 - 6 \cdot 6 = 20$. Mit der Cramerschen Regel (oder Einsetzen):

$$w^* = \frac{29 \cdot 4 - 6 \cdot 14}{20} = \frac{32}{20} = \boxed{1{,}6}, \qquad b^* = \frac{14 \cdot 14 - 6 \cdot 29}{20} = \frac{22}{20} = \boxed{1{,}1}.$$

Residuen am Optimum (−0,1; 0,3; −0,3; 0,1), also $L^* = \frac{0{,}01+0{,}09+0{,}09+0{,}01}{4} = \boxed{0{,}05}$.

Richtungsvergleich: $-\nabla L(\theta_0) = (4{,}5;\ 2)$, aber $\theta^* - \theta_0 = (0{,}6;\ 0{,}1)$. Die Verhältnisse b zu w sind $2/4{,}5 \approx 0{,}44$ und $0{,}1/0{,}6 \approx 0{,}17$, die Vektoren sind also nicht parallel (Winkel etwa 14,5°). Der negative Gradient zeigt nur die lokal steilste Abstiegsrichtung, nicht zum Minimum. Man sieht es an $b_1 = 1{,}2$: Der Schritt schießt über $b^* = 1{,}1$ hinaus.

Typischer Fehler

Das Minuszeichen der inneren Ableitung $\partial r_i/\partial w = -x_i$ fehlt. Dann sind beide Komponenten positiv, und der Schritt verkleinert w und b: Der Loss steigt. Ebenfalls häufig: durch n zu teilen vergessen, das liefert -18 und -8.

Bewertung: (a) Vorhersagen und Residuen 1 P, MSE 1 P. (b) je Ableitung ½ P, Deutung der Vorzeichen 1 P. (c) neue Parameter 1 P, neuer Loss 1 P. (d) Lösung der Normalgleichungen mit L^* 1 P, Richtungsvergleich mit Begründung 1 P. Folgefehler werden nicht doppelt abgezogen.

Lösung zu Aufgabe 2 Lernrate und Konvergenz

(a) Ausmultiplizieren und die Normalgleichungen $X^\top y = X^\top X\,\theta^*$ einsetzen:

$$\nabla L(\theta) = \frac{2}{n}(X^\top X\,\theta - X^\top y) = \frac{2}{n}(X^\top X\,\theta - X^\top X\,\theta^*) = \frac{2}{n}X^\top X\,(\theta - \theta^*) = H\,(\theta - \theta^*).$$

In die Update-Regel einsetzen und auf beiden Seiten θ^* abziehen:

$$\theta_{k+1} - \theta^* = \theta_k - \theta^* - \eta H(\theta_k - \theta^*) \quad\Longrightarrow\quad \boxed{e_{k+1} = (I - \eta H)\,e_k}.$$

(b) Mit $Hv = \lambda v$ gilt

$$e_{k+1} = (I - \eta H)\,c_k v = c_k\,(v - \eta\lambda v) = (1 - \eta\lambda)\,c_k\,v.$$

Also $c_k = (1-\eta\lambda)^k c_0$. Das geht genau dann gegen null, wenn $|1 - \eta\lambda| < 1$ ist, also $-1 < 1 - \eta\lambda < 1$, also $\boxed{0 < \eta < 2/\lambda}$. H ist symmetrisch, seine Eigenvektoren bilden eine Basis. Jeder Startfehler zerfällt in Anteile entlang dieser Eigenvektoren, und jeder Anteil entwickelt sich für sich mit seinem eigenen Faktor. Konvergenz braucht $\eta < 2/\lambda$ für alle Eigenwerte. Am knappsten ist das beim größten: $0 < \eta < 2/\lambda_{\max}$.

(c) Charakteristisches Polynom: $\lambda^2 - (\text{Spur})\,\lambda + \det = \lambda^2 - 9\lambda + 5 = 0$, denn $7 + 2 = 9$ und $14 - 9 = 5$.

$$\lambda_{1,2} = \frac{9 \pm \sqrt{81 - 20}}{2} = \frac{9 \pm \sqrt{61}}{2}: \qquad \boxed{\lambda_{\max} \approx 8{,}405}, \quad \boxed{\lambda_{\min} \approx 0{,}595}.$$

Kontrolle: Summe 9 (Spur), Produkt 5 (Determinante). Größte zulässige Lernrate: $\eta < 2/8{,}405 \approx \boxed{0{,}238}$. Bei $\eta = 0{,}1$ sind die Faktoren $1 - 0{,}1 \cdot 8{,}405 \approx 0{,}159$ in der steilen und $1 - 0{,}1 \cdot 0{,}595 \approx 0{,}941$ in der flachen Richtung. Der steile Anteil ist nach zwei, drei Schritten praktisch verschwunden, der flache schrumpft nur um etwa 6 % pro Schritt. Das erklärt Aufgabe 1: Der erste Schritt bringt fast alles, der Rest bis $L^* = 0{,}05$ dauert lange.

(d) (i) Die Faktoren $1 - \eta\lambda$ sind:

η	steil ($\lambda_{\max}$)	flach ($\lambda_{\min}$)	Verhalten
0,02	0,832	0,988	konvergiert, aber sehr langsam: Lauf B
0,2	−0,681	0,881	konvergiert schnell, steiler Anteil pendelt: Lauf A
0,25	−1,101	0,851	$\lvert-1{,}101\rvert > 1$, divergiert: Lauf C

0,25 liegt knapp über der Grenze 0,238, deshalb steigt der Loss in Lauf C schon ab dem ersten Schritt.

(ii) In Lauf C ist $q = |1 - 0{,}25 \cdot 8{,}405| \approx 1{,}1013$, also $q^2 \approx 1{,}2128$ pro Schritt. Über 30 Schritte: $1{,}2128^{30} \approx 326$. Aus der Tabelle: $22325/68{,}42 \approx 326$. Das passt; der flache Anteil schrumpft und spielt keine Rolle mehr. (Mit dem gerundeten $q^2 \approx 1{,}213$ erhältst du 328; auch das gilt als Bestätigung, denn die Potenz verstärkt Rundungsfehler.)

(iii) In der flachen Richtung ist der Faktor $1 - 0{,}02 \cdot 0{,}595 \approx 0{,}988$: Der Fehler schrumpft nur um 1,2 % pro Schritt. Nach 50 Schritten ist noch $0{,}988^{50} \approx 0{,}55$ des anfänglichen flachen Fehleranteils übrig. Weil der Loss quadratisch im Fehler ist, bleibt vom zugehörigen Loss-Überschuss noch $0{,}55^2 \approx 0{,}30$, in der Tabelle $L - L^* \approx 0{,}0024$. Der steile Anteil ist dagegen längst verschwunden ($0{,}832^{50} \approx 10^{-4}$). Bis dieser Anteil zehnmal kleiner ist, braucht es etwa $\log 0{,}1 / \log 0{,}988 \approx 190$ Schritte.

Typischer Fehler

Die Bedingung mit dem kleinsten Eigenwert prüfen. $2/\lambda_{\min} \approx 3{,}4$ ist keine Grenze für Konvergenz, sondern nur für die flache Richtung. Ebenso falsch: die Eigenwerte von $X^\top X$ statt von $H = \frac{2}{n} X^\top X$ nehmen, das liefert 16,81 und 1,19 und eine halb so große Grenze.

Bewertung: (a) Umformung mit Normalgleichungen 1 P, Fehlerrekursion 1 P. (b) Rechnung e_{k+1} 1 P, Bedingung mit Begründung über $\lambda_{\max}$ 1 P. (c) Eigenwerte 1 P, Grenze und Faktoren 1 P. (d) je Teil (i) bis (iii) 1 P.

Lösung zu Aufgabe 3 Sigmoid, Softmax und Cross-Entropy

(a) $z = 3 \cdot 1 - 1 = 2$, $p = \frac{1}{1+e^{-2}} = \frac{1}{1{,}1353} \approx 0{,}881$. Mit $y = 0$ zählt nur der zweite Term:

$$\ell = -\log(1 - p) = -\log 0{,}1192 \approx \boxed{2{,}127}.$$

Gradient: $\partial\ell/\partial z = p - y \approx 0{,}881$, also $\partial\ell/\partial w = (p-y)\,x \approx \boxed{0{,}881}$ und $\partial\ell/\partial b = p - y \approx \boxed{0{,}881}$. Beide sind positiv, ein Schritt dagegen verkleinert w und b. Damit sinken z und p, und das Modell sagt für diese Schicht weniger Ausfall voraus. Genau richtig, denn es gab keinen.

(b) Erweitern mit e^{-z}:

$$\sigma(-z) = \frac{1}{1+e^{z}} = \frac{e^{-z}}{e^{-z}+1} = \frac{(1+e^{-z})-1}{1+e^{-z}} = 1 - \frac{1}{1+e^{-z}} = 1 - \sigma(z).$$

Für $y = 0$ folgt $\ell = -\log\big(1 - \sigma(z)\big) = -\log\sigma(-z) = \boxed{\log\left(1 + e^{z}\right)}$. Probe: $\log(1 + e^2) = \log 8{,}389 \approx 2{,}127$, wie in (a). Für großes z gilt $\log(1+e^z) = z + \log(1+e^{-z}) \approx z$, zum Beispiel 5,007 bei $z = 5$ und 10,00005 bei $z = 10$. Der Loss wächst also ohne Grenze und ungefähr linear mit der Zuversicht im Irrtum. Der Gradient $p - y$ geht dabei gegen 1 und verschwindet nicht.

(c) $e^z = (6;\ 3;\ 1)$, Summe 10:

$$p = \left(\tfrac{6}{10};\ \tfrac{3}{10};\ \tfrac{1}{10}\right) = \boxed{(0{,}6;\ 0{,}3;\ 0{,}1)}.$$

Richtige Klasse elektrisch: $\ell = -\log 0{,}3 \approx \boxed{1{,}204}$. Richtige Klasse mechanisch: $\ell = -\log 0{,}6 \approx \boxed{0{,}511}$. Der Loss ist für elektrisch mehr als doppelt so groß, weil das Modell dieser Klasse nur 30 % gibt.

(d) Mit $y =$ elektrisch ist $\mathbf{1}[k = y] = (0;\ 1;\ 0)$:

$$\frac{\partial \ell}{\partial z} = (0{,}6 - 0;\ 0{,}3 - 1;\ 0{,}1 - 0) = \boxed{(0{,}6;\ -0{,}7;\ 0{,}1)}.$$

Ein Schritt dagegen hebt das Logit für elektrisch um $0{,}7\,\eta$ an und senkt mechanisch um $0{,}6\,\eta$ und Kühlung um $0{,}1\,\eta$. Am stärksten sinkt die Klasse, die fälschlich die meiste Wahrscheinlichkeit bekommt. Allgemein: $\sum_k (p_k - \mathbf{1}[k = y]) = \sum_k p_k - 1 = 1 - 1 = 0$, weil sich die Softmax zu eins summiert und der Indikator genau einmal eins ist. Deutung: Die Summe der Komponenten ist das Skalarprodukt $\nabla_z \ell \cdot (1;\ 1;\ 1)$, also die Steigung von ℓ, wenn du alle Logits um dieselbe Konstante verschiebst. Weil die Softmax bei dieser Verschiebung unverändert bleibt, ändert sich auch ℓ nicht, und die Steigung in diese Richtung muss null sein.

Typischer Fehler

Mit dem Zehnerlogarithmus rechnen: $-\lg 0{,}3 \approx 0{,}523$ statt 1,204. In den Lerneinheiten ist log immer der natürliche Logarithmus. Ebenfalls häufig: in (a) $-\log p$ statt $-\log(1 - p)$ verwenden, obwohl $y = 0$ ist.

Bewertung: (a) z, p, ℓ 1 P, Gradient mit Deutung 1 P. (b) Beweis der Symmetrie 1 P, Folgerung, Probe und Verhalten für großes z 1 P. (c) Softmax 1 P, beide Cross-Entropy-Werte 1 P. (d) Gradient mit Richtungen 1 P, Summe null mit Begründung 1 P.

Lösung zu Aufgabe 4 Backpropagation in einem Mini-Netz

(a) Parameter: W_1 hat 4, b_1 hat 2, W_2 hat 2, b_2 hat 1, zusammen $\boxed{9}$. Vorwärts:

$$a = \begin{pmatrix} 1 \cdot 1 + (-1) \cdot 2 \\ 0{,}5 \cdot 1 + 0{,}5 \cdot 2 \end{pmatrix} = \begin{pmatrix} -1 \\ 1{,}5 \end{pmatrix}, \quad h = \begin{pmatrix} 0 \\ 1{,}5 \end{pmatrix}, \quad z = 2 \cdot 0 + 1 \cdot 1{,}5 - 1{,}5 = 0, \quad p = \sigma(0) = 0{,}5,$$

$$\ell = -\log 0{,}5 = \log 2 \approx \boxed{0{,}693}.$$

(b) Sigmoid-Ausgabe mit binärer Cross-Entropy ist genau die logistische Regression aus Lerneinheit 4 mit h als Eingabe. Dort gilt $\partial \ell / \partial z = p - y$, hier also $-0{,}5$. Weil $z = W_2 h + b_2$ linear in W_2 und b_2 ist:

$$\frac{\partial \ell}{\partial W_2} = (p - y)\, h^\top = -0{,}5 \cdot (0;\ 1{,}5) = \boxed{(0;\ -0{,}75)}, \qquad \frac{\partial \ell}{\partial b_2} = p - y = \boxed{-0{,}5}.$$

(c) Das Signal geht über W_2 zurück zu h, dann durch die ReLU-Maske zu a:

$$\frac{\partial \ell}{\partial h} = W_2^\top (p - y) = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \cdot (-0{,}5) = \begin{pmatrix} -1 \\ -0{,}5 \end{pmatrix},$$

$$\frac{\partial \ell}{\partial a} = \frac{\partial \ell}{\partial h} \odot \mathrm{ReLU}'(a) = \begin{pmatrix} -1 \\ -0{,}5 \end{pmatrix} \odot \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ -0{,}5 \end{pmatrix}.$$

$$\frac{\partial \ell}{\partial W_1} = \frac{\partial \ell}{\partial a}\, x^\top = \begin{pmatrix} 0 \\ -0{,}5 \end{pmatrix} (1 \ \ 2) = \boxed{\begin{pmatrix} 0 & 0 \\ -0{,}5 & -1 \end{pmatrix}}, \qquad \frac{\partial \ell}{\partial b_1} = \frac{\partial \ell}{\partial a} = \boxed{\begin{pmatrix} 0 \\ -0{,}5 \end{pmatrix}}.$$

Formen: W_1 und sein Gradient sind 2×2, b_1 und $\partial \ell / \partial b_1$ haben zwei Einträge, W_2 und $\partial \ell / \partial W_2$ sind Zeilen mit zwei Einträgen, b_2 und sein Gradient sind Zahlen. Alle neun Werte lassen sich mit dem zentralen Differenzenquotienten bestätigen.

(d) Neue Parameter (nur die von null verschiedenen Gradienten ändern etwas):

$$W_1 = \begin{pmatrix} 1 & -1 \\ 0{,}55 & 0{,}6 \end{pmatrix}, \quad b_1 = \begin{pmatrix} 0 \\ 0{,}05 \end{pmatrix}, \quad W_2 = (2;\ 1{,}075), \quad b_2 = -1{,}45.$$

Vorwärts: $a = (-1;\ 0{,}55 + 1{,}2 + 0{,}05) = (-1;\ 1{,}8)$, $h = (0;\ 1{,}8)$, $z = 1{,}075 \cdot 1{,}8 - 1{,}45 = 0{,}485$, $p = \sigma(0{,}485) \approx \boxed{0{,}619}$ und $\ell = -\log 0{,}619 \approx \boxed{0{,}480}$. Der Loss ist von 0,693 auf 0,480 gesunken.

(e) Null sind die erste Zeile von $\partial \ell / \partial W_1$, der erste Eintrag von $\partial \ell / \partial b_1$ und der erste Eintrag von $\partial \ell / \partial W_2$. Grund: Neuron 1 ist inaktiv ($a_1 = -1 < 0$). Seine ReLU-Ableitung ist null und blockiert das Signal zu W_1 und b_1. Außerdem ist $h_1 = 0$, deshalb bekommt das Gewicht W_2 von Neuron 1 zur Ausgabe den Gradienten $0 \cdot (p - y) = 0$. Ist Neuron 1 für alle Trainingsbeispiele inaktiv, ändern sich seine Eingangsgewichte, sein Bias und sein Ausgangsgewicht nie mehr: ein totes Neuron.

Typischer Fehler

Die ReLU-Maske vergessen und $\partial \ell / \partial a = \partial \ell / \partial h = (-1;\ -0{,}5)$ weiterreichen. Dann bekäme auch die erste Zeile von W_1 einen Gradienten, obwohl Neuron 1 nichts zur Ausgabe beiträgt. Ebenfalls häufig: $x\,(\partial \ell / \partial a)^\top$ statt $(\partial \ell / \partial a)\,x^\top$, das vertauscht Zeilen und Spalten.

Bewertung: (a) Parameterzahl ½ P, Vorwärtsrechnung bis ℓ 1½ P. (b) Begründung $p - y$ 1 P, beide Gradienten 1 P. (c) $\partial \ell / \partial h$ und $\partial \ell / \partial a$ 1 P, $\partial \ell / \partial W_1$ 1 P, $\partial \ell / \partial b_1$ mit Formprüfung 1 P. (d) Schritt und neuer Loss 1 P. (e) Begründung mit totem Neuron 1 P.

Lösung zu Aufgabe 5 Overfitting deuten

(a) Bis Epoche 40 sinken beide Loss-Werte. Danach steigt der Validierungs-Loss ($0{,}63 \to 0{,}66 \to \cdots \to 1{,}62$), während der Trainings-Loss weiter gegen null fällt ($0{,}52 \to 0{,}01$). Zweiter Beleg: Die Lücke in der Genauigkeit wächst von $78 - 80 = -2$ Prozentpunkten in Epoche 40 auf $100 - 67 = 33$ Prozentpunkte in Epoche 400. Ab etwa Epoche 40 bis 60 lernt das Netz also auswendig. Early Stopping behält die Parameter beim kleinsten Validierungs-Loss, also **Epoche 40**. Dort sind 80 % von 15, also $\boxed{12}$ Validierungsfälle richtig. Epoche 60 hat dieselbe Genauigkeit, aber schon einen höheren Validierungs-Loss.

(b) Cross-Entropy $-\log p_y$:

	Epoche 40		Epoche 400		
Fall	p_y	$-\log p_y$	p_y	$-\log p_y$	richtig?
1 (Kühlung)	0,40	0,916	0,08	2,526	nein, nein
2 (mechanisch)	0,60	0,511	0,97	0,030	ja, ja
Mittelwert		$\boxed{0{,}714}$		$\boxed{1{,}278}$	50 %; 50 %

Der mittlere Loss steigt um etwa 79 %, die Genauigkeit bleibt gleich. Das Netz wird bei beiden Fällen zuversichtlicher, auch bei Fall 1, den es falsch einordnet. Die Genauigkeit zählt nur richtig oder falsch, die Cross-Entropy bestraft die wachsende Zuversicht im Irrtum. Der Gewinn bei Fall 2 ($-0{,}48$) ist viel kleiner als der Verlust bei Fall 1 ($+1{,}61$).

(c) Mit $\nabla L_{\text{reg}} = \nabla L + \lambda\theta$:

$$\theta_{k+1} = \theta_k - \eta(\nabla L(\theta_k) + \lambda\theta_k) = \boxed{(1 - \eta\lambda)\,\theta_k - \eta\,\nabla L(\theta_k)}.$$

Mit $\nabla L = 0$ bleibt nur der Faktor $1 - 0{,}1 \cdot 0{,}05 = 0{,}995$: nach einem Schritt $2 \cdot 0{,}995 = \boxed{1{,}99}$, nach 100 Schritten $2 \cdot 0{,}995^{100} \approx 2 \cdot 0{,}606 \approx \boxed{1{,}212}$. Deutung: Gewichte, die auf den Trainingsdaten nichts bringen, schrumpfen in jedem Schritt in Richtung null. Groß bleibt ein Gewicht nur, wenn der Datengradient dagegenhält, im Gleichgewicht gilt $\nabla L = -\lambda\theta$. Das Netz kann so weniger Kapazität für das Auswendiglernen einzelner, verrauschter Trainingsfälle aufwenden.

Typischer Fehler

Den Zeitpunkt für Early Stopping am Trainings-Loss oder an der höchsten Trainingsgenauigkeit festmachen. Entscheidend ist die Validierung, denn der Trainings-Loss sinkt bei Overfitting immer weiter.

Bewertung: (a) zwei Belege 1 P, Epoche 40 mit 12 Fällen 1 P. (b) vier Cross-Entropy-Werte mit Mittelwerten 1 P, Genauigkeit und Deutung 1 P. (c) Umformung 1 P, Zahlenwerte und Deutung 1 P.

Lösung zu Aufgabe 6 Merkmale zentrieren (Zusatz)

(a) $wx + b = w(x' + \bar{x}) + b = wx' + (b + w\bar{x})$, also $b' = b + w\bar{x}$. Hier ist $\bar{x} = 1{,}5$, also $\theta_0' = (1;\ 1+1{,}5) = \boxed{(1;\ 2{,}5)}$. Es ist dieselbe Gerade, die Vorhersagen sind wieder $(1;\ 2;\ 3;\ 4)$.

(b) $x' = (-1{,}5;\ -0{,}5;\ 0{,}5;\ 1{,}5)$ mit $\sum x_i' = 0$ und $\sum x_i'^2 = 5$:

$$X'^{\top}X' = \begin{pmatrix} 5 & 0 \\ 0 & 4 \end{pmatrix}, \qquad H' = \frac{2}{4}\,X'^{\top}X' = \begin{pmatrix} 2{,}5 & 0 \\ 0 & 2 \end{pmatrix}.$$

H' ist diagonal, die Eigenwerte sind $\lambda_{\max} = 2{,}5$ und $\lambda_{\min} = 2$. Grenze $\eta < 2/2{,}5 = \boxed{0{,}8}$ statt 0,238, Konditionszahl $\boxed{1{,}25}$ statt etwa 14,1. Die Schale ist fast rund.

(c) Residuen $(0;\ 1;\ 1;\ 2)$ wie in Aufgabe 1, also $\partial L/\partial w = -\frac{2}{4}(0 - 0{,}5 + 0{,}5 + 3) = -1{,}5$ und $\partial L/\partial b' = -\frac{2}{4} \cdot 4 = -2$. Schritt mit $\eta = 0{,}4$:

$$w_1 = 1 + 0{,}4 \cdot 1{,}5 = \boxed{1{,}6} = w^*, \qquad b_1' = 2{,}5 + 0{,}4 \cdot 2 = 3{,}3 \quad (b'^* = 1{,}1 + 1{,}5 \cdot 1{,}6 = 3{,}5).$$

w ist nach einem Schritt exakt optimal. Weil H' diagonal ist, sind die Eigenrichtungen die Koordinatenachsen. In w-Richtung ist der Faktor $1 - 0{,}4 \cdot 2{,}5 = 0$, in b'-Richtung $1 - 0{,}4 \cdot 2 = 0{,}2$: Der Abstand $3{,}3 - 3{,}5 = -0{,}2$ schrumpft pro Schritt auf ein Fünftel. Der Loss ist nach einem Schritt $0{,}05 + 0{,}2^2 = 0{,}09$ und nach zwei Schritten 0,0516. Ohne Zentrieren stand er bei $\eta = 0{,}1$ nach zwei Schritten erst bei 0,0572 und kam danach kaum voran.