# Tutoriumsblatt 4

## Tokens und Embeddings

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

**Nach diesem Blatt kannst du**

- BPE von Hand ausführen und neue Wörter mit den gelernten Merges zerlegen,
- Tokenzahlen in Kosten und Platz im Kontextfenster umrechnen,
- die Embedding-Schicht als One-Hot mal Matrix deuten und ihren Gradienten herleiten,
- Kosinus-Ähnlichkeiten und eine semantische Suche von Hand berechnen,
- eine PCA in 2D rechnen: Kovarianzmatrix, Eigenvektor, erklärte Varianz.

**So arbeitest du mit dem Blatt**

Bearbeite die Aufgaben der Reihe nach, sie werden schwieriger. Aufgabe 3 nutzt den Tokenizer aus Aufgabe 1. Erlaubt sind Taschenrechner und Formelblatt des Moduls. Runde auf drei Nachkommastellen. Alle Zahlen sind ausgedacht und glatt gewählt. Das Notebook programmiert dieselben Ideen (BPE: TODO 2 und 3, Tokens zählen: TODO 1 und 4, One-Hot: TODO 5, Suche: TODO 6 und 7, PCA: TODO 8). Hier rechnest du nach, was dort NumPy erledigt.

### Aufgabe 1 Byte-Pair-Encoding von Hand

10 Punkte · etwa 22 Min.

Bezug: Modul 4, Lerneinheit 2 (Byte-Pair-Encoding Schritt für Schritt)

Ein Tokenizer für Wartungstexte wird auf einem Mini-Korpus trainiert: „sensor“ (6-mal), „sensoren“ (3-mal), „motor“ (8-mal) und „motoren“ (4-mal). BPE zählt benachbarte Paare, gewichtet mit der Worthäufigkeit, und verschmilzt das häufigste Paar. **Regel bei Gleichstand:** Es gewinnt das Paar, das zuerst vorkommt, wenn du die Wörter in der genannten Reihenfolge und jedes Wort von links nach rechts liest. So entscheidet auch `most_common` im Notebook.

(a) Gib den Startwortschatz an. Wie viele Symbole enthält das Korpus, gewichtet mit der Worthäufigkeit? [1 P]

(b) Zähle alle benachbarten Paare gewichtet und lege eine Tabelle an. Welches Paar wird im ersten Merge verschmolzen? Zur Kontrolle: Es gibt 9 verschiedene Paare. [3 P]

(c) Führe den ersten Merge aus, zähle neu und führe zwei weitere Merges aus. Notiere nach jedem Merge die Zerlegung der vier Wörter und die gewichtete Symbolzahl. Gib zum Schluss den Wortschatz an. [3 P]

(d) Zerlege die neuen Wörter „rotoren“ und „monitor“ mit den drei gelernten Merges. Was geht bei „monitor“ schief, und wie vermeidet GPT-2 dieses Problem? [2 P]

(e) Um wie viel sinkt die gewichtete Symbolzahl bei einem Merge? Begründe allgemein. Gilt deine Regel auch für das Paar „a a“ im Wort „aaa“? [1 P]

## Aufgabe 2 Tokenzahlen: Kontext und Kosten

7 Punkte · etwa 15 Min.

Bezug: Modul 4, Lerneinheit 3 (Tokenzahlen und ihre Folgen), dazu die Kostenformel aus Modul 2

Die Nordwerk GmbH lässt jede Störungsmeldung von einem Sprachmodell zusammenfassen. Eine typische Meldung hat auf Deutsch 360 Zeichen, ihre englische Übersetzung 320 Zeichen. Zwei Modelle A und B kommen in Frage. Für die Preise nimmst du die Referenzpreise aus Modul 2: A wie Claude Haiku 4.5, B wie Claude Sonnet 5.5 (Stand 04.10.2026). Die Tokenzahlen sind ausgedacht, aber typisch.

| | Modell A | Modell B |
|---|---|---|
| Tokens der englischen Übersetzung | 80 | 76 |
| Tokens der deutschen Meldung | 112 | 95 |
| Input-Tokens pro Aufruf (System-Prompt und Meldung) | 420 | 360 |
| Output-Tokens pro Aufruf (Zusammenfassung) | 60 | 52 |
| Preis pro Million Input- und Output-Tokens in US-Dollar | 1 und 5 | 2 und 10 |

(a) Wie viele Tokens liefert die Faustregel für die englische Übersetzung? Berechne für beide Modelle das Verhältnis der Tokenzahlen Deutsch zu Englisch und nenne zwei Gründe, warum es über 1 liegt. [2 P]

(b) Angenommen, beide Modelle haben ein Kontextfenster von 8192 Tokens. Für Anweisungen reservierst du 1000 Tokens, für die Antwort 500. Wie viele deutsche Meldungen passen mit dem Tokenizer von A in eine einzige Anfrage, wie viele mit dem von B? [1 P]

(c) Berechne die Kosten pro Aufruf in Cent und für 2000 Meldungen im Monat in US-Dollar. Welches Modell braucht weniger Tokens, welches ist billiger? Was folgt daraus für den Vergleich von Modellen? [2 P]

(d) Vereinfacht wächst die Arbeit der Attention quadratisch mit der Zahl der Tokens. Um welchen Faktor wächst sie bei Modell A für die deutsche Meldung gegenüber der englischen Übersetzung? [1 P]

(e) Jemand schlägt vor, Modell A einfach den Tokenizer von B zu geben, weil der Deutsch sparsamer zerlegt. Warum geht das nicht? [1 P]

## Aufgabe 3 Die Embedding-Matrix als Nachschlagetabelle

7 Punkte · etwa 15 Min.

Bezug: Modul 4, Lerneinheit 4 (Die Embedding-Matrix: von der ID zum Vektor)

Nimm den Mini-Tokenizer aus Aufgabe 1 nach drei Merges. Die sieben Buchstaben sind alphabetisch ab null nummeriert, die drei Merges folgen in ihrer Reihenfolge dahinter. Die Embedding-Matrix $E \in \mathbb{R}^{10\times 3}$ ist ausgedacht:

| ID | Token | Zeile $E_{i,:}$ | ID | Token | Zeile $E_{i,:}$ |
|---|---|---|---|---|---|
| 0 | e | (0,1; 0,4; −0,2) | 5 | s | (−0,4; 0,1; 0,2) |
| 1 | m | (0,3; −0,1; 0,5) | 6 | t | (0,2; 0,6; −0,1) |
| 2 | n | (−0,2; 0; 0,3) | 7 | or | (0,7; −0,2; 0) |
| 3 | o | (0,5; 0,2; 0,1) | 8 | en | (−0,1; 0,3; 0,6) |
| 4 | r | (0; −0,3; 0,4) | 9 | mo | (0,4; 0,5; −0,3) |

(a) Zerlege „motoren“ mit dem Mini-Tokenizer und gib die Token-IDs an. Stelle die One-Hot-Matrix $O \in \mathbb{R}^{4\times 10}$ auf (eine Zeile pro Token) und berechne $X = OE$. Wie viele Multiplikationen kostet $OE$, und bei wie vielen davon ist der Faktor aus $O$ ungleich null? [2 P]

(b) Wie viele Parameter hat $E$ hier? Ein größeres Modell hat $V = 100\,000$, $d = 4096$ und eine Ausgabeschicht ohne Bias mit ebenso vielen Einträgen wie $E$. Wie viele Parameter stecken in beiden zusammen, und wie viele kommen hinzu, wenn man den Wortschatz um 20 000 deutsche Subwords erweitert? [1 P]

(c) Die Lerneinheit skizziert, wie $E$ lernt. Führe es aus: Für ein Token $i$ sei $x = e_i^\top E \in \mathbb{R}^{1\times d}$ und $L$ ein Loss, der nur über $x$ von $E$ abhängt, mit $g = \partial L/\partial x$. Zeige mit der Kettenregel $\partial L/\partial E = e_i\, g$. Schreibe dazu $x_k = \sum_j (e_i)_j\, E_{jk}$. Welche Zeilen von $E$ bekommen einen Gradienten? [2 P]

(d) Im Text „sensoren“ kommen Tokens mehrfach vor, und die Gradienten aller Vorkommen addieren sich. An den beiden Positionen von s sei $g_1 = (0{,}1;\ -0{,}2;\ 0)$ und $g_3 = (0{,}3;\ 0{,}1;\ -0{,}1)$. Berechne die Zeile von s nach einem Schritt mit $\eta = 0{,}5$. Welche Zeilen ändern sich bei diesem Text nicht? Was folgt daraus für seltene Tokens? [2 P]

## Aufgabe 4 Kosinus-Ähnlichkeit und semantische Suche

7 Punkte · etwa 16 Min.

Bezug: Modul 4, Lerneinheit 5 (Ähnlichkeit und semantische Suche)

Eine Mini-Wissensbasis enthält drei Meldungen mit ausgedachten Embeddings ($d = 4$, noch nicht normiert):

| | Meldung | Embedding $m_j$ |
|---|---|---|
| M1 | Spindel läuft unrund, starke Vibrationen beim Fräsen | $(4;\ 2;\ 2;\ 1)$ |
| M2 | Kühlmittelpumpe undicht, Pfütze unter der Maschine | $(1;\ 2;\ 2;\ 4)$ |
| M3 | Lager der Hauptspindel macht laute Mahlgeräusche | $(6;\ 6;\ 3;\ 0)$ |

Die Suchanfrage lautet „Hauptspindel vibriert“. Das Satz-Embedding-Modell liefert für ihre drei Tokens die kontextuellen Vektoren $h_1 = (3;\ 0;\ 1;\ 0)$, $h_2 = (2;\ 2;\ 2;\ 0)$ und $h_3 = (1;\ 1;\ 3;\ 0)$.

(a) Berechne den Satzvektor $q$ der Anfrage per Mean Pooling. [1 P]

(b) Normiere $q$ und die drei Meldungen auf Länge 1. Berechne alle Scores auf einmal als $\hat{X}\hat{q}$ ($\hat{X}$: normierte Meldungen als Zeilen) und gib die zwei besten Treffer an. Zur Kontrolle: Alle vier Längen sind ganze Zahlen. [2 P]

(c) Jemand vergisst die Normierung und sortiert nach den Skalarprodukten $m_j \cdot q$. Welche Rangfolge kommt heraus? Erkläre den Unterschied. [1 P]

(d) Zeige für Einheitsvektoren $\|\hat{a} - \hat{b}\|^2 = 2 - 2\cos\theta$. Berechne damit die euklidischen Abstände von $\hat{q}$ zu den normierten Meldungen. Gibt es dieselbe Rangfolge wie beim Kosinus? [2 P]

(e) Ein Kollege prüft das Modell aus dem Notebook und findet diese Werte (ausgedacht, aber typisch): „Spindel läuft unrund“ und „Spindel läuft nicht unrund“ haben den Kosinus 0,93, „Störung an M-03“ und „Störung an M-05“ sogar 0,97. Was bedeutet das für eine Suche im Nordwerk, und was würdest du ergänzen? [1 P]

## Aufgabe 5 PCA von Hand

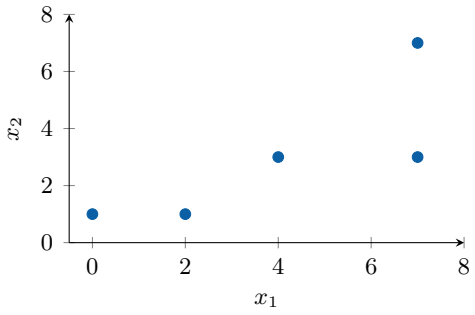
9 Punkte · etwa 20 Min.

Bezug: Modul 4, Lerneinheit 6 (PCA: Embeddings sichtbar machen)

Fünf ausgedachte Embeddings mit $d = 2$ sollen auf eine einzige Achse projiziert werden:

$$x^{(1)} = (0;\ 1), \quad x^{(2)} = (2;\ 1), \quad x^{(3)} = (4;\ 3),$$
$$x^{(4)} = (7;\ 3), \quad x^{(5)} = (7;\ 7).$$

Rechne mit $C = \frac{1}{n}\tilde{X}^\top \tilde{X}$ wie in der Lerneinheit, $\tilde{X}$ ist die zentrierte Datenmatrix mit einem Punkt pro Zeile.




(a) Berechne den Mittelwert $\bar{x}$ und die zentrierten Punkte. [1 P]

(b) Stelle die Kovarianzmatrix $C$ auf. Zur Kontrolle: $C_{12} = 4{,}8$. [2 P]

(c) Berechne die Eigenwerte von $C$ über $\det(C - \lambda I) = 0$ und einen normierten Eigenvektor $v_1$ zum größten Eigenwert, mit positiven Komponenten. [2 P]

(d) Projiziere die zentrierten Punkte auf $v_1$ und berechne die Varianz der fünf Projektionen. Vergleiche mit $\lambda_1$. Welchen Anteil der Gesamtvarianz zeigt diese eine Achse? [2 P]

(e) Die Lerneinheit sagt nur, dass der zweite Eigenvektor senkrecht auf dem ersten steht. Beweise es: Ist $C$ symmetrisch, $Cv_1 = \lambda_1 v_1$, $Cv_2 = \lambda_2 v_2$ und $\lambda_1 \neq \lambda_2$, dann gilt $v_1^\top v_2 = 0$. Berechne dazu $v_1^\top C\, v_2$ auf zwei Arten. Bestimme $v_2$ im Beispiel und prüfe die Aussage. [2 P]

## Aufgabe 6 (⋆) PCA ohne Eigenwertrechnung

Zusatz · etwa 10 Min.

Bezug: Modul 4, Lerneinheit 6 (Kurve: Varianz der Projektion je nach Richtung)

Die Lerneinheit zeigt die Varianz $v^\top C v$ für alle Richtungen $v = (\cos\varphi;\ \sin\varphi)$ als Kurve. Rechne das für die Matrix $C$ aus Aufgabe 5 exakt nach.

(a) Zeige: $v^\top C v = 6{,}2 + 1{,}4\cos 2\varphi + 4{,}8\sin 2\varphi$.

(b) Bestimme Maximum und Minimum dieser Funktion und die Winkel $\varphi \in [0°, 180°)$, an denen sie angenommen werden. Vergleiche mit Aufgabe 5.

# Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

## Lösung zu Aufgabe 1 Byte-Pair-Encoding von Hand

(a) Startwortschatz: {e, m, n, o, r, s, t}, also 7 Zeichen. Gewichtete Symbolzahl (Wortlänge mal Häufigkeit):

$$6 \cdot 6 + 3 \cdot 8 + 8 \cdot 5 + 4 \cdot 7 = 36 + 24 + 40 + 28 = \boxed{128}.$$

(b) Spalten 2 bis 5: wie oft das Paar im Wort steht. Letzte Spalte: Summe, gewichtet mit der Worthäufigkeit.

| Paar | sensor (6) | sensoren (3) | motor (8) | motoren (4) | Anzahl |
|---|---|---|---|---|---|
| s e | 1 | 1 | 0 | 0 | 9 |
| e n | 1 | 2 | 0 | 1 | $6 + 6 + 4 = 16$ |
| n s | 1 | 1 | 0 | 0 | 9 |
| s o | 1 | 1 | 0 | 0 | 9 |
| o r | 1 | 1 | 1 | 1 | $6 + 3 + 8 + 4 = \mathbf{21}$ |
| r e | 0 | 1 | 0 | 1 | 7 |
| m o | 0 | 0 | 1 | 1 | 12 |
| o t | 0 | 0 | 1 | 1 | 12 |
| t o | 0 | 0 | 1 | 1 | 12 |

Kontrolle: Die Anzahlen summieren sich zu $107 = 128 - 21$, denn ein Wort mit $\ell$ Zeichen hat $\ell - 1$ Paare und es gibt $6 + 3 + 8 + 4 = 21$ Wörter. Erster Merge: $\boxed{\text{o} + \text{r} \to \text{or}}$ mit 21 Vorkommen.

(c) Nach jedem Merge neu zählen:

| Schritt | Zerlegung (sensor, sensoren, motor, motoren) | Symbole |
|---|---|---|
| Merge 1: o r (21) | s e n s or \| s e n s or e n \| m o t or \| m o t or e n | $128 - 21 = 107$ |
| Merge 2: e n (16) | s en s or \| s en s or en \| m o t or \| m o t or en | $107 - 16 = 91$ |
| Merge 3: m o (12) | s en s or \| s en s or en \| mo t or \| mo t or en | $91 - 12 = 79$ |

Neuzählung nach Merge 1: e n 16, m o 12, o t 12, t or 12, s e 9, n s 9, s or 9, or e 7. Das Paar t o gibt es nicht mehr, dafür t or. Sieger ist e n.

Neuzählung nach Merge 2: m o 12, o t 12, t or 12, s en 9, en s 9, s or 9, or en 7. Gleichstand bei 12. In „sensor“ und „sensoren“ kommt keines der drei Paare vor, in „motor“ steht m o vorn. Also gewinnt m o.

Wortschatz: $\boxed{\text{e, m, n, o, r, s, t, or, en, mo}}$, also $7 + 3 = 10$ Tokens. Auch m bleibt im Wortschatz, obwohl es im Korpus gerade nicht mehr allein vorkommt.

(d) „rotoren“: r o t o r e n → r o t or e n → r o t or en, der Merge m o passt nirgends. Ergebnis: $\boxed{\text{r} \mid \text{o} \mid \text{t} \mid \text{or} \mid \text{en}}$, 5 Tokens. Obwohl „rotor“ wie „motor“ aussieht, gibt es keinen Merge für r o oder o t.

„monitor“: m o n i t o r → m o n i t or → (kein e n) → mo n i t or. Das Zeichen i kommt im Startwortschatz nicht vor und hat keine ID. Ein BPE auf Zeichen kann das Wort deshalb nicht vollständig darstellen. GPT-2 arbeitet auf Bytes: Der Startwortschatz enthält alle 256 Bytes, also hat jedes Zeichen eine Darstellung, notfalls als einzelne Bytes.

(e) Jedes Vorkommen des Paares macht aus zwei Symbolen eines. Die gewichtete Symbolzahl sinkt also genau um die gewichtete Anzahl des Paares: 128 → 107 → 91 → 79, Abnahme 21, 16, 12. Das gilt nur, wenn sich die Vorkommen nicht überlappen. In „aaa“ zählt „a a“ doppelt, aber das Verschmelzen von links ergibt „aa a“: nur ein Merge, die Symbolzahl sinkt um 1 statt um 2.

**Typischer Fehler**

Ungewichtet zählen: Dann kommt o r nur auf 4 statt 21. Ebenso häufig: In „sensoren“ steht e n zweimal, wer das übersieht, erhält 13 statt 16. Und wer nach einem Merge nicht neu zählt, verschmilzt womöglich ein Paar wie t o, das es gar nicht mehr gibt.

**Bewertung:** (a) 1 P. (b) 2 P für die Tabelle (je falscher Anzahl 1 P Abzug, höchstens 2), 1 P für den Merge. (c) je Merge 1 P, einschließlich Zerlegung und Symbolzahl; Folgefehler aus (b) werden nicht erneut abgezogen. (d) je Wort 1 P, bei „monitor“ nur mit Byte-Begründung. (e) 1 P, nur mit dem Überlappungsfall.

## Lösung zu Aufgabe 2 Tokenzahlen: Kontext und Kosten

(a) Faustregel: $320/4 = 80$ Tokens. Verhältnisse: A: $112/80 = \boxed{1{,}40}$, B: $95/76 = \boxed{1{,}25}$. Für die deutsche Meldung ergäbe die Faustregel $360/4 = 90$ Tokens, sie ist für Deutsch also zu optimistisch. Gründe: Viele Tokenizer wurden überwiegend auf englischem Text trainiert, und BPE belohnt Häufigkeit (Aufgabe 1). Deutsche Wortteile sind im Wortschatz deshalb seltener. Außerdem zerfallen lange Komposita wie „Kühlschmierstoff“ in mehrere Teile.

(b) Platz für Meldungen: $8192 - 1000 - 500 = 6692$ Tokens. A: $6692/112 = 59{,}75$, also $\boxed{59}$ Meldungen. B: $6692/95 \approx 70{,}44$, also $\boxed{70}$ Meldungen. Abrunden, denn eine angefangene Meldung passt nicht mehr hinein.

(c) Mit $K = (n_{\text{in}}\, p_{\text{in}} + n_{\text{out}}\, p_{\text{out}})/10^6$ in US-Dollar:

$$K_A = \frac{420 \cdot 1 + 60 \cdot 5}{10^6}\ \text{USD} = \frac{720}{10^6}\ \text{USD} = 0{,}072\ \text{Cent},$$
$$K_B = \frac{360 \cdot 2 + 52 \cdot 10}{10^6}\ \text{USD} = \frac{1240}{10^6}\ \text{USD} = 0{,}124\ \text{Cent}.$$

Für 2000 Meldungen: $\boxed{A : 1{,}44\ \text{USD}}$, $\boxed{B : 2{,}48\ \text{USD}}$. B braucht mit 412 statt 480 Tokens pro Aufruf etwa 14 % weniger, kostet aber etwa 72 % mehr. Folgerung: Tokenzahlen und Preise pro Token sind zwischen Modellen nicht direkt vergleichbar, weil jedes Modell mit seinem eigenen Tokenizer zählt. Vergleiche den Aufwand für die ganze Aufgabe, also Tokens mal Preis, und natürlich die Qualität.

(d) $1{,}4^2 = \boxed{1{,}96}$, also fast doppelt so viel Arbeit in der Attention. Die Teile, die linear mit der Länge wachsen (jedes Token durch alle Schichten), wachsen um den Faktor 1,4.

(e) Tokenizer und Modell gehören fest zusammen. Embedding-Matrix und Ausgabeschicht haben genau eine Zeile pro Token des Wortschatzes, und diese Zeilen wurden mit den IDs des eigenen Tokenizers trainiert. Mit den IDs von B würde A falsche Zeilen nachschlagen, und für Stücke, die A nicht kennt, gibt es keine gelernten Zeilen. Man müsste das Modell neu trainieren.

**Typischer Fehler**

Dollar und Cent verwechseln: $720/10^6$ ist ein Betrag in US-Dollar, in Cent muss man noch mit 100 multiplizieren. Bei der Faustregel mit 4 multiplizieren statt teilen. In (b) aufrunden.

**Bewertung:** (a) 1 P für beide Verhältnisse, 1 P für zwei Gründe. (b) 1 P, nur mit Abrunden. (c) 1 P für die Kosten, 1 P für die Folgerung. (d) 1 P. (e) 1 P.

## Lösung zu Aufgabe 3 Die Embedding-Matrix als Nachschlagetabelle

(a) „motoren“ → mo | t | or | en (wie in Aufgabe 1), IDs $\boxed{9,\ 6,\ 7,\ 8}$. Jede Zeile von $O$ hat eine Eins in der Spalte der ID (Spalten 0 bis 9):

$$O = \begin{pmatrix} 0&0&0&0&0&0&0&0&0&1\\ 0&0&0&0&0&0&1&0&0&0\\ 0&0&0&0&0&0&0&1&0&0\\ 0&0&0&0&0&0&0&0&1&0 \end{pmatrix}, \qquad X = OE = \begin{pmatrix} E_{9,:}\\ E_{6,:}\\ E_{7,:}\\ E_{8,:} \end{pmatrix} = \boxed{\begin{pmatrix} 0{,}4 & 0{,}5 & -0{,}3\\ 0{,}2 & 0{,}6 & -0{,}1\\ 0{,}7 & -0{,}2 & 0\\ -0{,}1 & 0{,}3 & 0{,}6 \end{pmatrix}}.$$

Zeile 1 von $X$ ist $\sum_j O_{1j} E_{j,:} = 0 \cdot E_{0,:} + \cdots + 1 \cdot E_{9,:} = E_{9,:}$. $OE$ kostet $4 \cdot 10 \cdot 3 = 120$ Multiplikationen, nur bei $4 \cdot 3 = 12$ davon ist der Faktor aus $O$ eine Eins (eine davon trifft auf die Null in der Zeile von or). Nachschlagen liefert dasselbe ohne Rechnung.

(b) Hier $Vd = 10 \cdot 3 = \boxed{30}$ Parameter. Großes Modell: $Vd = 100\,000 \cdot 4096 = 409\,600\,000$, mit Ausgabeschicht $\boxed{819\,200\,000}$, also rund 819 Millionen. Erweiterung: $2 \cdot 20\,000 \cdot 4096 = \boxed{163\,840\,000}$ zusätzliche Parameter, und die neuen Zeilen müssen erst trainiert werden. Dafür werden deutsche Folgen kürzer (Aufgabe 2).

(c) Es gilt $x_k = \sum_j (e_i)_j E_{jk} = E_{ik}$, also $\dfrac{\partial x_k}{\partial E_{jl}} = (e_i)_j\, \delta_{kl}$ ($\delta_{kl} = 1$ für $k = l$, sonst 0). Kettenregel:

$$\frac{\partial L}{\partial E_{jl}} = \sum_k \frac{\partial L}{\partial x_k} \frac{\partial x_k}{\partial E_{jl}} = \sum_k g_k\, (e_i)_j\, \delta_{kl} = (e_i)_j\, g_l \quad \Longrightarrow \quad \boxed{\frac{\partial L}{\partial E} = e_i\, g}.$$

Das ist ein äußeres Produkt aus der Spalte $e_i \in \mathbb{R}^{V \times 1}$ und der Zeile $g \in \mathbb{R}^{1 \times d}$. Zeile $j$ ist $(e_i)_j\, g$, also null für $j \neq i$. Nur die Zeile des Tokens, das im Text vorkommt, bekommt einen Gradienten.

(d) „sensoren“ → s | en | s | or | en, IDs 5, 8, 5, 7, 8. Gradient der Zeile 5: $g_1 + g_3 = (0{,}4;\ -0{,}1;\ -0{,}1)$. Neue Zeile:

$$E_{5,:} - \eta\,(g_1 + g_3) = (-0{,}4;\ 0{,}1;\ 0{,}2) - 0{,}5 \cdot (0{,}4;\ -0{,}1;\ -0{,}1) = \boxed{(-0{,}6;\ 0{,}15;\ 0{,}25)}.$$

Unverändert bleiben die Zeilen 0, 1, 2, 3, 4, 6 und 9 (e, m, n, o, r, t, mo). Ein seltenes Token kommt selten in Trainingstexten vor, bekommt also selten einen Gradienten, und sein Vektor bleibt schlechter gelernt. Das ist ein Grund gegen riesige Wortschätze.

> **Typischer Fehler**
>
> Mit der ID als Zahl rechnen, etwa so, als wäre mo (9) „mehr“ als t (6). Die ID wählt nur eine Zeile aus. In (d) wird oft nur einer der beiden Gradienten von s verwendet.

**Bewertung:** (a) 1 P für IDs und $X$, 1 P für die Zählung der Multiplikationen. (b) 1 P für alle drei Zahlen. (c) 1 P für die Kettenregel mit Indizes, 1 P für die Folgerung „nur Zeile $i$“. (d) 1 P für die neue Zeile, 1 P für unveränderte Zeilen und Folgerung.

## Lösung zu Aufgabe 4 Kosinus-Ähnlichkeit und semantische Suche

(a) $q = \frac{1}{3}(h_1 + h_2 + h_3) = \frac{1}{3}(6;\ 3;\ 6;\ 0) = \boxed{(2;\ 1;\ 2;\ 0)}$.

(b) Längen: $\|q\| = \sqrt{4+1+4} = 3$, $\|m_1\| = \sqrt{16+4+4+1} = 5$, $\|m_2\| = 5$ und $\|m_3\| = \sqrt{36+36+9} = 9$. Damit

$$\hat{q} = \tfrac{1}{3}(2;\ 1;\ 2;\ 0), \qquad \hat{X} = \begin{pmatrix} 0{,}8 & 0{,}4 & 0{,}4 & 0{,}2 \\ 0{,}2 & 0{,}4 & 0{,}4 & 0{,}8 \\ \frac{2}{3} & \frac{2}{3} & \frac{1}{3} & 0 \end{pmatrix},$$

$$\hat{X}\hat{q} = \begin{pmatrix} (1{,}6+0{,}4+0{,}8)/3 \\ (0{,}4+0{,}4+0{,}8)/3 \\ (\frac{4}{3}+\frac{2}{3}+\frac{2}{3})/3 \end{pmatrix} = \begin{pmatrix} 14/15 \\ 8/15 \\ 8/9 \end{pmatrix} \approx \boxed{\begin{pmatrix} 0{,}933 \\ 0{,}533 \\ 0{,}889 \end{pmatrix}}.$$

Die zwei besten Treffer: $\boxed{\text{M1 (0,933) und M3 (0,889)}}$.

(c) Skalarprodukte: $m_1 \cdot q = 14$, $m_2 \cdot q = 8$, $m_3 \cdot q = 24$. Rangfolge $\boxed{\text{M3, M1, M2}}$. Das Skalarprodukt mischt Richtung und Länge. M3 hat die Länge 9 statt 5 und gewinnt deshalb, obwohl seine Richtung weniger gut passt. Nur der Kosinus vergleicht reine Richtungen.

(d) Für $\|\hat{a}\| = \|\hat{b}\| = 1$: $\|\hat{a} - \hat{b}\|^2 = (\hat{a}-\hat{b})\cdot(\hat{a}-\hat{b}) = \hat{a}\cdot\hat{a} - 2\,\hat{a}\cdot\hat{b} + \hat{b}\cdot\hat{b} = 1 - 2\cos\theta + 1 = 2 - 2\cos\theta$.

Abstände: M1: $\sqrt{2 - 28/15} = \sqrt{2/15} \approx \boxed{0{,}365}$, M2: $\sqrt{2 - 16/15} = \sqrt{14/15} \approx \boxed{0{,}966}$, M3: $\sqrt{2 - 16/9} = \sqrt{2/9} \approx \boxed{0{,}471}$. Rangfolge nach kleinstem Abstand: M1, M3, M2, also dieselbe wie beim Kosinus. Der Abstand fällt streng mit $\cos\theta$.

(e) Verneinung und Maschinennummer ändern den Vektor kaum. Eine reine Vektorsuche nach „Störung an M-03“ liefert deshalb auch Meldungen zu M-05, und „läuft nicht unrund“ landet neben „läuft unrund“. Ergänzen: eine Stichwortsuche oder einen Filter auf die Maschinen-ID (Suchsysteme kombinieren beides, mehr in Modul 7). Außerdem Rangfolgen innerhalb eines Modells vergleichen und keine festen Schwellen von einem Modell auf ein anderes übertragen.

**Typischer Fehler**

Nur die Meldungen normieren und $q$ vergessen: Die Rangfolge bleibt dann zwar gleich, die Scores sind aber keine Kosinus-Werte (hier dreimal zu groß). In (d) die Wurzel vergessen.

**Bewertung:** (a) 1 P. (b) 1 P für die Normierung, 1 P für Scores und Treffer. (c) 1 P mit Erklärung. (d) 1 P für die Herleitung, 1 P für die Abstände und den Vergleich. (e) 1 P für Deutung und eine sinnvolle Ergänzung.

## Lösung zu Aufgabe 5 PCA von Hand

(a) $\bar{x} = \frac{1}{5}(0+2+4+7+7;\ 1+1+3+3+7) = \boxed{(4;\ 3)}$. Zentriert: $(-4;\ -2)$, $(-2;\ -2)$, $(0;\ 0)$, $(3;\ 0)$, $(3;\ 4)$.

(b) $\sum \tilde{x}_1^2 = 16+4+0+9+9 = 38$, $\sum \tilde{x}_2^2 = 4+4+0+0+16 = 24$, $\sum \tilde{x}_1\tilde{x}_2 = 8+4+0+0+12 = 24$. Also

$$C = \frac{1}{5}\begin{pmatrix} 38 & 24 \\ 24 & 24 \end{pmatrix} = \boxed{\begin{pmatrix} 7{,}6 & 4{,}8 \\ 4{,}8 & 4{,}8 \end{pmatrix}}.$$

(c) $\det(C-\lambda I) = (7{,}6-\lambda)(4{,}8-\lambda) - 4{,}8^2 = \lambda^2 - 12{,}4\,\lambda + 36{,}48 - 23{,}04 = \lambda^2 - 12{,}4\,\lambda + 13{,}44 = 0.$

$$\lambda_{1,2} = \frac{12{,}4 \pm \sqrt{12{,}4^2 - 4\cdot 13{,}44}}{2} = \frac{12{,}4 \pm \sqrt{100}}{2} \quad\Longrightarrow\quad \boxed{\lambda_1 = 11{,}2, \quad \lambda_2 = 1{,}2}.$$

Eigenvektor zu $\lambda_1$: $(7{,}6 - 11{,}2)\,a + 4{,}8\,b = 0$, also $b = 0{,}75\,a$, Richtung $(4;\ 3)$, normiert $\boxed{v_1 = (0{,}8;\ 0{,}6)}$. Probe: $Cv_1 = (6{,}08 + 2{,}88;\ 3{,}84 + 2{,}88) = (8{,}96;\ 6{,}72) = 11{,}2 \cdot (0{,}8;\ 0{,}6)$. Kontrolle: $\lambda_1 + \lambda_2 = 12{,}4 = 7{,}6 + 4{,}8$, die Spur von $C$.

(d) $z = \tilde{X} v_1 = (-3{,}2 - 1{,}2;\ -1{,}6 - 1{,}2;\ 0;\ 2{,}4;\ 2{,}4 + 2{,}4) = (-4{,}4;\ -2{,}8;\ 0;\ 2{,}4;\ 4{,}8)$. Der Mittelwert ist 0, also

$$\mathrm{Var}(z) = \tfrac{1}{5}\,(19{,}36 + 7{,}84 + 0 + 5{,}76 + 23{,}04) = \tfrac{56}{5} = \boxed{11{,}2 = \lambda_1}.$$

Anteil: $\lambda_1/(\lambda_1 + \lambda_2) = 11{,}2/12{,}4 \approx \boxed{0{,}903}$. Eine Achse zeigt hier gut 90 % der Streuung. Bei den 384-dimensionalen Embeddings im Notebook ist der Anteil zweier Achsen meist viel kleiner.

(e) Weil $C$ symmetrisch ist, gilt $v_1^\top C = (Cv_1)^\top = \lambda_1 v_1^\top$. Damit

$$\lambda_1\, v_1^\top v_2 = (v_1^\top C)\, v_2 = v_1^\top (C v_2) = \lambda_2\, v_1^\top v_2 \quad\Longrightarrow\quad (\lambda_1 - \lambda_2)\, v_1^\top v_2 = 0.$$

Wegen $\lambda_1 \neq \lambda_2$ folgt $v_1^\top v_2 = 0$. Im Beispiel: $(7{,}6 - 1{,}2)\,a + 4{,}8\,b = 0$, also $b = -\frac{4}{3}\,a$, normiert $v_2 = (-0{,}6;\ 0{,}8)$ (oder das Negative). Probe: $v_1 \cdot v_2 = -0{,}48 + 0{,}48 = 0$.

**Typischer Fehler**

$v_1 = (4;\ 3)$ nicht normieren: Varianz $25 \cdot 11{,}2 = 280$ statt 11,2. Nicht zentrieren: $\frac{1}{5} X^\top X$ hat den größten Eigenwert $36{,}2 = 11{,}2 + \|\bar{x}\|^2$, die Richtung stimmt nur zufällig, weil $\bar{x}$ parallel zu $v_1$ liegt. Wer mit $\frac{1}{n-1}$ rechnet, erhält $C = \left(\begin{smallmatrix} 9{,}5 & 6 \\ 6 & 6 \end{smallmatrix}\right)$ mit Eigenwerten 14 und 1,5. Richtung und Anteil bleiben gleich, das gibt volle Punkte.

**Bewertung:** (a) 1 P. (b) 2 P (1 P für die Summen, 1 P für $C$). (c) 1 P für die Eigenwerte, 1 P für $v_1$. (d) 1 P für Projektion und Varianz, 1 P für den Anteil. (e) 1 P für den Beweis, 1 P für $v_2$ und die Probe.

## Lösung zu Aufgabe 6 PCA ohne Eigenwertrechnung (Zusatz)

(a) $v^\top C v = 7{,}6\cos^2\varphi + 2 \cdot 4{,}8 \sin\varphi\cos\varphi + 4{,}8\sin^2\varphi$. Mit $\cos^2\varphi = \frac{1}{2}(1 + \cos 2\varphi)$, $\sin^2\varphi = \frac{1}{2}(1 - \cos 2\varphi)$ und $2\sin\varphi\cos\varphi = \sin 2\varphi$:

$$v^\top C v = 3{,}8 + 3{,}8\cos 2\varphi + 2{,}4 - 2{,}4\cos 2\varphi + 4{,}8\sin 2\varphi = 6{,}2 + 1{,}4\cos 2\varphi + 4{,}8\sin 2\varphi.$$

(b) Es gilt $a\cos u + b\sin u = \sqrt{a^2 + b^2}\,\cos(u - u_0)$ mit $\tan u_0 = b/a$. Hier $\sqrt{1{,}4^2 + 4{,}8^2} = \sqrt{25} = 5$ und $\tan u_0 = 4{,}8/1{,}4 = 24/7$, also $u_0 \approx 73{,}74°$. Alternativ: Ableitung null setzen, $-2{,}8\sin 2\varphi + 9{,}6\cos 2\varphi = 0$.

Maximum $6{,}2 + 5 = \boxed{11{,}2}$ bei $\varphi \approx 36{,}87°$, dort ist $v = (0{,}8;\ 0{,}6)$.
Minimum $6{,}2 - 5 = \boxed{1{,}2}$ bei $\varphi \approx 126{,}87°$, dort ist $v = (-0{,}6;\ 0{,}8)$.
Das sind genau $\lambda_1$, $\lambda_2$, $v_1$ und $v_2$ aus Aufgabe 5.

