Tutoriumsblatt 5

Transformer und Attention

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Attention mit gelernten Projektionen und kausaler Maske für drei Tokens von Hand rechnen,
- die Varianz eines Scores selbst herleiten und die Skalierung mit $\sqrt{d_k}$ begründen,
- Rechenaufwand, Speicher und Parameterzahl eines Transformers aus den Matrixformen abschätzen,
- Temperatur und Entropie einer Verteilung über das nächste Token berechnen und deuten.

So arbeitest du mit dem Blatt

Bearbeite die Aufgaben der Reihe nach, sie werden schrittweise anspruchsvoller. Taschenrechner und das Formelblatt der Lerneinheiten sind erlaubt, Code brauchst du nicht. Rechne mit mindestens drei Nachkommastellen und runde erst am Ende. Bei der Softmax rechnest du mit den ungerundeten skalierten Scores, wie in Lerneinheit 3. ln ist der natürliche Logarithmus. Wo „Zur Kontrolle“ steht, bekommst du ein Zwischenergebnis, damit ein Folgefehler nicht die ganze Aufgabe kippt.
Bezug zum Notebook: Aufgabe 1 ist die Theorie zu TODO 2 bis 4, Aufgabe 2 zu TODO 5, Aufgabe 3 zum KV-Cache und zu Teil B3, Aufgabe 5 zu TODO 6. Im Notebook prüfst du die Rechnungen, hier verstehst du, warum sie so aussehen.

Aufgabe 1 Attention mit gelernten Projektionen von Hand 12 Punkte · etwa 26 Min.

Bezug: Modul 5, Lerneinheit 2 (Projektionen), Lerneinheit 3 (Papierübung) und Lerneinheit 5 (kausale Maske)

Ein Ausschnitt einer Störungsmeldung besteht aus den Tokens „Palette“, „Lager“ und „heiß“, in dieser Reihenfolge. Wie in der Papierübung steht die erste Dimension für Maschine, die zweite für Logistik. Anders als dort gibt es jetzt gelernte Projektionen. Die Zahlen sind erfunden und so gewählt, dass du gut von Hand rechnen kannst:

$$X = \begin{pmatrix} 0 & 2 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{matrix} \leftarrow \text{Palette} \\ \leftarrow \text{Lager} \\ \leftarrow \text{heiß} \end{matrix} \qquad W_Q = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}, \quad W_K = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix}, \quad W_V = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad d_k = 2.$$

Weil W_V die Einheitsmatrix ist, gilt $V = X$, und die Ausgabe bleibt im Raum (Maschine, Logistik) deutbar.

(a) Berechne $Q = XW_Q$ und $K = XW_K$. Gib die Formen von Q, K und V an. [2 P]

(b) Berechne die Score-Matrix $S = QK^\top$. Zeile i gehört zur Query von Token i, Spalte j zum Key von Token j. [2 P]

(c) Vergleiche $S_{\text{Lager,heiß}}$ mit $S_{\text{heiß,Lager}}$ sowie $S_{\text{Lager,Palette}}$ mit $S_{\text{Palette,Lager}}$. Zeige mit $S = XW_QW_K^\top X^\top$, dass S symmetrisch wäre, wenn $W_Q = W_K$ gilt. Was bedeutet die Asymmetrie hier inhaltlich? [2 P]

(d) Zur Kontrolle: Die Zeile von „Lager“ in S lautet $(-2,\ 1,\ 2)$. Teile sie durch $\sqrt{d_k}$ und berechne die Attention-Gewichte α_{Lager} mit der Softmax. [3 P]

(e) Berechne den neuen Vektor o_{Lager} und vergleiche ihn mit $x_{\text{Lager}} = (1,\ 1)$. [1 P]

(f) Jetzt gilt die kausale Maske. Welche Gewichte und welchen neuen Vektor bekommt „Lager“? Welche Zeile der Gewichtsmatrix bleibt unverändert? Deute den Unterschied zu (e) in einem Satz. [2 P]

Aufgabe 2 Die Varianz eines Scores herleiten

9 Punkte · etwa 20 Min.

Bezug: Modul 5, Lerneinheit 4 (Warum durch die Wurzel aus d_k teilen?)

Lerneinheit 4 hat die Varianz eines Scores für Varianz 1 skizziert. Hier führst du die Herleitung allgemein aus. Annahme: Die Komponenten $q_1, \ldots, q_{d_k}$ und $k_1, \ldots, k_{d_k}$ sind alle unabhängig, mit $\mathbb{E}[q_i] = \mathbb{E}[k_i] = 0$ und $\mathrm{Var}(q_i) = \mathrm{Var}(k_i) = \sigma^2 > 0$. Der Score ist $s = q \cdot k = \sum_{i=1}^{d_k} q_i k_i$. Du darfst verwenden: $\mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y]$ für unabhängige X, Y; Funktionen unabhängiger Größen sind unabhängig; $\mathrm{Var}(\sum_i Y_i) = \sum_i \mathrm{Var}(Y_i) + 2\sum_{i<j} \mathrm{Cov}(Y_i, Y_j)$ und $\mathrm{Var}(cY) = c^2\,\mathrm{Var}(Y)$.

(a) Zeige $\mathbb{E}[q_i k_i] = 0$ und $\mathrm{Var}(q_i k_i) = \sigma^4$. [2 P]

(b) Zeige $\mathrm{Cov}(q_i k_i,\ q_j k_j) = 0$ für $i \neq j$ und folgere $\mathrm{Var}(s) = d_k\,\sigma^4$. Welche Rechenregel aus Lerneinheit 4 hast du damit für die Summanden $q_i k_i$ gerechtfertigt? [2 P]

(c) Bestimme den Faktor $c > 0$ mit $\mathrm{Var}(c\,s) = 1$. Gib für $\sigma^2 = 1$ die Standardabweichung von s und den Faktor c für $d_k = 16$ und $d_k = 100$ an. Welche Varianz hat $s/\sqrt{d_k}$, wenn $\sigma^2 = 2$ und $d_k = 64$ ist? [2 P]

(d) Eine Kommilitonin zeigt dir ihre Ausgabe von TODO 5 (erfundene Beispielwerte):

```
d =   4   var_ohne =   4.03   var_mit = 0.2519
d =  64   var_ohne =  63.52   var_mit = 0.0155
d = 512   var_ohne = 509.87   var_mit = 0.0019
```

Welchen Fehler hat sie gemacht? Begründe mit einer Zahl aus der Ausgabe. Vergleiche dann für $d_k = 16$ drei Fassungen desselben Score-Tripels: richtig skaliert $(1,\ 0,\ 0)$, unskaliert $(4,\ 0,\ 0)$ und mit ihrem Fehler $(0{,}25;\ 0;\ 0)$. Berechne jeweils das größte Gewicht p_1, für die ersten beiden auch $p_1(1 - p_1)$. Erkläre, warum beide falschen Fassungen das Lernen behindern. [3 P]

Aufgabe 3 Rechenaufwand und Speicher bei langen Texten

8 Punkte · etwa 18 Min.

Bezug: Modul 5, Lerneinheit 2 (Formen), Lerneinheit 5 (quadratischer Aufwand), Lerneinheit 6 (Block) und Lerneinheit 7 (KV-Cache)

Die Nordwerk GmbH möchte lange Wartungsberichte mit GPT-2 small verarbeiten: $d = 768$, $h = 12$ Köpfe mit $d_k = 64$, 12 Blöcke, höchstens 1024 Tokens. Zähle nur Multiplikationen in Matrixprodukten: Das Produkt einer $(a \times b)$- mit einer $(b \times c)$-Matrix braucht $a \cdot b \cdot c$ Multiplikationen. Jede gespeicherte Zahl belegt 4 Byte (float32), und es gilt 1 MB $= 10^6$ Byte.

(a) Wie viele Multiplikationen brauchen $QK^\top$ und das Produkt der Gewichte mit V in einem Kopf bei n Tokens? Zeige, dass alle Köpfe eines Blocks zusammen $2n^2d$ brauchen, und werte für $n = 1024$ aus. Um welchen Faktor wächst der Wert, wenn sich n verdoppelt? [2 P]

(b) Zur Kontrolle: Die übrigen Matrixprodukte eines Blocks (Projektionen W_Q, W_K, W_V, W_O und das MLP) brauchen zusammen $12\,n\,d^2$ Multiplikationen. Begründe das kurz mit der Parameterzahl aus Lerneinheit 6. Ab welcher Länge n^* ist der quadratische Teil aus (a) genauso groß? Welchen Anteil an allen Multiplikationen hat er bei $n = 1024$? [2 P]

(c) In Teil B3 des Notebooks lässt du dir die Attention-Gewichte aller Köpfe in allen Blöcken ausgeben. Wie viel Speicher belegen sie für einen Satz mit $n = 10$ Tokens und für $n = 1024$ Tokens? [2 P]

(d) Beim Generieren speichert der KV-Cache für jedes bisherige Token in jedem Block Key und Value über alle Köpfe. Wie viele Byte sind das pro Token und für 1024 Tokens? Warum dürfen die gespeicherten Keys und Values unverändert weiterverwendet werden? Wie wachsen der Cache und der Speicher aus (c) mit n? [2 P]

Aufgabe 4 Parameter zählen: Köpfe und Block

5 Punkte · etwa 10 Min.

Bezug: Modul 5, Lerneinheit 5 (Multi-Head Attention) und Lerneinheit 6 (Transformer-Block)

Ein kleineres Modell für Störungsmeldungen (fiktives Beispiel) hat $d = 512$, $h = 8$ Köpfe, die MLP-Breite $4d$ und 6 Blöcke. Wie in der Lerneinheit haben W_Q, W_K, W_V und W_O keinen Bias. Das MLP hat die Biases b_1 und b_2, und jeder Block hat zwei LayerNorms mit je γ und β.

(a) Berechne d_k und die Zahl der Parameter von $W_Q^{(k)}$, eines ganzen Kopfes ($W_Q^{(k)}$, $W_K^{(k)}$, $W_V^{(k)}$), aller Köpfe zusammen und der ganzen Attention-Schicht mit W_O. Drücke die letzten beiden Ergebnisse durch d aus. [2 P]

(b) Zeige allgemein, dass die Projektionen aller Köpfe zusammen $3d^2$ Parameter haben, unabhängig von h. Was ändert sich bei $h = 16$? [1 P]

(c) Zähle die Parameter eines Blocks exakt. Wie stark weicht die Faustregel $12d^2$ ab, welchen Anteil hat die Attention, und wie viele Parameter haben die 6 Blöcke zusammen? [2 P]

Aufgabe 5 Temperatur und Entropie beim Generieren

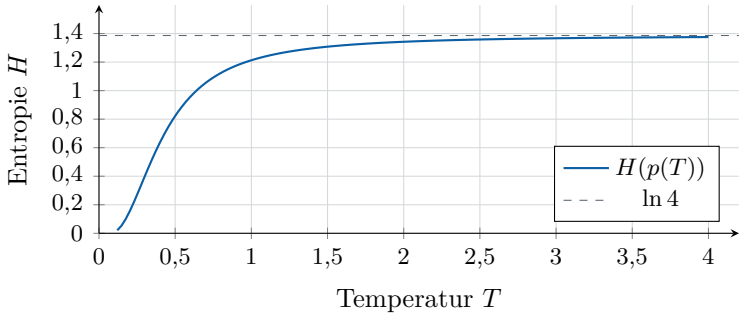
6 Punkte · etwa 14 Min.

Bezug: Modul 5, Lerneinheit 7 (Generierung, Temperatur, Entropie)

Nach „Die Spindel von M-03 läuft“ liefert ein Modell für vier Kandidaten die folgenden Logits. Vereinfacht nehmen wir an, dass nur diese vier Tokens möglich sind.

Token	„unrund“	„heiß“	„laut“	„ruhig“
Logit z_k	$\ln 4 \approx 1{,}386$	$\ln 2 \approx 0{,}693$	0	0

Das Diagramm zeigt die Entropie H dieser Verteilung abhängig von der Temperatur T. Nutze es zur Kontrolle.



(a) Berechne die Verteilung p für $T = 1$ und ihre Entropie H. Wie viel Prozent des größtmöglichen Werts sind das? [2 P]

(b) Berechne p und H für $T = 0{,}5$ und markiere beide Entropiewerte im Diagramm. Welche der beiden Temperaturen nimmst du für ein automatisch erstelltes Instandhaltungsprotokoll? Begründe kurz. [2 P]

(c) Zeige allgemein: $p_a(T)/p_b(T) = e^{(z_a - z_b)/T}$. Folgere, dass die Temperatur die Rangfolge nie ändert. Berechne das Verhältnis von „unrund“ zu „heiß“ für $T = 0{,}5$, $T = 1$ und $T = 2$. Wogegen strebt es für $T \to 0$ und für $T \to \infty$? [2 P]

Aufgabe 6 (⋆) Die Ableitung der Softmax (Vertiefung)

Zusatz · etwa 10 Min.

Bezug: Modul 5, Lerneinheit 4 (dort ist die Ableitung ohne Herleitung angegeben)

Sei $p_i = e^{z_i}/N$ mit $N = \sum_{l=1}^{n} e^{z_l}$.

(a) Leite $\dfrac{\partial p_i}{\partial z_j} = p_i\,(\delta_{ij} - p_j)$ mit der Quotientenregel her.

(b) Zeige $\sum_{i=1}^{n} \dfrac{\partial p_i}{\partial z_j} = 0$. Warum muss das so sein?

(c) Zeige $p\,(1-p) \le \frac{1}{4}$ für alle $p \in [0,1]$. Werte $\partial p_1/\partial z_1$ und $\partial p_1/\partial z_2$ für die Verteilung aus Aufgabe 5(a) aus.

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Attention mit gelernten Projektionen von Hand

(a) Für eine Zeile $x = (x_1,\ x_2)$ gilt $xW_Q = (2x_1,\ x_2)$ und $xW_K = (x_1 - x_2,\ x_2)$. Damit

$$Q = \begin{pmatrix} 0 & 2 \\ 2 & 1 \\ 2 & 0 \end{pmatrix}, \qquad K = \begin{pmatrix} -2 & 2 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}, \qquad V = X.$$

Formen: $(3 \times 2)(2 \times 2) = (3 \times 2)$, also $Q, K, V \in \mathbb{R}^{3\times 2}$, das heißt $n \times d_k$.

(b) Eintrag (i, j) ist $q_i \cdot k_j$. Für „Lager“ mit $q = (2,\ 1)$: $2 \cdot (-2) + 1 \cdot 2 = -2$, $2 \cdot 0 + 1 \cdot 1 = 1$, $2 \cdot 1 + 1 \cdot 0 = 2$. Insgesamt

$$S = QK^\top = \begin{pmatrix} 4 & 2 & 0 \\ -2 & 1 & 2 \\ -4 & 0 & 2 \end{pmatrix} \begin{matrix} \leftarrow \text{Palette} \\ \leftarrow \text{Lager} \\ \leftarrow \text{heiß} \end{matrix}$$

(c) $S_{\text{Lager,heiß}} = 2$, aber $S_{\text{heiß,Lager}} = 0$. $S_{\text{Lager,Palette}} = -2$, aber $S_{\text{Palette,Lager}} = 2$. Herleitung mit $(AB)^\top = B^\top A^\top$:

$$S = QK^\top = XW_Q\,(XW_K)^\top = XW_QW_K^\top X^\top.$$

Mit $W_Q = W_K = W$ folgt $S^\top = \left(XWW^\top X^\top\right)^\top = XWW^\top X^\top = S$, die Matrix wäre symmetrisch. Hier ist dagegen

$$W_QW_K^\top = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}\begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & -2 \\ 0 & 1 \end{pmatrix}$$

nicht symmetrisch. Inhaltlich: „Lager“ sucht mit seiner Query nach Maschinenkontext und achtet stark auf „heiß“, „heiß“ achtet dagegen deutlich schwächer auf „Lager“ (Score 0 statt 2). Mit $Q = K$ müssten beide Richtungen gleich stark sein.

(d) Skaliert: $s/\sqrt{2} \approx (-1{,}414;\ 0{,}707;\ 1{,}414)$. Exponentiert: $e^{-1{,}414} \approx 0{,}243$, $e^{0{,}707} \approx 2{,}028$, $e^{1{,}414} \approx 4{,}113$, Summe $\approx 6{,}384$. Geteilt:

$$\boxed{\alpha_{\text{Lager}} \approx (0{,}038;\ 0{,}318;\ 0{,}644)}, \qquad \text{Summe } 1.$$

Auch der negative Score bekommt ein positives, nur kleines Gewicht.

(e) Gewichtete Summe der Values:

$$o_{\text{Lager}} = 0{,}038 \cdot (0,\ 2) + 0{,}318 \cdot (1,\ 1) + 0{,}644 \cdot (1,\ 0) = \boxed{(0{,}962;\ 0{,}394)}.$$

Vorher lag „Lager“ genau zwischen Maschine und Logistik, jetzt zeigt der Vektor deutlich Richtung Maschine. „heiß“ zieht am stärksten.

(f) „Lager“ steht an Position 2 und sieht nur „Palette“ und sich selbst. Der Score zu „heiß“ wird $-\infty$, sein Gewicht exakt 0. Aus $(-1{,}414;\ 0{,}707)$ folgt

$$\alpha_{\text{Lager}} = \left(\tfrac{1}{1+e^{2{,}121}};\ \tfrac{e^{2{,}121}}{1+e^{2{,}121}};\ 0\right) \approx (0{,}107;\ 0{,}893;\ 0), \qquad o_{\text{Lager}} \approx \boxed{(0{,}893;\ 1{,}107)}$$

mit $e^{2{,}121} \approx 8{,}342$. „Palette“ bekommt die Zeile $(1;\ 0;\ 0)$. Unverändert bleibt die Zeile von „heiß“, denn das letzte Token sieht alle: $(0{,}011;\ 0{,}193;\ 0{,}795)$. Deutung: An Position 2 kennt „Lager“ das Wort „heiß“ noch nicht und kippt leicht Richtung Logistik; der Hinweis „heiß“ wirkt erst an späteren Positionen.

Typischer Fehler

Skalierung vergessen: $\mathrm{softmax}(-2,\ 1,\ 2) \approx (0{,}013;\ 0{,}265;\ 0{,}721)$ ist zu spitz. Ebenso häufig: $S = QK$ statt $QK^\top$ (Formfehler $(3 \times 2)(3 \times 2)$) oder die Softmax über eine Spalte. Bei der Maske wird oft vergessen, dass „Lager“ sich selbst sieht.

Bewertung: (a) Q und K je 0,5 P, Formen 1 P. (b) 2 P, je falsche Zeile 0,5 P Abzug. (c) Vergleich 0,5 P, Symmetriebeweis 1 P, Deutung 0,5 P. (d) Skalierung 1 P, Exponentialwerte und Summe 1 P, Gewichte 1 P. (e) 1 P. (f) Gewichte 1 P, Vektor und Deutung 1 P. Folgefehler werden nicht doppelt abgezogen.

Lösung zu Aufgabe 2 Die Varianz eines Scores herleiten

(a) Wegen der Unabhängigkeit: $\mathbb{E}[q_i k_i] = \mathbb{E}[q_i]\,\mathbb{E}[k_i] = 0 \cdot 0 = 0$. Bei Mittelwert 0 gilt $\mathbb{E}[q_i^2] = \mathrm{Var}(q_i) + \mathbb{E}[q_i]^2 = \sigma^2$, ebenso für k_i. Da auch q_i^2 und k_i^2 unabhängig sind:

$$\mathrm{Var}(q_i k_i) = \mathbb{E}[q_i^2 k_i^2] - \big(\mathbb{E}[q_i k_i]\big)^2 = \mathbb{E}[q_i^2]\,\mathbb{E}[k_i^2] - 0 = \sigma^4.$$

(b) Für $i \neq j$ sind q_i, k_i, q_j, k_j vier unabhängige Größen:

$$\mathrm{Cov}(q_i k_i,\ q_j k_j) = \mathbb{E}[q_i k_i q_j k_j] - \mathbb{E}[q_i k_i]\,\mathbb{E}[q_j k_j] = \mathbb{E}[q_i]\,\mathbb{E}[k_i]\,\mathbb{E}[q_j]\,\mathbb{E}[k_j] - 0 = 0.$$

Alle Kovarianzen fallen weg, also

$$\mathrm{Var}(s) = \sum_{i=1}^{d_k} \mathrm{Var}(q_i k_i) = \boxed{d_k\,\sigma^4}.$$

Gerechtfertigt ist damit die Regel „Varianzen unabhängiger Summanden addieren sich“ aus Lerneinheit 4: Die Summanden $q_i k_i$ sind unkorreliert (sogar unabhängig), weil sie aus verschiedenen Komponenten gebildet werden, also fallen alle Kovarianzterme weg. Für $\sigma^2 = 1$ ergibt sich die Formel $\mathrm{Var}(q \cdot k) = d_k$ der Lerneinheit.

(c) Aus $\mathrm{Var}(c\,s) = c^2 d_k \sigma^4 = 1$ folgt

$$\boxed{c = \frac{1}{\sigma^2 \sqrt{d_k}}}, \qquad \text{für } \sigma^2 = 1 \text{ also } c = \frac{1}{\sqrt{d_k}}.$$

Bei $d_k = 16$: $\mathrm{SD}(s) = 4$, $c = 0{,}25$. Bei $d_k = 100$: $\mathrm{SD}(s) = 10$, $c = 0{,}1$. Mit $\sigma^2 = 2$ und $d_k = 64$ ist $\mathrm{Var}(s) = 64 \cdot 4 = 256$ und $\mathrm{Var}(s/8) = 256/64 = 4$. Der Faktor $1/\sqrt{d_k}$ normiert also nur bei $\sigma^2 = 1$ exakt auf 1. Er gleicht das Wachstum mit d_k aus, nicht die Skala der Eingaben. Dass diese Skala fest bleibt, unterstützt die LayerNorm vor der Attention (Lerneinheit 6).

(d) Diagnose: `var_mit` $\approx 1/d$ statt ≈ 1, zum Beispiel $4{,}03/16 \approx 0{,}2519$, also `var_ohne`$/d^2$. Sie hat durch d statt durch $\sqrt{d}$ geteilt, denn $\mathrm{Var}(s/d) = d/d^2 = 1/d$. Die drei Fassungen:

Fassung	Scores	p_1	$p_1(1-p_1)$
richtig skaliert	$(1,\ 0,\ 0)$	$e/(e+2) \approx 0{,}576$	0,244
unskaliert	$(4,\ 0,\ 0)$	$54{,}598/56{,}598 \approx 0{,}965$	0,034
durch d_k geteilt	$(0{,}25;\ 0;\ 0)$	$1{,}284/3{,}284 \approx 0{,}391$	nicht verlangt

Unskaliert ist die Softmax gesättigt: Die Ableitung ist etwa siebenmal kleiner, es fließen kaum Gradienten. Durch d_k geteilt sind die Gewichte fast gleich (0,391 gegen zweimal 0,305): Attention kann kaum noch auswählen und mittelt fast gleichmäßig. Gegensteuern könnte das Modell nur mit sehr großen Projektionswerten.

Typischer Fehler

$\mathrm{Var}(q_i k_i) = \mathrm{Var}(q_i)\,\mathrm{Var}(k_i)$ ohne Begründung hinschreiben. Das stimmt hier nur, weil beide Mittelwerte 0 sind. Ebenso oft wird vergessen, dass c quadratisch in die Varianz eingeht, und deshalb $c = 1/d_k$ gewählt.

Bewertung: (a) Erwartungswert 1 P, Varianz 1 P. (b) Kovarianz 1 P, Folgerung mit Benennung der Regel 1 P. (c) Faktor c allgemein und Zahlen 1 P, Fall $\sigma^2 = 2$ 1 P. (d) Diagnose mit Zahl 1 P, Tabelle 1 P, Erklärung beider Fehler 1 P.

Lösung zu Aufgabe 3 Rechenaufwand und Speicher bei langen Texten

(a) $QK^\top$: $(n \times d_k)(d_k \times n)$ braucht $n^2 d_k$ Multiplikationen. Gewichte mal V: $(n \times n)(n \times d_k)$ braucht ebenfalls $n^2 d_k$. Pro Kopf also $2n^2 d_k$, für alle Köpfe wegen $h\,d_k = d$:

$$h \cdot 2n^2 d_k = 2n^2 d = 2 \cdot 1024^2 \cdot 768 = \boxed{1\,610\,612\,736 \approx 1{,}61 \cdot 10^9}.$$

Doppelte Länge ergibt den Faktor $2^2 = 4$.

(b) Jeder Parameter einer Gewichtsmatrix wird pro Token genau einmal multipliziert. Projektionen: $4 \cdot (n \times d)(d \times d)$ ergibt $4nd^2$. MLP: $(n \times d)(d \times 4d)$ und $(n \times 4d)(4d \times d)$ ergeben $8nd^2$. Zusammen $12nd^2 = n \cdot 12d^2$, also Tokens mal Parameter pro Block. Gleichsetzen:

$$2n^2 d = 12\,n\,d^2 \iff \boxed{n^* = 6d = 4608}.$$

Anteil bei $n = 1024$:

$$\frac{2n^2 d}{2n^2 d + 12nd^2} = \frac{n}{n + 6d} = \frac{1024}{5632} \approx \boxed{18\ \%}.$$

Innerhalb des Kontexts von GPT-2 überwiegt also der lineare Teil. Erst für $n > 6d$ dominiert der quadratische.

(c) Pro Kopf n^2 Gewichte, insgesamt $12 \cdot 12 = 144$ Matrizen. Für $n = 10$: $144 \cdot 100 \cdot 4$ Byte $= 57\,600$ Byte $\approx 57{,}6$ kB. Für $n = 1024$:

$$144 \cdot 1024^2 \cdot 4 \text{ Byte} = 603\,979\,776 \text{ Byte} \approx \boxed{604 \text{ MB}}.$$

Bei 2048 Tokens wären es schon etwa 2,4 GB.

(d) Pro Token und Block je ein Key und ein Value über alle Köpfe, also $2 \cdot 12 \cdot 64 = 2d = 1536$ Zahlen. Über 12 Blöcke sind es 18 432 Zahlen, also pro Token

$$18\,432 \cdot 4 \text{ Byte} = \boxed{73\,728 \text{ Byte} \approx 73{,}7 \text{ kB}}.$$

Für 1024 Tokens: 75 497 472 Byte $\approx 75{,}5$ MB. Wiederverwendung: Wegen der kausalen Maske sieht kein altes Token je ein neues. Seine Vektoren in allen Schichten ändern sich also nicht mehr, und damit auch nicht seine Keys und Values. Der Cache wächst linear mit n, der Speicher aus (c) quadratisch. Bei $n = 1024$ ist er achtmal so groß wie der Cache.

Typischer Fehler

Pro Block $12 \cdot 768$ statt 768 Key-Komponenten zählen. Die 12 Köpfe teilen sich die Breite d, sie vervielfachen sie nicht. Ebenso häufig fehlt beim KV-Cache der Faktor 2 für Keys und Values.

Bewertung: (a) Formel pro Kopf 0,5 P, $2n^2d$ 0,5 P, Zahl 0,5 P, Faktor 4 0,5 P. (b) Begründung $12nd^2$ 0,5 P, n^* 1 P, Anteil 0,5 P. (c) je Wert 1 P. (d) Bytes pro Token und für 1024 Tokens 1 P, Begründung über die Maske 0,5 P, Wachstum 0,5 P.

Lösung zu Aufgabe 4 Parameter zählen: Köpfe und Block

(a) $d_k = 512/8 = 64$. $W_Q^{(k)}$: $512 \cdot 64 = 32\,768$. Ein Kopf: $3 \cdot 32\,768 = 98\,304$. Alle Köpfe: $8 \cdot 98\,304 = 786\,432 = 3d^2$. Dazu W_O mit $512^2 = 262\,144$. Attention-Schicht:

$$786\,432 + 262\,144 = \boxed{1\,048\,576 = 4d^2}.$$

(b) $h \cdot 3 \cdot d \cdot d_k = h \cdot 3 \cdot d \cdot \frac{d}{h} = 3d^2$, das h kürzt sich. Bei $h = 16$ ist $d_k = 32$: Jeder Kopf wird kleiner, die Summe bleibt gleich.

(c) MLP: W_1 mit $512 \cdot 2048 = 1\,048\,576$, b_1 mit 2048, W_2 mit 1 048 576, b_2 mit 512, zusammen 2 099 712. LayerNorms: $2 \cdot (512 + 512) = 2048$. Block:

$$1\,048\,576 + 2\,099\,712 + 2048 = \boxed{3\,150\,336} = 12d^2 + 9d.$$

Die Faustregel $12d^2 = 3\,145\,728$ liegt nur $4608 = 9d$ darunter, das sind etwa 0,15 %. Anteil der Attention: $1\,048\,576/3\,150\,336 \approx 33{,}3$ %, das MLP hat doppelt so viele Parameter. Sechs Blöcke: 18 902 016 ≈ 18,9 Mio., ohne Embedding und Positionsvektoren.

Bewertung: (a) d_k und $W_Q^{(k)}$ 0,5 P, Kopf und alle Köpfe 0,5 P, Attention-Schicht mit Ausdruck in d 1 P. (b) 1 P. (c) Blocksumme 1 P, Abweichung, Anteil und 6 Blöcke 1 P.

Lösung zu Aufgabe 5 Temperatur und Entropie beim Generieren

(a) $e^z = (4,\ 2,\ 1,\ 1)$ mit Summe 8, also

$$\boxed{p = (0{,}5;\ 0{,}25;\ 0{,}125;\ 0{,}125)}.$$

Mit $-\ln p_k = \ln 2,\ \ln 4,\ \ln 8,\ \ln 8$ folgt

$$H = 0{,}5 \ln 2 + 0{,}25 \ln 4 + 2 \cdot 0{,}125 \ln 8 = (0{,}5 + 0{,}5 + 0{,}75) \ln 2 = 1{,}75 \ln 2 \approx \boxed{1{,}213}.$$

Maximum $\ln 4 = 2 \ln 2 \approx 1{,}386$, also genau 87,5 % davon.

(b) $z/T = (2 \ln 4,\ 2 \ln 2,\ 0,\ 0)$, also $e^{z/T} = (16,\ 4,\ 1,\ 1)$ mit Summe 22 und

$$\boxed{p \approx (0{,}727;\ 0{,}182;\ 0{,}045;\ 0{,}045)}.$$

Die Entropie ist

$$H = \tfrac{16}{22} \ln \tfrac{22}{16} + \tfrac{4}{22} \ln \tfrac{22}{4} + 2 \cdot \tfrac{1}{22} \ln 22 \approx 0{,}232 + 0{,}310 + 0{,}281 = \boxed{0{,}823}.$$

Die Verteilung ist spitzer, die Entropie kleiner. Für das Protokoll nimmst du $T = 0{,}5$: weniger Zufall, sachlich und eher wiederholbar. Volle Punkte auch für „noch kleiner oder greedy“, wenn mit wenig Zufall begründet.

(c) Der Nenner $N = \sum_j e^{z_j/T}$ kürzt sich: $\dfrac{p_a}{p_b} = \dfrac{e^{z_a/T}/N}{e^{z_b/T}/N} = e^{(z_a - z_b)/T}$. Ist $z_a > z_b$ und $T > 0$, dann ist der Exponent positiv und das Verhältnis größer als 1. Die Rangfolge bleibt also. Hier ist $z_a - z_b = \ln 2$, das Verhältnis also $2^{1/T}$:

$$T = 0{,}5\text{: } \boxed{4}, \qquad T = 1\text{: } \boxed{2}, \qquad T = 2\text{: } \boxed{\sqrt{2} \approx 1{,}414}.$$

Für $T \to 0$ strebt es gegen ∞ (greedy), für $T \to \infty$ gegen 1 (Gleichverteilung).

Typischer Fehler

$\log_2$ statt ln verwenden, dann kommt 1,75 statt 1,213 heraus. Außerdem: die Temperatur auf die Wahrscheinlichkeiten statt auf die Logits anwenden.

Bewertung: (a) Verteilung 1 P, Entropie und Prozent 1 P. (b) Verteilung 0,5 P, Entropie 1 P, Wahl mit Begründung 0,5 P. (c) Herleitung und Rangfolge 1 P, Zahlen und Grenzfälle 1 P.

Lösung zu Aufgabe 6 Die Ableitung der Softmax (Vertiefung)

(a) Mit $\partial N/\partial z_j = e^{z_j}$ und $\partial e^{z_i}/\partial z_j = \delta_{ij}\, e^{z_i}$:

$$\frac{\partial p_i}{\partial z_j} = \frac{\delta_{ij}\, e^{z_i}\, N - e^{z_i}\, e^{z_j}}{N^2} = \delta_{ij}\, p_i - p_i\, p_j = p_i\,(\delta_{ij} - p_j).$$

(b) $\sum_i p_i(\delta_{ij} - p_j) = p_j - p_j \sum_i p_i = p_j - p_j = 0$. Die Summe aller p_i ist immer 1. Ändert sich ein Logit, verschiebt sich nur Wahrscheinlichkeit zwischen den Tokens.

(c) $p(1-p) = \frac{1}{4} - \left(p - \frac{1}{2}\right)^2 \le \frac{1}{4}$, mit Gleichheit bei $p = \frac{1}{2}$. Für $p = (0{,}5;\ 0{,}25;\ 0{,}125;\ 0{,}125)$: $\partial p_1/\partial z_1 = 0{,}5 \cdot 0{,}5 = 0{,}25$, das Maximum, und $\partial p_1/\partial z_2 = -0{,}5 \cdot 0{,}25 = -0{,}125$.