Tutoriumsblatt 9

Evaluation: Qualität messbar machen

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- Testfälle als normal, Rand oder negativ einordnen und Code-Checks mit Begriffsgruppen von Hand auswerten,
- die Übereinstimmung eines Judges mit Handlabels als p_o und als Cohens κ berechnen und abschätzen, wie Judge-Fehler die gemessene Erfolgsrate verschieben,
- Standardfehler und Wald-Intervall berechnen und begründen, wann das Wald-Intervall versagt,
- das Wilson-Intervall selbst herleiten und von Hand berechnen,
- zwei Versionen gepaart mit dem exakten McNemar-Test vergleichen und typische Fehlschlüsse entkräften.

So arbeitest du mit dem Blatt

Bearbeite die Aufgaben der Reihe nach, sie werden schwieriger. Aufgabe 4 nutzt das Ergebnis aus Aufgabe 3. Erlaubt ist ein Taschenrechner. Rechne mit $z = 1{,}96$ und $z^2 = 3{,}8416$, runde Zwischenergebnisse auf mindestens vier Nachkommastellen und Endergebnisse auf drei. Alle Zahlen zu Testläufen und Kalibrierung sind ausgedachte Beispieldaten.
Das Blatt liefert die Theorie zu TODO 2, 3, 6 und 8 im Notebook (`code_check`, `wilson`, `uebereinstimmung`, `mcnemar_exakt`). Dort programmierst du, hier rechnest du von Hand.

Aufgabe 1 Testfälle und Code-Checks für M-04

6 Punkte · etwa 12 Min.

Bezug: Modul 9, Lerneinheit 1 (Testset) und Lerneinheit 2 (Code-Checks und LLM-Judge)

Du erweiterst das Testset des Instandhaltungs-Assistenten der Nordwerk GmbH um Fälle zur Rundschleifmaschine M-04 in Halle 2. Der Assistent hat vier Tools:

- lesend: `get_machine_status`, `get_maintenance_history`, `search_knowledge_base`
- schreibend: `create_ticket`

(a) Ordne jede Frage als normal, Rand oder negativ ein. Begründe kurz und nenne je ein erwartetes oder ein verbotenes Tool.

1. „Wie viele Betriebsstunden hat M-04?“
2. „Was ist mit der Schleifmaschine in Halle 2 los?“
3. „Ist die nächste Wartung von M-04 schon fällig?“
4. „Setz den Status von M-04 auf außer Betrieb.“

[2 P]

(b) Der Fall zu Frage 1 hat die Referenz „M-04 hat 22.310 Betriebsstunden.“ und die Pflichtbegriffe

```
muss = [["M-04"], ["22310", "22.310", "22 310"]]
```

Der Inhalts-Check verlangt aus jeder Gruppe mindestens einen Begriff und ignoriert Groß- und Kleinschreibung. Werte ihn für die vier Antworten aus. Welche Antwort besteht ihn fälschlich, welche fällt fälschlich durch?

A: „M-04 steht bei 22.310 Betriebsstunden.“

B: „Die Rundschleifmaschine hat 22310 Betriebsstunden.“

C: „M-04 hat nicht 22.310, sondern 41.980 Betriebsstunden.“

D: „m-04: 22 310 h“

[3 P]

(c) Einen der beiden Fehler aus (b) behebst du mit besseren Begriffsgruppen, den anderen nicht. Welcher ist welcher? Gib die Änderung an `muss` an und nenne, wer den anderen Fehler abfängt. [1 P]

Aufgabe 2 Den Judge kalibrieren

9 Punkte · etwa 18 Min.

Bezug: Modul 9, Lerneinheit 3 (Den Judge prüfen: Verzerrungen und Kalibrierung)

Du lässt den Judge 20 Antworten bewerten, für die Handlabels vorliegen. Die Tabelle zählt, wie oft welches Paar aus Handlabel (Zeile) und Judge-Urteil (Spalte) vorkam.

	Judge			
Hand	richtig	teilweise	falsch	Summe
richtig	9	1	0	10
teilweise	2	2	0	4
falsch	1	0	5	6
Summe	12	3	5	20

(a) Berechne die beobachtete Übereinstimmung p_o. [1 P]

(b) Berechne aus den Randsummen die erwartete Zufallsübereinstimmung $p_e = \sum_k p_{\text{Hand},k}\, p_{\text{Judge},k}$ und daraus Cohens $\kappa = \frac{p_o - p_e}{1 - p_e}$. Zur Kontrolle: p_e liegt zwischen 0,40 und 0,41. [3 P]

(c) Der eine Fall mit Handlabel falsch und Judge-Urteil richtig ist eine lange, flüssig formulierte Antwort mit falschem Grenzwert. Welche Verzerrung vermutest du? Warum sind die drei Fälle, in denen der Mensch nicht richtig, der Judge aber richtig sagt, für die gemessene Erfolgsrate besonders kritisch? Was tust du als Nächstes? [2 P]

(d) Für den Erfolg zählt nur das Urteil richtig. Fasse teilweise und falsch zu „nicht richtig“ zusammen. Bestimme α (Anteil der nicht richtigen Antworten, die der Judge als richtig wertet) und β (Anteil der richtigen Antworten, die er nicht als richtig wertet). Welche Erfolgsrate misst du mit diesem Judge, wenn die wahre Rate $p = 0{,}6$ ist? Nutze

$$p_{\text{gemessen}} = p\,(1 - \beta) + (1 - p)\,\alpha.$$

[2 P]

(e) Löse die Formel aus (d) nach p auf. Ein Eval-Lauf ergibt $p_{\text{gemessen}} = 0{,}81$. Welche wahre Rate passt dazu? Nenne einen Grund, warum du dieser Korrektur nur grob trauen solltest. [1 P]

Aufgabe 3 Standardfehler und Wald-Intervall

6 Punkte · etwa 12 Min.

Bezug: Modul 9, Lerneinheit 4 (Standardfehler und Wald-Intervall) und Lerneinheit 7 (Wie viele Fälle brauchst du?)

Nach mehreren Prompt-Änderungen besteht dein Assistent 23 von 25 Fällen.

(a) Berechne $\hat{p}$, den geschätzten Standardfehler $\text{SE} = \sqrt{\hat{p}(1-\hat{p})/n}$ und das 95-%-Wald-Intervall $\hat{p} \pm 1{,}96 \cdot \text{SE}$. [2 P]

(b) Was ist am Ergebnis aus (a) offensichtlich falsch? Prüfe die Faustregel für die Normal-Näherung und nenne die Näherung des Wald-Intervalls, die hier versagt. [1 P]

(c) Fallzahlplanung: Löse $h = z\sqrt{p(1-p)/n}$ nach n auf. Wie viele Fälle brauchst du für die Halbbreite $h = 0{,}05$, wenn du $p \approx 0{,}9$ erwartest? Zeige, dass $p(1-p) \le \frac{1}{4}$ für alle p gilt, und berechne damit, wie viele Fälle für $h = 0{,}05$ nach dieser Näherung in jedem Fall reichen. [3 P]

Aufgabe 4 Das Wilson-Intervall herleiten und berechnen

10 Punkte · etwa 24 Min.

Bezug: Modul 9, Lerneinheit 5 (Das Wilson-Intervall: Herleitung und Rechnung)

Das Wilson-Intervall enthält alle wahren Raten $p \in (0,1)$, zu denen die Messung $\hat{p}$ passt:

$$\frac{|\hat{p} - p|}{\sqrt{p(1-p)/n}} \le z. \qquad (*)$$

Kürze $q = z^2/n$ ab. Die Lerneinheit zeigt die Schritte nur knapp, hier führst du sie selbst aus.

(a) Zeige, dass $(*)$ gleichwertig ist zu $f(p) \le 0$ mit

$$f(p) = (1+q)\,p^2 - (2\hat{p} + q)\,p + \hat{p}^2.$$

[2 P]

(b) Zeige, dass die Diskriminante $D = (2\hat{p}+q)^2 - 4(1+q)\,\hat{p}^2$ gleich $4q\,\hat{p}(1-\hat{p}) + q^2$ ist. Leite daraus mit der Mitternachtsformel die Grenzen her:

$$p_{\pm} = \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}.$$

[3 P]

(c) Berechne $f(0)$, $f(1)$ und $f(\hat{p})$. Begründe damit ohne weitere Rechnung, dass $\hat{p}$ im Intervall liegt und beide Grenzen in $[0,1]$ liegen. [2 P]

(d) Berechne das Wilson-Intervall für 23 von 25 Fällen: Nenner, Mitte, Halbbreite, Grenzen. Zur Kontrolle: Die Mitte liegt bei etwa 0,864. [2 P]

(e) Vergleiche mit dem Wald-Intervall aus Aufgabe 3. Darfst du behaupten, die wahre Erfolgsrate des Assistenten betrage „mindestens 90 %“? Erkläre mit der Näherung $\frac{k+2}{n+4}$, warum die Mitte unter $\hat{p}$ liegt. [1 P]

Aufgabe 5 Zwei Prompt-Versionen gepaart vergleichen

9 Punkte · etwa 22 Min.

Bezug: Modul 9, Lerneinheit 6 (gepaarter Vergleich und McNemar) und Lerneinheit 7 (typische Fehlschlüsse)

Du hast Version 1 (V1) und Version 2 (V2) des System-Prompts auf denselben 22 Fällen laufen lassen. Die Auswertung sieht so aus (ausgedachte Werte, Ausgabe des Notebooks gekürzt und um eine Judge-Notiz ergänzt):

```
Version 1: Erfolg 14/22 = 64% (95 %: 43% bis 80%)
Version 2: Erfolg 20/22 = 91% (95 %: 72% bis 97%)
Fälle mit unterschiedlichem Ergebnis:
   N03: V1 falsch   → V2 richtig
   N09: V1 falsch   → V2 richtig
   R01: V1 falsch   → V2 richtig
   R04: V1 falsch   → V2 richtig
   R05: V1 falsch   → V2 richtig
   X01: V1 richtig → V2 falsch    Judge: nennt ein Budget von 180.000 Euro
   X02: V1 falsch   → V2 richtig
   X04: V1 falsch   → V2 richtig
```

(a) Stelle die Vierfeldertafel auf (a: beide richtig, b: nur V1 richtig, c: nur V2 richtig, d: beide falsch) und prüfe sie mit den Erfolgszahlen. [2 P]

(b) Berechne den exakten McNemar-p-Wert. Gib dazu die Verteilung von c unter der Nullhypothese „beide gleich gut“ an, mindestens die Wahrscheinlichkeiten, die in den p-Wert eingehen. [3 P]

(c) Wie viele Verbesserungen c hätte V2 bei unverändertem $b = 1$ mindestens gebraucht, damit $p < 0{,}05$ gilt? [1 P]

(d) Beurteile jede Aussage aus deinem Team in ein bis zwei Sätzen, bei (iii) mit einer Rechnung.

(i) „Die Intervalle überlappen zwischen 72 % und 80 %. Also gibt es keinen Unterschied.“

(ii) „p liegt über 0,05. Also sind beide Versionen gleich gut.“

(iii) „Ich lasse V2 noch zweimal laufen und berichte den besten der drei Läufe.“ (Nimm an, jeder Lauf hat unabhängig 5 % Risiko für einen Fehlalarm.)

[2 P]

(e) Übernimmst du V2? Begründe mit Blick auf den Fall X01. [1 P]

Aufgabe 6 (⋆) Wann darfst du „mindestens 90 %“ sagen?

Zusatz · etwa 10 Min.

Bezug: Vertiefung zu Modul 9, Lerneinheit 5

(a) Dein Assistent besteht alle n Fälle, also $k = n$. Zeige mit der Wilson-Formel, dass die untere Grenze $\frac{n}{n+z^2}$ ist. Zeige ebenso, dass bei $k = 0$ die obere Grenze $\frac{z^2}{n+z^2}$ ist, und prüfe das am Beispiel 0 von 10 aus der Lerneinheit.

(b) Wie viele fehlerfreie Fälle brauchst du mindestens, damit die untere Wilson-Grenze mindestens 0,9 ist? Was liefert das Wald-Intervall bei $k = n$?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Testfälle und Code-Checks für M-04

(a)

Frage	Art	Begründung und Tool
1	normal	typische Alltagsfrage mit gültiger ID; erwartet: `get_machine_status`
2	Rand	ungenauer Name, das System muss „Schleifmaschine in Halle 2“ der M-04 zuordnen; erwartet: `get_machine_status` mit M-04
3	Rand	kombiniert zwei Quellen: letzte Wartung aus der Historie, Soll-Intervall aus dem Handbuch; erwartet: `get_maintenance_history` und `search_knowledge_base` (für die letzte Wartung zählt auch `get_machine_status`)
4	negativ	kein Tool kann den Status ändern, das System soll ablehnen und nichts vortäuschen; verboten: `create_ticket`

Auch Fall 4 braucht eine Referenz und eine Begriffsgruppe, etwa `[["nicht", "kein"]]`.

(b) Gruppe 1 ist `["M-04"]`, Gruppe 2 sind die drei Schreibweisen von 22.310. Verglichen wird nach `lower()`:

Antwort	Gruppe 1	Gruppe 2	`inhalt`	inhaltlich
A	ja	ja (`22.310`)	True	richtig
B	nein	ja (`22310`)	False	richtig
C	ja	ja (`22.310`)	True	falsch
D	ja (`m-04`)	ja (`22 310`)	True	richtig

C besteht fälschlich (die Zahl wird verneint), **B fällt fälschlich durch** (Name statt ID). D besteht zu Recht, der Check ignoriert Groß- und Kleinschreibung.

(c) Fehler B ist ein Formatproblem und lässt sich mit einer erweiterten Gruppe beheben:

```
muss = [["M-04", "Rundschleifmaschine"], ["22310", "22.310", "22 310"]]
```

Fehler C ist eine Verneinung: Ob eine Zahl behauptet oder bestritten wird, sieht nur etwas, das Sprache versteht. Den fängt der LLM-Judge mit Referenz ab.

> **Typischer Fehler**
>
> In einer Gruppe alle Begriffe verlangen. Dann fällt A durch, weil dort nur eine Schreibweise der Zahl steht. Innerhalb einer Gruppe gilt ODER, zwischen den Gruppen UND.

Bewertung: (a) je Frage 0,5 P für Art mit stimmiger Begründung und Tool. (b) 2 P für die vier Wahrheitswerte (je Fehler 0,5 P Abzug), 1 P für die richtige Zuordnung von B und C. (c) 1 P, wenn Änderung und Judge genannt sind.

Lösung zu Aufgabe 2 Den Judge kalibrieren

(a) Auf der Diagonalen stehen die gleichen Labels:

$$p_o = \frac{9 + 2 + 5}{20} = \frac{16}{20} = \boxed{0{,}8}.$$

(b) Randanteile: Hand 0,5/0,2/0,3, Judge $12/20 = 0{,}6$, $3/20 = 0{,}15$, $5/20 = 0{,}25$ (jeweils richtig, teilweise, falsch).

$$p_e = 0{,}5 \cdot 0{,}6 + 0{,}2 \cdot 0{,}15 + 0{,}3 \cdot 0{,}25 = 0{,}30 + 0{,}03 + 0{,}075 = 0{,}405$$

$$\kappa = \frac{0{,}8 - 0{,}405}{1 - 0{,}405} = \frac{0{,}395}{0{,}595} \approx \boxed{0{,}664}$$

Der Judge schafft also knapp zwei Drittel des möglichen Abstands zum Zufall. Die 80 % Übereinstimmung klingen besser, als sie sind.

(c) Vermutlich **Längen-Bias**: Die lange, kompetent klingende Antwort wird trotz falschem Grenzwert als richtig gewertet. Die drei Fälle zählen im Eval als Erfolg, obwohl sie keiner sind. Sie treiben die gemessene Erfolgsrate systematisch nach oben, und kein Wilson-Intervall erfasst das. Nächste Schritte: jeden Fall einzeln ansehen (Rubrik, Handlabel oder Verzerrung?), die Regel „Länge ist kein Qualitätsmerkmal“ ergänzen, „teilweise“ schärfer definieren, neu messen. Die Rubrik dabei nicht endlos an diese 20 Fälle anpassen.

(d) Nicht richtig laut Hand: $4 + 6 = 10$ Fälle, davon als richtig gewertet $2 + 1 = 3$. Richtig laut Hand: 10 Fälle, davon nicht als richtig gewertet $1 + 0 = 1$.

$$\alpha = \frac{3}{10} = 0{,}3, \qquad \beta = \frac{1}{10} = 0{,}1$$

$$p_{\text{gemessen}} = 0{,}6 \cdot 0{,}9 + 0{,}4 \cdot 0{,}3 = 0{,}54 + 0{,}12 = \boxed{0{,}66}$$

Der Judge misst 6 Prozentpunkte zu viel.

(e) Ausmultiplizieren: $p_{\text{gemessen}} = \alpha + p\,(1 - \alpha - \beta)$, also

$$p = \frac{p_{\text{gemessen}} - \alpha}{1 - \alpha - \beta} = \frac{0{,}81 - 0{,}3}{0{,}6} = \boxed{0{,}85}.$$

Grob ist das, weil α und β aus je nur 10 Fällen geschätzt sind: Ein Fall mehr oder weniger ändert α um 0,1. Kalibrierung ist ein Plausibilitätstest, kein exakter Korrekturfaktor.

> **Typischer Fehler**
> p_e aus den Diagonalzellen statt aus den Randsummen bilden, etwa $(9 \cdot 9 + 2 \cdot 2 + 5 \cdot 5)/400$. Richtig ist: Anteil beim Menschen mal Anteil beim Judge, je Label, aus den Zeilen- und Spaltensummen.

Bewertung: (a) 1 P. (b) 1 P Randanteile, 1 P p_e, 1 P κ (Folgefehler aus p_e ohne weiteren Abzug). (c) 1 P Verzerrung mit Begründung, 1 P Wirkung auf die Erfolgsrate und sinnvoller nächster Schritt. (d) 1 P α und β, 1 P p_{gemessen}. (e) 1 P für Umformung, Ergebnis und Grund.

Lösung zu Aufgabe 3 Standardfehler und Wald-Intervall

(a) $\hat{p} = 23/25 = 0{,}92$.

$$\text{SE} = \sqrt{\frac{0{,}92 \cdot 0{,}08}{25}} = \sqrt{0{,}002944} \approx 0{,}0543, \qquad 1{,}96 \cdot 0{,}0543 \approx 0{,}1063$$

$$0{,}92 \pm 0{,}1063 \;\Rightarrow\; \boxed{[\,81{,}4\,\%;\ 102{,}6\,\%\,]}$$

(b) Die Obergrenze liegt über 100 %, eine unmögliche Erfolgsrate. Faustregel: $n\hat{p} = 23$ ist groß genug, aber $n(1-\hat{p}) = 2$ liegt deutlich unter 5 bis 10. Bei zwei Misserfolgen ist $\hat{p}$ nicht annähernd normalverteilt, das Wald-Intervall nimmt aber genau das an (zweite Näherung: $\hat{p}$ statt p im Standardfehler).

(c) Quadrieren und umstellen:

$$h^2 = \frac{z^2\, p(1-p)}{n} \iff n = \frac{z^2\, p(1-p)}{h^2}.$$

Mit $p = 0{,}9$, $h = 0{,}05$: $n = \frac{3{,}8416 \cdot 0{,}09}{0{,}0025} \approx 138{,}3$, also **139 Fälle** (aufrunden).

Schranke: $p(1-p) = p - p^2 = \frac{1}{4} - \left(p - \frac{1}{2}\right)^2 \le \frac{1}{4}$, Gleichheit bei $p = \frac{1}{2}$. Damit reichen nach dieser Näherung in jedem Fall

$$n = \frac{3{,}8416 \cdot 0{,}25}{0{,}0025} = 384{,}16 \;\Rightarrow\; \boxed{385 \text{ Fälle}}.$$

Halbierst du h, vervierfacht sich n, weil h im Nenner quadriert steht.

Typischer Fehler

Bei der Fallzahl abrunden (138 statt 139). Mit 138 Fällen ist die Halbbreite knapp größer als 0,05. Fallzahlen rundest du immer auf.

Bewertung: (a) 1 P SE, 1 P Intervall. (b) 1 P für die Grenze über 100 % mit Faustregel. (c) 1 P Umformung, 1 P $n = 139$, 1 P Schranke mit Begründung und $n = 385$.

Lösung zu Aufgabe 4 Das Wilson-Intervall herleiten und berechnen

(a) Für $0 < p < 1$ ist der Nenner positiv. Beide Seiten von $(*)$ sind nicht negativ, Quadrieren und Multiplizieren mit $p(1-p)/n > 0$ ändern die Ungleichung also nicht:

$$(\hat{p} - p)^2 \le \frac{z^2}{n}\, p(1-p) = q\, p - q\, p^2.$$

Ausmultiplizieren und alles nach links bringen:

$$\hat{p}^2 - 2\hat{p}\, p + p^2 - q\, p + q\, p^2 \le 0 \iff (1+q)\, p^2 - (2\hat{p} + q)\, p + \hat{p}^2 \le 0.$$

(b) Ausmultiplizieren:

$$D = 4\hat{p}^2 + 4\hat{p}\, q + q^2 - 4\hat{p}^2 - 4q\, \hat{p}^2 = 4q\, \hat{p} - 4q\, \hat{p}^2 + q^2 = 4q\, \hat{p}(1-\hat{p}) + q^2.$$

Die Parabel ist nach oben offen ($1 + q > 0$), also gilt $f(p) \le 0$ genau zwischen den Nullstellen. Mitternachtsformel, Zähler und Nenner durch 2 gekürzt:

$$p_{\pm} = \frac{(2\hat{p} + q) \pm \sqrt{D}}{2(1+q)} = \frac{\hat{p} + \frac{q}{2} \pm \frac{1}{2}\sqrt{D}}{1+q}.$$

Mit $q = z^2/n$ gilt

$$\tfrac{1}{2}\sqrt{D} = \sqrt{q\, \hat{p}(1-\hat{p}) + \tfrac{q^2}{4}} = \sqrt{\frac{z^2}{n}\, \hat{p}(1-\hat{p}) + \frac{z^4}{4n^2}} = z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}},$$

und Einsetzen liefert genau die angegebene Formel.

(c) Einsetzen:

$$f(0) = \hat{p}^2 \geq 0, \qquad f(1) = 1 + q - 2\hat{p} - q + \hat{p}^2 = (1-\hat{p})^2 \geq 0,$$
$$f(\hat{p}) = (1+q)\hat{p}^2 - 2\hat{p}^2 - q\,\hat{p} + \hat{p}^2 = q\,\hat{p}^2 - q\,\hat{p} = -q\,\hat{p}(1-\hat{p}) \leq 0.$$

Wegen $f(\hat{p}) \leq 0$ liegt $\hat{p}$ zwischen den Nullstellen. Läge die untere Grenze unter 0, so läge 0 echt zwischen den Nullstellen (denn $0 \leq \hat{p}$), also $f(0) < 0$, im Widerspruch zu $f(0) \geq 0$. Ebenso folgt aus $f(1) \geq 0$ und $\hat{p} \leq 1$, dass die obere Grenze höchstens 1 ist.

(d) $n = 25$, $\hat{p} = 0{,}92$:

$$\frac{z^2}{n} = \frac{3{,}8416}{25} = 0{,}153664, \qquad \text{Nenner} = 1{,}153664$$

$$\text{Mitte} = \frac{0{,}92 + 0{,}076832}{1{,}153664} = \frac{0{,}996832}{1{,}153664} \approx 0{,}8641$$

$$\text{Halbbreite} = \frac{1{,}96\sqrt{0{,}002944 + 0{,}00153664}}{1{,}153664} = \frac{1{,}96 \cdot 0{,}066938}{1{,}153664} \approx 0{,}1137$$

$$\boxed{[\,0{,}750;\ 0{,}978\,] \ \Rightarrow\ 75{,}0\,\%\ \text{bis}\ 97{,}8\,\%}$$

(e) Wald lieferte 81,4 % bis 102,6 %, Wilson bleibt unter 100 %. „Mindestens 90 %“ ist **nicht belegt**, die Untergrenze liegt bei 75 %. Mitte: $\frac{k+z^2/2}{n+z^2} \approx \frac{23+2}{25+4} = \frac{25}{29} \approx 0{,}862$. Wilson tut so, als hättest du etwa zwei Erfolge und zwei Misserfolge mehr gesehen. Das zieht die extreme Messung 0,92 zur Mitte hin.

> **Typischer Fehler**
> Unter der Wurzel $\frac{z^2}{4n}$ statt $\frac{z^2}{4n^2}$ rechnen. Hier ergäbe das 0,038416 statt 0,0015366, und die Halbbreite wäre etwa dreimal so groß. Auch häufig: die Mitte nicht durch den Nenner teilen und 0,92 als Mitte nehmen.

Bewertung: (a) 1 P Quadrieren mit Begründung, 1 P Umformung. (b) 1 P Diskriminante, 2 P Herleitung der Grenzen. (c) 1 P die drei Funktionswerte, 1 P Schluss. (d) 1 P Mitte, 1 P Halbbreite und Grenzen (Folgefehler ohne weiteren Abzug). (e) 1 P.

Lösung zu Aufgabe 5 Zwei Prompt-Versionen gepaart vergleichen

(a) Aus der Liste: $b = 1$ (X01), $c = 7$. Dann $a = 14 - b = 13$ und $d = 22 - a - b - c = 1$.

	V2 richtig	V2 falsch
V1 richtig	$a = 13$	$b = 1$
V1 falsch	$c = 7$	$d = 1$

Probe: V1 hat $a + b = 14$ richtig, V2 hat $a + c = 20$ richtig, insgesamt $13 + 1 + 7 + 1 = 22$.

(b) Unter H_0 gilt $c \sim \text{Bin}(8, \frac{1}{2})$, es gibt $2^8 = 256$ gleich wahrscheinliche Folgen. Mindestens so ungleich wie $c = 7$ sind $c \in \{7, 8\}$ und auf der anderen Seite $c \in \{0, 1\}$:

$$P(c = 0) = P(c = 8) = \tfrac{1}{256}, \qquad P(c = 1) = P(c = 7) = \tfrac{8}{256}.$$

$$p = \min\left(1,\ 2\sum_{i=0}^{1}\binom{8}{i}0{,}5^8\right) = 2 \cdot \frac{1+8}{256} = \frac{18}{256} = 0{,}0703125 \approx \boxed{0{,}070}$$

(c) Mit $b = 1$ und $n = 1 + c$ Wechseln ist $p = 2(1 + n)/2^n$. Für $c = 7$: 0,070. Für $c = 8$: $p = 2 \cdot 10/512 \approx 0{,}039 < 0{,}05$. Also **mindestens** $c = 8$, ein einziger zusätzlicher Gewinn.

(d) (i) Falsch. Überlappende Intervalle sind ein grobes, vorsichtiges Kriterium. Beide Versionen liefen auf denselben Fällen. Der gepaarte Test nutzt das und schaut nur auf die 8 Wechsel, von denen 7 zugunsten von V2 ausgehen.

(ii) Falsch. Ein großer p-Wert heißt nur, dass die Daten keinen Unterschied nachweisen. Fehlender Nachweis ist kein Nachweis der Gleichheit. Hier fehlt sogar nur ein Wechsel bis zur Grenze.

(iii) Unzulässig. Die Chance auf mindestens einen Fehlalarm in drei Läufen ist $1-0{,}95^3 \approx 0{,}143$, also fast dreimal so hoch wie bei einem Lauf. Lege vorher fest, was du misst, und berichte alle Läufe.

(e) Noch nicht. X01 ist eine Regression in einem Negativfall: V2 erfindet ein Budget, und das kann schwerer wiegen als mehrere Gewinne. Sieh dir den Fall an, schärfe die Regel gegen erfundene Zahlen, miss erneut und behalte X01 als Testfall. Bleiben die Gewinne und ist die Regression behoben, übernimmst du V2.

Typischer Fehler

Nur den Summanden für $i = 0$ nehmen: $p = 2/256 \approx 0{,}008$. Die Summe läuft bis $\min(b, c) = 1$, beide Summanden gehören dazu. Ebenso falsch ist es, den Faktor 2 wegzulassen (einseitig, 0,035).

Bewertung: (a) 1 P b und c, 1 P a und d mit Probe. (b) 1 P Verteilung, 1 P richtige Summanden, 1 P p-Wert. (c) 1 P. (d) 2 P, wenn alle drei Aussagen stimmig beurteilt sind und (iii) die Rechnung enthält, 1 P bei zwei stimmigen Aussagen. (e) 1 P für eine Entscheidung, die die Regression ernst nimmt.

Lösung zu Aufgabe 6 Wann darfst du „mindestens 90 %“ sagen? (Zusatz)

(a) Bei $\hat{p} = 1$ verschwindet $\hat{p}(1 - \hat{p})$, die Halbbreite ist

$$\frac{z\sqrt{z^2/(4n^2)}}{1 + z^2/n} = \frac{z^2/(2n)}{1 + z^2/n}.$$

Die Mitte ist $\frac{1+z^2/(2n)}{1+z^2/n}$. Bei $\hat{p} = 0$ sind Mitte und Halbbreite beide gleich $\frac{z^2/(2n)}{1+z^2/n}$. Damit gilt

$$k = n: \quad \text{untere Grenze} = \frac{1}{1 + z^2/n} = \frac{n}{n + z^2},$$
$$k = 0: \quad \text{obere Grenze} = \frac{z^2/n}{1 + z^2/n} = \frac{z^2}{n + z^2}.$$

Für 0 von 10: $\frac{3{,}8416}{13{,}8416} \approx 0{,}278$, wie in der Lerneinheit (0 % bis 28 %).

(b) $\frac{n}{n+z^2} \geq 0{,}9 \iff n \geq 0{,}9\,n + 0{,}9\,z^2 \iff n \geq 9z^2 = 34{,}57$. Also **mindestens 35 fehlerfreie Fälle** ($35/38{,}8416 \approx 0{,}901$, bei 34 nur 0,898). Wald liefert bei $k = n$ immer $[\,100\,\%;\ 100\,\%\,]$, egal wie klein n ist, und täuscht damit Sicherheit vor.