Tutoriumsblatt 11

Context Engineering und Memory

Bearbeitungszeit etwa 90 Minuten · 40 Punkte · Lösungen im Anhang ab Seite 5

Nach diesem Blatt kannst du

- eine Kontextbilanz aufstellen und die Kursformel für den Verlauf begründen,
- das Wachstum des Inputs über n Fragen analysieren und in Referenzkosten umrechnen,
- Kürzen und Kompaktieren durchrechnen und den Schnittpunkt in einem Verlauf bestimmen,
- entscheiden, was in ein Memory gehört, und die Grenzen eines Namensfilters belegen,
- Prompt Caching von Hand rechnen und seine Gewinnschwelle herleiten.

So arbeitest du mit dem Blatt

Bearbeite die Aufgaben der Reihe nach, sie folgen den Lerneinheiten 1 bis 7. Aufgabe 3 rechnet mit den Zahlen aus Aufgabe 2 weiter. Taschenrechner ist erlaubt. Runde Prozentwerte auf eine Nachkommastelle und Cent auf zwei. Alle Token-Zahlen sind ausgedachte Beispielwerte. Kommerzielle Referenz sind die Preise für Claude Haiku 4.5 (Stand 04.10.2026) pro Million Tokens: Input 1 USD, Output 5 USD, Cache schreiben 1,25 USD, Cache lesen 0,10 USD. In der KI-Toolbox zahlst du nichts. Bezug zum Notebook: Aufgabe 1 und 2 liefern die Theorie zu TODO 1 und 2, Aufgabe 3 zu TODO 3 und 4, Aufgabe 4 zu TODO 5 bis 7, Aufgabe 5 zu TODO 8. Dort misst du die echten Werte.

Aufgabe 1 Kontextbilanz einer Spätschicht

8 Punkte · etwa 16 Min.

Bezug: Modul 11, Lerneinheit 2 (Den Kontext messen: die Kontextbilanz)

Am Ende einer Spätschicht hat der Instandhaltungs-Agent der Nordwerk GmbH acht Fragen beantwortet. Wie im Notebook zählst du mit vier Mini-Anfragen (`max_tokens=1`) die Input-Tokens im Feld `usage.prompt_tokens`:

Zählung	Inhalt der Mini-Anfrage	Tokens
z_0	nur Platzhalter-Nachricht	14
z_S	System-Prompt und Platzhalter	264
z_T	System-Prompt, Tools und Platzhalter	2 064
z_V	System-Prompt, Tools und echter Verlauf statt Platzhalter	10 000

(a) Berechne die Anteile S (System-Prompt), T (Tools) und V (Verlauf) mit den Formeln aus der Lerneinheit: $S = z_S - z_0$, $T = z_T - z_S$ und $V \approx z_V - z_T + z_0$. Gib jeden Anteil auch in Prozent von z_V an und mache die Probe. [3 P]

(b) Die Lerneinheit beschreibt die Zählungen mit der Verpackung c der Chat-Vorlage und der Platzhalter-Nachricht p:

$$z_0 = c + p, \qquad z_S = c + S + p, \qquad z_T = c + S + T + p, \qquad z_V = c + S + T + V.$$

Zeige erstens, dass die Probe $S + T + V_{\text{Kurs}} = z_V$ mit $V_{\text{Kurs}} = z_V - z_T + z_0$ für beliebige Zählergebnisse aufgeht. Zeige zweitens, dass V_{Kurs} den wahren Verlauf V um genau c überschätzt. Schätze drittens mit $z_0 = 14$ ab, wie groß dieser Fehler relativ zu V höchstens ist. [3 P]

(c) Der Verlauf besteht aus 8 Fragen mit je 25 Tokens, 8 Schlussantworten mit je 120 Tokens und 10 Tool-Aufrufen mit je 35 Tokens. Der Rest sind Tool-Ergebnisse. Berechne den Anteil der Tool-Ergebnisse an z_V. Begründe in zwei Sätzen, wo du den Kontext zuerst verkleinerst und welche Teile du wegen des Cachings vorne und unverändert lässt. [2 P]

Aufgabe 2 Wachstum des Verlaufs und kumulierte Kosten

8 Punkte · etwa 17 Min.

Bezug: Modul 11, Lerneinheit 1 (Der Kontext ist ein Budget)

In der Nachtschicht stellt ein Instandhalter einem Agenten mit längerem System-Prompt 30 Fragen. Der feste Anfang jeder Anfrage (System-Prompt, Tools, aktuelle Frage) hat $T_0 = 3000$ Tokens. Jede Runde (Frage, Tool-Ergebnisse, Antwort) bringt $\Delta = 800$ Tokens in den Verlauf. Wie in der Lerneinheit gilt

$$\text{Anfrage}_k = T_0 + (k-1)\,\Delta, \qquad S(n) = n\,T_0 + \frac{n(n-1)}{2}\,\Delta.$$

(a) Berechne die Anfragen bei Frage 1, 10 und 30 sowie $S(10)$ und $S(30)$. [2 P]

(b) In $S(n)$ ist $n\,T_0$ der feste Anteil und $\frac{n(n-1)}{2}\Delta$ der Verlaufsanteil. Leite allgemein her, ab welcher Fragenzahl n der Verlaufsanteil größer ist als der feste Anteil. Werte die Bedingung für die Nachtschicht aus und prüfe sie an den Nachbarzahlen. [3 P]

(c) Pro Frage erzeugt das Modell insgesamt 150 Output-Tokens. Berechne die kommerziellen Referenzkosten der Schicht mit 30 Fragen ohne Caching in Cent und den Anteil des Inputs. Zur Kontrolle: $S(30) = 438\,000$. [2 P]

(d) Eine lange Schicht hat 60 statt 30 Fragen. Um welchen Faktor wachsen die Input-Tokens? Begründe, warum der Faktor zwischen 2 und etwa 4 liegt. [1 P]

Aufgabe 3 Kürzen und Kompaktieren durchrechnen

10 Punkte · etwa 22 Min.

Bezug: Modul 11, Lerneinheit 3 (Auswählen, kürzen, zusammenfassen, kompaktieren) und Lerneinheit 4 (Kompaktieren: wo schneiden, was behalten)

Du rechnest mit dem Zahlenmodell aus Aufgabe 2 weiter: $T_0 = 3000$, $\Delta = 800$, 30 Fragen. Zur Kontrolle: Ohne Gegenmaßnahmen ist $S(30) = 438\,000$.

(a) *Kürzen an der Quelle.* Von den $\Delta = 800$ Tokens pro Runde entfallen 500 auf Tool-Ergebnisse. Ein knappes Sensor-Tool wie in Bonus B2 gibt nur auffällige Messwerte und die Anzahl der übrigen zurück. Es kürzt die Tool-Ergebnisse um 60 %. Berechne Δ', die neue Summe $S'(30)$ und die Ersparnis in Prozent. Erkläre mit der Formel für $S(n)$, warum ein gekürztes Tool-Ergebnis aus Runde k mehrfach spart. [3 P]

(b) *Schreibtischtest zu TODO 3.* Ein Verlauf hat diese Nachrichten (F: Frage, A: Antwort):

Index	Rolle	Index	Rolle
0	`user` (F1)	8	`assistant` (A2)
1	`assistant` mit 2 Tool-Aufrufen	9	`user` (F3)
2	`tool`	10	`assistant` (A3)
3	`tool`	11	`user` (F4)
4	`assistant` (A1)	12	`assistant` mit 1 Tool-Aufruf
5	`user` (F2)	13	`tool`
6	`assistant` mit 1 Tool-Aufruf	14	`assistant` (A4)
7	`tool`		

Bestimme die Menge Q der Fragen-Indizes und den Rückgabewert von `finde_schnitt` für $b = 2$ und $b = 4$. Wie viele Nachrichten hat die Liste für $b = 2$ nach `kompaktiere` (Zusammenfassung und „Verstanden.“ davor)? Warum wäre ein Schnitt bei Index 7 falsch? [2 P]

(c) *Kompaktierung im Zahlenmodell.* Liegt die letzte Anfrage über der Schwelle von 8000 Tokens, wird vor der nächsten Frage kompaktiert. Die letzten $b = 2$ Fragen bleiben vollständig, die Zusammenfassung samt „Verstanden.“ hat $Z = 400$ Tokens.
(i) Vor welcher Frage wird zum ersten Mal kompaktiert, und wie groß ist die Anfrage danach?
(ii) Zeige allgemein: Direkt nach einer Kompaktierung hat die Anfrage die Größe $A^* = T_0 + Z + b\,\Delta$. Gilt $A^* \le$ Schwelle, dann ist keine Anfrage größer als Schwelle $+\,\Delta$. Folgere, dass die Summe aller Input-Tokens mit Kompaktierung höchstens linear in n wächst. Was passiert, wenn $A^* >$ Schwelle ist? [3 P]

(d) Zur Kontrolle: Die Anfragen 1 bis 8 ergeben zusammen 46 400 Tokens, danach wiederholt sich ein Zyklus aus fünf Anfragen ab 5000 Tokens. Jede Zusammenfassung ist ein eigener Aufruf mit dem alten Teil des Verlaufs plus 100 Tokens Zusammenfassungs-Prompt als Input: beim ersten Mal sechs Runden, danach jeweils Z und fünf Runden. Berechne die Summe aller Input-Tokens mit Kompaktierung (Anfragen und Zusammenfassungen) und die Ersparnis gegenüber $S(30)$. [2 P]

Aufgabe 4 Ein Memory für die Instandhaltung

6 Punkte · etwa 14 Min.

Bezug: Modul 11, Lerneinheit 5 (Memory: Kurzzeit, Langzeit und zwei Tools) und Lerneinheit 6 (Datenschutz im Code)

Der Agent soll sich Befunde über Schichten hinweg merken. `remember_sicher` aus TODO 7 prüft vor dem Speichern Namen als ganze Wörter und sensible Begriffe als Wortanfang:

```
PERSONEN = ["Yilmaz", "Becker", "Nguyen", "Schäfer", "Wolf", "Kowalski"]
SENSIBEL = ["krank", "arzt", "privat", "leistungsbewertung",
            "beurteilung", "abmahnung", "fehlzeit"]
text = thema + " " + inhalt
name = any(re.search(rf"\b{re.escape(p)}\b", text, re.IGNORECASE)
           for p in PERSONEN)
sens = any(re.search(rf"\b{re.escape(w)}", text, re.IGNORECASE)
           for w in SENSIBEL)
# name oder sens: ValueError, sonst remember(thema, inhalt)
```

(a) Entscheide für jede Notiz, ob sie in ein Instandhaltungs-Memory gehört. Begründe mit einem Grundsatz oder Artikel der DSGVO aus der Lerneinheit.
(A) „M-05: Kühlmittel am Brenner 68 °C über Grenzwert 60 °C, Kühler gereinigt.“
(B) „Die Bedienerin der Waschanlage in der Nachtschicht vom 14.10. arbeitet zu langsam.“
(C) „M-03: Spindellagersatz HTD-1100 hat 6 Wochen Lieferzeit, Bestand prüfen.“
(D) „Die Schichtleitung von Halle 2 fehlt nach einem Bandscheibenvorfall.“ [2 P]

(b) Spiele den Filter für die drei Notizen von Hand durch: gespeichert oder abgelehnt? Ist das Ergebnis richtig, ein Fehlalarm oder ein Durchrutscher?
N1: Thema „M-07“, Inhalt „Ersatzlüfter vom Lieferanten Becker kommt erst in KW 44“
N2: Thema „M-07“, Inhalt „Prüfung verschoben, weil der Schichtleiter nach einem Zahnarzttermin später kam“
N3: Thema „Schicht“, Inhalt „Fehlzeiten der Nachtschicht im Oktober auswerten“ [2 P]

(c) `memory.json` enthält die IDs 1 bis 5. Du rufst `vergiss(2)` und `vergiss(5)` auf, danach zweimal `remember`. Welche IDs entstehen, wenn die neue ID die größte vorhandene ID plus 1 ist, und welche bei Anzahl der Einträge plus 1? Was bewirkt dann ein späteres `vergiss(4)`? [2 P]

Aufgabe 5 Prompt Caching von Hand

8 Punkte · etwa 18 Min.

Bezug: Modul 11, Lerneinheit 7 (Prompt Caching: gleiche Präfixe wiederverwenden)

Wie in TODO 8 liegt das Handbuch im System-Prompt. Der Präfix hat $P = 10\,000$ Tokens und liegt über der Mindestlänge des Anbieters. Ein Instandhalter stellt $N = 8$ Fragen im Abstand von jeweils weniger als 5 Minuten. Der Cache lebt 5 Minuten, jeder Treffer startet die Frist neu. Für eine Anfrage gilt

$$K = (n_{\text{in}} + 1{,}25\, n_{\text{write}} + 0{,}1\, n_{\text{read}})\, p_{\text{in}} + n_{\text{out}}\, p_{\text{out}}, \qquad p_{\text{in}} = \frac{1\ \text{USD}}{10^6}, \quad p_{\text{out}} = \frac{5\ \text{USD}}{10^6}.$$

(a) Berechne die Kosten nur für den Präfix über alle 8 Fragen ohne und mit Caching und die Ersparnis. [2 P]

(b) Allgemein kostet Schreiben das w-Fache und Lesen das r-Fache des Input-Preises, mit $w > 1 > r > 0$. Leite für die Ersparnis $E(N) = 1 - K_{\text{mit}}/K_{\text{ohne}}$ des Präfixes her:

$$E(N) = 1 - r - \frac{w - r}{N}, \qquad E(N) > 0 \iff N > \frac{w - r}{1 - r}.$$

Schreibe dazu $K_{\text{mit}}/K_{\text{ohne}}$ zuerst als $r + \frac{w-r}{N}$. Welcher Grenzwert ergibt sich für $N \to \infty$? Werte Schwelle und Grenzwert für $w = 1{,}25$ und $r = 0{,}1$ aus. Ab welchem N beträgt die Ersparnis mindestens 85 %? [3 P]

(c) Realistischer: Jede Frage hat 30 Input-Tokens, jede Antwort 120 Output-Tokens. Beides wird nie gecacht. Berechne die Gesamtkosten der 8 Fragen ohne und mit Caching und die Ersparnis. Warum ist sie kleiner als in (a)? [2 P]

(d) Nach Frage 4 macht der Instandhalter 12 Minuten Pause. Die Fragen 5 bis 8 folgen wieder zügig. Was kostet der Präfix jetzt mit Caching? [1 P]

Aufgabe 6 (⋆) Verdünnte Aufmerksamkeit im Spielzeugmodell

Zusatz · etwa 10 Min.

Bezug: Modul 11, Lerneinheit 1, Vertiefung zum dritten Grund für einen sparsamen Kontext

Im Spielzeugmodell der Lerneinheit hat ein relevantes Token den Score s, N irrelevante Tokens haben den Score 0. Die Softmax gibt dem relevanten Token das Gewicht $\alpha_{\text{rel}} = e^s/(e^s + N)$.

(a) Sei $s = 3$. Ab welchem N fällt α_{rel} unter 0,1?

(b) Welchen Score s braucht das relevante Token, damit es bei $N = 10\,000$ noch mindestens die Hälfte des Gewichts bekommt? Um wie viel muss s steigen, wenn sich N verdoppelt?

(c) Was folgt daraus für das Kontextbudget? Wo liegt die Grenze dieses Modells?

Anhang: Lösungen

Erst selbst rechnen, dann vergleichen. Die Lösungen zeigen den Rechenweg und typische Fehler.

Lösung zu Aufgabe 1 Kontextbilanz einer Spätschicht

(a) Differenzen der Zählungen:

$$S = 264 - 14 = 250, \qquad T = 2064 - 264 = 1800, \qquad V \approx 10\,000 - 2064 + 14 = 7950.$$

Anteile an $z_V = 10\,000$: System 2,5 %, Tools 18,0 %, Verlauf 79,5 %.
Probe: $250 + 1800 + 7950 = 10\,000 = z_V$. **Bilanz:** $S = 250$**,** $T = 1800$**,** $V = 7950$**.**

(b) *Probe allgemein.* Setze die drei Formeln ein:

$$(z_S - z_0) + (z_T - z_S) + (z_V - z_T + z_0) = z_V.$$

Jede Zwischenzählung kommt einmal mit Plus und einmal mit Minus vor (Teleskopsumme). Die Probe geht deshalb für beliebige Zahlen auf.

Überschätzung um c. Im Modell gilt

$$z_V - z_T = (c + S + T + V) - (c + S + T + p) = V - p \quad \Rightarrow \quad V = z_V - z_T + p.$$

Die Kursformel addiert statt p die ganze erste Zählung $z_0 = c + p$:

$$V_{\text{Kurs}} = z_V - z_T + c + p = V + c.$$

Abschätzung. Die Platzhalter-Nachricht hat mindestens ein Token, also $c = z_0 - p < z_0 = 14$. Relativer Fehler: höchstens $13/7937 \approx 0{,}16\,\%$, grob $< 14/7950 \approx 0{,}18\,\%$ (beides richtig). **Die Kursformel ordnet höchstens 13 Tokens Verpackung dem Verlauf zu.** Das ist für die Bilanz unerheblich, dafür geht die Probe exakt auf.

(c) Tool-Ergebnisse: $7950 - 8 \cdot 25 - 8 \cdot 120 - 10 \cdot 35 = 7950 - 200 - 960 - 350 = 6440$ Tokens, also 64,4 % **von** z_V (81 % des Verlaufs).
Musterbegründung: Den größten Hebel haben die Tool-Ergebnisse. Sie kürzt du zuerst, am besten an der Quelle mit knappen Tools oder durch Auswählen. Den System-Prompt (2,5 %) zu kürzen bringt kaum etwas. System-Prompt und Tools (zusammen 20,5 %) sind fest, sie bleiben vorne und unverändert, damit sie gecacht werden können.

> **Typischer Fehler**
>
> Beim Verlauf nur $z_V - z_T = 7936$ rechnen. Dann fehlt die Platzhalter-Nachricht, die in z_T steckt, in z_V aber durch den Verlauf ersetzt ist. Die Probe ergibt $9986 \neq 10\,000$.

Bewertung: (a) 1 P für S, T, V, 1 P für die Prozentwerte, 1 P für die Probe. (b) je 1 P für Teleskopsumme, Überschätzung um c und Abschätzung. (c) 1 P Rechnung, 1 P Begründung (Tool-Ergebnisse zuerst, feste Teile vorne).

Lösung zu Aufgabe 2 Wachstum des Verlaufs und kumulierte Kosten

(a) $\text{Anfrage}_1 = 3000$, $\text{Anfrage}_{10} = 3000 + 9 \cdot 800 = 10\,200$, $\text{Anfrage}_{30} = 3000 + 29 \cdot 800 = 26\,200$.

$$S(10) = 10 \cdot 3000 + 45 \cdot 800 = 30\,000 + 36\,000 = 66\,000,$$

$$S(30) = 30 \cdot 3000 + 435 \cdot 800 = 90\,000 + 348\,000 = \mathbf{438\,000}.$$

Kontrolle mit dem Mittelwert aus erster und letzter Anfrage: $30 \cdot \frac{3000 + 26\,200}{2} = 30 \cdot 14\,600 = 438\,000$.

(b) Der Verlaufsanteil ist größer als der feste Anteil, wenn

$$\frac{n(n-1)}{2}\,\Delta > n\,T_0 \iff \frac{(n-1)\,\Delta}{2} > T_0 \iff n > 1 + \frac{2\,T_0}{\Delta}.$$

Im zweiten Schritt teilst du durch $n > 0$. Nachtschicht: $1 + \frac{2 \cdot 3000}{800} = 8{,}5$, also **ab der 9. Frage**. Prüfung: $n = 8$: Verlauf $28 \cdot 800 = 22\,400 < 24\,000 = 8 \cdot 3000$. $n = 9$: Verlauf $36 \cdot 800 = 28\,800 > 27\,000 = 9 \cdot 3000$.

(c) Input: $438\,000 \cdot \frac{1\ \text{USD}}{10^6} = 0{,}438$ USD $= 43{,}80$ ct.
Output: $30 \cdot 150 = 4500$ Tokens, $4500 \cdot \frac{5\ \text{USD}}{10^6} = 0{,}0225$ USD $= 2{,}25$ ct.
Gesamt 46,05 **Cent pro Schicht**, davon Input $43{,}80/46{,}05 \approx 95{,}1\,\%$.

(d) $S(60) = 60{\cdot}3000 + 1770{\cdot}800 = 180\,000 + 1\,416\,000 = 1\,596\,000$, Faktor $1\,596\,000/438\,000 \approx \mathbf{3{,}64}$. Begründung: Der feste Anteil verdoppelt sich (Faktor 2). Der Verlaufsanteil wächst mit $\frac{60 \cdot 59}{30 \cdot 29} = \frac{1770}{435} \approx 4{,}07$, also etwa quadratisch. Der Gesamtfaktor ist das gewichtete Mittel: $0{,}205 \cdot 2 + 0{,}795 \cdot 4{,}07 \approx 3{,}64$ mit den Anteilen von $S(30)$. Er liegt deshalb zwischen 2 und etwa 4.

> **Typischer Fehler**
> Mit $\frac{n(n+1)}{2}$ statt $\frac{n(n-1)}{2}$ rechnen. Dann ergibt sich $S(30) = 462\,000$. Bei Frage 1 ist der Verlauf aber noch leer, bei Frage k stecken nur $k-1$ Runden darin.

Bewertung: (a) 1 P Anfragen, 1 P Summen. (b) 2 P Herleitung der Bedingung, 1 P Auswertung mit Prüfung. (c) 1 P Kosten, 1 P Anteil. (d) 1 P Faktor mit Begründung. Folgefehler aus (a) werden in (c) und (d) nicht erneut abgezogen.

Lösung zu Aufgabe 3 Kürzen und Kompaktieren durchrechnen

(a) $\Delta' = 800 - 0{,}6 \cdot 500 = 500$ Tokens.

$$S'(30) = 30 \cdot 3000 + 435 \cdot 500 = 90\,000 + 217\,500 = 307\,500.$$

Ersparnis $438\,000 - 307\,500 = 130\,500$ Tokens, also $29{,}8\,\%$.
Grund: Das Tool-Ergebnis aus Runde k bleibt im Verlauf und steht in allen Anfragen $k+1$ bis n, also $(n-k)$-mal. Über alle Runden sind das $\sum_{k=1}^{n}(n-k) = \frac{n(n-1)}{2} = 435$ Wiederholungen. Jedes in Δ gesparte Token spart über die Schicht 435 Tokens: $300 \cdot 435 = 130\,500$.

(b) Fragen erkennst du an der Rolle `user`: $Q = \{0, 5, 9, 11\}$. Mit $b = 2$ liegt der Schnitt bei der zweitletzten Frage, **Index 9**. Mit $b = 4$ gibt es nur $|Q| = 4 = b$ Fragen, also nichts Altes: Rückgabe **0**, es wird nicht kompaktiert. Für $b = 2$ werden die Indizes 9 bis 14 behalten, also 6 Nachrichten. Mit Zusammenfassung und „Verstanden.“ hat die neue Liste **8 Nachrichten**. Index 7 ist ein Tool-Ergebnis. Sein Tool-Aufruf steht in Index 6 und verschwände in der Zusammenfassung. Eine `tool`-Nachricht ohne passenden Aufruf lehnt die API ab.

(c) (i) Die Anfragen sind $3000, 3800, \ldots, 7800$ (Frage 7) und 8600 (Frage 8). Frage 8 liegt erstmals über 8000, also wird **vor Frage 9** kompaktiert. Danach:

$$A_9 = T_0 + Z + 2\,\Delta = 3000 + 400 + 1600 = \mathbf{5000}.$$

(ii) Nach einer Kompaktierung besteht der Verlauf aus der Zusammenfassung (Z) und den b behaltenen Runden ($b\Delta$). Dazu kommt der feste Anfang T_0, also $A^* = T_0 + Z + b\,\Delta$. Danach wächst jede Anfrage um Δ. Kompaktiert wird, sobald eine Anfrage über der Schwelle liegt. Die Anfrage davor lag höchstens auf der Schwelle, denn $A^* \le$ Schwelle und vor der ersten

Kompaktierung $T_0 \leq$ Schwelle. Also ist jede Anfrage $\leq$ Schwelle $+ \Delta$, hier 8800 (tatsächlich höchstens 8600).
Damit gilt für die Anfragen $\sum_k A_k \leq n\,(\text{Schwelle} + \Delta)$. Jeder Zusammenfassungs-Aufruf liest nur einen Teil des Verlaufs dieser Anfragen plus den kurzen Zusammenfassungs-Prompt, und es gibt höchstens n davon. **Die Gesamtsumme wächst also höchstens linear in** n, ohne Kompaktierung quadratisch.
Ist $A^* >$ Schwelle, liegt schon die erste Anfrage nach der Kompaktierung über der Schwelle. Dann wird vor jeder Frage kompaktiert: viele zusätzliche Aufrufe, und der Cache für den Verlauf ist jedes Mal ungültig. Abhilfe: höhere Schwelle, kürzere Zusammenfassung oder kleineres b.

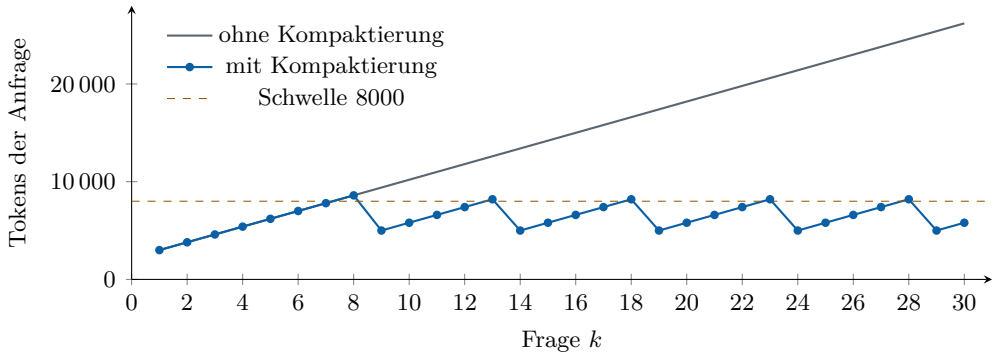
(d) Zyklus: $5000 + 5800 + 6600 + 7400 + 8200 = 33\,000$. Die Fragen 9 bis 28 sind vier Zyklen, dazu kommen die Fragen 29 und 30:

$$\sum A_k = 46\,400 + 4 \cdot 33\,000 + (5000 + 5800) = 46\,400 + 132\,000 + 10\,800 = 189\,200.$$

Kompaktiert wird vor den Fragen 9, 14, 19, 24 und 29, also fünfmal:

$$\underbrace{6 \cdot 800 + 100}_{4900} + 4 \cdot \underbrace{(400 + 5 \cdot 800 + 100)}_{4500} = 4900 + 18\,000 = 22\,900.$$

Gesamt $189\,200 + 22\,900 = 212\,100$ **Tokens, Ersparnis** $1 - 212\,100/438\,000 \approx 51{,}6\,\%$**.**
Ehrlich gerechnet kommen noch bis zu $5 \cdot 400 = 2000$ Output-Tokens der Zusammenfassungen dazu (kommerziell höchstens 1 Cent), gegenüber 225 900 gesparten Input-Tokens (22,59 Cent). Offen bleibt die Qualität: Was die Zusammenfassung vergisst, ist verloren.



Typischer Fehler

Die Zusammenfassungs-Aufrufe vergessen. Dann ergibt sich eine Ersparnis von 56,8 % statt 51,6 %. Die Zusammenfassung ist ein eigener Aufruf mit eigenem Input und Output.

Bewertung: (a) 1 P Δ' und $S'(30)$, 1 P Ersparnis, 1 P Begründung mit $\frac{n(n-1)}{2}$. (b) 1 P Q und beide Rückgabewerte (9 und 0), 1 P Länge 8 und Begründung zu Index 7. (c) 1 P für (i), 2 P für (ii): Größe A^*, Schranke Schwelle $+ \Delta$, lineares Wachstum. (d) 1 P Summe der Anfragen, 1 P Zusammenfassungen und Ersparnis.

Lösung zu Aufgabe 4 Ein Memory für die Instandhaltung

(a) (A) **Ja.** Fachlicher Befund mit Maschine und Messwert, genau der Zweck des Memorys.
(B) **Nein.** Eine Leistungsbewertung. Die Person ist über Anlage, Schicht und Datum identifizierbar, also personenbezogen (Art. 4). Das Memory dient der Instandhaltung, nicht der Leistungskontrolle (Zweckbindung, Art. 5).

(C) **Ja.** Offener Punkt zur Maschine, wichtig für die Planung.
(D) **Nein.** Gesundheitsdaten (Art. 9) einer identifizierbaren Person, für die Instandhaltung nicht nötig (Datenminimierung, Art. 5).
Für (A) und (C) gilt zusätzlich die Speicherbegrenzung: Zeitstempel und Löschfrist.

(b) N1: „Becker“ steht als ganzes Wort zwischen Leerzeichen, der Namensfilter schlägt an: **abgelehnt, Fehlalarm**. Becker ist hier ein Lieferant, kein Mitarbeiter, und die Notiz ist fachlich wichtig. Die Wortgrenze hilft nicht. Besser wäre eine Lieferanten-Nummer statt eines Namens.
N2: Kein Name aus der Liste. „arzt“ steckt in „Zahnarzttermin“, aber nicht am Wortanfang, also passt `\barzt` nicht: **gespeichert, Durchrutscher**. Die Notiz verrät einen Gesundheitsbezug einer identifizierbaren Person. Richtig wäre nur „Prüfung M-07 verschoben“ ohne Grund. Ein naiver Teilstring-Vergleich hätte sie abgelehnt: weniger Fehlalarme erkaufst du mit mehr Durchrutschern.
N3: „Fehlzeiten“ beginnt mit „fehlzeit“: **abgelehnt, richtig**. Eine Auswertung von Fehlzeiten ist Anwesenheitskontrolle und nicht der Zweck des Memorys.

(c) Nach dem Löschen bleiben die IDs 1, 3, 4.
Größte ID plus 1: $4+1=5$, dann $5+1=6$. **Ergebnis** $[1,3,4,5,6]$**, alle IDs eindeutig.**
Anzahl plus 1: $3+1=4$ (gibt es schon), dann $4+1=5$. **Ergebnis** $[1,3,4,4,5]$ **mit doppelter ID 4.**
`vergiss(4)` behält nur Einträge mit `id != 4` und löscht damit beide, also auch die neue Notiz. Auch die Reihenfolge von `recall` (nach ID absteigend) ist dann nicht mehr eindeutig.
Hinweis: Mit „größte ID plus 1“ bekommt die neue Notiz die ID 5 der gelöschten Notiz. Unter den vorhandenen Einträgen bleibt sie eindeutig. Wer IDs nie wiederverwenden will, speichert zusätzlich einen Zähler.

> **Typischer Fehler**
> Annehmen, die Wortgrenze `\b` finde „arzt“ überall im Text. Das Muster `\barzt` verlangt, dass vor „arzt“ kein Buchstabe steht. Wörter wie „Zahnarzttermin“ oder „Betriebsarzt“ rutschen deshalb durch.

Bewertung: (a) je Notiz 0,5 P für Entscheidung mit Begründung. (b) 2 P bei allen drei Notizen richtig (Ergebnis und Einordnung), 1 P bei zwei. (c) 1 P für die IDs beider Regeln, 1 P für die Folge von `vergiss(4)`.

Lösung zu Aufgabe 5 Prompt Caching von Hand

(a) Ohne Cache zahlt jede Frage den vollen Präfix:

$$K_{\text{ohne}} = 8 \cdot 10\,000 \cdot \frac{1\ \text{USD}}{10^6} = 0{,}08\ \text{USD} = 8{,}00\ \text{ct}.$$

Mit Cache schreibt Frage 1, die Fragen 2 bis 8 lesen:

$$K_{\text{mit}} = (10\,000 \cdot 1{,}25 + 7 \cdot 10\,000 \cdot 0{,}1)\,\frac{1\ \text{USD}}{10^6} = \frac{12\,500 + 7000}{10^6}\ \text{USD} = 1{,}95\ \text{ct}.$$

Ersparnis $1 - 1{,}95/8{,}00 \approx 75{,}6\,\%$, passend zu $E(8) = 0{,}9 - 1{,}15/8 \approx 0{,}756$.

(b) Mit $K_{\text{ohne}} = NP\,p_{\text{in}}$ und $K_{\text{mit}} = (wP + (N-1)\,rP)p_{\text{in}}$ folgt

$$\frac{K_{\text{mit}}}{K_{\text{ohne}}} = \frac{w + (N-1)\,r}{N} = r + \frac{w-r}{N} \quad \Rightarrow \quad E(N) = 1 - r - \frac{w-r}{N}.$$

Wegen $1 - r > 0$ und $N > 0$ gilt

$$E(N) > 0 \iff \frac{w - r}{N} < 1 - r \iff N > \frac{w - r}{1 - r}.$$

Für $N \to \infty$ geht $\frac{w-r}{N} \to 0$, also $E(N) \to 1 - r$. Mehr geht nicht, weil jedes Lesen den Anteil r kostet.
Mit $w = 1{,}25$, $r = 0{,}1$: Schwelle $\frac{1{,}15}{0{,}9} \approx 1{,}28$, **Caching lohnt sich ab der 2. Frage**. **Grenzwert** 90 %.
Mindestens 85 %: $0{,}9 - \frac{1{,}15}{N} \geq 0{,}85 \iff \frac{1{,}15}{N} \leq 0{,}05 \iff N \geq 23$. Kontrolle: $E(22) \approx 84{,}8\,\%$, $E(23) = 85{,}0\,\%$. **Ab 23 Fragen.**

(c) Kosten in Millionstel USD (Tokens mal Preis):
ohne Cache: Input $8 \cdot (10\,000 + 30) = 80\,240$, Output $8 \cdot 120 \cdot 5 = 4800$, zusammen 85 040, also 8,50 ct.
mit Cache: Präfix 19 500, Fragen $8 \cdot 30 = 240$, Output 4800, zusammen 24 540, also 2,45 ct.
Ersparnis $1 - 24\,540/85\,040 \approx 71{,}1\,\%$**.** Sie ist kleiner, weil Frage und Antwort nie gecacht werden und ein Output-Token fünfmal so viel kostet wie ein Input-Token.

(d) Frage 1 schreibt, die Fragen 2 bis 4 lesen. In der Pause läuft der Cache nach 5 Minuten ab, Frage 5 schreibt neu, die Fragen 6 bis 8 lesen:

$$2 \cdot 12\,500 + 6 \cdot 1000 = 31\,000 \;\Rightarrow\; \textbf{3,10 ct} \text{ statt } 1{,}95 \text{ ct}.$$

In der KI-Toolbox gäbe es keinen Geldeffekt, dort zeigt sich Caching höchstens als kürzere Wartezeit.

> **Typischer Fehler**
> Achtmal Lesen rechnen, obwohl die erste Frage schreibt: $12\,500 + 8 \cdot 1000 = 20\,500$, also 2,05 ct. Oder den Aufpreis beim Schreiben vergessen: $10\,000 + 7000$, also 1,70 ct.

Bewertung: (a) 1 P für beide Kosten, 1 P Ersparnis. (b) 2 P Herleitung von $E(N)$ und Bedingung, 1 P Auswertung (Schwelle, Grenzwert, $N \geq 23$). (c) 1 P Rechnung, 1 P Begründung. (d) 1 P.

Lösung zu Aufgabe 6 Verdünnte Aufmerksamkeit im Spielzeugmodell (Zusatz)

(a) $\frac{e^3}{e^3 + N} < 0{,}1 \iff 10\,e^3 < e^3 + N \iff N > 9\,e^3 \approx 9 \cdot 20{,}09 \approx 180{,}8$. **Ab** $N = 181$ **irrelevanten Tokens.**

(b) $\frac{e^s}{e^s + N} \geq 0{,}5 \iff e^s \geq N \iff s \geq \ln N$. Für $N = 10\,000$: $s \geq \ln 10\,000 \approx 9{,}21$. Verdoppelt sich N, muss s um $\ln 2 \approx 0{,}69$ steigen.

(c) Das relevante Signal muss mit der Kontextlänge logarithmisch stärker werden, sonst verdünnt sich sein Gewicht. Jedes irrelevante Token konkurriert also um Aufmerksamkeit, ein kleiner Kontext hilft. Grenze: Echte Modelle haben viele Köpfe und Schichten und suchen gezielter. Das Spielzeugmodell zeigt nur die Richtung, die Messungen wie „Lost in the Middle“ bestätigen.